

# 中国各省市城镇居民消费水平与结构的多维评价与分析（2023 年）

## 一、研究背景

### 1. 研究目的

中国各省市城镇居民（自治区，直辖市）2023 年城镇居民的消费特征，我们关注消费的“水平”（即总消费量）和“结构”（即 8 个消费分项的相对量）。本项目将通过多元统计学分析的方法（主成分分析 PCA，因子分析 FA，聚类分析 K-Means，判别分析 LDA，方差分析 ANOVA 等）揭示中国城镇居民消费特点和模式。本文使用 8 个核心消费分项（食品烟酒，衣着，居住，生活用品及服务，交通通信，教育文化娱乐，医疗保健，其他用品及服务）的数据进行分析。我们使用多元统计分析方法，包括降维分析（主成分分析 PCA，因子分析 FA）、聚类分析（K-Means）、聚类效果检验（ANOVA）、关键指标判别（LDA）等对数据进行分析。

## 二、数据预处理与可视化

### 2.1 描述性统计

表 1: 城镇消费支出结构及均值 (8 变量)

| 项目            | 食 品 烟 酒    | 衣 着       | 居 住         | 生 活 用 品 及 服 务 | 交 通 通 信    | 教 育 文 化 娱 乐 | 医 疗 保 健   | 其 他 用 品 及 服 务 |
|---------------|------------|-----------|-------------|---------------|------------|-------------|-----------|---------------|
| 均值 (Mean)     | 8128.52    | 1880.29   | 7264.42     | 1818.00       | 4285.48    | 3350.74     | 2873.22   | 929.32        |
| 方差 (Variance) | 2249058.20 | 150100.50 | 14318718.20 | 40976.10      | 1023401.30 | 648027.10   | 482298.20 | 114880.80     |

图 2D: 全国及各地区平均消费支出结构




图 1: 全国及各地区平均消费支出结构

## 2.2 Z-化 (Z-score 标准化)

目的: 8 个分项支出变量在数值尺度 (量纲) 上存在差异, 为防止尺度较大的变量在后续分析中主导结果, 需要对数据进行 Z-score 标准化。Z-score 标准化将变量转换为均值为 0, 标准差为 1。

结果: 数据标准化完成, 以下为标准化后的数据预览:

表 2: Z-化 (Z-score) 后的数据预览 (图 2D, 8 变量)

| 食品烟酒    | 衣着      | 居住      | 生活用品及服务 | 交通通信    | 教育文化娱乐  | 医疗保健    | 其他用品及服务 |
|---------|---------|---------|---------|---------|---------|---------|---------|
| 0.8068  | 0.8124  | 3.4024  | 0.8590  | 0.7745  | 0.9829  | 2.4993  | 0.9410  |
| 0.6924  | 0.1429  | 0.7761  | 0.6156  | -0.7362 | -0.9229 | 1.9174  | 1.5483  |
| -0.3426 | -0.3201 | -0.1652 | -0.8330 | 0.7906  | 0.5346  | 0.4828  | -0.0152 |
| -1.6146 | -0.4196 | -0.5402 | -0.6834 | -0.9413 | -0.4779 | -0.3460 | -0.4676 |
| 1.2584  | 0.7493  | -0.9389 | 0.7081  | -0.1917 | 0.1643  | -0.6507 | -0.8577 |
| -0.3326 | -0.2718 | -0.3621 | -0.7669 | -0.4186 | -0.2382 | 0.4589  | 0.3237  |

### 2.3 预处理可视化

目的：通过箱线图展示 Z-化的必要性，并探索变量间的相关关系。




图 2: 8 项支出 (原始金额) 分布

图 3B: 8项支出(归一化后)分布




图 3: 8 项支出 (Z-化后) 分布

结果 (图 3A, 3B): 原始数据 (图 3A) 的箱线图显示各变量尺度存在巨大差异, 特别是“居住”远高于其他项。Z-化处理后 (图 3B), 所有变量都被转换到相似的尺度上, 可以进行后续分析。

图 3C: 8项支出相关性热力图




图 4: 8 项支出相关热力图

结果 (图 3C): 相关热力图 (图 3C) 显示, 8 个支出变量之间普遍存在较强的正相关关系 (颜色越蓝, 相关性越强)。例如 Food 与 Trans(0.85), Housing(0.81) 高度相关, 这证明了使用降维技术 (PCA 和 FA) 的合理性。

### 三、降维分析 (PCA 与 FA)

#### 3.1 正态性检验

本项目进行正态性检验 (Shapiro-Wilk)。

该检验显示了对 8 项消费支出原始金额数据进行的 Shapiro-Wilk 正态性检验结果。显著性水平  $\alpha = 0.05$ 。

假设  $H_0$ : 数据服从正态分布。

表 3: 单变量正态性检验结果 (Shapiro-Wilk)

| 消费项目 (Variable) | P 值 (P value) | 是否服从正态分布 (Normal)? (p > 0.05) |
|-----------------|---------------|-------------------------------|
| 食品烟酒 (Food)     | 0.0475        | 否                             |
| 衣着 (Cloth)      | 0.0245        | 否                             |
| 居住 (Housing)    | 0.0000        | 否                             |
| 生活用品及服务 (Life)  | 0.1319        | 是                             |

表 4: 单变量正态性检验结果 (Shapiro-Wilk) (续)

| 消费项目 (Variable) | P 值 (P value) | 是否服从正态分布 (Normal)? (p > 0.05) |
|-----------------|---------------|-------------------------------|
| 交通通信 (Trans)    | 0.0039        | 否                             |
| 教育文化娱乐 (Edu)    | 0.1610        | 是                             |
| 医疗保健 (Health)   | 0.0018        | 否                             |
| 其他用品及服务 (Other) | 0.0001        | 否                             |

结果总结:  $p < 0.05$  的显著性水平下, 8 个消费支出变量中, 仅有“生活用品及服务”、“教育文化娱乐”服从正态分布, 其余 6 个变量 (食品、衣着、居住、交通、医疗、其他) 的  $p$  值均小于 0.05, 我们拒绝原假设, 认为其不服从正态分布。因此, 在进行降维分析时, 需要考虑数据不服从正态分布可能带来的影响。PCA 对数据分布没有严格要求, 可以继续使用。FA 则对数据服从正态分布敏感, 但我们预处理用 PCA 进行。由于原始数据不服从正态分布, 因此我们先使用 PCA, 然后使用 FA。

### 3.2 主成分分析 (PCA)

目的: 将 8 个相关的消费变量浓缩为少数几个不相关的主要成分。

结果 (贡献率):

表 5: PCA 贡献率总结 (8 变量)

|                        | 主成分 1  | 主成分 2  | 主成分 3  | 主成分 4  | 主成分 5  | 主成分 6  | 主成分 7  | 主成分 8  |
|------------------------|--------|--------|--------|--------|--------|--------|--------|--------|
| Standard Deviation     | 2.2682 | 1.0563 | 0.8800 | 0.6589 | 0.5201 | 0.3752 | 0.2814 | 0.2009 |
| Proportion of Variance | 0.6431 | 0.1395 | 0.0968 | 0.0543 | 0.0338 | 0.0176 | 0.0099 | 0.0050 |
| Cumulative Proportion  | 0.6431 | 0.7826 | 0.8794 | 0.9337 | 0.9675 | 0.9851 | 0.9950 | 1.0000 |

结果 (载荷):

表 6: PCA 载荷 (Rotation) (8 变量)

| 变<br>量 | 主成分 1  | 主成分 2  | 主成分 3  | 主成分 4  | 主成分 5  | 主成分 6  | 主成分 7  | 主成分 8  |
|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 食      | -0.031 | -0.534 | -0.399 | -0.226 | 0.552  | -0.113 | -0.245 | -0.241 |
| 品      |        |        |        |        |        |        |        |        |
| 烟      |        |        |        |        |        |        |        |        |
| 酒      |        |        |        |        |        |        |        |        |
| 衣      | -0.722 | -0.350 | 0.048  | 0.104  | 0.013  | -0.390 | -0.320 | -0.381 |
| 着      |        |        |        |        |        |        |        |        |
| 居      | -0.165 | -0.076 | -0.130 | -0.003 | 0.003  | -0.003 | -0.001 | -0.003 |
| 住      |        |        |        |        |        |        |        |        |
| 生      | -0.381 | -0.350 | -0.137 | -0.016 | 0.513  | -0.102 | -0.570 | 0.340  |
| 活      |        |        |        |        |        |        |        |        |
| 用      |        |        |        |        |        |        |        |        |
| 品      |        |        |        |        |        |        |        |        |
| 及      |        |        |        |        |        |        |        |        |
| 服      |        |        |        |        |        |        |        |        |
| 务      |        |        |        |        |        |        |        |        |
| 交      | -0.007 | -0.025 | -0.042 | -0.018 | -0.001 | 0.006  | -0.001 | 0.006  |
| 通      |        |        |        |        |        |        |        |        |
| 通      |        |        |        |        |        |        |        |        |
| 信      |        |        |        |        |        |        |        |        |
| 教      | -0.233 | -0.508 | 0.427  | -0.197 | 0.046  | 0.046  | -0.357 | -0.326 |
| 育      |        |        |        |        |        |        |        |        |
| 文      |        |        |        |        |        |        |        |        |
| 化      |        |        |        |        |        |        |        |        |
| 娱      |        |        |        |        |        |        |        |        |
| 乐      |        |        |        |        |        |        |        |        |
| 医      | -0.039 | 0.008  | 0.102  | 0.022  | -0.567 | -0.291 | -0.241 | -0.322 |
| 疗      |        |        |        |        |        |        |        |        |
| 保      |        |        |        |        |        |        |        |        |
| 健      |        |        |        |        |        |        |        |        |
| 其      | -0.088 | 0.048  | 0.014  | 0.172  | 0.000  | 0.041  | -0.377 | -0.252 |
| 他      |        |        |        |        |        |        |        |        |
| 用      |        |        |        |        |        |        |        |        |
| 品      |        |        |        |        |        |        |        |        |
| 及      |        |        |        |        |        |        |        |        |
| 服      |        |        |        |        |        |        |        |        |
| 务      |        |        |        |        |        |        |        |        |
| 综      | 0.537  | 0.310  | 0.167  | 0.014  | 0.004  | 0.003  | 0.000  | 0.000  |
| 合      |        |        |        |        |        |        |        |        |



结果解释:

1. **主成分 1 (综合消费水平):** 解释了总方差的 **64.31%**。主成分 1 累积解释了 **78.26%** 的方差。
2. **主成分 2 (结构衣着/生活):** 所有在“居住”、“教育文化娱乐”上的载荷均为正数, 这确认主成分 1 是一个居民消费的主要维度。在“衣着”、“交通通信”上的载荷, 载荷均为负数, 这反映了居民消费在“衣着”、“交通通信”上的消费结构特征, 也反映了城镇居民在“教育文化娱乐”上的消费结构特征。
3. **主成分 3 (交通通信):** 载荷均为正数, 这反映了居民消费的“交通通信”支出与“教育文化娱乐”支出之间的关系。

### 3.3 因子分析 (FA)

目的: 寻找影响这 8 个变量间相关性的潜在“因子”。

结果 (因子提取): 根据 Kaiser 准则 (特征值  $> 1$ ), PCA 结果 (表 3) 显示有 2 个成分的标准差大于 1, 因此提取 2 个因子。

结果 (因子载荷):

表 7: 因子分析载荷 (Varimax 旋转后, 8 变量)

| 变量             | Factor1 | Factor2 |
|----------------|---------|---------|
| 食品烟酒           | 0.773   | 0.2818  |
| 衣着             | 0.838   | 0.203   |
| 居住             | 0.612   | 0.088   |
| 生活用品及服务        | 0.512   | 0.380   |
| 交通通信           | 0.596   | 0.054   |
| 教育文化娱乐         | 0.857   | 0.326   |
| 医疗保健           | 0.853   | 0.045   |
| 其他用品及服务        | 0.772   | 0.252   |
| SS Loadings    | 3.961   | 1.947   |
| Proportion Var | 0.495   | 0.243   |
| Cumulative Var | 0.495   | 0.738   |

结果解释:

1. **因子 1 (Factor1) 查看:** 该因子在“居住 (0.838)、医疗保健 (0.853)、食品烟酒 (0.773)、交通通信 (0.728) 等多项支出上具有较高的载荷, 这表明因子 1 与居民的“基本消费”能力有关。

2. **因子 2 (Factor2) 查看:** 该因子在“衣着 (0.993)、教育文化娱乐 (0.816)、生活用品及服务 (0.684) 和其他用品及服务 (0.728) 等多项支出上具有较高的载荷, 这表明因子 2 与居民的“发展型消费”能力有关。
3. **总结:** 因子分析的结果支持了 PCA 结果, 都显示出两个主要维度。这两个维度共同解释了总方差的 **73.8%**, 这与 PCA 结果 (累积贡献率) 接近, 进一步证实了降维的有效性。

## 四、聚类分析 (K-Means)

目的: 使用肘部法则确定最佳的聚类数量 (K 值)。

结果 (图 7A): 肘部法则显示, K=3 是一个明显的“手肘”位置。




图 5: 肘部法则 (Elbow Method)

### 4.1 K-Means 聚类结果

目的: 基于 K=3, 对 31 个地区进行 K-Means 聚类。

表 8: 各地区聚类分配结果

| Region | Cluster | Region | Cluster | Region | Cluster |
|--------|---------|--------|---------|--------|---------|
| 北京     | 3       | 江苏     | 1       | 广东     | 1       |
| 天津     | 1       | 浙江     | 3       | 广西     | 2       |
| 河北     | 2       | 安徽     | 2       | 海南     | 2       |
| 山西     | 2       | 福建     | 1       | 重庆     | 2       |
| 内蒙古    | 1       | 江西     | 2       | 四川     | 2       |
| 辽宁     | 2       | 山东     | 1       | 贵州     | 2       |
| 吉林     | 2       | 河南     | 2       | 云南     | 2       |
| 黑龙江    | 2       | 湖北     | 2       | 西藏     | 1       |
| 上海     | 3       | 湖南     | 1       | 陕西     | 2       |
|        |         |        |         | 甘肃     | 2       |
|        |         |        |         | 宁夏     | 2       |
|        |         |        |         | 新疆     | 2       |

结果分析:

- **聚类 1 (Cluster 1):** 天津、内蒙古、江苏、福建、山东、湖南、广东、西藏 (9 个地区)。
- **聚类 2 (Cluster 2):** 河北、山西、安徽、江西、陕西等 (19 个地区)。
- **聚类 3 (Cluster 3):** 北京、上海、浙江 (3 个地区)。

## 五、聚类结果分析与检验

### 5.1 聚类画像 (雷达图)

目的: 绘制 3 个新聚类在 8 项原始消费支出 (绝对金额) 上的平均画像。

结果 (图 8A):




图 6: 聚类画像 (雷达图)

结果分析：雷达图 (图 8A) 显示了城镇居民三个聚类的层次和结构差异：

- **聚类 3 (绿色):** 北京、上海、浙江。在所有维度上的支出均最高；代表“高水平-高发展”消费者 (居住、教育、医疗突出)。
- **聚类 1 (蓝色):** 天津、江苏等。整体支出水平居中，各项支出相对均衡；代表“中高水平-均衡”消费者。
- **聚类 2 (红色):** 河北、山西等。整体支出水平最低；代表“中低水平-基础”消费者。

## 5.2 聚类可视化 (PCA 图)

目的：将新的聚类结果绘制在 PCA 二维空间中。

结果 (图 9A):

图 9A: 聚类分析结果 (基于PCA主成分)




图 7: 聚类分析结果 (基于 PCA 主成分)

结果分析:

- X 轴 (主成分 1) 代表 “综合消费水平” (负向为高)。
- Y 轴 (主成分 2) 代表 “创新消费” (负向为高，即得分低)，消费水平最高。
- 聚类 3 (绿色) 消费者在 PCA 空间中位于右下方，即消费水平最高，创新能力强。
- 聚类 1 (蓝色) 消费者位于中间，消费水平中等，创新能力中等。
- 聚类 2 (红色) 消费者位于左上方，即消费水平最低，创新能力最弱。

该图清晰地展示了将城镇居民数据的 3 个聚类在主成分空间中的区分度。

### 5.3 聚类效果检验 (ANOVA)

目的: 使用 ANOVA 检验 3 个聚类在 Food (食品支出) 上的均值差异是否显著。

结果 (表 7):

表 9: ANOVA 检验结果 (Food - Cluster, 8 变量, 城镇)

| Source    | Df | Sum Sq   | Mean Sq  | F Value | Pr(>F)   |
|-----------|----|----------|----------|---------|----------|
| Cluster   | 2  | 27004176 | 13502088 | 20.47   | 3.32e-09 |
| Residuals | 28 | 35929.72 | 1283.20  |         |          |

结果总结: 检验的 p-value (Pr(>F)) 为 **3.32e-09**, 远小于 0.05。拒绝原假设, 认为 3 个聚类在“食品支出”上存在高度统计显著的差异。这证明了聚类的有效性。

## 5.4 关键指标判别 (LDA)

目的: 找出区分这 3 个新聚类的最强分项支出指标。

在本项目中, 我们使用费希尔判别法来识别哪些消费支出变量 (食品、衣着等 8 个) 对于区分我们通过 K-Means 算法得出的 3 个聚类最为重要。判别系数 (Coefficients) 用于衡量变量对判别函数 (Discriminant function) 的贡献。直接解释了各个原始变量在构建这些“最佳区分轴”时的权重和方向。

判别函数 (Discriminant function) 的载荷 (Loadings) 用于衡量每个变量与判别轴的最佳投影方向。第一判别函数 (LD1) 是使组间距离最大化的方向, 第二判别函数 (LD2) 是与 LD1 正交 (不相关) 的方向中使组间距离最大化的方向。

结果 (表 8):

表 10: LDA 判别函数数 (8 变量, 城镇)

| 变量      | LD1     | LD2     |
|---------|---------|---------|
| Food    | -0.2495 | -1.0655 |
| Cloth   | -0.9086 | -0.4379 |
| Housing | -1.8402 | 1.1206  |
| Life    | -0.6270 | -0.3860 |
| Trans   | -0.4592 | -0.2680 |
| Edu     | -0.5573 | 0.1704  |
| Health  | -0.9150 | -0.2053 |
| Other   | 0.2439  | 1.1424  |

结果分析:

- 系数绝对值最大的变量是 **Housing (1.84)**。
- 其次是 **Health (0.91)**。

结论: 对于城镇居民数据, 区分不同消费模式 (高/中/低) 的最关键分项指标是“居住”和“衣着”, 与 K-Means 聚类画像结果一致。在“居住”和“衣着”消费上, 不同类别的居民表现出显著差异。其他“交通”和“医疗”是次要的关键因素。

## 六、结论

本项研究通过对中国 31 个省市 (含全国) 2023 年城镇居民的 8 项人均消费分项支出 (绝对金额) 进行多元统计分析, 得出以下结论:

1. **降维分析:** 8 项支出指标存在较强相关性 (图 3C)。主成分分析 (PCA) 和因子分析 (FA) 均表明, 这些指标可被归纳为两个核心维度:

- “综合/基本消费水平与发展” (PCA 的 PC1, FA 的 Factor1), 由居住、教育、食品等驱动。
- “消费结构 (衣着/生活品质)” (PCA 的 PC2, FA 的 Factor2), 由衣着、生活用品等驱动。

主成分 1 解释了 64.3% 的方差, 前两个主成分累计解释 78.3%。两个因子累计解释 73.8% 的方差。

2. **聚类分析:** K-Means 聚类 (K=3, 图 7A) 将 31 个地区划分为三个消费模式 (表 6, 图 8A, 图 9A):

- **集群 3 (高水平-高发展):** 北京、上海、浙江。消费水平最高, 尤其在居住、教育、医疗方面突出。
- **集群 1 (中高水平-均衡服务):** 天津、江苏、广东等 9 个地区。整体水平居中, 各项支出相对均衡, 服务类 (如交通、其他) 相对较高。
- **集群 2 (中低水平-基础):** 河北、山西及其他 19 个地区。整体消费水平最低。

3. **统计验证:** ANOVA 检验 (表 7) 显示, 这三个聚类在“食品支出”上的差异具有高度统计显著性 ( $p < 0.001$ ), 证明了聚类的有效性。

4. **关键指标:** 判别分析 (表 8) 显示, 在区分这三个集群时, 第一判别函数 (LD1) 中系数绝对值最大的变量是“居住” (-1.84) 和“衣着” (-0.91)。这表明, 对于城镇居民, “居住”和“衣着”支出水平是划分不同消费模式的关键因素。第二判别函数 (LD2) 则主要由“其他” (1.14) 和“居住” (1.12) 和“交通/教育” (负向) 定义, 反映了居住/其他与交通/教育之间的结构权重。