

第2章 离散信源及其信息测度

2.1 信源的数学模型及分类

2.2 离散信源的信息熵 (信息的测度方式)


2.3 信息熵的基本性质

2.5 离散无记忆的扩展信源

2.6 离散平稳信源

2.7 马尔可夫信源

2.8 信源剩余度与自然语言的熵



2.1 信源的数学模型及分类

信源：

产生消息或消息序列的源。消息携带信息，是信息的具体形式。

描述方法：

通信过程中，信源发出何种消息是不确定的、是随机的。

因此，信源可用随机变量、随机矢量或随机过程（或样本空间及其概率测度）来描述。

不同的信源根据其输出消息的不同的随机性质进行分类。

1、随机变量描述的信源（单符号）

1) 离散信源

- **特点：**输出单符号消息。符号集的取值 $A: \{a_1, a_2, \dots, a_q\}$ 是**有限的或可数的**, 可用**离散型随机变量 X** 描述。
- **数学模型：**设每个信源符号 a_i 出现的(先验)概率 $p(a_i)(i=1,2,\dots,q)$ 满足：

$$\sum_{i=1}^q p(a_i) = 1$$

则：

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix}$$

概率空间能表征离散信源的**统计特性**，因此也称概率空间为**信源空间**。

2) 连续信源

- **特点：**输出单符号消息，消息符号集A取值**连续的**（不可数），可用**连续型随机变量X**描述。
 - 例：语音信号、热噪声信号、遥控系统中有关电压、温度、压力等测得的连续数据等等。
- **数学模型：**连续型的概率空间。即：

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} (a, b) \\ p(x) \end{bmatrix} \quad \text{或} \quad \begin{bmatrix} R \\ p(x) \end{bmatrix}$$

$$\text{满足} \quad \int_a^b p(x) dx = 1 \quad \text{或} \quad \int_R p(x) dx = 1$$

2、随机矢量描述的信源

1) 平稳信源

- 特点:

信源输出的消息由一符号序列所组成。

可用N维随机矢量 $X = (X_1, X_2, \dots, X_N)$ 描述，且随机矢量X的各维概率分布都与时间起点无关。

- 离散平稳信源：每个随机变量 X_i ($i=1, 2, \dots, N$)是取值离散的随机变量。
- 连续平稳信源：每个随机变量 X_i ($i=1, 2, \dots, N$)是取值连续的随机变量。

2) 离散无记忆平稳信源

- 离散平稳信源的特例，信源发出的符号都相互统计独立，即各随机变量 X_i ($i=1, 2, \dots, N$)之间统计独立。
- 性质：
 - 独立 $\rightarrow P(\mathbf{X}) = P(X_1, X_2, \dots, X_N) = P(X_1) \cdot P(X_2) \cdot \dots \cdot P(X_N)$
 - 平稳 $\rightarrow P_1(X_i) = P_2(X_i) = \dots = P_N(X_i) = P(X_i)$ (下标1-N为时间标志)

$$\Rightarrow P(\mathbf{X}) = P(X_1 X_2 \dots X_N) = \prod_{i=1}^N P(X_i)$$

若各随机变量 X_i 取值同样符号集 $A: \{a_1, a_2, \dots, a_q\}$ ，则

$$P(\mathbf{x} = \alpha_i) = P(a_{i_1} a_{i_2}, \dots, a_{i_N}) = \prod_{k=1}^N P(a_{i_k}), i_k = (1, 2, \dots, q)$$

N维随机矢量的一个取值，
 $\alpha_i = (a_{i_1}, a_{i_2}, \dots, a_{i_N})$

$P(a_{i_k})$ 是符号集A的一维概率分布

3) 离散无记忆信源的N次扩展信源

若X为离散无记忆信源:

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix}$$

矢量信源X的各输出 X_i 间统计独立、且取值同一符号集A。该信源输出的N维随机矢量 X^N 为离散无记忆信源X的N次扩展信源。

此扩展信源取值为符号集 $\alpha_i = (a_{i_1}, a_{i_2}, \dots, a_{i_N})$, 其中
($i_1, i_2, \dots, i_N = 1, 2, \dots, q$),

其数学模型是X信源空间的N重空间:

$$\begin{bmatrix} X^N \\ P(\alpha_i) \end{bmatrix} = \begin{bmatrix} \alpha_1 & \alpha_2 & \dots & \alpha_{q^N} \\ P(\alpha_1) & P(\alpha_2) & \dots & P(\alpha_{q^N}) \end{bmatrix}$$

$$\text{其中, } P(\alpha_i) = \prod_{k=1}^N P(a_{i_k}), i_k = (1, 2, \dots, q)$$

4) 有记忆信源

信源在不同时刻发出的符号之间是相互依赖的，即信源输出的随机序列 X 中，各随机变量 X_i 之间相互依赖。

须使用随机矢量的联合概率分布和条件概率分布来说明它们之间的关联关系。

例：汉字组成的中文序列中，只有根据中文的语法、习惯用语、修辞制约和表达实际意义的制约所构成的中文序列才是有意义的中文句子或文章。所以，在汉字序列中前后文字的出现是有依赖的，是彼此相关的。

5) m阶马尔可夫信源（非平稳信源）

不同时刻发出的符号间的依赖关系

$$\begin{aligned} &P(x_i \mid \cdots x_{i+2} x_{i+1} x_{i-1} x_{i-2} \cdots x_{i-m} \cdots x_1) \\ &= P(x_i \mid x_{i-1} x_{i-2} \cdots x_{i-m}) \quad (i = 1, 2, \cdots, N) \end{aligned}$$

记忆信源的记忆长度为 $m+1$ 时，称这种有记忆信源为m阶马尔可夫信源。

若上述条件概率与时间起点 i 无关，信源输出的符号序列可看成为时齐马尔可夫链，则此信源称为时齐马尔可夫信源。

3、随机过程描述的信源

随机波形信源（随机模拟波形）

信源输出的消息是时间和取值都连续的。随机波形信源在某一固定时间 t_0 的可能取值是连续和随机的。对于这种信源输出的消息，可用随机过程描述。

例：语音信号 $X(t)$ 、热噪声信号 $n(t)$ 、电视图像信号 $X(r(t), g(t), b(t))$ 等时间连续函数。

常采用采样、离散的方法进行时间和取值的离散化，将随即波形信源化为随机矢量进行处理。

2.2 离散信源的信息熵

基本的离散信源：

输出单符号消息，且这些消息间两两互不相容。用一维随机变量 X 来描述信源的输出，其数学模型可抽象为：

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix} \quad \sum_{i=1}^q P(a_i) = 1$$

问题：这样的信源能输出多少信息？

每个消息的出现携带多少信息量？

信息的度量

- 要点:

- 信息的度量（信息量）和不确定性消除的程度有关，消除的不确定性=获得的信息量；
- 不确定性就是随机性，可以用概率论和随机过程来测度；

- 推论:

- 概率小→信息量大，即信息量是概率的单调递减函数；
- 信息量应该具有可加性；
- 信息量的计算公式为（香农（自）信息量的度量）：

$$I(a_k) = \log_r \frac{1}{P(a_k)} = -\log_r P(a_k)$$

2.1.1 自信息

设离散信源 X 的概率空间为：

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix} \quad \sum_{i=1}^q P(a_i) = 1$$

自信息量：事件 a_i 发生所含有的信息量

$$I(a_i) = f[P(a_i)] = \log_r \frac{1}{P(a_i)} = -\log_r P(a_i)$$

$I(a_i)$ 代表两种**含义**：

- (1) 当事件 a_i 发生以前，表示事件 a_i 发生的**不确定性**
- (2) 当事件 a_i 发生以后，表示事件 a_i 所提供的**信息量**

(略) 自信息公式的导出

- 某事件发生所含有的信息量应该是该事件发生的先验概率的函数。即：

$$I(a_i) = f[p(a_i)]$$

- 根据客观事实和人们的习惯概念，函数 $f[p(a_i)]$ 应满足以下条件：

(1) 它应是先验概率 $p(a_i)$ 的单调递减函数，即当

$$p(a_1) > p(a_2) \text{ 时, 有 } f[p(a_1)] < f[p(a_2)] ;$$

(2) 当 $p(a_i) = 1$ 时, $f[p(a_i)] = 0$

(3) 当 $p(a_i) = 0$ 时, $f[p(a_i)] = \infty$

(4) 两个独立事件的联合信息量应等于它们分别的信息量之和。即统计独立信源的信息量等于它们分别的信息量之和。

- 容易证明对数函数满足上述条件：

$$I(a_i) = f[P(a_i)] = \log_r \frac{1}{P(a_i)}$$

度量单位


- 计算自信息量时要注意有关事件发生概率的计算;
- 自信息量的单位取决于对数的底;
 - 底为2, 单位为“比特”(bit, binary unit) ;
 - 底为e, 单位为“奈特”(nat, nature unit) ;
 - 底为10, 单位为“哈特”(hat, Hartley) ;
 - 根据换底公式得:

$$\log_a X = \frac{\log_b X}{\log_b a}$$

$$1 \text{ nat} = 1.44\text{bit} , 1 \text{ hat} = 3.32 \text{ bit};$$

- ◆ 一般计算都采用以“2”为底的对数, 为了书写简洁, 常把底数“2”略去不写

[例] 8个串联的灯泡 $x_1, x_2, \dots, x_8$, 其损坏的可能性是等概率的, 现假设其中有一个灯泡已损坏, 问每进行一次测量可获得多少信息量? 总共需要多少次测量才能获知和确定哪个灯泡已损坏。



解:

8个灯泡等概率损坏, 先验概率 $P_1(x) = 1/8$, 不确定性:

$$I[P_1(x)] = \log_2 \frac{1}{P_1(x)} = 3(\text{bit})$$

一次测量后, 剩4个灯泡, 等概率损坏, $P_2(x) = 1/4$, 不确定性:

$$I[P_2(x)] = \log_2 \frac{1}{P_2(x)} = 2(\text{bit})$$

第一次测量获得的信息量 = $I[P_1(x)] - I[P_2(x)] = 1(\text{bit})$

经过二次测量后，剩2个灯泡，等概率损坏，先验概率为 $P_3(x) = 1/2$ ，不确定性：

$$I[P_3(x)] = \log_2 \frac{1}{P_3(x)} = 1(\text{bit})$$

第二次测量获得的信息量 = $I[P_2(x)] - I[P_3(x)] = 1(\text{bit})$

同理，第三次测量获得的信息量 = $I[P_3(x)] - 0 = 1(\text{bit})$

至少要获得3个比特的信息量就可确切知道哪个灯泡已坏了。

收信者收到某消息获得的信息量

= 不确定性减少的量

= (收到此消息前关于某事件的不确定性)

– (收到此消息后关于某事件的不确定性)

通信的实质？

即：传递信息，消除不确定性。

2.2.2 信息熵

- 对一个信源发出不同消息所含有的信息量也不同。所以自信息 $I(a_i)$ 是一个随机变量，不能用它来作为整个信源的信息测度。
- 信息熵：自信息的数学期望，平均自信息量 $H_r(X)$ ：

$$H_r(X) = E\left(\log_r \frac{1}{p(a_i)}\right) = -\sum_{i=1}^q p(a_i) \log_r p(a_i) \quad \text{r进制单位/符号}$$

$$\text{当 } r = 2 \text{ 时: } H(X) = E\left(\log \frac{1}{p(a_i)}\right) = -\sum_{i=1}^q p(a_i) \log p(a_i)$$

$$H_r(X) = H(X) / \log r$$

例：

有一布袋内放100个球，其中80个球是红色的，20个球是白色的。随便摸出一个球，猜测是什么颜色，那么其概率空间为：

$$\begin{pmatrix} X \\ P(X) \end{pmatrix} = \begin{bmatrix} a_1 & a_2 \\ 0.8 & 0.2 \end{bmatrix}$$

如果被告知摸出的是红球，那么获得的信息量是：

$$I(a_1) = -\log p(a_1) = -\log 0.8 = 0.32 \quad (\text{比特})$$

如被告知摸出来的是白球，所获得的信息量应为：

$$I(a_2) = -\log p(a_2) = -\log 0.2 = 2.32 \quad (\text{比特})$$

平均摸取一次所能获得的信息量为：

$$H(X) = p(a_1)I(a_1) + p(a_2)I(a_2) = 0.72 \quad (\text{比特/符号})$$

熵的含义

- 熵是从整个集合的统计特性来考虑的，它从平均意义上表征信源的总体特征。
- 信源输出前，熵 $H(X)$ 表示信源的平均不确定性；
- 信源输出后，熵 $H(X)$ 表示每个消息的平均信息量；
- 信息熵 $H(X)$ 表征了变量 X 的随机性。

[例] 试求甲、乙两地天气预报各自提供的平均信息量。

$$\text{甲地: } \begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} \text{晴} & \text{阴} & \text{大雨} & \text{小雨} \\ 1/2 & 1/4 & 1/8 & 1/8 \end{bmatrix}$$

$$\text{乙地: } \begin{bmatrix} Y \\ P(y) \end{bmatrix} = \begin{bmatrix} \text{晴} & \text{小雨} \\ 7/8 & 1/8 \end{bmatrix}$$

解: 甲地天气预报构成的信源空间的信息熵为:

$$\begin{aligned} H(X) &= -\sum_{i=1}^4 P(a_i) \log P(a_i) \\ &= -\frac{1}{2} \log \frac{1}{2} - \frac{1}{4} \log \frac{1}{4} - \frac{1}{8} \log \frac{1}{8} - \frac{1}{8} \log \frac{1}{8} = 1.75 \text{ (bit / 符号)} \end{aligned}$$

乙地天气预报的信源空间的信息熵为:

$$H(Y) = -\frac{7}{8} \log \frac{7}{8} - \frac{1}{8} \log \frac{1}{8} = -\log \frac{1}{8} - \frac{7}{8} \log 7 = 0.544 \text{ (bit / 符号)}$$

讨论：甲地极端情况

1. 极端情况1：晴天概率=1
$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} \text{晴} & \text{阴} & \text{大雨} & \text{小雨} \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H(X) = -1 \cdot \log 1 - 0 \cdot \log 0 - 0 \cdot \log 0 - 0 \cdot \log 0$$

$$\because \lim_{\varepsilon \rightarrow 0} \varepsilon \log \varepsilon = 0 \quad \therefore H(X) = 0(\text{bit} / \text{符号})$$

2. 极端情况2：各种天气等概率分布

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} \text{晴} & \text{阴} & \text{大雨} & \text{小雨} \\ 1/4 & 1/4 & 1/4 & 1/4 \end{bmatrix}$$

$$H(X) = -\frac{1}{4} \cdot \log \frac{1}{4} - \frac{1}{4} \cdot \log \frac{1}{4} - \frac{1}{4} \cdot \log \frac{1}{4} - \frac{1}{4} \cdot \log \frac{1}{4} = 2(\text{bit} / \text{符号})$$

结论：等概率分布时信源的不确定性最大，所以信息熵（平均信息量）最大。

2.3 信息熵的基本性质

信息熵是信源概率空间的一种特殊函数。这个函数的取值大小，与信源的符号数及其概率分布有关。

用概率矢量 $\mathbf{P}$ 来表示概率分布 $\mathbf{P}(\mathbf{x})$:

$$\mathbf{P} = (P(a_1), P(a_2), \dots, P(a_q)) = (p_1, p_2, \dots, p_q)$$

$$\sum_{i=1}^q p_i = 1, p_i \geq 0 \quad (i = 1, 2, \dots, q)$$

则信息熵 $H(X)$ 是概率矢量 $\mathbf{P}$ 或它的分量 $p_1, p_2, \dots, p_q$ 的 $q - 1$ 元函数(独立变量只有 $q - 1$ 元)。则 $H(X)$ 可写成:

$$\begin{aligned} H(X) &= -\sum_{i=1}^q P(a_i) \log P(a_i) = -\sum_{i=1}^q p_i \log p_i \\ &= H(p_1, p_2, \dots, p_q) = H(\mathbf{P}) \end{aligned}$$

熵函数的向量形式

- $H(\mathbf{P})$ 是概率矢量 $\mathbf{P}$ 的函数，称为熵函数。
- 我们用下述表示方法：
 - 用 $H(\mathbf{X})$ 表示以离散随机变量 $\mathbf{X}$ 描述的信源的信息熵；
 - 用 $H(\mathbf{P})$ 或 $H(p_1, p_2, \dots, p_q)$ 表示概率矢量为 $\mathbf{P} = (p_1, p_2, \dots, p_q)$ 的 q 个符号信源的信息熵。
 - 若当 $q = 2$ 时，因为 $p_1 + p_2 = 1$ ，所以将两个符号的熵函数写成 $H(p_1)$ 或 $H(p_2)$ 。
- 熵函数 $H(\mathbf{P})$ 是一种特殊函数，具有以下性质。

熵函数性质

1、对称性:

$H(\mathbf{P})$ 的取值与分量 $p_1, p_2, \dots, p_q$ 的顺序无关。

- 说明:

$H(\mathbf{P}) = \sum p_i \cdot \log p_i$ 中的和式满足交换率;

熵只与随机变量的总体统计特性有关。

例子:

$$\begin{bmatrix} x \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 \\ 1/3 & 1/6 & 1/2 \end{bmatrix}, \begin{bmatrix} y \\ P(y) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 \\ 1/6 & 1/2 & 1/3 \end{bmatrix}, \begin{bmatrix} z \\ P(z) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 \\ 1/3 & 1/2 & 1/6 \end{bmatrix}$$

$$H(X) = H\left(\frac{1}{3}, \frac{1}{6}, \frac{1}{2}\right) = 1.459(\text{Bit} / \text{Symbol})$$

$$H(Y) = H\left(\frac{1}{6}, \frac{1}{2}, \frac{1}{3}\right) = 1.459(\text{Bit} / \text{Symbol})$$

$$H(Z) = H\left(\frac{1}{3}, \frac{1}{2}, \frac{1}{6}\right) = 1.459(\text{Bit} / \text{Symbol})$$

$$\Rightarrow H(X) = H(Y) = H(Z)$$

2、确定性： $H(1, 0) = H(1, 0, 0) = H(1, 0, 0 \dots, 0) = 0$

- 说明：从总体来看，信源虽然有不同输出符号，但它只有一个符号几乎必然出现，而其它符号则是几乎不可能出现，那么，这个信源是一个确知信源，其熵为零。

分析：

若 $P_i = 1, P_i \log P_i = 0$ ；其他 P_j 趋于 0， $P_j \log P_j$ 趋于 0。由罗比塔法则：

$$\begin{aligned} -\lim_{x \rightarrow 0} x \log x &= -\lim_{x \rightarrow 0} \frac{x}{1/\log x} = -\lim_{x \rightarrow 0} \frac{x'}{(1/\log x)'} \\ &= -\lim_{x \rightarrow 0} \frac{1}{(1/\log_a x)'} = -\lim_{x \rightarrow 0} \frac{1'}{(1/\log_a x)''} = 0 \end{aligned}$$

因此
$$H_r(X) = -\sum_{i=1}^q p(a_i) \log_r p(a_i) = 0$$

3、非负性： $H(\mathbf{P}) \geq 0$

- 说明：

- 随机变量X的概率分布满足 $0 < p_i < 1$ ，对数函数的底大于1时， $\log(p_i) < 0$ ， $-p_i \log(p_i) > 0$ ，即得的熵为正值。只有当随机变量是一确知量时熵才等于零。
- 这种非负性合适于离散信源的熵，对连续信源来说这一性质并不存在（基于差熵、相对熵概念）。

非负性体现信息是非负的。

4、扩展性

$$\lim_{\varepsilon \rightarrow 0} H_{q+1}(p_1, p_2, \dots, p_q - \varepsilon, \varepsilon) = H_q(p_1, p_2, \dots, p_q)$$

因为 $\lim_{\varepsilon \rightarrow 0} H_{q+1}(p_1, p_2, \dots, p_q - \varepsilon, \varepsilon)$

$$= \lim_{\varepsilon \rightarrow 0} \left\{ -\sum_{i=1}^{q-1} p_i \log p_i - (p_q - \varepsilon) \log(p_q - \varepsilon) - \varepsilon \log \varepsilon \right\}$$

$$= -\sum_{i=1}^q p_i \log p_i = H_q(p_1, p_2, \dots, p_q)$$

趋于0

所以，上式成立。

- 说明：信源的符号数增多时，若这些取值对应的概率很小(接近于零)，则信源的熵不变。

5、可加性

统计独立信源X和Y的联合信源XY的熵等于信源X和Y各自的熵之和：

$$H(XY) = H(X) + H(Y)$$

即：

$$\begin{aligned} & H_{nm}(p_1q_1, p_1q_2, \dots, p_1q_m, p_2q_1, \dots, p_nq_m) \\ &= H_n(p_1, p_2, \dots, p_n) + H_m(q_1, q_2, \dots, q_m) \end{aligned}$$

$$\text{其中, } \sum_{i=1}^n p_i = 1, \quad \sum_{j=1}^m q_j = 1 \quad \sum_{i=1}^n \sum_{j=1}^m p_i q_j = 1$$

信源XY的符号联合概率

$$p(x_i y_j) = p(x_i) p(y_j) = p_i q_j$$

另外：可加性是熵函数的一个重要特性，正因具有可加性，才能保证熵函数的形式是唯一的。

证明:

$$\begin{aligned} & H_{nm}(p_1q_1, p_1q_2, \dots, p_1q_m, p_2q_1, \dots, p_nq_m) \\ &= -\sum_{i=1}^n \sum_{j=1}^m p_iq_j \log p_iq_j \\ &= -\sum_{i=1}^n \sum_{j=1}^m p_iq_j \log p_i - \sum_{i=1}^n \sum_{j=1}^m p_iq_j \log q_j \\ &= -\sum_{i=1}^n p_i \log p_i \sum_{j=1}^m q_j - \sum_{j=1}^m q_j \log q_j \sum_{i=1}^n p_i \\ &= -\sum_{i=1}^n p_i \log p_i - \sum_{j=1}^m q_j \log q_j \\ &= H_n(p_1, p_2, \dots, p_n) + H_m(q_1, q_2, \dots, q_m) \end{aligned}$$

例如，甲信源为

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & \dots & a_n \\ 1/n & 1/n & \dots & 1/n \end{bmatrix}$$

乙信源为

$$\begin{bmatrix} Y \\ p(y) \end{bmatrix} = \begin{bmatrix} b_1 & b_2 & \dots & b_m \\ 1/m & 1/m & \dots & 1/m \end{bmatrix}$$

它们的联合信源是

$$\begin{bmatrix} Z \\ p(z) \end{bmatrix} = \begin{bmatrix} c_1 & c_2 & \dots & c_{nm} \\ \frac{1}{nm} & \frac{1}{nm} & \dots & \frac{1}{nm} \end{bmatrix}$$

可计算得联合信源的联合熵：

$$\begin{aligned} H(Z) &= H(XY) = \log(nm) = \log m + \log n \\ &= H(X) + H(Y) \end{aligned}$$

6、强可加性

两个互相关联的信源X和Y的联合信源XY的熵等于信源X的熵加上在X已知条件下信源Y的条件熵。

$$H(XY) = H(X) + H(Y|X)$$

- 证明：

设X、Y的概率分布为 $(p_1, p_2, \dots, p_n)$, $(q_1, q_2, \dots, q_m)$
X、Y之间存在关联，用条件概率描述：

$$p_{ij} = p(Y = y_j | X = x_i), \quad 1 \geq p_{ij} \geq 0, \quad \begin{matrix} (i = 1, 2, \dots, n) \\ (j = 1, 2, \dots, m) \end{matrix}$$

同时，联合信源XY的各个符号，由X、Y信源中的符号构成，每个联合符号的联合概率为：

$$p(x_i y_j) = p(X = x_i \quad Y = y_j) = p(x_i) p(y_j | x_i) = p_i p_{ij}$$

显然

联合概率

$$\sum_{i=1}^n p_i = 1, \quad \sum_{i=1}^n \sum_{j=1}^m p_i p_{ij} = \sum_{i=1}^n \sum_{j=1}^m \underline{p(x_i y_j)} = 1,$$

$$\text{边缘分布概率: } q_j = \sum_{i=1}^n p(x_i y_j) = \sum_{i=1}^n p_i p_{ij}$$

对于任意的 $X = x_i$, Y 输出各种可能符号的概率和必为1:

$$\sum_{j=1}^m p_{ij} = 1 \quad (i = 1, 2, \dots, n)$$

则

$$\begin{aligned} H(XY) &= H[p(x_1 y_1), p(x_1 y_2), \dots, p(x_1 y_m), p(x_2 y_1), \dots, p(x_n y_m)] \\ &= H_{nm}(p_1 p_{11}, p_1 p_{12}, \dots, p_1 p_{1m}, p_2 p_{21}, \dots, p_n p_{nm}) \\ &= - \sum_{i=1}^n \sum_{j=1}^m p_i p_{ij} \log p_i p_{ij} \end{aligned}$$

$$= -\sum_{i=1}^n \sum_{j=1}^m p_i p_{ij} \log p_i - \sum_{i=1}^n \sum_{j=1}^m p_i p_{ij} \log p_{ij}$$

=1

$$= -\sum_{i=1}^n p_i \log p_i \left(\sum_{j=1}^m p_{ij} \right) - \sum_{i=1}^n p_i \sum_{j=1}^m p_{ij} \log p_{ij}$$

$$= -\sum_{i=1}^n p_i \log p_i + \sum_{i=1}^n p_i \left(-\sum_{j=1}^m p_{ij} \log p_{ij} \right)$$

$$= H_n(p_1, p_2, \dots, p_n) + \sum_{i=1}^n p_i H_m(p_{i1}, p_{i2}, \dots, p_{im})$$

条件熵

$$= H_n(p_1, p_2, \dots, p_n) + \sum_{i=1}^n p_i H(Y | X = x_i)$$

$$= H(X) + H(Y | X)$$

条件熵

- **条件熵:**

$H(Y|X)$ 表示信源 X 输出一符号的条件下，信源 Y 再输出一符号所能提供的平均信息量。

由前面的推导，可得：

$$H(Y|X) = \sum_{i=1}^n p_i H(Y|X=x_i) = - \sum_{i=1}^n \sum_{j=1}^m p_i p_{ij} \log p_{ij}$$

也即：

$$\begin{aligned} H(Y|X) &= - \sum_{j=1}^m \sum_{i=1}^n p(x_i) p(y_j|x_i) \log p(y_j|x_i) \\ &= - \sum_{j=1}^m \sum_{i=1}^n p(x_i y_j) \log p(y_j|x_i) \end{aligned}$$

7、递增性

若原信源 X 中有一个符号分割成了 m 个元素 (符号), 这 m 个元素的概率之和等于原元素的概率, 而其他符号的概率不变, 则新信源的熵增加。

熵的增加量等于由分割而产生的不确定性量。

$$\begin{aligned} & H_{n+m-1}(p_1, p_2, \dots, p_{n-1}, q_1, q_2, \dots, q_m) \\ &= H_n(p_1, p_2, \dots, p_{n-1}, p_n) + p_n H_m\left(\frac{q_1}{p_n}, \frac{q_2}{p_n}, \dots, \frac{q_m}{p_n}\right) \\ & \sum_{i=1}^n p_i = 1, \quad \sum_{j=1}^m q_j = p_n \end{aligned}$$

(选讲)

证明： 可以从熵的定义或强可加性得出：

$$\begin{aligned} & H_{nm}(p_1 p_{11}, p_1 p_{12}, \dots, p_1 p_{1m}, p_2 p_{21}, \dots, p_n p_{nm}) \\ &= H_{n+m-1}(p_1, p_2, \dots, p_{n-1}, p_n p_{n1}, \dots, p_n p_{nm}) \\ &= H_n(p_1, p_2, \dots, p_n) + \sum_{i=1}^n p_i H_m(p_{i1}, p_{i2}, \dots, p_{im}) \\ &= \sum_{i=1}^n p_i H_m(p_{i1}, p_{i2}, \dots, p_{im}) \\ &= p_1 H_m(p_{11}, p_{12}, \dots, p_{1m}) + p_2 H_m(p_{21}, p_{22}, \dots, p_{2m}) \\ &\quad + \dots + p_n H_m(p_{n1}, p_{n2}, \dots, p_{nm}) \\ &= p_n H_m(p_{n1}, p_{n2}, \dots, p_{nm}) \\ &\therefore H_{n+m-1}(p_1, p_2, \dots, p_{n-1}, p_n p_{n1}, \dots, p_n p_{nm}) \\ &\quad = H_n(p_1, p_2, \dots, p_n) + p_n H_m(p_{n1}, p_{n2}, \dots, p_{nm}) \end{aligned}$$

$$\begin{aligned}
 & H_{n+m-1}(p_1, p_2, \dots, p_{n-1}, p_n p_{n1}, \dots, p_n p_{nm}) \\
 &= H_n(p_1, p_2, \dots, p_n) + p_n H_m(p_{n1}, p_{n2}, \dots, p_{nm})
 \end{aligned}$$

因为 $\sum_{i=1}^n p_i p_{ij} = q_j$ 而当 $i \neq n$ 时 $p_{ij} = 0$, 所以

$$p_n p_{nj} = q_j$$

$$p_{nj} = q_j / p_n \quad (j = 1, \dots, m)$$

即得:

$$\begin{aligned}
 & H_{n+m-1}(p_1, p_2, \dots, p_{n-1}, q_1, \dots, q_m) \\
 &= H_n(p_1, p_2, \dots, p_n) + p_n H_m\left(\frac{q_1}{p_n}, \frac{q_2}{p_n}, \dots, \frac{q_m}{p_n}\right)
 \end{aligned}$$

递增性的推广

$$\begin{aligned} H_n(p_1, p_2, \dots, p_n) &= H_2(p_1, \sum_{i=2}^n p_i) + (\sum_{i=2}^n p_i) H_{n-1}(\frac{p_2}{\sum_{i=2}^n p_i}, \frac{p_3}{\sum_{i=2}^n p_i}, \dots, \frac{p_n}{\sum_{i=2}^n p_i}) \\ &= H_2(p_1, \sum_{i=2}^n p_i) + \sum_{i=2}^n p_i \cdot H_2(\frac{p_2}{\sum_{i=2}^n p_i}, \frac{\sum_{i=3}^n p_i}{\sum_{i=2}^n p_i}) + \dots + \sum_{i=n-1}^n p_i H_2(\frac{p_{n-1}}{\sum_{i=n-1}^n p_i}, \frac{p_n}{\sum_{i=n-1}^n p_i}) \end{aligned}$$

- 它表示 n 个元素的信源熵可以递推成 $(n - 1)$ 个二元信源的熵函数的加权和。这样，可使多元信源的熵函数的计算简化成计算若干个二元信源的熵函数。因此，熵函数的递增性又可称为递推性。

(选讲)

[例]: 运用熵函数的递增性 (的推广), 计算熵函数 $H(1/3, 1/3, 1/6, 1/6)$ 的数值。

$$\begin{aligned}
 & H\left(\frac{1}{3}, \frac{1}{3}, \frac{1}{6}, \frac{1}{6}\right) \\
 &= H\left(\frac{1}{3}, \frac{2}{3}\right) + \frac{2}{3} H\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{1}{3} H\left(\frac{1}{2}, \frac{1}{2}\right) \\
 &= H\left(\frac{1}{3}, \frac{2}{3}\right) + H\left(\frac{1}{2}, \frac{1}{2}\right) = 1.918 (\text{Bit} / \text{Symbol})
 \end{aligned}$$

$$H = H_2\left(p_1, \sum_{i=2}^n p_i\right) + \sum_{i=2}^n p_i \cdot H_2\left(\frac{p_2}{\sum_{i=2}^n p_i}, \frac{\sum_{i=3}^n p_i}{\sum_{i=2}^n p_i}\right) + \dots + \sum_{i=n-1}^n p_i H_2\left(\frac{p_{n-1}}{\sum_{i=n-1}^n p_i}, \frac{p_n}{\sum_{i=n-1}^n p_i}\right)$$

8、极值性

在离散信源情况下，信源各符号等概率分布时，熵值达到最大。

$$H(P_1, P_2, \dots, P_q) \leq H\left(\frac{1}{q}, \frac{1}{q}, \dots, \frac{1}{q}\right) = \log q$$

等概率分布信源的平均不确定性为最大。这是一个重要结论，称为**最大离散熵定理**。

证明： 因为对数函数是 $\cap$ 型凸函数，满足**詹森不等式**

$E[\log Y] \leq \log E[Y]$ ，令**矢量** $Y = 1/P$ 即 $(y_i = 1/p_i)$ ，则有：

$$H(p_1, p_2, \dots, p_q) = \sum_{i=1}^q p_i \log \frac{1}{p_i} \leq \log \left(\sum_{i=1}^q p_i \frac{1}{p_i} \right) = \log q$$

(Note: In the original image, a red dotted line connects the $\log$ in the Jensen inequality to the $\log$ in the final expression. Another red dotted line connects the $\frac{1}{p_i}$ term in the sum to the $\frac{1}{p_i}$ term in the final expression, which is circled in red. A green box with $=1$ is placed next to the circled term.)

特例：二进制离散信源。


该信源符号只有二个，设为“0”和“1”。符号输出的概率分别为“ ω ”和“ $1 - \omega$ ”，即信源的概率空间为：

$$\begin{bmatrix} x \\ p(x) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ \omega & \overline{\omega} = 1 - \omega \end{bmatrix}$$

$$H(X) = -\omega \log \omega - (1 - \omega) \log(1 - \omega) = H(\omega)$$

即信息熵 $H(X)$ 是 ω 的函数。

ω 取值于 $[0, 1]$ 区间，可画出熵函数 $H(\omega)$ 的曲线来，如右图所示。



9、上凸性

熵函数 $H(\mathbf{P})$ 是概率矢量 $\mathbf{P}=(p_1, p_2, \dots, p_q)$ 的严格 $\cap$ 型凸函数 (或称上凸函数)。

(因为 $H(\mathbf{P})$ 是由具有严格上凸性的对数函数 $-x \log x$ (二阶导数 ≤ 0) 的线性组合。)

即：对任意概率矢量

$$\mathbf{P}_1=(p_1, p_2, \dots, p_q) \text{ 和 } \mathbf{P}_2=(p'_1, p'_2, \dots, p'_q),$$

和任意的 $0 < \theta < 1$, 有:

$$H[\theta \mathbf{P}_1 + (1 - \theta) \mathbf{P}_2] > \theta H(\mathbf{P}_1) + (1 - \theta) H(\mathbf{P}_2)$$

因为熵函数具有上凸性, 所以熵函数具有极值, 其最大值存在。

2.4 离散无记忆的扩展信源

扩展信源的由来:

当离散无记忆信源发出固定长度的消息序列时，则得到原信源的扩展信源。

例如：在电报系统中，若信源输出的是二个符号组成的符号序列，此时可认为是一个新的信源，它由四个符号（00，01，10，11）组成，我们把该信源称为二元无记忆信源的二次扩展信源。

更进一步，如果把 N 个二元符号组成一组，则信源等效成一个具有 2^N 个符号的新信源，把它称为二元无记忆信源的 N 次扩展信源。

概念:

一般地，对一个离散无记忆信源 X ，其样本空间为 $\{a_1, a_2, \dots, a_q\}$ ，对它的输出消息序列，可用一组组长度为 N 的序列来表示它。这时，它等效成一个新信源。

新信源输出的符号是 N 维离散随机矢量

$$\mathbf{X} = (X_1, X_2, \dots, X_N),$$

其中每个分量 X_i ($i=1, 2, \dots, N$)都是随机变量，它们都取值于同一信源符号集，并且分量之间统计独立，则由随机矢量 $\mathbf{X}$ 组成的新信源称为离散无记忆信源 X 的 N 次扩展信源。

单符号离散无记忆信源X的数学模型：

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & \dots & a_q \\ p_1 & p_2 & \dots & p_q \end{bmatrix} \quad \sum_{i=1}^q p_i = 1$$



N 次扩展

N 次扩展信源

N 次扩展信源的数学模型

- N 次扩展信源与单符号离散信源比较，其输出不是单个符号，而是一串 N 个相互独立的符号序列：

$$X = (X_1, X_2, \dots, X_N) ,$$

联合分布概率 $P(X) = P(X_1 X_2 \dots X_N)$

它们把 X 等效为一个新信源——— X 的 N 次扩展信源。

N 次扩展信源数学模型表示为:

$$\begin{bmatrix} X^N \\ p(\alpha_i) \end{bmatrix} = \begin{bmatrix} \alpha_1 & \alpha_2 & \dots & \alpha_{q^N} \\ p(\alpha_1) & p(\alpha_2) & \dots & p(\alpha_{q^N}) \end{bmatrix}, \quad \alpha_i = (a_{i_1} a_{i_2} \dots a_{i_N})$$

因为是无记忆的(彼此统计独立)则:

$$P(\alpha_i) = P(a_{i_1} \dots a_{i_N}) = \prod_{k=1}^N P(a_{i_k}) = \prod_{k=1}^N p_{i_k}$$

$$\sum_{i=1}^{q^N} P(\alpha_i) = 1$$

性质：离散平稳无记忆 N 次扩展信源的熵

$$H(X^N) = N \cdot H(X)$$

证明：

$$H(X^N) = - \sum_{X^N} p(\alpha_i) \log P(\alpha_i)$$

$$= \sum_{X^N} p(\alpha_i) \log \frac{1}{p_{i_1} p_{i_2} \cdots p_{i_N}} = \sum_{X^N} p(\alpha_i) (\log \frac{1}{p_{i_1}} + \log \frac{1}{p_{i_2}} + \cdots + \log \frac{1}{p_{i_N}})$$

其中：

$$\sum_{X^N} p(\alpha_i) \log \frac{1}{p_{i_1}} = \sum_{X^N} p_{i_1} p_{i_2} \cdots p_{i_N} \log \frac{1}{p_{i_1}}$$

$$= \sum_{i_1=1}^q p_{i_1} \log \frac{1}{p_{i_1}} \left(\sum_{i_2=1}^q p_{i_2} \left(\cdots \sum_{i_N=1}^q p_{i_N} \right) \right) = H(X)$$

同理计算式中其余各项，得到：

分解为 N 重求和

$$H(X^N) = H(X) + H(X) + \cdots + H(X) = N H(X)$$

[例] 求如下离散无记忆信源的二次扩展信源及其熵。

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \end{bmatrix}, \sum_{i=1}^3 p_i = 1$$

解：二次扩展信源的概率空间为

X^2 的信源符号	α_1	α_2	α_3	α_4	α_5	α_6	α_7	α_8	α_9
对应的符号序列	$a_1 a_1$	$a_1 a_2$	$a_1 a_3$	$a_2 a_1$	$a_2 a_2$	$a_2 a_3$	$a_3 a_1$	$a_3 a_2$	$a_3 a_3$
概率 $P(\alpha_i)$	$1/4$	$1/8$	$1/8$	$1/8$	$1/16$	$1/16$	$1/8$	$1/16$	$1/16$

$$H(X) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{4} \log \frac{1}{4} - \frac{1}{4} \log \frac{1}{4} = 1.5 (Bit / Symbol)$$

$$H(X^2) = -\sum_{i=1}^9 P(\alpha_i) \log P(\alpha_i) = 3 (Bit / Symbols) = 2H(X)$$

2.6 离散平稳信源

1、概念

在一般情况下，信源在 $t = i$ 时刻将要发出什么样的符号决定于两方面：

(1) 与信源在 $t = i$ 时刻，随机变量 X_i 取值的概率分布 $P(x_i)$ 有关。一般情况下 t 不同，概率分布也不同：

$$[\text{一般 } P(x_i) \neq P(x_j)]$$

(2) 与 $t = i$ 时刻以前信源发出的符号有关。

[即与条件概率 $P(x_i | x_{i-1} x_{i-2} \dots)$ 有关]

- 平稳随机序列：其统计性质与时间的推移无关，即信源发出符号序列的概率分布与时间起点无关。

- 一维平稳信源:

若当 $t = i$, $t = j$ 时 (i, j 是大于1的任意整数), 信源输出的随机序列满足一维概率分布时间起点无关条件

$$P(x_i) = P(x_j) = P(x)$$

- 二维平稳信源:

除满足上述一维平稳信源条件外, 如果联合概率分布 $P(x_i x_{i+1})$ 也与时间起点无关, 即

$$P(x_i x_{i+1}) = P(x_j x_{j+1}) \quad (i, j \text{ 为任意整数且 } i \neq j)$$

它表示任何时刻, 信源先后发出二个符号的联合概率分布也完全相等。

- 完全平稳信源:

如果各维联合概率分布均与时间起点无关, 那么信源是完全平稳的 (N 为任意正整数)。

$$P(x_i) = P(x_j)$$

$$P(x_i x_{i+1}) = P(x_j x_{j+1})$$

.....

$$P(x_i x_{i+1} x_{i+2} \dots x_{i+N}) = P(x_j x_{j+1} \dots x_{j+N-1} x_{j+N})$$

由于联合概率与条件概率有以下关系:

$$P(x_i x_{i+1}) = P(x_i) P(x_{i+1} | x_i)$$

$$P(x_i x_{i+1} x_{i+2}) = P(x_i x_{i+1}) P(x_{i+2} | x_i x_{i+1}) = P(x_i) P(x_{i+1} | x_i) P(x_{i+2} | x_i x_{i+1})$$

.....

$$P(x_i x_{i+1} x_{i+2} \dots x_{i+N}) = P(x_i) P(x_{i+1} | x_i) \dots P(x_{i+N} | x_i x_{i+1} \dots x_{i+N-1})$$

则由前面两个关系，可推知各维条件概率也满足时间起点无关性：

$$P(x_{i+1} | x_i) = P(x_{j+1} | x_j)$$

$$P(x_{i+2} | x_i x_{i+1}) = P(x_{j+2} | x_j x_{j+1})$$

.....

$$P(x_{i+N} | x_i x_{i+1} \cdots x_{i+N-1}) = P(x_{j+N} | x_j x_{j+1} \cdots x_{j+N-1})$$
$$= P(x_N / x_0 x_1 \cdots x_{N-1})$$

平稳信源的特点：

- 对于平稳信源发出的随机序列，其前后符号依赖的条件概率均与时间起点无关，只与关联长度 N 有关。
- 如果某时刻发出什么符号只与前面发出的 N 个符号有关，那么由平稳性，则任何时刻它们的依赖关系都是一样的。

2、二维平稳信源及其信息熵

最简单的平稳信源是二维平稳信源。它满足一维和二维概率分布与时间起点无关。也即：其输出的随机序列中只有前后两个符号之间有确定的统计性依赖关系。

- 设有一个离散二维平稳信源，其概率空间为：

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix} \quad \sum_{i=1}^q P(a_i) = 1$$

连续两个信源符号出现的联合概率分布满足：

$$\left\{ \begin{array}{l} \sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) = 1 \\ P(a_j | a_i) = \frac{P(a_i a_j)}{P(a_i)} \quad (i, j = 1, 2, \dots, q) \\ \sum_{j=1}^q P(a_j | a_i) = 1 \end{array} \right.$$

离散二维平稳信源的信息测度

由于只有前后两个符号有关联，且其关联与时间无关，则可以把这个信源输出的随机序列分成每两个符号一组；

假设组与组之间统计无关（实际上，组尾的符号与下一组组头的符号是有关的）。则信源 X 可等效为新信源 X_1X_2 ，其信源空间（联合概率空间）为：

$$\begin{array}{c} \overbrace{\hspace{15em}}^{q * q \text{ 个符号}} \\ \left[\begin{array}{c} X_1X_2 \\ P(x_1x_2) \end{array} \right] = \left[\begin{array}{cccccc} a_1a_1 & a_1a_2 & a_1a_3 & \dots & \dots & a_qa_q \\ P(a_1a_1) & P(a_1a_2) & P(a_1a_3) & \dots & \dots & P(a_qa_q) \end{array} \right] \end{array}$$

且满足

$$\sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) = 1$$

Ø信息测度1: X_1X_2 的联合熵

$$H(X_1X_2) = -\sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) \log P(a_i a_j)$$

二维平稳信源联合熵的意义:

- $H(X_1X_2)$ 表示信源 X 输出任意一对消息的共熵, 即描述信源 X 输出长度为2的序列的平均不确定性 (或所含有的信息量)。
- 可用 $H(X_1X_2)/2$ 作为信源 X 的信息熵的近似值。

Ø信息测度2 : X_1X_2 的条件熵

1) 符号序列中前后两个符号之间有依赖性, 可以先求出在已知前面一个符号时, 输出下一个符号的条件熵:

$$H(X_2 | X_1 = a_i) = - \sum_{j=1}^q P(a_j | a_i) \log P(a_j | a_i)$$

2) 前一个符号 X_1 又可取 $a_i \in \{a_1, a_2, \dots, a_q\}$ 中任一个, 对某一个 a_i 存在一个熵, 那么对所有 a_i 的可能值进行统计平均就得到信源 X_1X_2 的条件熵 $H(X_2/X_1)$:

$$\begin{aligned} H(X_2 | X_1) &= \sum_{i=1}^q P(a_i) H(X_2 | X_1 = a_i) \\ &= - \sum_{i=1}^q \sum_{j=1}^q P(a_i) P(a_j | a_i) \log P(a_j | a_i) = - \sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) \log P(a_j | a_i) \end{aligned}$$

□ 联合熵与条件熵的关系

$$H(X_1X_2) = H(X_1) + H(X_2 | X_1)$$

证明: $H(X_1X_2) = -\sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) \log P(a_i a_j)$

$$= -\sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) \log [P(a_i) P(a_j | a_i)]$$

$$= -\sum_{i=1}^q \sum_{j=1}^q P(a_i) P(a_j | a_i) \log P(a_i) - \sum_{i=1}^q \sum_{j=1}^q P(a_i a_j) \log P(a_j | a_i)$$

$$= -\sum_{i=1}^q P(a_i) \log P(a_i) \sum_{j=1}^q P(a_j | a_i) + H(X_2 | X_1)$$


$$= H(X_1) + H(X_2 | X_1)$$

□ 无条件熵与条件熵的关系

$$H(X_2 | X_1) \leq H(X_2)$$

证明：在区域 $[0, 1]$ 中，设 $f(x) = -x \log x$ ，它是区域内的 $\cap$ 型凸函数：

$$\frac{df^2(x)}{dx^2} = \frac{d}{dx} \left(-\log_a x - x \frac{1}{x \ln a} \right) = -\frac{1}{x \ln a} < 0$$



设 $x_i = P(a_j | a_i) = p_{ij}$ 而 $p_i = P(a_i)$, $\sum_{i=1}^q p_i = 1$

对于 $\cap$ 型凸函数 $f(x) = -x \log x$, 由詹森不等式有:

$$\sum_{i=1}^q p_i f(x_i) \leq f\left(\sum_{i=1}^q p_i x_i\right)$$

得: $\sum_{i=1}^q p_i f(x_i) = -\sum_{i=1}^q p_i p_{ij} \log p_{ij} \leq f\left(\sum_{i=1}^q p_i x_i\right) = f\left(\sum_{i=1}^q p_i p_{ij}\right)$

$$= -\sum_{i=1}^q p_i p_{ij} \log\left(\sum_{i=1}^q p_i p_{ij}\right) = -\sum_{i=1}^q p_i p_{ij} \log p_j = -p_j \log p_j$$

$$\sum_{i=1}^q p_i p_{ij} = \sum_{i=1}^q P(a_i a_j) = P(a_j) = p_j$$

再对两边对 j 求和: $-\sum_{i=1}^q \sum_{j=1}^q p_i p_{ij} \log p_{ij} \leq -\sum_{j=1}^q p_j \log p_j$

即: $H(X_2 | X_1) \leq H(X_2)$

当前后符号统计独立时, 等号成立:

$$p_{ij} = p_j \Rightarrow H(X_2 | X_1) = H(X_2)$$

□ 联合熵与信源熵的关系

$$H(X_1X_2) \leq 2H(X)$$

对同一平稳信源 X ，其发出的先后两个符号的平均信息量应该相同：

$$H(X_2) = H(X_1) = H(X)$$

而由前面结论知：

$$\begin{aligned} H(X_1X_2) &= H(X_1) + H(X_2 | X_1) \\ &\leq H(X_1) + H(X_2) = 2H(X) \end{aligned}$$

故

$$H(X_1X_2) \leq 2H(X)$$

一般情况下，输出二个符号的联合熵总是小于等于二倍信源的熵。

[例] 某一离散二维平稳信源

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 2 \\ \frac{11}{36} & \frac{4}{9} & \frac{1}{4} \end{bmatrix}, \sum_{i=1}^3 p_i = 1$$

其发出的符号只与前一个符号有关，即可用联合概率 $P(a_i a_j)$ 给出它们的关联程度，如下表所示

$P(a_i a_j) \backslash a_j$	a_i		
	0	1	2
0	1/4	1/18	0
1	1/18	1/3	1/18
2	0	1/18	7/36

求信源的熵 $H(X)$ 、条件熵 $H(X_2/X_1)$ 和联合熵 $H(X_1 X_2)$ 。

解： 根据概率关系可计算得条件概率 $P(a_j/a_i)$ ，计算结果列表如下：

$P(a_i a_j)$ a_j	a_i		
	0	1	2
0	1/4	1/18	0
1	1/18	1/3	1/18
2	0	1/18	7/36

$$\begin{bmatrix} X \\ p(x) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 2 \\ \frac{11}{36} & \frac{4}{9} & \frac{1}{4} \end{bmatrix}$$

$$P(a_j / a_i) = P(a_i a_j) / P(a_i)$$



a_j	a_i		
	0	1	2
0	9/11	1/8	0
1	2/11	3/4	2/9
2	0	1/8	7/9

得：

$$H(X) = -\sum_{i=1}^3 P(a_i) \log P(a_i) = 1.542(\text{Bit} / \text{Symbol})$$

$$H(X_2 / X_1) = -\sum_{i=1}^3 \sum_{j=1}^3 P(a_i a_j) \log P(a_j / a_i) = 0.87(\text{Bit} / \text{Symbol})$$

$$H(X_1 X_2) = -\sum_{i=1}^3 \sum_{j=1}^3 P(a_i a_j) \log P(a_i a_j) = 2.41(\text{Bit} / \text{Symbols})$$

虽然信源X发出的随机序列中每个符号只与前一个有直接关联，但在平稳序列中，由于每一时刻的符号都通过前一个符号与更前一个符号联系起来，因此序列的关联是可引伸到无穷的。

两种信息熵的近似值

二维平稳信源的信息熵的近似值可用两种方法度量：

$$\left\{ \begin{array}{l} H_2(X) \leftarrow \frac{1}{2} H(X_1 X_2) \\ H_2(X) \leftarrow H(X_2 | X_1) \end{array} \right.$$

？ 问题：

到底选取哪一个值更能接近实际二维平稳信源的熵，通过后面对一般离散平稳信源的分析来解决这个问题。

3、离散平稳信源的极限熵

- 对于一般平稳有记忆信源，设其概率空间为：

$$\begin{bmatrix} X \\ P(x) \end{bmatrix} = \begin{bmatrix} a_1 & a_2 & a_3 & \dots & \dots & a_q \\ P(a_1) & P(a_2) & P(a_3) & \dots & \dots & P(a_q) \end{bmatrix} \quad \sum_{i=1}^q P(a_i) = 1$$

发出的符号序列为 $(X_1, X_2, \dots, X_N, \dots)$ ，假设信源符号之间的依赖长度为 N ，且各维概率分布为：

$$\left\{ \begin{array}{l} P(x_1 x_2) = P(x_1 = a_{i_1} x_2 = a_{i_2}) \\ P(x_1 x_2 x_3) = P(x_1 = a_{i_1} x_2 = a_{i_2} x_3 = a_{i_3}) \\ \dots\dots\dots \\ P(x_1 x_2 \dots x_N) = P(x_1 = a_{i_1} x_2 = a_{i_2} \dots x_N = a_{i_N}) \end{array} \right. \xrightarrow{\text{简记为}} \left\{ \begin{array}{l} P(a_{i_1} a_{i_2}) \\ P(a_{i_1} a_{i_2} a_{i_3}) \\ \dots\dots\dots \\ P(a_{i_1} a_{i_2} \dots a_{i_N}) \end{array} \right. \\ (i_1, i_2, \dots, i_q = 1, 2, \dots, q)$$

且满足完备集条件，各维概率密度之和皆为1：

$$\left\{ \begin{array}{l} \sum_{i_1=1}^q \sum_{i_2=1}^q P(a_{i_1} a_{i_2}) = 1 \\ \sum_{i_1=1}^q \sum_{i_2=1}^q \sum_{i_3=1}^q P(a_{i_1} a_{i_2} a_{i_3}) = 1 \\ \dots\dots\dots \\ \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) = 1 \quad (i_1, i_2, \dots, i_q = 1, 2, \dots, q) \end{array} \right.$$

信息度量1：平均符号熵

已知联合概率分布，可得离散平稳信源的一系列联合熵：

$$H(X_1 X_2 \dots X_N) = - \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) \log P(a_{i_1} a_{i_2} \dots a_{i_N}) \quad (N=2, 3, \dots, N)$$

平均符号熵：

N 长的信源符号序列中平均每符号携带的信息量为：

$$H_N(X) = \frac{1}{N} H(X_1 X_2 \dots X_N)$$

信息度量2：条件熵

另一方面，因信源符号之间的依赖关系长度为N，所以可以求出已知前面 $N - 1$ 个符号时，后面出现一个符号的平均不确定性。

条件熵：

若已知前面 $N - 1$ 个符号，后面出现一个符号的平均不确定性（平均信息量），即得一系列的**条件熵**：

$$H(X_N | X_1 X_2 \dots X_{N-1}) = - \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) \log P(a_{i_N} | a_{i_1} a_{i_2} \dots a_{i_{N-1}})$$
$$(N = 2, 3, \dots, N)$$

离散平稳信源的性质

对离散平稳信源若 $H_1(X) < \infty$ ，有以下性质：

- (1) 条件熵 $H(X_N | X_1 X_2 \dots X_{N-1})$ 随 N 的增加是非递增的；
- (2) $H_N(X) \geq H(X_N | X_1 X_2 \dots X_{N-1})$ ；
- (3) 平均符号熵 $H_N(X)$ 也是随 N 增加而非递增的；
- (4) 极限熵 H_∞ 存在，并且：

$$H_\infty = \lim_{N \rightarrow \infty} H_N(X) = \lim_{N \rightarrow \infty} H(X_N | X_1 X_2 \dots X_{N-1})$$

- 即：当依赖关系趋于无穷时，平均符号熵和条件熵都非递增地一致趋于平稳信源的信息熵。

性质-1 证明

根据 $H(X_2 | X_1) \leq H(X_2)$ 的证明，同理可根据熵函数得

$$H(X_3 | X_1 X_2) \leq H(X_3 | X_2)$$

又因是平稳信源，故

$$H(X_3 | X_2) = H(X_2 | X_1)$$

故
$$H(X_3 | X_1 X_2) \leq H(X_2 | X_1) \leq H(X_2) = H(X_1)$$

同理：
$$H(X_4 | X_1 X_2 X_3) \leq H(X_3 | X_1 X_2) \leq H(X_2 | X_1) = H(X_1)$$

由此递推
$$\begin{aligned} H(X_N | X_1 \dots X_{N-1}) &\leq H(X_{N-1} | X_1 \dots X_{N-2}) \\ &\leq H(X_{N-2} | X_1 \dots X_{N-3}) \end{aligned}$$

.....

$$\leq H(X_3 | X_1 X_2)$$

$$\leq H(X_2 | X_1)$$

$$\leq H(X_2) = H(X_1)$$

因此，条件熵 $H(X_N | X_1 X_2 \dots X_{N-1})$ 随 N 的增加是递减的。

性质-2 证明

$$H_N(X) \geq H(X_N | X_1 X_2 \dots X_{N-1})$$

推广 $H(X_1 X_2) = H(X_1) + H(X_2 | X_1)$

根据熵函数定义，可得如下展开：

$$\begin{aligned} NH_N(X) &= H(X_1 \dots X_N) \\ &= H(X_1) + H(X_2 \dots X_{N-1} X_N | X_1) \\ &= H(X_1) + H(X_2 | X_1) + H(X_3 \dots X_{N-1} X_N | X_1 X_2) \\ &= H(X_1) + H(X_2 | X_1) + H(X_3 | X_1 X_2) + H(X_4 \dots X_{N-1} X_N | X_1 X_2 X_3) \\ &= \dots = H(X_1) + H(X_2 | X_1) + \dots + H(X_N | X_1 X_2 \dots X_{N-1}) \end{aligned}$$

根据性质1，条件熵随着N增大非递增，则有 最小的条件熵

$$\begin{aligned} NH_N(X) &\geq H(X_N | X_1 \dots X_{N-1}) + \dots + H(X_N | X_1 \dots X_{N-1}) \\ &= NH(X_N | X_1 X_2 \dots X_{N-1}) \end{aligned}$$

故得性质2：

即：N固定时，平均符号熵大于条件熵。

性质-3 证明

$$H_N(X) \leq H_{N-1}(X)$$

推广概率关系 $H(XY) = H(X) + H(Y | X)$

根据熵函数有

$$NH_N(X) = H(\underbrace{X_1 \dots X_{N-1}}_{\text{看作一个消息}} X_N)$$

$$= H(X_1 \dots X_{N-1}) + H(X_N | X_1 \dots X_{N-1})$$

$$= (N-1)H_{N-1}(X) + \underbrace{H(X_N | X_1 \dots X_{N-1})}_{\text{看作} N-1 \text{ 长的条件熵}}$$

根据性质2，平均符号熵大于条件熵，有

$$NH_N(X) \leq H_N(X) + (N-1)H_{N-1}(X)$$

故

$$H_N(X) \leq H_{N-1}(X)$$

即平均符号熵也随着 N 增大而非递增。

性质-4 证明

$$H_{\infty} = \lim_{N \rightarrow \infty} H_N(X) = \lim_{N \rightarrow \infty} H(X_N | X_1 \dots X_{N-1})$$

因性质3 $H_N(X) \leq H_{N-1}(X)$

又 $H_N(X) \geq 0$

$$\rightarrow 0 \leq H_N(X) \leq H_{N-1}(X) \leq H_{N-2}(X) \leq \dots \leq H_1(X) < \infty$$

因此，极限 $\lim_{N \rightarrow \infty} H_N(X)$ 存在，且处于0和 $H(X_1)$ 之间。

设一整数 k ，有

$$\begin{aligned} H_{N+k}(X) &= \frac{1}{N+k} H(\underbrace{X_1 \dots X_{N-1}}_{\text{看作一个消息}} X_N \dots X_{N+k}) \\ &= \frac{1}{N+k} [H(X_1 \dots X_{N-1}) + H(X_N | X_1 \dots X_{N-1}) + \dots \\ &\quad + H(X_{N+k} | X_1 \dots X_{N+k-1})] \end{aligned}$$

$K + 1$ 项条件熵

根据条件熵的非递增性和平稳性，有

$$\begin{aligned} H_{N+k}(X) &\leq \frac{1}{N+k} [H(X_1 \dots X_{N-1}) + \underbrace{H(X_N | X_1 \dots X_{N-1}) + \dots + H(X_N | X_1 \dots X_{N-1})}_{K+1 \text{ 项相同项}}] \\ &= \frac{1}{N+k} H(X_1 \dots X_{N-1}) + \frac{k+1}{N+k} H(X_N | X_1 \dots X_{N-1}) \end{aligned}$$

当固定 N ， k 取足够大时，

$$\begin{aligned} &\lim_{k \rightarrow \infty} H_{N+k}(X) \\ &\leq \lim_{k \rightarrow \infty} \frac{1}{N+k} H_N(X_1 \dots X_{N-1}) + \lim_{k \rightarrow \infty} \frac{k+1}{N+k} H(X_N | X_1 \dots X_{N-1}) \\ &= 0 + H(X_N | X_1 \dots X_{N-1}) = H(X_N | X_1 \dots X_{N-1}) \end{aligned}$$

即：

$$\lim_{k \rightarrow \infty} H_{N+k}(X) \leq H(X_N | X_1 \dots X_{N-1})$$

在上式中，再令 $N \rightarrow \infty$ ，

可得：

$$\lim_{N \rightarrow \infty} H_N(X) \leq \lim_{N \rightarrow \infty} H(X_N | X_1 \dots X_{N-1})$$

再由性质2，平均符号熵大于条件熵，有：


$$H_N(X) \geq H(X_N | X_1 X_2 \dots X_{N-1})$$

令 $N \rightarrow \infty$ ，得到

$$\lim_{N \rightarrow \infty} H_N(X) \geq \lim_{N \rightarrow \infty} H(X_N | X_1 \dots X_{N-1})$$

则得到

$$H_\infty = \lim_{N \rightarrow \infty} H_N(X) = \lim_{N \rightarrow \infty} H(X_N | X_1 \dots X_{N-1})$$



离散平稳信源性质总结

对离散平稳信源，若 $H_1(X) < \infty$ ，则有：

- 1) 条件熵、平均符号熵都随序列长度 N 的增加是非递增的；
- 2) 对于任意序列长度 N ，平均符号熵不小于条件熵；
- 3) 极限熵 H_∞ 存在，并且等于序列长度 N 无穷大时的平均符号熵或条件熵。

近似计算

对于一般平稳信源，求 H_∞ 相当困难（ N 取无穷大），但 N 不很大时有：

$$H_\infty \approx H_N(X) \text{ 或 } H_\infty \approx H(X_N | X_1 X_2 \dots X_{N-1})。$$

特例分析：离散二维平稳信源

对离散二维平稳信源，一维和二维概率分布确定，且与时间推移无关。

对于这样的二维平稳信源，二符号之间的条件概率反映了前面输出某一个符号、后面再输出某一个符号的概率，其输出符号序列中依赖关系是有限的，所以有：

$$\begin{aligned} P(a_{i_N} | a_{i_1} a_{i_2} \dots a_{i_{N-1}}) &= P(a_{i_N} | a_{i_{N-1}}) \\ &= P(a_{i_2} | a_{i_1})_{i_2, i_1 \text{ 可以任意取值}} = P(a_j | a_i) \end{aligned}$$

$$(i = 1, 2, \dots, q)$$

$$(j = 1, 2, \dots, q)$$

另外，可从联合概率得到边缘分布概率：

联合概率满足完备性

边缘分布概率

$$\left\{ \begin{array}{ll} \sum_{i_1=1}^q \sum_{i_2=1}^q P(a_{i_1} a_{i_2}) = 1 & \longrightarrow \sum_{i_2=1}^q P(a_{i_1} a_{i_2}) = P(a_{i_1}) \\ \sum_{i_1=1}^q \sum_{i_2=1}^q \sum_{i_3=1}^q P(a_{i_1} a_{i_2} a_{i_3}) = 1 & \longrightarrow \sum_{i_3=1}^q P(a_{i_1} a_{i_2} a_{i_3}) = P(a_{i_1} a_{i_2}) \\ \dots\dots & \dots\dots \\ \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) = 1 & \longrightarrow \sum_{i_3=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) = P(a_{i_1} a_{i_2}) \\ & (i_1, i_2, \dots, i_q = 1, 2, \dots, q) \end{array} \right.$$

则条件熵表示为：

$$\begin{aligned}
H_N(X_N | X_1 \dots X_{N-1}) &= - \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) \log P(a_{i_N} | a_{i_1} \dots a_{i_{N-1}}) \\
&= - \sum_{i_1=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) \log P(a_{i_2} | a_{i_1}) \\
&= - \sum_{i_1=1}^q \sum_{i_2=1}^q \log P(a_{i_2} | a_{i_1}) \sum_{i_3=1}^q \dots \sum_{i_N=1}^q P(a_{i_1} a_{i_2} \dots a_{i_N}) \\
&= - \sum_{i_1=1}^q \sum_{i_2=1}^q \log P(a_{i_2} | a_{i_1}) P(a_{i_1} a_{i_2}) = H(X_2 | X_1)
\end{aligned}$$

N-2维边缘概率

此时：

$$\begin{aligned}
H_\infty &= \lim_{N \rightarrow \infty} H_N(X_N | X_1 \dots X_{N-1}) \\
&= \lim_{N \rightarrow \infty} H(X_2 | X_1) = H(X_2 | X_1)
\end{aligned}$$

- 可见：离散二维平稳信源的极限熵，等于条件熵 $H(X_2|X_1)$ 。

推广：

一般情况，如果平稳信源的记忆长度有限，也即某时刻输出什么符号只与前面的 m 个符号有关。

此时，则可用有限记忆长度的条件熵来测度离散平稳信源的极限熵：

$$\begin{aligned} H_{\infty} &= \lim_{N \rightarrow \infty} H_N(X_N | X_1 \dots X_{N-1}) \\ &= H(X_{m+1} | X_1 X_2 \dots X_m) \\ &= - \sum_{i_1} \dots \sum_{i_m} \sum_{i_{m+1}} P(a_{i_1} \dots a_{i_{m+1}}) \log P(a_{i_{m+1}} | a_{i_1} \dots a_{i_m}) \\ &= - \sum_{i_1} \dots \sum_{i_m} \sum_{i_{m+1}} P(a_{i_1} \dots a_{i_m}) P(a_{i_{m+1}} | a_{i_1} \dots a_{i_m}) \log P(a_{i_{m+1}} | a_{i_1} \dots a_{i_m}) \end{aligned}$$

2.7 马尔可夫信源

2.7.1 马尔可夫信源和 m 阶马尔可夫信源的定义

一类特殊的非平稳离散信源：

1. 输出符号序列中符号间的依赖关系有限，任何时刻信源符号发生的概率只与前边已经发出的若干个符号有关，而与更前面的符号无关。
2. 信源输出消息符号与信源状态有关。描述这类信源除了信源符号集外，还要引入状态集。

如：广播、电视随节目的不同，其发出的符号和概率测度也不同。

人在不同场合说不同的话，信源则在不同状态下，发出不同符号。

基础概念：马尔可夫链

体系的状态变化过程是时间离散、状态离散的无后效性的特殊随机过程。

一体系做随机运动，任意时刻它所处的状态为可列个或有限个状态中的一个： $E = \{E_1, E_2, \dots\}$

同时，该体系只能在离散的時刻 $t = 1, 2, \dots, n, \dots$ 改变状态。随着体系运动的进程，可得到一个随机序列：

$$\{X_{t_n} = E_{i_k}\}$$
$$(t_n = 0, 1, 2, \dots; \quad i_k = 1, 2, \dots)$$

马尔可夫链：随机序列 $\{X_{t_n}\}$ 的各变量之间有依赖。且满足：

$$P(X_{t_k} = E_{j_k} \mid X_{t_{k-1}} = E_{i_{k-1}}, X_{t_{k-2}} = E_{i_{k-2}}, \dots, X_{t_1} = E_{i_1}, X_{t_0} = E_{i_0})$$
$$= P(X_{t_k} = E_{j_k} \mid X_{t_{k-1}} = E_{i_{k-1}}), \quad (k = 1, 2, \dots)$$

特点:

马氏链体系某时刻 ($t = k$) 的状态只与前一时刻的 ($t = k - 1$) 体系状态有关, 与之前的状态无关。

即: 任意时刻, 体系状态的转移仅仅依赖于前一时刻转移后的状态。

时齐马尔可夫链:

条件概率与时间 k 无关 (仅与 i, j 相关), 即满足:

$$\begin{aligned} P(X_{t_1} = E_j \mid X_{t_0} = E_i) &= P(X_{t_2} = E_j \mid X_{t_1} = E_i) = \dots \\ &= P(X_{t_n} = E_j \mid X_{t_{n-1}} = E_i) = \underline{P(E_j \mid E_i)} = P_{ij} \quad \text{转移概率} \end{aligned}$$

分析对象：时齐马尔可夫链

1. 一步转移概率

$$P_{ij} = P(E_j | E_i) = P(X_{t_n} = E_j | X_{t_{n-1}} = E_i), (i, j = 1, 2, \dots, n)$$

转移矩阵 $P =$

$$\begin{bmatrix} P_{11} & P_{12} & \dots & P_{1j} & \dots & P_{1n} \\ P_{21} & P_{22} & \dots & P_{2j} & \dots & P_{2n} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ P_{i1} & P_{i2} & \dots & P_{ij} & \dots & P_{in} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ P_{n1} & P_{n2} & \dots & P_{nj} & \dots & P_{nn} \end{bmatrix}$$

转移矩阵性质：

$$\left\{ \begin{array}{l} \text{转移概率非负：} \quad 0 \leq P_{ij} \leq 1 \\ \text{转移矩阵中任一行向量之和为1：} \\ \quad \sum_j P_{ij} = 1, (i = 1, 2, \dots, n) \end{array} \right.$$

2. n 步转移概率

$$P_{ij}^{(n)} = P(X_{t_{k+n}} = E_j \mid X_{t_k} = E_i), (i, j = 1, 2, \dots, n)$$

n 步概率可由一步转移概率求得，如2步转移概率：

$$P_{ij}^{(2)} = P_{i1} P_{1j} + P_{i2} P_{2j} + \dots + P_{in} P_{nj} = \sum_k P_{ik} P_{kj}$$
$$P^{(2)} = P \cdot P$$

以此类推，对任意整数1和n：

$$P_{ij}^{(n+l)} = \sum_k P_{ik}^{(n)} \cdot P_{kj}^{(l)}$$

→ $P^{(n+l)} = P^{(n)} \cdot P^{(l)}$ 切普曼-柯尔莫哥洛夫方程

→ $P^{(n)} = P^n$

可见，由一步转移概率可确定所有的转移概率，也就确定了体系的状态转移过程。

3. 起始状态概率分布

马氏链体系的初始状态不能由转移概率决定，须引入起始状态的概率分布：

$$q_i = P(X_{t_0} = E_i), (i = 1, 2, \dots, n) \quad 0 \leq q_i \leq 1, \sum_{i=1}^n q_i = 1$$

$\{q_i\}$ 称为马氏链的起始分布（起始概率）。

4. 绝对概率

$t = n$ 时刻，体系处于状态 E_j 的概率称为绝对概率：

$$P(X_{t_n} = E_j) = P_j(n), \quad (j = 1, 2, \dots), \text{ 且 } \sum_j P_j(n) = 1$$

绝对概率可由起始概率分布和转移概率决定：

$$P_j(n) = P(X_{t_n} = E_j) = q_1 p_{1j}^{(n)} + q_2 p_{2j}^{(n)} \dots + q_n p_{nj}^{(n)} = \sum_i q_i p_{ij}^{(n)}$$

其中： q_i 为状态的初始概率； $p_{ij}^{(n)}$ 为时齐马氏链的 n 步转移概率

6. 各态历经定理

若时齐、有限状态的马氏链存在一个正整数 $r(r \geq 1)$, 使得转移矩阵 $P^{(r)}$ 中各元素 $p_{ij}^{(r)} > 0$, 则此马氏链具有各态历经性:

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = p_j \quad (j \in E)$$

此马氏链称为遍历马氏链。

定理表明, 当 $n \rightarrow \infty$ 时, 经过 n 步转以后处于状态 Ej 的概率与初始状态无关。因此称 $\{p_j\}$ 为极限分布, 且满足

$$\left\{ \begin{array}{l} \sum_{j \in E} p_j = 1 \\ p_j = \sum_{i \in E} p_i p_{ij} \quad (j \in E) \end{array} \right.$$

7. 遍历马氏链的平稳性

前面已知，系统状态的**绝对概率**是某时刻所处状态的概率：

$$P(X_{t_n} = E_j) = \sum_i q_i p_{ij}^{(n)}$$

其中： q_i 为状态的初始概率； $p_{ij}^{(n)}$ 为时齐马氏链的 n 步转移概率

因为： $\lim_{n \rightarrow \infty} p_{ij}^{(n)} = p_j$ 则有：

$$\lim_{n \rightarrow \infty} P(X_{t_n} = E_j) = \lim_{n \rightarrow \infty} p_{ij}^{(n)} \sum_i q_i = \lim_{n \rightarrow \infty} p_{ij}^{(n)} = p_j$$

遍历的马氏链的**绝对概率的极限**等于**极限概率**。

遍历马氏链的平稳性

极限概率是经过很多次转移后体系所处状态的概率，已与**初始概率**无关，达到了一**稳定分布**。若不考虑起始状态的变化，从稳定状态开始考虑，则极限分布就是体系的**平稳分布**。

如果马氏链的初始分布刚好等于平稳分布，则对一切 n ，马氏链的分布也是**平稳分布**，且等于**极限概率**。一般情况下，初始概率是任意的，不等于平稳分布。

主题：马尔可夫信源

设信源所处的状态为： $S \in E = \{E_1, E_2, \dots, E_J\}$

在每一状态下可能输出的符号： $X \in A = \{a_1, a_2, \dots, a_q\}$

在每一个时刻，信源输出一个符号后，信源状态将转移：

信源输出的随机符号序列为： $x_1, x_2, \dots, x_{l-1}, x_l, \dots$
信源所处状态的随机序列为： $s_1, s_2, \dots, s_{l-1}, s_l, \dots$

信源特征

1) 第 l 时刻，信源处于状态 E_i 时，输出符号 a_k 的概率为：

$$P(x_l = a_k \mid s_l = E_i)$$

2) 第 $(l-1)$ 时刻，信源从状态 E_i 转移到状态 E_j 的转移概率为：

$$P_{ij}(l) = P(s_l = E_j \mid s_{l-1} = E_i)$$

由马氏链概念可知，此信源的状态序列是马尔可夫链。

时齐马尔可夫链

状态转移概率和已知状态输出符号的概率与时刻*l*无关时，即满足：

$$\begin{cases} P(x_l = a_k | s_l = E_i) = P(a_k | E_i) \\ P_{ij} = P(E_j | E_i) \end{cases}$$

信源的状态序列服从时齐马尔科夫链。

定义：马尔可夫信源

信源输出的符号序列和信源所处的状态满足两个条件：

条件（1）

某一时刻信源输出的符号的概率只与当前状态有关，而与以前的状态和输出无关。即

$$P(x_l = a_k | s_l = E_i, x_{l-1} = a_{k_1}, s_{l-1} = E_j, \dots) = P(x_l = a_k | s_l = E_i)$$

时齐马尔可夫信源： $P(x_l = a_k | s_l = E_i) = P(a_k | E_i), \sum_{a_k \in A} P(a_k | E_i) = 1$

条件 (2)

信源下一状态由当前状态和下一时刻输出唯一确定：

$$P(s_l = E_j \mid x_l = a_k, s_{l-1} = E_i) = \begin{cases} 0 \\ 1 \end{cases} \quad E_i, E_j \in E; a_k \in A$$

即：信源处于某状态，当它发出一个符号后，状态就发生转移。状态的转移依赖于前一时刻的状态和当前发出的符号。

状态的一步转移概率

当满足时齐性时，

$$P_{ij} = P(E_j \mid E_i) = \sum_{a_k \in A} P(a_k \mid E_i) \cdot \underbrace{P(E_j \mid a_k, E_i)}_{=0 \text{ or } 1}$$

状态转移图

时齐的马尔科夫信源在数学模型上可作为时齐马尔科夫链来处理。因而可用马尔科夫链的状态转移图来描述信息。

- (1) 把 J 个所有可能的状态分别用圆圈表示；
- (2) 状态之间用有向线连接，表示信源输出某符号后，状态发生了转移；
- (3) 在连线旁边，标示出输出的符号 a_k 以及条件概率 $P(a_k|E_i)$ 。

例 设信源符号 $X \in \{x_1, x_2, x_3\}$ ，信源所处的状态 $S \in \{e_1, e_2, e_3, e_4, e_5\}$ 。各状态之间的转移情况由图给出，考察其是否是马尔科夫信源。




图2.2.1 状态转移图

分析:

将图中信源在 e_i 状态下发符号 x_k 的条件概率 $p(x_k | e_i)$ 用矩阵表示

$p(x_k | e_i)$

	x_1	x_2	x_3
e_1	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$
e_2	0	$\frac{1}{2}$	$\frac{1}{2}$
e_3	0	$\frac{3}{4}$	$\frac{1}{4}$
e_4	1	0	0
e_5	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$

显然:

$$\sum_{k=1}^3 p(x_k | e_i) = 1,$$
$$i = 1, 2, 3, 4, 5$$

由状态图可知
(75个条件概率):

$P(e_j | x_k, e_i)$

$q \cdot N^2$ (q : 符号数, N : 状态数)

$$\left\{ \begin{array}{l} P(S_l = e_1 | X_l = x_1, S_{l-1} = e_1) = 1 \\ P(S_l = e_2 | X_l = x_1, S_{l-1} = e_1) = 0 \\ P(S_l = e_2 | X_l = x_2, S_{l-1} = e_1) = 1 \\ P(S_l = e_2 | X_l = x_3, S_{l-1} = e_1) = 0 \\ P(S_l = e_3 | X_l = x_3, S_{l-1} = e_1) = 0 \\ P(S_l = e_4 | X_l = x_3, S_{l-1} = e_1) = 1 \\ \dots\dots \end{array} \right.$$

- 由图中可得状态的一步转移概率矩阵

$$P_{ij} = P(e_j | e_i) = \sum_{x_k \in A} P(x_k | e_i) \cdot P(e_j | x_k, e_i)$$




图2.2.1 状态转移图

	e_1	e_2	e_3	e_4	e_5
e_1	$\frac{1}{2}$	$\frac{1}{4}$	0	$\frac{1}{4}$	0
e_2	0	$\frac{1}{2}$	$\frac{1}{2}$	0	0
e_3	0	$\frac{3}{4}$	$\frac{1}{4}$	0	0
e_4	0	0	0	0	1
e_5	0	0	0	$\frac{3}{4}$	$\frac{1}{4}$

该信源满足马尔可夫信源定义。

◆定义： m 阶马尔可夫信源

一个马尔可夫信源在任何时刻 L ，符号发生的概率只与前面 m 个符号有关，而与更前面的符号无关。其数学模型如下：

$$\begin{bmatrix} X \\ P \end{bmatrix} = \begin{bmatrix} a_1, a_2, \dots, a_q \\ p(a_{k_{m+1}} | \underbrace{a_{k_1} a_{k_2} \dots a_{k_m}}_{\text{状态}}) \end{bmatrix}$$

并满足

$$\sum_{k_{m+1}=1}^q p(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m}) = 1; \quad k_1, k_2, \dots, k_m + 1 = 1, 2, \dots, q$$

当 $m = 1$ 时，为一阶马尔可夫信源。

时齐性:

m 阶马尔可夫信源在任何时刻1, 符号发生的概率只与前 m 个符号有关, 与时间推移无关, 故具备时齐性。可设信源状态为:

$$E_i = (a_{k_1} a_{k_2} \dots a_{k_m})$$

$$k_1, k_2, \dots, k_m \in (1, 2, \dots, q)$$

则可得信源的状态集:

$$E = [E_1, E_2, \dots, E_J], \quad J = q^m$$

可得条件概率表达式:

$$P(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m}) = P(a_{k_{m+1}} | E_i) = P(a_k | E_i)$$

$$k \in [1, 2, \dots, q], i \in [1, 2, 3, \dots, J]$$

$a_{k_{m+1}}$ 可任取 $a_1, a_2, \dots, a_q$ 之一, 因此可以简化为: a_k

状态转移特性:

m 阶马尔可夫信源在任何时刻输出某符号后, 则随机序列就自然组成了新的信源状态, 则状态发生了转移。

状态之间的一步转移概率 $P(E_j | E_i)$ 也可由条件概率 $P(a_{k_{m+1}} | a_{k_1} \dots a_{k_m})$ 来确定:

$$P_{ij} = P(E_j | E_i) = \sum_{a_k \in A} P(a_k | E_i) \cdot P(E_j | a_k, E_i)$$

很明显, m 阶马尔科夫信源符合一般的马尔科夫信源的定义。通常, 它是一种常见的、简单的马尔科夫信源, 并且不是离散平稳信源。

[例] 二元2阶马尔可夫信源，原始信号 X 的符号集为

$\{x_1 = 0, x_2 = 1\}$ ，其状态空间共有 $n^m = 2^2 = 4$ 个不同的状态 e_1, e_2, e_3, e_4 ，即 $E: \{e_1 = 00, e_2 = 01, e_3 = 10, e_4 = 11\}$

状态转移图见右图所示，计算其状态转移概率。

解： 根据转移箭头，考察状态间转移情况：

$$p(e_1|e_1) = p(x_1|e_1) = p(0|00) = 0.8$$

$$p(e_2|e_1) = p(x_2|e_1) = p(1|00) = 0.2$$

$$p(e_3|e_2) = p(x_1|e_2) = p(0|01) = 0.5$$

$$p(e_4|e_2) = p(x_2|e_2) = p(1|01) = 0.5$$

$$p(e_1|e_3) = p(x_1|e_3) = p(0|10) = 0.5$$

$$p(e_2|e_3) = p(x_2|e_3) = p(1|10) = 0.5$$

$$p(e_3|e_4) = p(x_1|e_4) = p(0|11) = 0.2$$

$$p(e_4|e_4) = p(x_2|e_4) = p(1|11) = 0.8$$

其余转移概率为0。




图2.2.2 二元二阶马尔可夫信源状态转移图

$$P_{ij} = P(E_j | E_i) = \sum_{a_k \in A} P(a_k | E_i) \cdot P(E_j | a_k, E_i)$$

2.7.2 马尔可夫信源和 m 阶马尔可夫信源的信息熵

时齐的马尔可夫信源的熵

一方面，马尔可夫信源在某种状态下，输出一个符号的概率分布及其状态转移分布是确定的，故可从此角度考察其**某状态下的条件熵**（但其他状态情况未考虑）：

$$H(X | s = E_i) = - \sum_{k=1}^q P(a_k | E_i) \log P(a_k | E_i)$$

另一方面，因为依赖关系是**无限**的，且**起始状态不同**，输出的符号序列也不同。一般的马尔可夫信源的熵应该为**平均符号熵的极限值**：

$$H_{\infty} = H_{\infty}(X) = \lim_{N \rightarrow \infty} \frac{1}{N} H(X_1 X_2 \dots X_N)$$

对**时齐、遍历**的马氏信源，其**状态**随着状态转移次数无限增大，最终趋于**稳定的**概率分布——**极限概率分布**。

设 $Q(E_i)$ 为各状态的**极限概率**，则**时齐、遍历**的马尔可夫信源的熵为：

$$\begin{aligned} H_{\infty} &= \sum_{i=1}^J Q(E_i) H(X | E_i) \\ &= \sum_{i=1}^J \sum_{k=1}^q Q(E_i) P(a_k | E_i) \log P(a_k | E_i) \end{aligned}$$

并满足：

$$\begin{cases} Q(E_i) = \sum_{E_j \in E} Q(E_j) P(E_i | E_j), \\ \sum_{E_i \in E} Q(E_i) = 1 \end{cases}$$

注 意

上述计算须满足状态**各态历经性**，才存在状态的**极限概率**。
所以要先判断马氏链是否具备各态历经性。

极限概率的计算：为得到**时齐、遍历**马尔科夫信源的熵，可根据如下 $(J+1)$ 个方程计算出 J 个**极限概率**：

$$\begin{cases} \sum_{E_j \in E} Q(E_j) \underline{P(E_i | E_j)} = Q(E_i), \\ \sum_{E_i \in E} Q(E_i) = 1 \end{cases}$$

上述关系展开，就是：

$$\begin{bmatrix} Q(E_1) \\ Q(E_2) \\ \dots \\ Q(E_i) \\ \dots \\ Q(E_J) \end{bmatrix} = \begin{bmatrix} P(E_1 | E_1) & P(E_1 | E_2) & \dots & P(E_1 | E_j) & \dots & P(E_1 | E_J) \\ P(E_2 | E_1) & P(E_2 | E_2) & \dots & P(E_2 | E_j) & \dots & P(E_2 | E_J) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ P(E_i | E_1) & P(E_i | E_2) & \dots & P(E_i | E_j) & \dots & P(E_i | E_J) \\ \dots & \dots & \dots & \dots & \dots & \dots \\ P(E_J | E_1) & P(E_J | E_2) & \dots & P(E_J | E_j) & \dots & P(E_J | E_J) \end{bmatrix} \begin{bmatrix} Q(E_1) \\ Q(E_2) \\ \dots \\ Q(E_i) \\ \dots \\ Q(E_J) \end{bmatrix}$$

$$\sum_{E_i \in E} Q(E_i) = 1$$

设一步转移概率矩阵为 P ，设状态极限概率向量为：

$$Q = \begin{bmatrix} Q(E_1) \\ Q(E_2) \\ \dots \\ Q(E_i) \\ \dots \\ Q(E_J) \end{bmatrix}, \quad \sum_{E_i \in E} Q(E_i) = 1$$

则实际关系可表示为：

$$\left\{ \begin{array}{l} Q = P^T \cdot Q \\ \sum_{E_i \in E} Q(E_i) = 1 \end{array} \right.$$

通过求解上述方程组，即可求解出状态的极限概率和信息熵。

$$\begin{aligned} H_{\infty} &= \sum_{i=1}^J Q(E_i) H(X | E_i) \\ &= \sum_{i=1}^J \sum_{k=1}^q Q(E_i) P(a_k | E_i) \log P(a_k | E_i) \end{aligned}$$

特例： m 阶马尔可夫信源的熵

$$H_{\infty} = H_{m+1} = \sum_{i=1}^J Q(E_i) H(X | E_i), \quad E_i = (a_{k_1} a_{k_2} \dots a_{k_m})$$

$$(k_1, k_2, \dots, k_m) = 1, 2, \dots, q; \quad i = 1, 2, \dots, J = q^m$$

其中：

$$H(X | E_i) = - \sum_{k=1}^q P(a_k | E_i) \log P(a_k | E_i)$$

$$= - \sum_{k_{m+1}=1}^q P(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m}) \log P(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m})$$

则m阶马尔可夫信源的熵可表达为:

$$\begin{aligned} H_{m+1} &= \sum_{i=1}^J Q(E_i) H(X | E_i) \\ &= - \sum_{k_1=1}^q \sum_{k_2=1}^q \dots \sum_{k_m=1}^q \sum_{k_{m+1}=1}^q \underbrace{Q(a_{k_1} a_{k_2} \dots a_{k_m}) P(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m})}_{\text{极限概率}} \\ &\quad \log P(a_{k_{m+1}} | a_{k_1} a_{k_2} \dots a_{k_m}) \\ &= H(X_{m+1} | X_1 X_2 \dots X_m) \quad \longleftarrow \text{条件熵的形式} \end{aligned}$$

因此，时齐、遍历的m阶马尔可夫信源的熵，等于达到信源稳定后有限记忆长度为m的条件熵。

它不同于有限记忆长度为m的离散平稳信源。只有当时间N足够长之后，由m个符号组成的各种可能状态达到一种稳定分布后，才可以将时齐、遍历的m阶马尔可夫信源作为记忆长度为m的离散平稳信源。

[例] 二元2阶马尔可夫信源，原始信号 x 的符号集为 $\{x_1=0, x_2=1\}$ ，其状态空间共有 $n^m=2^2=4$ 个不同的状态 e_1, e_2, e_3, e_4 ，即 $E: \{e_1=00, e_2=01, e_3=10, e_4=11\}$ 状态转移图见右图所示。计算信源熵。

解：

$$p(e_1|e_1) = p(x_1|e_1) = p(0|00) = 0.8$$

$$p(e_2|e_1) = p(x_2|e_1) = p(1|00) = 0.2$$

$$p(e_3|e_2) = p(x_1|e_2) = p(0|01) = 0.5$$

$$p(e_4|e_2) = p(x_2|e_2) = p(1|01) = 0.5$$

$$p(e_1|e_3) = p(x_1|e_3) = p(0|10) = 0.5$$

$$p(e_2|e_3) = p(x_2|e_3) = p(1|10) = 0.5$$

$$p(e_3|e_4) = p(x_1|e_4) = p(0|11) = 0.2$$

$$p(e_4|e_4) = p(x_2|e_4) = p(1|11) = 0.8$$

.....




图2.2.2 二元二阶马尔可夫信源状态转移图

由二元信源 $X \in \{0, 1\}$ 得到的状态空间 (e_1, e_2, e_3, e_4) 和相应的一步转移概率构成的2阶马尔可夫信源模型为

$$\left\{ \begin{array}{cccc} e_1 & e_2 & e_3 & e_4 \\ p(e_j | e_i) \end{array} \right\} \quad i, j = 1, 2, 3, 4$$

$$\text{且} \quad \sum_{j=1}^4 p(e_j | e_i) = 1, \quad p(e_i) > 0$$

$$\begin{aligned} \text{由} \quad q(e_i) &= \sum_{j=1}^4 q(e_j) p(e_i | e_j) \quad i = 1, 2, 3, 4 \\ \sum_{i=1}^4 q(e_i) &= 1 \end{aligned} \quad \left. \vphantom{\begin{aligned} q(e_i) &= \sum_{j=1}^4 q(e_j) p(e_i | e_j) \\ \sum_{i=1}^4 q(e_i) &= 1 \end{aligned}} \right\}$$

求出稳定状态下的 $q(e_j)$ （极限概率）。将一步转移概率代入上式得

$$\left\{ \begin{array}{l} q(e_1)=0.8 \quad q(e_1)+0.5 \quad q(e_3) \\ q(e_2)=0.2 \quad q(e_1)+0.5 \quad q(e_3) \\ q(e_3)=0.5 \quad q(e_2)+0.2 \quad q(e_4) \\ q(e_4)=0.5 \quad q(e_2)+0.8 \quad q(e_4) \\ q(e_1)+q(e_2)+q(e_3)+q(e_4)=1 \end{array} \right.$$

解方程组得

$$q(e_1)=q(e_4)=5/14, \quad q(e_2)=q(e_3)=1/7$$

计算极限熵

$$H_{\infty} = H_{2+1} = - \sum_{e_i \in E} \sum_{k=1}^q q(e_i) p(a_k | e_i) \log p(a_k | e_i)$$

=

$$= 0.8(\text{比特/符号})$$

平稳信源的 m 阶马尔科夫信源近似

当时齐、遍历的马尔科夫信源达到稳定后，可以看成
一个平稳信源。

由于平稳信源必须知道信源的各维概率分布，这实际
上是很难实现的。而 m 阶马尔科夫信源却只需要知道与前
 m 个符号有关的条件概率（这较容易实现），即可计算出
信源的信息熵。

所以，一般平稳信源可用 m 阶马尔科夫信源近似。

(##选讲例题)

例：分析如下信源的熵和信源平稳后符号输出概率：

一个二元二阶马尔可夫信源，信源符号集 $A=\{0,1\}$ 。信源开始时，它以初始概率 $p(0)=p(1)=0.5$ 发出随机变量 X_1 。

然后，**第二时刻**输出的随机变量 X_2 与 X_1 有依赖关系，由条件概率 $p(X_2|X_1)$ 表示：

输出	依赖状态 X_1	
X_2	0	1
0	0.3	0.4
1	0.7	0.6

第三时刻输出随机变量 X_3 ，而 X_3 依赖于前面变量。依赖关系由条件概率 $p(X_3|X_1X_2)$ 表示：


输出	依赖状态 X ₁ X ₂			
X ₃	00	01	10	11
0	0.4	0.2	0.3	0.4
1	0.6	0.8	0.7	0.6

从第四时刻开始往后，任意时刻信源发出的随机变量X_i只与前面二个单位时间的随机变量有关：


$$P(x_i | x_{i-2}x_{i-1}) = P(x_3 | x_1x_2)(i > 3)$$

分析:

根据题意, 前3个时刻信源的状态转移图-a。



第3个时刻之后, 信源必处在 E_3, E_4, E_5, E_6 四种状态之一, 见状态转移图-b:



输出	依赖状态 x_1x_2			
x_3	00	01	10	11
0	0.4	0.2	0.3	0.4
1	0.6	0.8	0.7	0.6


状态E1和E5的功能相同：

- 1) 都以概率0.3和0.7输出符号0和1；
- 2) 输出0后都转移到状态E3，输出1后都转移到状态E4.

状态E2和E6的功能相同：


- 1) 都以概率0.4和0.6输出符号0和1；
- 2) 输出0后都转移到状态E5，输出1后都转移到状态E6.

故可将前两图合并为状态图-c。



由图-c可知， E_0 是过渡态，而 $E_3 E_4 E_5 E_6$ 构成不可分（状态间互通）闭集，且具有遍历性（根据转移概率矩阵可知）。则此马氏信源的状态必然会进入这个不可分闭集。

故计算信源熵时，可不考虑过渡状态和过渡过程，仅仅须求出 $E_3 E_4 E_5 E_6$ 的极限概率，即可计算出信源熵。



根据状态图，求出一步状态转移概率，代入下列方程：

$$\begin{aligned} Q &= P^T Q, \\ \sum_{E_i \in E} Q(E_i) &= 1 \end{aligned} \quad \rightarrow \quad \begin{cases} Q(E_3) = 0.4Q(E_3) + 0.3Q(E_5) \\ Q(E_4) = 0.6Q(E_3) + 0.7Q(E_5) \\ Q(E_3) = 0.2Q(E_4) + 0.4Q(E_6) \\ Q(E_3) = 0.8Q(E_4) + 0.6Q(E_6) \\ Q(E_3) + Q(E_4) + Q(E_5) + Q(E_6) = 1 \end{cases}$$

解得：

$$Q(E_4) = Q(E_5) = 2/9 \quad Q(E_6) = 4/9 \quad Q(E_3) = 1/9$$

代入

$$H_{\infty} = H_{m+1} = \sum_{i=1}^J Q(E_i) H(X | E_i)$$

$$\begin{aligned} H_{\infty} &= Q(E_3)H(0.4, 0.6) + Q(E_4)H(0.2, 0.8) + Q(E_5)H(0.3, 0.7) + Q(E_6)H(0.4, 0.6) \\ &= \mathbf{0.8956} \end{aligned}$$

当此马尔可夫信源达到稳定后，符号0和1的分布概率可根据下式计算，

$$P(a_k) = \sum_{i=1}^J Q(E_i) P(a_k / E_i)$$

因此得：

$$P(0) = 0.4Q(E_3) + 0.2Q(E_4) + 0.3Q(E_5) + 0.4Q(E_6) = 1/3$$

$$P(1) = 0.6Q(E_3) + 0.8Q(E_2) + 0.7Q(E_5) + 0.6Q(E_6) = 2/3$$

可见，信源达到稳定后，信源符号的概率分布与初始分布是不同的。因此，一般马尔科夫信源并非平稳信源。

2.8 信源剩余度与自然语言的熵

1、离散信源熵的近似

实际信源一般是非平稳的， H_∞ 不一定存在；

解决方法：

- 假设其为离散平稳信源，并用其极限熵 H_∞ 来近似，但求解困难；
- 假设其为 m 阶马尔科夫信源，用 m 阶马尔科夫信源的信息熵 H_{m+1} 近似，近似程度取决于记忆长度 m 的大小；
- 可进一步假设为一阶马尔科夫信源，用其一阶条件熵来近似：

$$H_{m+1} = H_2 = H(X_2 | X_1) = - \sum_{k=1}^q \sum_{k-1=1}^q Q(a_{k-1}) P(a_k | a_{k-1}) \log P(a_k | a_{k-1})$$

- 最简化的信源是离散无记忆信源，其熵为 $H(x)$ ；
- 最后可以假定为等概的离散无记忆信源，其熵 $H(x)$ 为最大熵：

$$H_0 = \log q$$

各种熵之间的关系可以表示为：

m 阶马尔科夫信源近似

$$\log q = H_0(x) \geq H_1(x) \geq H_{1+1}(x) \geq H_{2+1}(x) \geq \cdots \geq H_{m+1}(x) \geq H_\infty$$

这表明

- 由于信源符号之间的依赖性，使得信源的熵减小。
- 如果它们的前后依赖关系越长，则信源的熵越小。
- 且当信源符号间无依赖、等概率分布时，信源的熵达到最大值。

即：信源符号之间的依赖性越强，每个符号提供的平均信息量越小。每个符号提供的平均自信息量随着符号之间的依赖关系长度的增加而减小。

2、熵的相对率

一个信源实际的熵，与具有同样符号集的最大熵的比值：

$$\eta = \frac{H_{\infty}}{H_0}$$

$$H_0 = \log q$$

3、信源剩余度（冗余度，多余度）

1 减去熵的相对率：

$$\gamma = 1 - \eta = 1 - \frac{H_{\infty}}{H_0}$$

信源剩余度的意义

信源剩余度反映了离散信源输出的符号序列中的符号之间依赖性关系的强弱。

剩余度越大，表示信源的实际熵越小，信源符号之间的依赖性越强，即符号间记忆长度越长。反之，剩余度越小，表明信源符号间依赖性越弱，符号之间记忆长度越短。

当**剩余度=0**时，信源的熵等于**极大值**，这表明信源符号之间不但**统计独立**，而且各符号还是**等概率分布**。

我们可以压缩剩余度来压缩信源，提高通信的**有效性**——**信源编码的目的**。

4、自然语言的熵

(1) 对于英文字母，信源剩余度：

(考虑字母的概率、字母间依赖性、单词间依赖性、语法等，运用马尔科夫信源模型逼近)

$$\gamma = 1 - \eta = 1 - \frac{H_{\infty}}{H_0} = 1 - \frac{1.4}{\log 27} = 0.71$$

(2) 对于中文，信源剩余度：

$$\gamma = 1 - \eta = 1 - \frac{H_{\infty}}{H_0} = 1 - \frac{9.733}{\log 10^4} = 0.264$$

本章习题

2-5 2-8
2-20 2-21 2-24