

# 无失真信源编码 定理



- ❖ 通信的实质是信息的传输,而高效率、高质量地传送信息却又是信息传输的基本问题
- ❖ 将信源信息通过信道传输给信宿,怎样才能做到尽可能不失真而又快速呢? 这就要解决两个问题:
  - ❧ 第一: 在不失真或允许一定失真条件下, 如何尽可能少的符号来表示信源信息, 以便提高信息传输率。
  - ❧ 第二: 在信道受干扰的情况下, 如何增加信号的抗干扰能力, 提高信息传输的可靠性, 同时又使得信息传输率最大。
- ❖ 为此, 我们引入信源编码和信道编码

- ❖ 一般来说，提高抗干扰的能力（降低失真或错误概率）往往是增加冗余度以降低信息传输率为代价的；反之，要提高信息传输率往往通过压缩信源的冗余度来实现而常常又会使抗干扰能力减弱。二者是有矛盾的。
- ❖ 然而在信息论的编码定理中，已从理论上证明，至少存在某种最佳的编码或信息处理方法，能够解决上述矛盾，做到既可靠又有效地传输信息。
- ❖ 这些结论对各种通信系统的设计个估价具有重大的理论指导意义。

- ❖ 本章将重点讨论对离散信源进行无失真信源编码的要求、方法以及理论极限，并得出一个极为重要的极限定理



## 香农第一定理

# 目录

- ❖ 5.1 编码器
- ❖ 5.2 等长码
- ❖ 5.3 渐进等分割性和  $\varepsilon$  典型序列
- ❖ 5.4 等长信源编码定理
- ❖ 5.5 变长码
- ❖ 5.6 变长信源编码定理

# 5.1 编码器

- ❖ 编码实质上是对信源的原始符号按照一定的数学规则进行一种变换。
- ❖ 为了分析方便和突出问题的重点，当研究信源编码时，我们将信道编码和译码看成是信道的一部分，而突出信源编码。同样，研究信道编码时，将信源编码和译码看成是信源和信宿的一部分，突出信道编码。






图5.1 无失真信源编码器

- ❖ 上述模型中, 输入符号集  $S = \{s_1, s_2, \dots, s_q\}$ 。同时存在另一符号集  $X = \{x_1, x_2, \dots, x_r\}$ , 一般元素  $x_j$  是适合信道传输的, 称为**码符号** (或者**码元**)。

- ❖ 编码器是将信源符号集中的符号 $s_i$ （或者长为 $N$ 的信源符号序列 $\alpha_i$ ）变换成由 $x_j$ （ $j=1, 2, \dots, r$ ）组成的长度为 $l_i$ 的一一对应序列。即

$$s_i (i = 1, \dots, q) \leftrightarrow W_i = (x_{i_1} x_{i_2} \dots x_{i_{l_i}}) \quad x_{i_k} \in X \quad (k = 1, \dots, l_i)$$

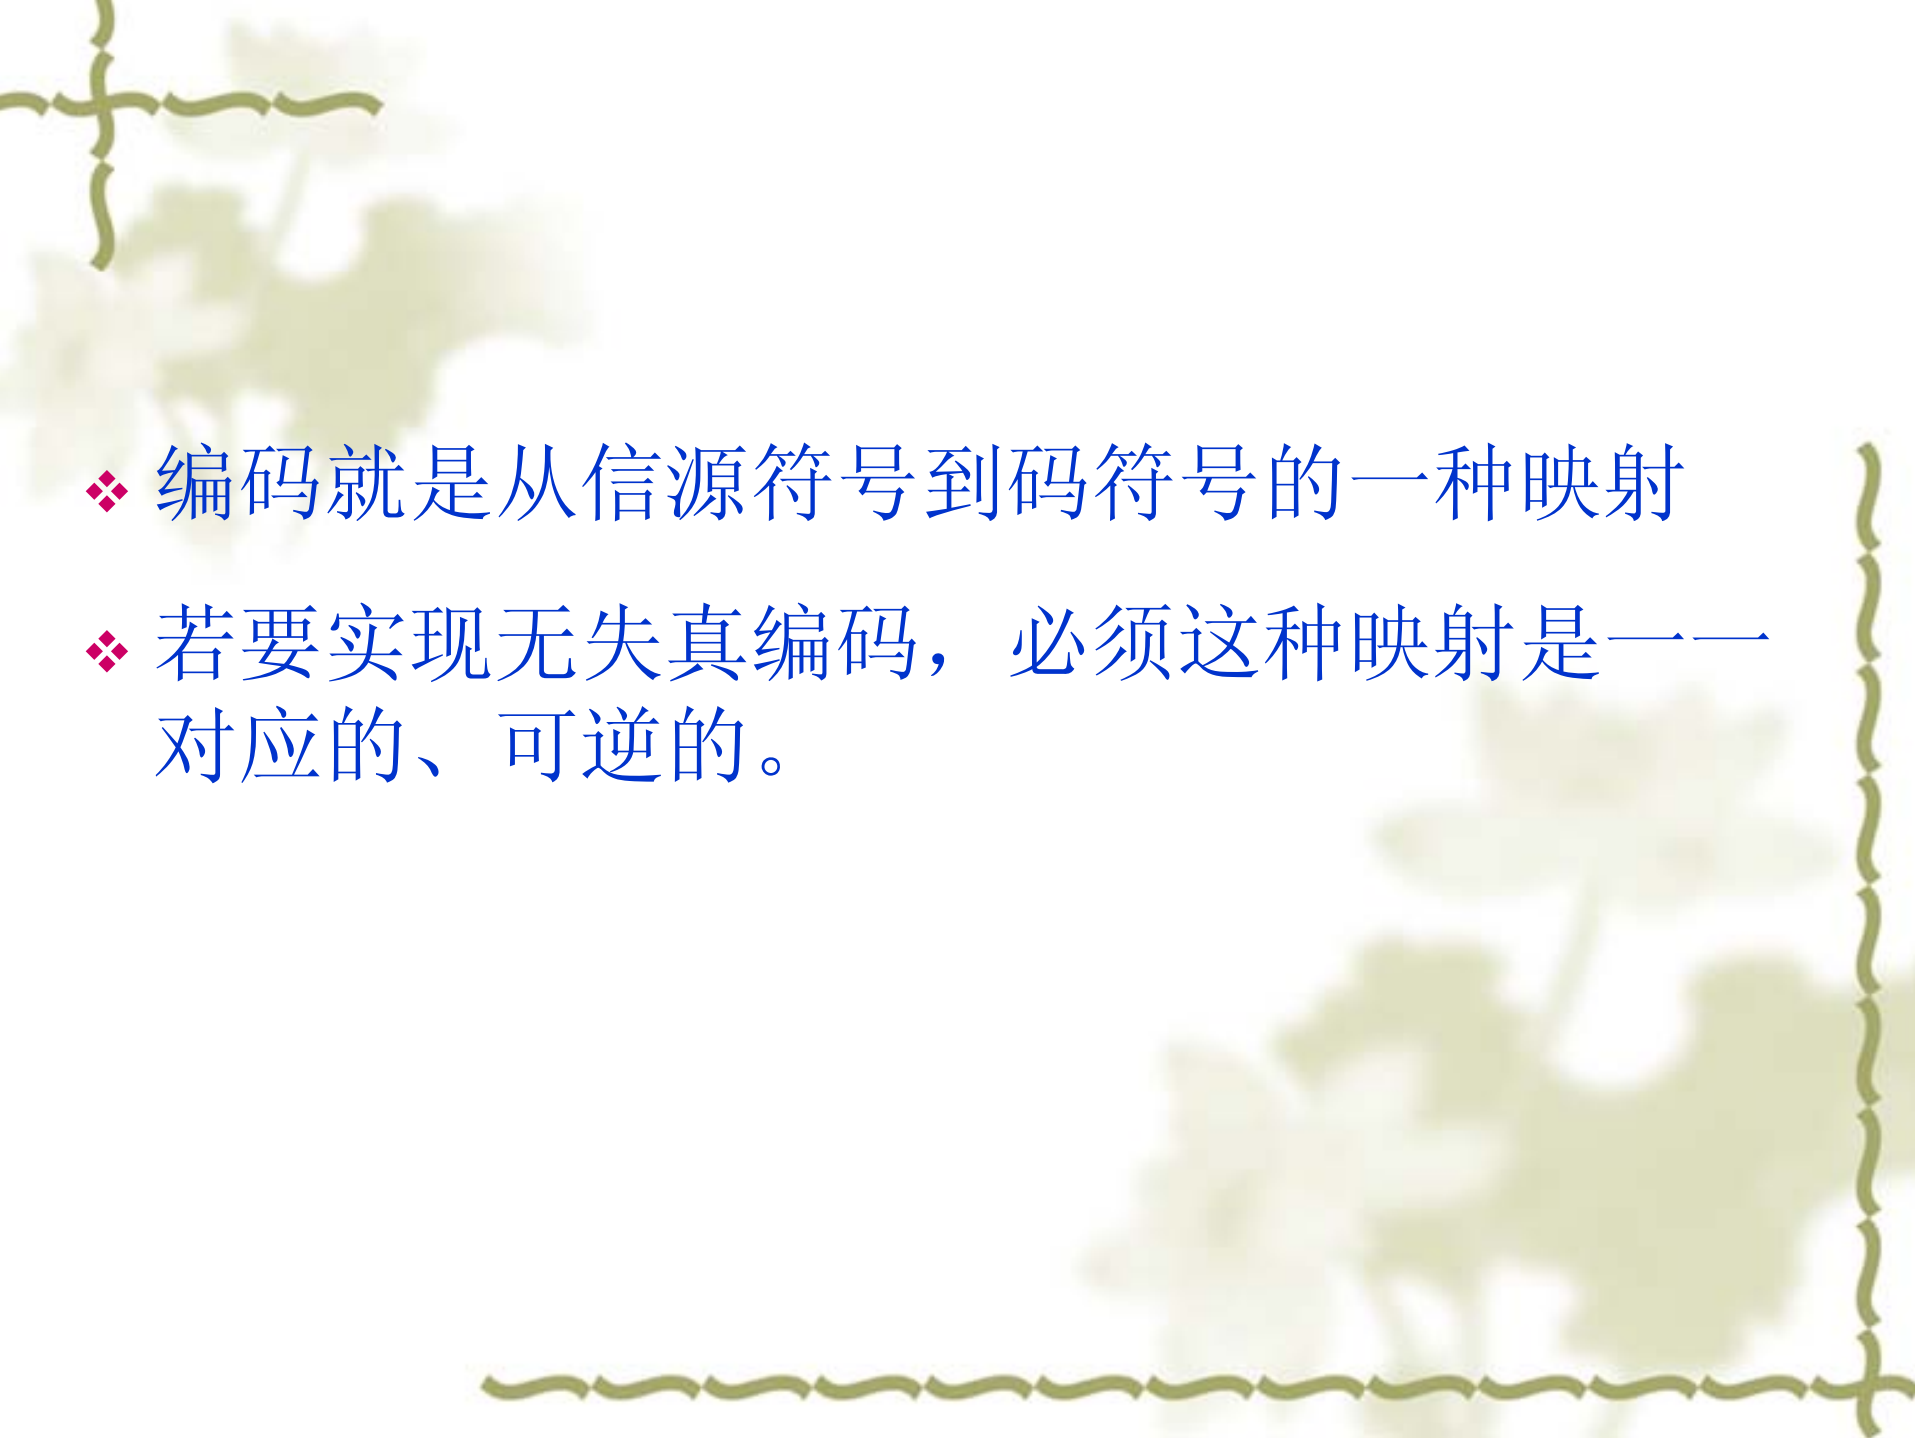
或者

$$\alpha_i = (s_{i_1} s_{i_2} \dots s_{i_N}) \leftrightarrow W_i = (x_{i_1} x_{i_2} \dots x_{i_{l_i}}) \quad (i = 1, 2, \dots, q^N)$$

$$s_{i_k} \in S \quad (k = 1, 2, \dots, N) \quad x_{i_k} \in X \quad (k = 1, 2, \dots, l_i)$$

- ❖ 这种码符号序列 $W_i$ ，称为码字。长度 $l_i$ 称为码字长度或简称码长。所有这些码字的集合 $C$ 称为码（或称码书）此码为 $r$ 元码或称 $r$ 进制码。



- 
- ❖ 编码就是从信源符号到码符号的一种映射
  - ❖ 若要实现无失真编码，必须这种映射是一一对应的、可逆的。

## 二元码

- ❖ 若码符号集为 $X = \{0, 1\}$ （即 $r=2$ ），所得码字就是一些二元序列，则称为二元码（或称二进制码）
- ❖ 若将信源通过一个二元信道进行传输，为使信源适合信道传输，就必须把信源符号变换成0, 1符号组成的码符号序列（二元序列）这种编码所得的码为二元码。
- ❖ 二元码是数字通信和计算机系统中最常用的一种码。

## 等长码

- ❖ 若一组码中所有的码字的码长都相同，即  $l_i=l(i=1, 2, \dots, q)$ ，则称为等长码。

## 变长码

- ❖ 若一组码中所有的码字的码长各不相同，即任意码字由不同长度  $l_i$  的码符号序列组成，则称为变长码。

## 非奇异码

- ❖ 若一组码中所有的码字都不相同，即所有信源符号映射到不同的码符号序列

$$s_i \neq s_j \Rightarrow W_i \neq W_j \quad (s_i, s_j \in S \quad W_i, W_j \in C)$$

则称码C为非奇异码。

## 奇异码

- ❖ 若一组码中有相同的码字，即

$$s_i \neq s_j \Rightarrow W_i = W_j \quad (s_i, s_j \in S \quad W_i, W_j \in C)$$

则称码C为奇异码。

## 同价码

- ❖ 若码符号集 $X: \{x_1, x_2, \dots, x_r\}$ 中每个码符号 $x_i$ 所占的传输时间相同，则所得的码 $C$ 为同价码。
- ❖ 一般二元码是同价码。本章讨论的都是同价码。对同价码来说，等长码中每个码字的传输速度都相同；而变长码中每个码字的传输时间就不一定相同。电报中用的莫尔斯码是非同价码，其码符号点（.）和划（—）所占的传输时间不相同。

## 码的N次扩展码

- ❖ 假定某码C，它把信源S中的符号 $s_i$ 一一变换成码C中的码字 $W_i$ ，则称码C的N次扩展码是所有N个码字组成的码字序列的集合。
- ❖ 若码 $C = \{W_1, W_2, \dots, W_q\}$  其中

$$s_i \in S \leftrightarrow W_i = (x_{i_1} x_{i_2} \dots x_{i_{l_i}}) \quad x_{i_{l_i}} \in X$$

则N次扩展码

$$B = \left\{ B_i = (W_{i_1} W_{i_2} \dots W_{i_N}) \quad i_1, i_2, \dots, i_N = 1, \dots, q \right. \\ \left. i = 1, \dots, q^N \right\}$$

可见，码C的N次扩展码B中，每个码字 $B_i$  ( $i=1, 2, \dots, q^N$ ) 与N次扩展信源 $S^N$ 中每个信源序列符号 $\alpha_i$ 一一对应，而

$$\alpha_i = (s_{i_1} s_{i_2} \dots s_{i_N})$$



举例：

❖ 设信源S的概率空间为

$$\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1, & s_2, & \dots, & s_q \\ P(s_1), & P(s_2), & \dots, & P(s_q) \end{bmatrix} \quad \sum_{i=1}^q P(s_i) = 1$$

❖ 若把它通过一个二元信道进行传输，为使信源适合信道传输，就必须把信源符号 $s_i$ 变换成0,1符号组成的码符号序列（二元序列）。我们可以采用不同的二元序列使其与信源符号 $s_i$ 一一对应，这样就得到不同的二元码。

表 5.1

| 信源符号 $s_i$ | 符号概率 $P(s_i)$ | 码 1 | 码 2 |
|------------|---------------|-----|-----|
| $s_1$      | $P(s_1)$      | 00  | 0   |
| $s_2$      | $P(s_2)$      | 01  | 01  |
| $s_3$      | $P(s_3)$      | 10  | 001 |
| $s_4$      | $P(s_4)$      | 11  | 111 |

❖ 码 1 是等长非奇异码，码 2 是变长非奇异码。

## N次扩展码

- ❖ 我们可以求得表5.1中码 1 和码 2 的任意N次扩展码。例如求码 2 的二次扩展码。
- ❖ 因为信源S的二次扩展信源

$$S^2 = [\alpha_1 = s_1 s_1, \alpha_2 = s_1 s_2, \alpha_3 = s_1 s_3, \dots, \alpha_{16} = s_4 s_4]$$

所以码 2 的二次扩展码为

| 信源符号       | 码字                  | 信源符号       | 码字                 | 信源符号          | 码字                       |
|------------|---------------------|------------|--------------------|---------------|--------------------------|
| $\alpha_1$ | 00= $W_1 W_1=B_1$   | $\alpha_5$ | 010= $W_2 W_1=B_5$ | ...           | ...                      |
| $\alpha_2$ | 001= $W_1 W_2=B_2$  | ...        | ...                | ...           | ...                      |
| $\alpha_3$ | 0001= $W_1 W_3=B_3$ | ...        | ...                | ...           | ...                      |
| $\alpha_4$ | 0111= $W_1 W_4=B_4$ | ...        | ...                | $\alpha_{16}$ | 111111= $W_4 W_4=B_{16}$ |

## 惟一可译码

- ❖ 若码的任意一串有限长的码符号序列只能被惟一地译成所对应的信源符号序列，则此码称为惟一可译码，或单义可译码。否则称为非惟一可译码或非单义可译码。
- ❖ 若要所编的码是惟一可译码，不但要求编码时不同的信源符号变换成不同的码字，而且还要求任意有限长的信源序列所对应的码符号序列各不相同，即要求码的任意长 $N$ 次扩展码都是非奇异码。因为只有任意有限长的信源序列所对应的码符号序列各不相同，才能把该码符号序列唯一地分割成一个个对应的信源符号，从而实现惟一地译码。
- ❖ 所以，某码的任意有限长 $N$ 次扩展码都是非奇异码，则该码为惟一可译码。

- ❖ 例如，表5.1中码 1 是惟一可译码，而码 2 是非惟一可译码。
- ❖ 因为对于码 2，其有限长的码符号序列能译成不同的信源符号序列。如：0010,可译成  $s_1s_2s_1$  或  $s_3s_1$ ,显然不是惟一的。
- ❖ 下面，我们分别讨论等长码和变长码的最佳编码问题，也就是是否存在一种惟一可译编码方法，使平均每个信源符号所需的码符号最短。也就是无失真信源压缩的极限值。

## 5.2 等长码

- ❖ 一般来说, 若要实现无失真的编码, 这不但要求信源符号  $s_i$  ( $i=1, 2, \dots, q$ ) 与码字  $W_i$  ( $i=1, 2, \dots, q$ ) 是一一对应的, 而且要求码符号序列的反变换也是惟一的.
- ❖ 所编的码必须是惟一可译码. 否则, 所编的码不具有惟一可译码性, 就会引起译码带来的错误与失真.
- ❖ 对于等长码来说, 若等长码是非奇异码, 则它的任意有限长  $N$  次扩展码一定也是非奇异码.
- ❖ 因此等长非奇异码一定是惟一可译码.

表5.2 等长码

| 信源符号  | 码1 | 码2 |
|-------|----|----|
| $s_1$ | 00 | 00 |
| $s_2$ | 01 | 11 |
| $s_3$ | 10 | 10 |
| $s_4$ | 11 | 11 |

- ❖ 在上表中, 码2不是惟一可译码, 比如11
- ❖ 码1是等长非奇异码, 所以是惟一可译码.



- ❖ 若对信源进行等长编码,则必须满足

$$q \leq r^l \quad (5.1)$$

式中, $l$ 是等长码的码长, $r$ 是码符号集中码元数.

- ❖ 例如表5.2中,信源S共有 $q=4$ 个信源符号,现进行二元等长编码,其中码符号个数为 $r=2$ .根据式(5.1)可知,信源S存在惟一可译等长码的条件是码长 $l$ 必须不小于2.

- ❖ 如果我们对信源 $S$ 的 $N$ 次扩展信源进行等长编码. 设信源  $S = \{s_1, s_2, \dots, s_q\}$ , 有 $q$ 个符号, 那么它的 $N$ 次扩展信源  $S^N = \{\alpha_1, \alpha_2, \dots, \alpha_{q^N}\}$  共有 $q^N$ 个符号. 其中  $\alpha_i = \{s_{i_1}, s_{i_2}, \dots, s_{i_N}\} (s_{i_k} \in S \quad k = 1, 2, \dots, N)$  是长度为 $N$ 的信源符号序列
- ❖ 设码符号集为  $X = [x_1, x_2, \dots, x_r]$ .
- ❖ 现在需要把这些长为 $N$ 的信源符号序列  $\alpha_i (i = 1, \dots, q^N)$  变换成长度为 $l$ 的码符号序列

$$W_i = (x_{i_1} x_{i_2} \dots x_{i_l}), (x_{i_1}, \dots, x_{i_l} \in X)$$

- ❖ 根据前面的分析,若要求得编得的等长码是惟一可译码则必须满足

$$q^N \leq r^l \quad (5.2)$$

此式表明, 只有当 $l$ 长的码符号序列数( $r^l$ )大于或等于 $N$ 次扩展信源的符号数( $q^N$ )时, 才可能存在等长非奇异码.

- ❖ 对式(5.2)两边取对数, 则有  $\frac{l}{N} \geq \frac{\log q}{\log r}$

- ❖  $\frac{l}{N}$ 是平均每个信源符号所需要的码符号个数.

- ❖ 对于等长惟一可译码, 每个信源符号至少需要用  $\frac{\log q}{\log r}$  个码符号来变换.

- ❖ 当 $r=2$ ,  $\log r=1$ , 则  $\frac{l}{N} \geq \log q$
- ❖ 这结果表明:对于二元等长惟一可译码,每个信源符号至少需要 $\log q$ 个二元符号来变换.
- ❖ 这也表明:对信源进行二元等长不失真编码时,每个信源符号所需要码长的极限值为 $\log q$ 个.
- ❖ 英文符号至少需要5个二元符号编码才行.
- ❖ 是不是可以用更少的符号表示? 是

❖ 接下来的例子说明为什么每个信源符号平均所需的码符号个数可以减少.

❖ 设信源

$$\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1, & s_2, & s_3, & s_4 \\ P(s_1), & P(s_2), & P(s_3), & P(s_4) \end{bmatrix}, \sum_{i=1}^4 P(s_i) = 1$$

而其依赖关系为 $P(s_1|s_2)=P(s_2|s_1)=P(s_3|s_4)=P(s_4|s_3)=1$ ,  
其余 $P(s_j|s_i)=0$ .

❖ 若不考虑符号之间依赖关系,此信源 $q=4$ ,那么,进行等长二元编码,由前面可知, $l=2$ .

- ❖ 若考虑符号之间依赖关系,此特殊信源的二次扩展信源为

$$\begin{bmatrix} S^2 \\ P(s_i s_j) \end{bmatrix} = \begin{bmatrix} s_1 s_2, & s_2 s_1, & s_3 s_4, & s_4 s_3 \\ P(s_1 s_2), & P(s_2 s_1), & P(s_3 s_4), & P(s_4 s_3) \end{bmatrix}$$

$$\sum_{ij} P(s_i s_j) = 1$$

$$\text{又 } P(s_i s_j) = P(s_i) \cdot P(s_j | s_i) \quad (i, j = 1, 2, 3, 4)$$

- ❖ 由上述依赖关系可以知道,除了 $P(s_1|s_2)$ ,  $P(s_2|s_1)$ ,  $P(s_3|s_4)$ ,  $P(s_4|s_3)$ 不等于0,其余 $s_i s_j$ 出现的概率皆为0.
- ❖ 因此二次扩展信源 $S^2$ 由16个符号缩减到4个符号.因此对它进行等长编码,所需码长仍为 $l'=2$ .

❖ 由此可见,当考虑信源符号之间依赖关系后,有些信源符号序列不会出现,这样信源符号序列个数会减少,再进行编码时,所需平均码长就可以缩短.

❖ 英文

❖ 等长编码定理给出了信源进行等长编码所需码长的理论极限值.



## 5.3 渐进等分割性和 $\varepsilon$ 典型序列

- ❖ 渐进等分割性AEP是弱大数定理的直接推论
- ❖ 大数定理：若 $X_1, X_2, \dots, X_n$ 是独立同分布的随机变量，只要 $n$ 足够大， $\frac{1}{n} \sum_{i=1}^n X_i$  接近于数学期望 $E(X)$ 。
- ❖ 渐近等分割性指出：随机变量 $S_1, S_2, \dots, S_N$ 独立同分布，联合概率为 $P(S_1 S_2 \dots S_N)$ ，只要 $N$ 足够大， $N$ 个变量自信信息的平均值 $-\frac{1}{N} \log P(S_1 S_2 \dots S_N)$ 接近于信息熵 $H(S)$ (自信信息的数学期望)
- ❖ 即：  $P(S_1 S_2 \dots S_N)$  接近于  $2^{-NH(S)}$

注意： 
$$-\frac{1}{N} \log P(S_1 S_2 \dots S_N) = \frac{1}{N} \sum_{i=1}^n -\log P(S_i)$$

对离散无记忆信源:

$$\begin{bmatrix} S \\ P \end{bmatrix} = \begin{bmatrix} s_1 & s_2 & \cdots & s_q \\ P_1 & P_2 & \cdots & P_q \end{bmatrix} \quad \sum_{i=1}^q P_i = 1$$

$S^N = (S_1 S_2 \dots S_N)$  为其N次扩展信源.  $\alpha_i = (s_{i_1} s_{i_2} \cdots s_{i_N})$  表示扩展信源的输出。

定理5.1 渐近等分割性: 若随机序列  $S_1 S_2 \dots S_N$  相互独立并且都服从同一概率分布  $P(s)$ , 则:

$$-\frac{1}{N} \log P(\alpha_i) = -\frac{1}{N} \log P(s_{i_1} s_{i_2} \cdots s_{i_N}) \quad \text{依概率收敛于 } H(S)$$

即: 对任意  $\varepsilon > 0$ , 有:  $\lim_{N \rightarrow \infty} P\{ | -\frac{1}{N} \log P(\alpha_i) - H(S) | < \varepsilon \} = 1$

也就是N足够大时, N个变量自信息的平均值接近于信息熵  $H(S)$  (自信息的数学期望)

# $\varepsilon$ 典型序列

❖ 定义：N长的序列  $\alpha_i = (s_{i_1} s_{i_2} \cdots s_{i_N}) \in S^N$ ，对于任意小的正数  $\varepsilon$ ，满足

$$|-\frac{1}{N} \log P(\alpha_i) - H(S)| < \varepsilon$$

则称  $\alpha_i$  为  $\varepsilon$  典型序列。

反之。若满足  $|-\frac{1}{N} \log P(\alpha_i) - H(S)| \geq \varepsilon$

则称  $\alpha_i$  为  $\varepsilon$  非典型序列。

记：  $G_{\varepsilon N} = \{\alpha_i : |-\frac{1}{N} \log P(\alpha_i) - H(S)| < \varepsilon\}$  表示  $S^N$  中  $\varepsilon$  典型序列的集合

$\overline{G}_{\varepsilon N} = \{\alpha_i : |-\frac{1}{N} \log P(\alpha_i) - H(S)| \geq \varepsilon\}$  表示  $S^N$  中  $\varepsilon$  非典型序列的集合

❖ 定理5.2 对于任意小的正数  $\varepsilon > 0$ 、 $\delta > 0$ ，当N足够大时，则：

(1)  $P(G_{\varepsilon N}) > 1 - \delta$

$$P(\overline{G_{\varepsilon N}}) \leq \delta$$

(2) 若  $\alpha_i = (s_{i_1} s_{i_2} \cdots s_{i_N}) \in G_{\varepsilon N}$ ，则

$$2^{-N[H(S)+\varepsilon]} < P(\alpha_i) < 2^{-N[H(S)-\varepsilon]}$$

(3) 设  $\|G_{\varepsilon N}\|$  表示  $G_{\varepsilon N}$  中  $\varepsilon$  典型序列的个数，则有：

$$(1-\delta)2^{N[H(S)-\varepsilon]} \leq \|G_{\varepsilon N}\| \leq 2^{N[H(S)+\varepsilon]}$$

该定理指出，N次扩展信源中信源序列可分为两类，一类是  $\varepsilon$  典型序列，它是经常出现的，N趋于无穷大时，出现的概率接近于1，且每个序列出现的概率接近于  $2^{-NH(S)}$ ；另一类是  $\varepsilon$  非典型序列，其出现的概率很低，随N的增大，出现概率可以任意小。


由定理第三个结论：

$$(1-\delta)2^{N[H(S)-\varepsilon]} \leq \|G_{\varepsilon N}\| \leq 2^{N[H(S)+\varepsilon]}$$

❖  $\varepsilon$  典型序列总数占信源序列总数的比值为：

$$\xi = \frac{\|G_{\varepsilon N}\|}{q^N} \leq \frac{2^{N[H(S)+\varepsilon]}}{q^N} = \frac{2^{N[H(S)+\varepsilon]}}{2^{N \log q}} = 2^{-N[\log q - H(S) - \varepsilon]}$$

由于  $H(S) < \log q$ ，因而  $\log q - H(S) - \varepsilon > 0$ ，于是随着  $N$  趋于无穷大时， $\xi$  趋于 0，结论表明虽然  $\varepsilon$  典型序列是高概率集，但它所含序列的数比非典型序列要少得多。



只对高概率典型序列进行一一对应等长编码，所需的码字总数减少，所需码长就可减少。

## 5.4 等长信源编码定理

❖ 定理5.3 (等长信源编码定理) 一个熵为 $H(S)$ 的离散无记忆信源, 若对信源长为 $N$ 的符号序列进行等长编码, 设码字是从 $r$ 个字母的码符号集中, 选取 $l$ 个码元组成. 对于任意  $\varepsilon > 0$ , 只要满足

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r} \quad (5.30)$$

则当 $N$ 足够大, 可实现几乎无失真编码, 即译码错误概率能为任意小. 反之, 若

$$\frac{l}{N} \leq \frac{H(S) - 2\varepsilon}{\log r} \quad (5.31)$$

则不可能实现无失真编码, 而当 $N$ 足够大时, 译码错误概率近似等于1.



## 定理证明的基本思路

- ❖ 把离散无记忆信源的 $N$ 次扩展信源划分成两个互补的集合： $G_{\varepsilon N}$  和  $\overline{G_{\varepsilon N}}$  .
- ❖ 一个集合 $G_{\varepsilon N}$ 中元素较少但包含的是经常出现的信源序列, 而且这个集合出现的概率接近于1.
- ❖ 另一个集合 $\overline{G_{\varepsilon N}}$ 中虽包含的元素较多, 但总的出现概率极小, 趋于0.
- ❖ 那么, 对高概率集合  $G_{\varepsilon N}$  中的信源序列进行编码, 而将低概率集  $\overline{G_{\varepsilon N}}$  中的信源序列舍弃, 不编码. 这样, 所需的平均码长可以减少, 而所引起的错误概率却很小, 趋于0.
- ❖ 因此, 只要知道高概率集  $G_{\varepsilon N}$  中信源序列个数的上、下限, 就可证得所需平均码长的上下限。定理5.2



## 定理证明

证明：由定理5.1及5.2可知，离散无记忆信源的N次扩展信源序列可划分成两个互补的集合： $G_{\varepsilon N}$  和  $\bar{G}_{\varepsilon N}$ 。

$G_{\varepsilon N}$  出现的概率接近于1，其中包含序列个数约为：

$$\|G_{\varepsilon N}\| \approx 2^{N[H(S)+\varepsilon]}$$

对 $G_{\varepsilon N}$ 中每个序列进行一一对应编码，要求码字的总数不小于 $\|G_{\varepsilon N}\|$ ，即：

$$r^l \geq \|G_{\varepsilon N}\|$$

由课本5.28得：

$$r^l \geq 2^{N[H(S)+\varepsilon]} > \|G_{\varepsilon N}\|$$

取对数有：

$$l \log r \geq N[H(S)+\varepsilon]$$

则得：

$$\frac{l}{N} \geq \frac{H(S)+\varepsilon}{\log r}$$

当选取的码长 $l$ 满足(5.30)时,  $G_{\varepsilon N}$  中每一序列均有不同的码字与其对应, 因而能够正确译码, 而  $\overline{G}_{\varepsilon N}$  中序列被舍弃, 若这类序列出现, 将会导致译码错误。

因而错误概率为  $\overline{G}_{\varepsilon N}$  出现的概率。因此得

$$P_E = P(\overline{G}_{\varepsilon N}) \leq \delta(N, \varepsilon) = \frac{D[I(s_i)]}{N\varepsilon^2}$$

所以在码长满足(5.30)条件下, 有:  $\lim_{N \rightarrow \infty} P_E = 0$

也就是错误概率可无限小。

❖ 若码长满足(5.31)

$$\frac{l}{N} \leq \frac{H(S) - 2\varepsilon}{\log r}$$

即

$$r^l \leq 2^{N[H(S) - 2\varepsilon]} < 2^{N[H(S) - \varepsilon]}$$

### (定理5.3证明续)

由  $\|G_{\varepsilon N}\|$  的下界为  $(1-\delta)2^{N[H(S)-\varepsilon]}$ ，此时选取的码字总数小于  $G_{\varepsilon N}$  中序列个数，部分序列没有相应的码字来对应，若记可以给予不同码字来对应的信源序列出现的概率为  $P[G_{\varepsilon N}$  中  $r^l$  个  $\alpha_i$ ]，它必然满足：

$$P[G_{\varepsilon N} \text{ 中 } r^l \text{ 个 } \alpha_i] \leq r^l \bullet \max_{\alpha_i \in G_{\varepsilon N}} P(\alpha_i)$$

而由定理5.2可知， $P(\alpha_i) \leq 2^{-N[H(S)-\varepsilon]}$

$$P[G_{\varepsilon N} \text{ 中 } r^l \text{ 个 } \alpha_i] \leq 2^{N[H(S)-2\varepsilon]} \bullet 2^{-N[H(S)-\varepsilon]} = 2^{-N\varepsilon}$$

也就是正确译码概率小于  $2^{-N\varepsilon}$

因而错误概率  $P_E$  大于  $1 - 2^{-N\varepsilon}$ ，且  $\lim_{N \rightarrow \infty} P_E = 1$

❖ 定理5.3是在平稳无记忆离散信源的条件下论证的.但它同样适合于平稳有记忆信源,只是要求有记忆信源的极限熵 $H_{\infty}(S)$ 和极限方差 $\sigma_{\infty}^2(S)$ 存在即可.

❖ 对于平稳有记忆信源,式(5.30)和(5.31)中的 $H(S)$ 改为极限熵  $H_{\infty}(S)$  .即为

$$\frac{l}{N} \geq \frac{H_{\infty}(S) + \varepsilon}{\log r} \quad (5.37)$$

❖ 当二元编码时 $r=2$ ,式(5.30)和(5.37)成为

$$\frac{l}{N} \geq H(S) + \varepsilon \quad (5.38)$$

$$\frac{l}{N} \geq H_{\infty}(S) + \varepsilon \quad (5.39)$$

❖ 可见,定理5.3给出了等长编码时平均每个信源符号所需的二元码符号的理论极限,这些极限值由 $H(S)$ 或 $H_{\infty}(S)$  决定

- ❖ 比较式(5.5)和(5.38)可知,当信源符号具有等概率分布时,两式就完全一致.但一般情形下,信源符号并非等概率分布,而且符号之间有很强的关联性,故信源的极限熵将大大小于 $\log q$ .
- ❖ 根据定理5.3可知,这时在等长编码中每个信源符号平均所需的二元码符号可大大减小,从而使编码的效率提高.
- ❖ 英文电报符号  $H_{\infty}(S) \approx 1.4$
- ❖ 表明每个英文信源符号只需接近1.4个二元符号来编码,这比前面讨论的需要5位二元符号减少了许多.这样,每个二元符号载荷的信息将接近极大值1比特,所以提高了信息传输效率.

$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r} \quad (5.30)$$

❖ 定理5.3中的条件式(5.30)可改写成

$$l \log r > NH(S) \quad (5.40)$$

- ❖ 这个不等式左边表示长为 $l$ 的码符号序列能载荷的最大信息量, 而右边代表长为 $N$ 的信源序列平均携带的信息量.
- ❖ 所以等长编码定理告诉我们: 只要码字传输的信息量大于信源序列携带的信息量, 总可实现几乎无失真编码.



$$\frac{l}{N} \geq \frac{H(S) + \varepsilon}{\log r} \quad (5.30)$$

❖ 将(5.30)移项，又可得：

$$\frac{l}{N} \log r \geq H(S) + \varepsilon \quad (5.41)$$

令 
$$R' = \frac{l}{N} \log r \quad (5.42)$$

它是编码后平均每个信源符号所能载荷的最大信息量，称  $R'$  为编码后信源的信息传输率。可见编码后的信息传输率必须大于信源的信息熵。

引进 
$$\eta = \frac{H(S)}{R'} = \frac{H(S)}{\frac{l}{N} \log r} \quad (5.43)$$

称为编码效率，它是信源信息熵与编码后与每个信源符号所能载荷的最大信息量的比值，其值越大，效率越高。

由定理5.3可知，

$$\frac{l}{N} \log r \geq H(S) + \varepsilon \quad (5.41)$$

最佳等长编码效率为

$$\eta = \frac{H(S)}{H(S) + \varepsilon} (\varepsilon > 0) \quad (5.44)$$

也就是最佳等长编码效率接近于1。

一般情况下，在已知信源信息熵的条件下，若要求允许错误概率越小，编码效率要越高，则N必须越长，实际应用中，要实现几乎无失真的等长编码，N需要大到难以实现的程度。而在N有限时，高传输率的等长编码往往要引入一定的失真与错误。码长l越大，错误概率会越小，但编码效率  $\eta$  会越小；l越小，编码效率  $\eta$  会越大，但错误概率会越大。

例：设离散无记忆信源：

$$\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1 & s_2 \\ \frac{3}{4} & \frac{1}{4} \end{bmatrix}$$

$$H(S) = \frac{1}{4} \log 4 + \frac{3}{4} \log \frac{4}{3} = 0.811$$

$$D[I(s_i)] = \sum_{i=1}^2 p_i (\log p_i)^2 - [H(S)]^2 = \frac{1}{4} (\log 4)^2 + \frac{3}{4} (\log \frac{4}{3})^2 - 0.811^2 = 0.4715$$

若采用等长二元编码，要求编码效率  $\eta = 0.96$ ，允许错误率  $\delta \leq 10^{-5}$ ，则：  $N \geq 4.13 \times 10^7$

也就是长度要达到**4130**万以上。

由  $\eta = \frac{H(S)}{H(S) + \varepsilon}$  可以计算出  $\varepsilon$ ，由  $P_E = \frac{D[I(s_i)]}{N\varepsilon^2}$  可以计算出N.

## 5.5 变长码

- ❖ 5.5.1 唯一可译变长码与即时码
- ❖ 5.5.2 即时码的树图构造法
- ❖ 5.5.3 Kraft不等式
- ❖ 5.5.4 唯一可译变长码的判断法

## 5.5.1 惟一可译变长码与即时码

- ❖ 讨论对信源进行变长编码的问题。变长码往往在 $N$ 不是很大时就可编出效率很高而且无失真的编码。
- ❖ 同样，变长码必须是惟一可译码，才能实现无失真编码。对于变长码,要满足惟一可译码，不但码本身必须是**非奇异的**，而且任意有限长 $N$ 次扩展码也都必须是**非奇异的**。所以，**惟一可译变长码的任意有限长 $N$ 次扩展码都是非奇异码。**

| 信源符号 $s_i$ | 符号出现概率 $P(s_i)$ | 码1 | 码2 | 码3   | 码4   |
|------------|-----------------|----|----|------|------|
| $s_1$      | 1/2             | 0  | 0  | 1    | 1    |
| $s_2$      | 1/4             | 11 | 10 | 10   | 01   |
| $s_3$      | 1/8             | 00 | 00 | 100  | 001  |
| $s_4$      | 1/8             | 11 | 01 | 1000 | 0001 |

- ❖ 码1不是惟一可译码 (奇异码)
- ❖ 码2是一个非奇异码, 不是惟一可译码  
码2从单个码字看不是奇异的, 但从码符号序列来仍然是一个奇异码, 比如 $s_1s_3, s_3s_1$ 都是000
- ❖ 码3和码4都是惟一可译码, 但它们是不同的.




- ❖ 在码4中,每个码都以1结束.这样,我们在接收符号序列时,只要出现1,就知道码结束,新码开始了.所以当出现符号1,就可以立即译码.因此,码中的符号1起了逗点的作用,称为逗点码.
- ❖ 而在码3中,不能即时译码,必须等待下一个符号的出现才能判别.
- ❖ 定义:在惟一可译变长码中,有一类码,它在译码时无需参考后续的码符号就能立即做出判断,译成对应的信源符号,则这类码称为即时码.
- ❖ 逗点码就是一种即时码.
- ❖ 在码3中,1,10,100,1000来说,前者是所有后者的前缀,而后者是所有前者的延长.但码4没有这个性质.

❖ 定义:若码C中,没有任何完整的码字是其他码字的前缀,即设 $W_i=(x_{i1}x_{i2}\dots x_{in})$ 是码C中任一码字,而它不是其他码字 $W_k=(x_{i1}x_{i2}\dots x_{in}\dots x_{ij})(j>n)$ 的前缀,则此码为**即时码**,也称**非延长码**或**前缀条件码**.


❖ 两个定义是等价的.

❖ 即时码是唯一可译码的一类子码,所以即时码一定是唯一可译码,反之,唯一可译码不一定是即时码.因为有些非即时码也满足唯一可译性.




## 5.5.2 即时码的树图构造法


- ❖ 即时码的一种简单构造方法是树图法
- ❖ 对于给定码字 $C=\{W_1, W_2, \dots, W_q\}$ 来说,可以用码树来描述



- ❖ 给每个节点伸出的树枝从左到右标上码符号 $0, 1, \dots, r$
- ❖ 终端点所对应的码字就是根到终端节点走过的路径所对应的码符号组成
- ❖ 如终端节点E对应的路径为ABCDE, 码为0001.
- ❖ 按树图法构造出来的码字一定是即时码(中间节点不安排码字)



二元码树



三元码树

- ❖ 从码树上可以得知,当第 $i$ 阶的节点作为终端节点,且分配以码字,则码字的码长为 $i$ .
- ❖ 任一即时码可用树图法来表示.但当码字长度给定,即时码不是惟一.
- ❖ 比如图5.4的码可以是 $\{0,10,110,1110\}$ . 为什么?
- ❖ 思考题: 画出码3所对应的树来, 并分析它的性质。
- ❖ 每个中间节点上都有 $r$ 个分枝的树称为整树, 如前面展示的二元码树和三元码树。
- ❖ 否则称为非整树。



- ❖ 当 $r$ 元 $l$ 节的码树的所有树枝都被用上时，第 $l$ 阶节点共有 $r^l$ 个终端节点，正好对应于长度为 $l$ 的等长码，可见等长码也是即时码的一种。
- ❖ 即时码的码树图还可以用来译码。
- ❖ 当接收到一串码符号序列后，首先从树根出发，根据接收到的第一个码符号来选择应走的第一条路径。若沿着所选枝路走到中间节点，那就再根据接收到的第二个码符号来选择应走的第二条路径。若又走到中间节点，那就依次继续下去，直到终端节点为止。走到终端节点，就可根据所走的枝路，立即判断出所接收到的码字。同时使系统重新返回树根，再作下一个接收码字的判断。这样，就可以将接收到的一串码符号序列译成相对应的信源符号序列。

## 5.5.3 Kraft不等式

❖ **定理5.4** 对于码符号集 $X=\{x_1, x_2, \dots, x_r\}$ 的任意 $r$ 元即时码（非延长码），其码字为 $W_1, W_2, \dots, W_q$ ，所对应的码长为 $l_1, l_2, \dots, l_q$ ，则必定满足

$$\sum_{i=1}^q r^{-l_i} \leq 1 \quad (5.45)$$

反之，若码长满足不等式(5.45)，则一定存在具有这样码长的 $r$ 元即时码。

## ❖ 必要性的证明 即证明即时码满足(5.45)

- ❖ 设任意 $r$ 元即时码 $C$ ，其码字为 $W_1, \dots, W_q$ ，对应的码长为 $l_1, \dots, l_q$ 。因为任意 $r$ 元即时码都可用 $r$ 元树图来描述，那么 $r$ 元即时码一定也可用 $r$ 元树图来表示。
- ❖ 从树图来看，第 $N$ 阶所有可能伸出的树枝为 $r^N$ 枝。当某第 $i (i < N)$ 阶节点为码字，即码长 $l_i = i$ 。它将影响到第 $N$ 阶所伸出的树枝。它使第 $N$ 阶不能伸出的树枝数等于 $r^{N-i} = r^{N-l_i}$ 个，因为码字共有 $q$ 个，每个码字作为树的终端节点后，都会影响第 $N$ 阶伸出的树枝。
- ❖ 假设 $N \geq \max l_i (i=1, 2, \dots, q)$ ，那么， $q$ 个码字影响第 $N$ 阶总共不能伸出的树枝为
$$\sum_{i=1}^q r^{N-l_i}$$

❖ 这些总共不能伸出的树枝应该小于或等于第N阶所有可能伸出的树枝，所以有

$$\sum_{i=1}^q r^{N-l_i} \leq r^N \quad (5.46)$$

则得

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

❖ 充分性的证明:

- ❖ 证明码长满足不等式(5.45)一定存在具有这样码长的 $r$ 元即时码。我们采用构造性的方法。
- ❖ 因为即时码可用树图法构造，为了用 $r$ 元树上的节点分配为码字，首先将具有给定码字长度 $l_i(i=1,2,\dots,q)$ 的数值按大小顺序重新排列，并将下标改变，使下式成立

$$l_1 \leq l_2 \leq l_3 \leq \dots \leq l_q$$

- ❖ 这种重新排列和将下标改变是完全可以的。

❖ 因为这些码字长度满足不等式(5.45)，即有

$$r^{-l_1} + r^{-l_2} + \dots + r^{-l_{q-1}} + r^{-l_q} \leq 1$$

❖ 移项有

$$r^{-l_q} \leq 1 - \sum_{i=1}^{q-1} r^{-l_i} \quad (5.47)$$

❖ 两边乘以  $r^{l_q}$ ，得

$$1 = r^{l_q - l_q} \leq r^{l_q} - \sum_{i=1}^{q-1} r^{l_q - l_i} \quad (5.48)$$

❖ 显然又由式(5.45)可得

$$\sum_{i=1}^{q-1} r^{-l_i} < 1 \quad (5.49)$$



❖ 移项可得  $r^{-l_{q-1}} < 1 - \sum_{i=1}^{q-2} r^{-l_i}$  (5.50)

❖ 两边乘以  $r^{l_q}$ ，得

$$r^{l_q - l_{q-1}} \leq r^{l_q} - \sum_{i=1}^{q-2} r^{l_q - l_i} \quad (5.51)$$

❖ 依次类推，得到下列一系列不等式

$$r^{l_q - l_{q-2}} \leq r^{l_q} - \sum_{i=1}^{q-3} r^{l_q - l_i} \quad (5.52)$$

...


$$r^{l_q - l_3} < r^{l_q} - \sum_{i=1}^2 r^{l_q - l_i} \quad (5.53)$$

$$r^{l_q - l_2} < r^{l_q} - r^{l_q - l_1} \quad (5.54)$$

- ❖ 这样， $r, q, l_i$  满足式(5.45)转换成满足一系列不等式，将式(5.48)、式(5.51)...式(5.54)写成一般形式为

$$r^{l_q - l_{k+1}} \leq r^{l_q} - \sum_{i=1}^k r^{l_q - l_i} \quad (k = 1, 2, \dots, q-1) \quad (5.55)$$

- ❖ 现在我们根据式(5.55)中的码长用树图法来构造即时码的一棵码树。我们描画出一棵 $l_q$ 阶的整树(图为二元三阶整树)。



三阶节点的二元整树

- ❖ 在这棵树上，第 $l_q$ 阶的节点共有 $r^{l_q}$ 个。
- ❖ 如果选取第 $l_1$ 阶的任一节点作为终端节点且分配以码字 $W_1$ ，因此 $l_q$ 阶可利用的节点少了 $r^{l_q-l_1}$ 个。（如图5.8中，某 $k(k=1,2)$ 阶节点为码字，其下端的虚线枝杈都被去掉了，其下端的节点也都被去掉了。） $l_q$ 阶剩下的节点才能被安排为其他码字，剩下的节点有 $r^{l_q}-r^{l_q-l_1}$ 个。
- ❖ 现在需要给 $l_2$ 分配码字。即选取 $l_2$ 阶的任一节点分配以码字 $W_2$ 。这时 $l_2$ 阶的节点又将减少 $r^{l_q-l_2}$ 个。由于式满足(5.54)，所以安排码字 $W_2$ 是合理的。
- ❖ 安排完码字 $W_2$ 后，这是剩下可利用的节点有 $r^{l_q}-r^{l_q-l_1}-r^{l_q-l_2}$ 个。然后，再给码长为 $l_3$ 的分配码字，由于(5.55)满足，故可以在 $l_3$ 阶的任一节点分配码字 $W_3$ 。

- ❖ 以此继续，因为式满足(5.55)，故可在 $l_4, \dots, l_{q-1}$ 阶的节点上分配码字 $W_4, \dots, W_{q-1}$ 。
- ❖ 这样，在 $l_q$ 阶剩下的可利用的节点数为
$$r_{l_q} - r^{l_q-l_1} - r^{l_q-l_2} - \dots - r^{l_q-l_k} \quad (k=l_{q-1})$$
- ❖ 因为式(5.48)成立，因此足以在 $l_q$ 阶的节点上分配一个码长为 $l_q$ 的码字 $W_q$ 。
- ❖ 这样就构成一个即时码。
- ❖ 所以证得满足Kraft不等式，一定存在即时码。

❖ **定理5.5** 对于码符号为 $X=\{x_1, x_2, \dots, x_r\}$ 的任意 $r$ 元唯一可译码，其码字为 $W_1, W_2, \dots, W_q$ ，所对应的码长为 $l_1, l_2, \dots, l_q$ ，则必定满足kraft不等式：

$$\sum_{i=1}^q r^{-l_i} \leq 1 \quad (5.45)$$

反之，若码长满足不等式(5.45)，则一定存在具有这样码长的 $r$ 元唯一可译码。

❖ **定理5.5**指出了唯一可译码中 $r, q, l_i$ 之间的关系。说明如果符合这个关系式，则一定能够构成至少一种唯一可译码，否则，无法构成唯一可译码。

- ❖ 在表5.3中，信源符号个数 $q=4$ ，而 $r=2$ ，对于码长分别为 $l_1=1, l_2=l_3=l_4=2$ ，它们不满足Kraft不等式，所以一定不能构成惟一可译码。
- ❖ 若令 $l_1=1, l_2=2, l_3=3, l_4=4$ ，它们满足Kraft不等式，所以一定存在一种惟一可译码满足上面的条件。
- ❖ 例如码3和码4就满足 $l_1=1, l_2=2, l_3=3, l_4=4$ 。但是码4是即时码，码3不是即时码。可得到什么结论？
- ❖ 值得注意的是：满足Kraft不等式且满足 $l_1=1, l_2=2, l_3=3, l_4=4$ 的码不一定是惟一可译码。




- ❖ 定理5.5只给出了唯一可译变长码的存在性。它说明唯一可译码一定满足不等式；反之，满足不等式的码不一定是唯一可译码，但一定至少存在一种唯一可译码。
- ❖ 由定理5.4和定理5.5可得到如下的结论：
- ❖ 定理5.6 若存在一个码长为 $l_1, l_2, \dots, l_q$ 的**唯一可译码**，则一定存在相同码长的**即时码**。
- ❖ 即时码很容易用树图法构造出来。

## 5.5.4 惟一可译变长码的判断法

- ❖ 由定理5.4和5.5可知，若码长 $l_1, l_2, \dots, l_q$ 不满足Kraft不等式，则一定不是惟一可译码。但码长满足Kraft不等式的码，则不一定是惟一可译码。
- ❖ 因此，不能用Kraft不等式来判断码是不是惟一可译码。只能根据惟一可译码的定义来判断。
- ❖ Sardinas和Patterson于1957年设计出一种判断惟一可译码的测试方法。

- ❖ 根据惟一可译码的定义可知,当且仅当有限长的码符号序列能译成两种不同的码字序列,则此码一定不是惟一可译码.如下的情形则一定不是惟一可译码。




- ❖ 由上图可知,当图中的情况发生时, $B_1$ 一定是 $A_1$ 的前缀,而 $A_1$ 被 $B_1$ 截去前面部分后的尾随后缀一定是另一码字 $B_2$ 的前缀;又 $B_2$ 的尾随后缀又是其他码字的前缀。最后,码符号序列的尾部一定是某个码字。

- ❖ 由此可得，惟一可译码的判断方法是：
- ❖ 将码C中所有码字可能的尾随后缀组成一个集合F，当且仅当集合F中没有包含任一码字，则可判断码C为惟一可译变长码。F的构造方法：
  - ❖ 1) 观察码C中最短的码字是否是其他码字的前缀。若是，将其所有可能的尾随后缀排列出。而这些尾随后缀又可能是某些码字的前缀，再将由此这些尾随后缀产生新的尾随后缀列出。
  - ❖ 2) 再观察这些新的尾随后缀是否是某些码字的前缀，或者最短码字又仍是这些尾随后缀的前缀。将产生的尾随后缀列出。
  - ❖ 3) 依此下去，直至没有一个尾随后缀是码字的前缀或没有新的尾随后缀产生为止。
  - ❖ 4) 这样，首先获得由最短的码字能引起的所有尾随后缀。接着，按照上述步骤将次短的码字、...，所有码字可能产生的尾随后缀全部列出。由此得到由码C的所有可能的尾随后缀组成的集合F。

❖ **例5.1** 现设码 $C=\{0,10,1100,1110,1011,1101\}$ ,根据上述测试方法,来判断是否是惟一可译码。

- ❖ 因为最短码字“0”,不是其他码字的前缀,所以它没有尾随后缀。
- ❖ 码字“10”,它是码字“1011”的前缀所以有尾随后缀,将“1011”截去其前缀“10”,得尾随后缀为11,这尾随后缀又是其他3个码字的前缀部分,由此再列出所产生的新的尾随后缀为00,10,01。
- ❖ 它们又是一些码字的前缀部分或者某些码字是他们的的前缀部分。如码字“0”是00和01的前缀,而10是码字“1011”的前缀。又得新的尾随后缀为0,11,1。然后再列出它们的尾随后缀因11的尾随后缀已列出,所以只需列出“1”的尾随后缀,直至列出全部为止。



- ❖  $F=\{11,00,10,01,0,1,100,110,011,101\}$ , 而见“10”和“0”都是码字,所以不是惟一可译码。

❖(续例5.1) 根据前面的分析 部分码文有不同译法

☞码文101100可译为:  $S_5S_1S_1$ 或 $S_2S_3$

☞码文1011011100可译为:  $S_5S_1S_4S_1$ 或 $S_2S_5S_3$

❖ 例5.2 码 $C=\{110,11,100,00,10\}$ 。计算其尾随后缀。

| 码字  | 尾随后缀 |
|-----|------|
| 11→ | 0→0  |
| 10→ | 0→0  |

❖ 故得 $F=\{0\}$ 。 $F$ 集中没有元素是码 $C$ 的码字, 所以码 $C$ 是惟一可译码。

❖ 如果 $F$ 是空集, 则一定是惟一可译码。



## 5.6 变长信源编码定理

- ❖ 由上一节讨论可知道,对于已知信源 $S$ 可用码符号 $X$ 进行变长编码,而且对同一信源编成同一码符号的即时码或惟一可译码有许多种,究竟哪一种最好呢?
- ❖ 从高效率传输信息的观点来考虑,当然希望选择由短的码符号组成的码字,就是用码长作为选择准则,为此我们引进码的平均长度。



什么是“平均长度”?

❖ 设信源为  $\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1, & s_2, & \cdots, & s_q \\ p(s_1), & p(s_2), & \cdots, & p(s_q) \end{bmatrix}$

❖ 编码后的码字为  $W_1, W_2, \dots, W_q$

❖ 其码长分别为  $l_1, l_2, \dots, l_q$

❖ 因为对惟一可译码来说,信源符号与码字是一一对应的,所以有

$$P(W_i) = p(s_i) \quad (i = 1, 2, \dots, q)$$

❖ 则这个码的码字的平均长度为

$$\bar{L} = \sum_{i=1}^q p(s_i) l_i \quad \text{单位:码符号/信源符号}$$

- ❖ 平均长度是每个信源符号平均需要的码元数。
- ❖ 从工程观点来看,总希望通信设备经济、简单,并且单位时间内传输的信息量越大越好。当信源给定时,信源的熵就确定了(为 $H(S)$ 比特/信源符号),而编码后每个信源符号平均用  $\bar{L}$  个码符号来变换。
- ❖ 那么平均每个码元携带的信息量即编码后信道的信息传输率(又称码率)为

$$R = H(X) = \frac{H(S)}{\bar{L}} \quad \text{比特/码符号}$$

- ❖ 若传输一个码符号需要 $t$ 秒钟,则编码后信道每秒钟传输的信息量为

$$R_t = \frac{H(S)}{t\bar{L}} \quad \text{比特/秒}$$

- ❖ 由此可见 $\bar{L}$ 越短、 $R_t$ 越大，信息传输率就越高。为此我们感兴趣的是使平均码长 $\bar{L}$ 为最短的码。
- ❖ 对于某一信源和某一码符号集来说，若有一个惟一可译码其平均长度 $\bar{L}$ 小于所有其他惟一可译码的平均长度，则该码为**紧致码**，或称**最佳码**。
- ❖ 无失真信源编码的基本问题就是找紧致码。
- ❖ 现在我们来找紧致码的平均码长 $\bar{L}$ 可能达到的理论极限

- ❖ 定理5.7 若一个离散无记忆信源 $S$ 具有熵为 $H(S)$ ，并有 $r$ 个码元的码符号集 $X=\{x_1, x_2, \dots, x_r\}$ ，则总可以找到一种无失真编码方法，构成惟一可以码，使其平均码长满足

$$\frac{H(S)}{\log r} \leq \bar{L} < 1 + \frac{H(S)}{\log r} \quad (5.64)$$

- ❖ 定理告诉我们码字的平均长度 $\bar{L}$ 不能小于极限值 $\frac{H(S)}{\log r}$ ，否则惟一可译码不存在。
- ❖ 定理又给出了平均码长的上界。但并不是说大于这上界不能构成惟一可译码，而是我们希望 $\bar{L}$ 尽可能短。定理说明当平均码长小于上界时，惟一可译码也存在。
- ❖ 这个定理给出了紧致码的平均码长，并指出这个最短的平均码长 $\bar{L}$ 与信源熵是有关的。

❖ 定理的证明：先证下界

$$\bar{L} \geq \frac{H(S)}{\log r} \quad (5.65)$$

❖ 即证明  $H(S) - \bar{L} \log r \leq 0$  (5.66)

❖ 证明思路:利用平均长度及信息熵的定义展开上式,然后利用詹森不等式及克拉伏特不等式来证明.

❖ 根据  $\bar{L}$  的定义(5.62)及熵的定义得

$$\begin{aligned} H(S) - \bar{L} \log r &= -\sum_{i=1}^q P(s_i) \log P(s_i) - \log r \sum_{i=1}^q P(s_i) l_i \\ &= -\sum_{i=1}^q P(s_i) \log P(s_i) + \sum_{i=1}^q P(s_i) \log r^{-l_i} \\ &= \sum_{i=1}^q P(s_i) \log \frac{r^{-l_i}}{P(s_i)} \leq \log \sum_{i=1}^q P(s_i) \frac{r^{-l_i}}{P(s_i)} = \log \sum_{i=1}^q r^{-l_i} \end{aligned}$$

❖ 因为总可以找到一种惟一可译码, 它的码长满足 Kraft 不等式, 所以

$$H(S) - \bar{L} \log r \leq \log \sum_{i=1}^q r^{-l_i} \leq \log 1 = 0$$



于是证得：

$$\bar{L} \geq \frac{H(S)}{\log r}$$

❖ 由证明过程知道，上述等式成立的充要条件是

$$\frac{r^{-l_i}}{P(s_i)} = 1 (i = 1, 2, \dots, q)$$

❖ 即  $P(s_i) = r^{-l_i} (i = 1, 2, \dots, q)$  (5.67)

❖ 取对数得：  $l_i = \frac{-\log P(s_i)}{\log r} = -\log_r P(s_i) \quad (i = 1, 2, \dots, q)$  (5.68)

❖ 可见，只有当我们能够选择每个码长  $l_i$  等于  $\log_r \frac{1}{P(s_i)}$  时，才能达到下界值。由于  $l_i$  必须是正整数，所以  $\log_r \frac{1}{P(s_i)}$  也必须是正整数。这就是说，当等式成立时，每个信源符号的概率  $P(s_i)$  必须呈现  $\left(\frac{1}{r}\right)^{\alpha_i}$  的形式 ( $\alpha_i$  是正整数)。如果这个条件满足则只要选择  $l_i$  等于  $\alpha_i$ ，则可以构造紧致码。

❖ 再证上界:

❖ 思想: 构造一种码长序列, 满足右边的不等式, 同时满足kraft不等式, 因而存在惟一可译码。

❖ 首先令  $\alpha_i = \log_r \frac{1}{P(s_i)} = \frac{-\log P(s_i)}{\log r} (i=1,2,\dots,q)$ , 然后选取每个码字的长度  $l_i$  的原则是: 若  $\alpha_i$  是整数, 取  $l_i = \alpha_i$ ; 若  $\alpha_i$  不是整数, 选取  $l_i$  满足  $\alpha_i < l_i < \alpha_i + 1$  的整数, 即选择码长满足 
$$l_i = \left\lceil \log_r \frac{1}{P(s_i)} \right\rceil (i = 1, 2, \dots, q) \quad (5.69)$$

式(5.69)中符号  $\lceil x \rceil$  代表不小于  $x$  的最小正整数。

❖ 因此码长满足  $\alpha_i \leq l_i < \alpha_i + 1 (i = 1, 2, \dots, q) \quad (5.70)$

由  $\alpha_i \leq l_i$  可得:  $r^{-l_i} \leq P(s_i)$

❖ 将上式对所有的  $i$  求和, 即是kraft不等式。因此, 用这样选择的码长  $l_i$  满足Kraft不等式, 可构造惟一可译码, 但所得码并不一定是紧致码。

❖ 由式(5.70)右边不等式, 有

$$l_i < \frac{-\log P(s_i)}{\log r} + 1 \quad (5.71)$$

❖ 两边乘以 $P(s_i)$ , 并对 $i$ 求和得

$$\sum_{i=1}^q P(s_i) l_i < \frac{-\sum_{i=1}^q P(s_i) \log P(s_i)}{\log r} + 1$$

❖ 由此得到

$$\bar{L} < \frac{H(S)}{\log r} + 1 \quad (5.72)$$

❖ 由此证明得到, 平均码长小于上界的惟一可译码存在.

- ❖ 式(5.64)中熵 $H(S)$ 与 $\log(r)$ 的信息量单位必须一致。若熵以 $r$ 进制为单位，则(5.64)可以写成

$$H_r(S) \leq \bar{L} < H_r(S) + 1 \quad (5.73)$$

- ❖ 式中 
$$H_r(S) = - \sum_{i=1}^q P(s_i) \log_r P(s_i)$$

- ❖ 从单位来看，在式(5.64)中 $H(S)/\log r$ 的单位是码符号/信源符号，它与平均码长的单位是一致的。在式(5.73)中似乎 $H_r(S)$ 单位应是 $r$ 进制单位/信源符号，但因为现在每个 $r$ 元码符号携带1个 $r$ 进制单位信息量，所以实际上，式(5.73)中 $H_r(S)$ 的单位仍是码符号/信源符号，与平均码长的单位仍是一致的。

## ❖ 定理5.8 无失真变长信源编码定理（即香农第一定理）

离散无记忆信源 $S$ 的 $N$ 次扩展信源 $S^N = \{\alpha_1, \alpha_2, \dots, \alpha_{q^N}\}$ , 其熵为 $H(S^N)$ , 并有码符号 $X = \{x_1, \dots, x_r\}$ 。对信源 $S^N$ 进行编码, 总可以找到一种编码方法, 构成惟一可译码, 使信源 $S$ 中每个信源符号所需要的平均码长满足

$$\frac{H(S)}{\log r} + \frac{1}{N} > \frac{\bar{L}_N}{N} \geq \frac{H(S)}{\log r} \quad (5.74)$$

或者

$$H_r(S) + \frac{1}{N} > \frac{\bar{L}_N}{N} \geq H_r(S) \quad (5.75)$$

当 $N \rightarrow \infty$ 时, 则得  $\lim_{N \rightarrow \infty} \frac{\bar{L}_N}{N} = H_r(S)$  (5.76)

式中

$$\bar{L}_N = \sum_{i=1}^{q^N} P(\alpha_i) \lambda_i \quad (5.77)$$

式中， $\lambda_i$ 是 $\alpha_i$ 所对应的码字长度，因此 $\bar{L}_N$ 是无记忆扩展信源 $S^N$ 中每个符号 $\alpha_i$ 的平均码长，可见 $\frac{\bar{L}_N}{N}$ 仍是信源 $S$ 中每一单个信源符号需要的平均码长。

这里要注意 $\frac{\bar{L}_N}{N}$ 和 $\bar{L}$ 的区别。它们两者都是每个信源符号所需要的码符号的-平均数，但是， $\frac{\bar{L}_N}{N}$ 的含义是，为了得到这个平均值，不是对单个信源符号 $s_i$ 进行编码，而是对 $N$ 个信源符号的序列 $\alpha_i$ 进行编码。



# 证明

设离散无记忆信源

$$\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1, & s_2, & \cdots, & s_q \\ P(s_1), & P(s_2), & \cdots, & P(s_q) \end{bmatrix}, \sum_{i=1}^q P(s_i) = 1$$

它的  $N$  次扩展信源

$$\begin{bmatrix} S^N \\ P(\alpha) \end{bmatrix} = \begin{bmatrix} \alpha_1, & \alpha_2, & \cdots, & \alpha_{q^N} \\ P(\alpha_1), & P(\alpha_2), & \cdots, & P(\alpha_{q^N}) \end{bmatrix}, \sum_{i=1}^{q^N} P(\alpha_i) = 1$$

式中  $\alpha_i = (s_{i_1} s_{i_2} \cdots s_{i_N})$   $i_1, i_2, \dots, i_N = 1, 2, \dots, q$

$$P(\alpha_i) = P(s_{i_1})P(s_{i_2}) \cdots P(s_{i_N})$$

把定理5.7应用于扩展信源 $S^N$ 得

$$H_r(S^N) + 1 > \bar{L}_N \geq H_r(S^N) \quad (5.78)$$

式中,  $H_r(S^N)$ 是以 $r$ 进制为单位的扩展信源 $S^N$ 的熵。

离散无记忆信源的扩展 具有

$$H_r(S^N) = NH_r(S)$$

代入(5.78)得  $NH_r(S) + 1 > \bar{L}_N \geq NH_r(S)$

$$\text{两边除以 } N \text{ 得 } H_r(S) + \frac{1}{N} > \frac{\bar{L}_N}{N} \geq H_r(S)$$

$$\text{显然, 当 } N \rightarrow \infty \text{ 有 } \lim_{N \rightarrow \infty} \frac{\bar{L}_N}{N} = H_r(S)$$

证毕

- ❖ 定理5.8是香农信息论的主要定理之一.
- ❖ 定理指出,要做到无失真的信源编码,每个信源符号平均所需最少的 $r$ 元码元数就是信源的熵值.
- ❖ 若编码的平均码长小于信源的熵值,则惟一可译码不存在,在译码或反变换时必然要带来失真或差错.
- ❖ 同时定理还指出,通过对扩展信源进行变长编码,当 $N \rightarrow \infty$ 时,平均码长可达到这个极限值.
- ❖ 可见,信源的信息熵是无失真信源压缩的极限值.
- ❖ 也可以认为,信源的信息熵是描述信源每个符号平均所需最少的比特数.

若改写(5.74), 可得

$$H(S) + \varepsilon > \frac{\bar{L}_N}{N} \log r \geq H(S) \quad (5.82)$$

式中,  $\frac{\bar{L}_N}{N} \log r$  就是编码后平均每个信源符号能载荷的最大信息量, 即是变长信源编码后信源的信息传输率为  $R' = \frac{\bar{L}_N}{N} \log r$  它等同于式 (5.41)。

比较(5.41)和(5.82)可知, 等长编码和变长编码的编码后信源的信息传输率的理论极限值是一致的。

- ❖ 信源第一定理也可以描述为:
- ❖ 若 $R' > H(S)$ , 就存在惟一可变编码; 若 $R' < H(S)$ , 惟一可译变长编码不存在, 不能实现无失真的信源编码.

若从信道角度看，信道的信息传输率（码率）

$$R = \frac{H(S)}{\bar{L}} \left( \frac{\text{比特/信源符号}}{\text{码符号/信源符号}} \right) = \frac{H(S)}{\bar{L}} (\text{比特/码符号})$$

因为  $\bar{L} = \frac{\bar{L}_N}{N} \geq \frac{H(S)}{\log r}$  信道的信息传输率即平均每个信道符号所携带的信息量

所以，可得编码后信道的信息传输率为

$$R = \frac{H(S)}{\bar{L}} \leq \log r \quad (5.83)$$

当平均码长  $\bar{L}$  达到极限值  $H(S)/\log r$  时，上式等号成立

$$R = \log r \quad (\text{比特/码符号})$$



- ❖ 由此可见,这时信道的信息传输率等于无噪无损信道的信道容量 $C$ ,信道的信息传输率最高.
- ❖ 无失真信源编码的实质就是对离散信道进行适当的变换,使变换后新的码符号信源尽可能等概率分布,以使新信源的每个符号平均所含的信息量达到最大,从而使信道的信息传输率 $R$ 达到信道容量 $C$ ,实现信源与信道理想的统计匹配(香农第一定理的物理意义).
- ❖ 无失真信源编码定理通常又称为无噪信道编码定理。此定理可以表述为:若信道的信息传输率 $R$ 不大于信道容量 $C$ ,总能对信源的输出进行适当的编码,使得在无噪无损信道上能无差错地以最大信息传输率 $C$  传输信息;但要使信道的信息传输率 $R$ 大于 $C$ 而无差错地传输信息则是不可能的.

❖ 为了衡量各种编码距极限压缩值的情况,我们定义变长码的编码效率 (即: 传输信息量 $H(S)$ , 使用了 $\bar{L}$  个码符号, 码符号的利用效率如何? )

设对信源 $S$ 进行编码所得到的平均 码长 $\bar{L}$ , 因为 $\bar{L}$ 一定是大于或等于 $H_r(S)$ , 所以定义编码的效率  $\eta$ 为平均码长 $\bar{L}$ 与极限值之比, 一般对于有记忆信源, 有

$$\eta = \frac{\frac{H_\infty}{\log r}}{\bar{L}} = \frac{H_\infty}{\bar{L} \log r} \quad (5.85)$$

对于无记忆信源则有

$$\eta = \frac{H_r(S)}{\bar{L}} = \frac{H(S)}{\bar{L} \log r} \quad (5.86) \quad \text{其中} \quad \bar{L} = \frac{\bar{L}_N}{N}$$

$\eta$ 一定是小于或等于1的数。对同一信源来说, 若码的平均码长 $\bar{L}$ 越短, 越接近极限值 $H_r(S)$ , 信道的信息传输率就越高, 就越接近无噪无损信道容量, 这是 $\eta$ 也越接近于1, 所以可用码的效率 $\eta$ 来衡量各种编码的优势。

另外，为了衡量各种编码与最佳码的差距，定义码的

码的冗余度为：
$$1 - \eta = 1 - \frac{H_r(S)}{\bar{L}} \quad (5.87)$$

在二元无噪无损信道中 $r = 2$ ，所以 $H_r(s) = H(s)$ ，式(5.86)为

$$\eta = \frac{H(S)}{\bar{L}}$$

所以在二元无噪无损信道中，信道的信息传输率

$$R = \frac{H(S)}{\bar{L}} = \eta$$

为此，在二元信道中直接用码的效率来衡量编码后信道的信息传输率是否提高了。当 $\eta = 1$ 时，即 $R = 1$ 比特/码符号，达到了二元无噪无损信道的信道容量，此时编码效率最高，码的冗余度为0。

例5.3 有一离散无记忆信源

$$\begin{bmatrix} S \\ P(s) \end{bmatrix} = \begin{bmatrix} s_1, & s_2 \\ p_1 = 3/4, & p_2 = 1/4 \end{bmatrix}$$

其熵为？  $H(S) = \frac{1}{4} \log 4 + \frac{3}{4} \log \frac{4}{3} = 0.811$  (比特 / 信源符号)

现在我们用二元符号 ( 0,1 ) 来构造一个即时码

$$s_1 \rightarrow 0, \quad s_2 \rightarrow 1$$

这时平均码长  $\bar{L} = 1$  (二元码符号 / 信源符号)

$$\text{编码的效率为 } \eta = \frac{H(S)}{\bar{L}} = 0.811$$

信道信息传输率为  $R = 0.811$  比特 / 二元码符号。

- ❖ 为了提高传输效率,根据第一定理的概念,我们可以对无记忆信源 $S$ 的二次扩展信源 $S^2$ 进行编码.

| $a_i$    | $P(a_i)$ | 即时码 |
|----------|----------|-----|
| $s_1s_1$ | 9/16     | 0   |
| $s_1s_2$ | 3/16     | 10  |
| $s_2s_1$ | 3/16     | 110 |
| $s_2s_2$ | 1/16     | 111 |

这个码的平均长度 $\bar{L}_2 = \frac{27}{16}$ (二元码符号/两个信源符号)

得信源 $S$ 中每一单个符号的平均码长

$$\bar{L} = \frac{\bar{L}_2}{2} = \frac{27}{32} \text{ (二元码符号/信源符号)}$$

其编码效率  $\eta_2 = \frac{32 \times 0.811}{27} = 0.961$  得  $R_2 = 0.961$ (比特/二元码符号)

- ❖ 可见编码复杂了一些,但信息传输率有了提高.
- ❖ 用同样的方法可进一步对信源 $S$ 的三次和四次扩展信源进行编码,并求出其编码效率为:  $\eta_3 = 0.985$        $\eta_4 = 0.991$
- ❖ 这时,信道的传输率为:  $R_3 = 0.985$ (比特/二元码符号)  
 $R_4 = 0.991$ (比特/二元码符号)
- ❖ 对于这个信源,要求编码效率达到96%时,变长码只需2次扩展,而等长码则要求 $N$ 大于 $4.13 \times 10^7$



❖ 很明显,用变长码编码时, $N$ 不需要很大就可以达到相当高的编码效率,而且实现无失真地编码.随着扩展信源次数的增加,编码的效率越来越接近于1,编码后信道的信息传输率 $R$ 也越来越接近于无噪无损二元对称信道的信道容量 $C=1$ 比特/二元码符号,达到信源与信道的匹配,使信道得到充分利用.所以变长码在实际应用中更具有价值.

❖ 无失真信源编码(即香农第一定理)指出了信源无损压缩与信源信息熵的关系.它指出了信息熵是无损压缩编码所需平均码长的极限值,也指出了可以通过编码使平均码长达到极限值.所以这是一个很重要的定理.