

# 多元统计分析 小组实验报告

- 题目：中国各省市居民消费结构的多维分析与区域类型划分
- 班级：信计 2302 班
- 成员：路荣兵（1131230216）、林鑫（1043220122）、王州业（1131230218）、张珥珂（1131230215）、杨万仁（1131230217）
- 日期:2025 年 10 月

# 中国各省市城镇居民消费水平与结构的多维评价与分析（2023 年）

## 一、研究背景

### 1.1 研究目的

本研究旨在分析中国各省市（自治区、直辖市）2023 年城镇居民的消费特征。我们关注消费的“水平”（绝对支出金额）和“结构”（各项支出之间的相对关系）。为避免“总支出”变量对结构分析的干扰，本研究仅使用 **8 个核心消费分项**（食品烟酒、衣着、居住、生活用品及服务、交通通信、教育文化娱乐、医疗保健、其他用品及服务）的绝对金额进行分析。

我们将使用多元统计分析方法，包括降维分析（主成分分析 PCA、因子分析 FA）、聚类分析（K-Means）和判别分析（LDA），对各地区的消费模式进行分类和解读。

## 二、数据预处理与可视化

### 2.1 描述性统计

各项消费支出的均值与方差

| 统计量              | 食品烟酒<br>(Food) | 衣着<br>(Cloth) | 居住<br>(Housing) | 生活用品及<br>服务 (Life) | 交通通信<br>(Trans) | 教育文化娱乐<br>(Edu) | 医疗保健<br>(Health) | 其他用品及服务<br>(Other) |
|------------------|----------------|---------------|-----------------|--------------------|-----------------|-----------------|------------------|--------------------|
| 均值<br>(Mean)     | 9129.52        | 1880.29       | 7364.42         | 1818.00            | 4288.48         | 3359.74         | 2873.32          | 929.32             |
| 方差<br>(Variance) | 3249958.20     | 136100.50     | 14367155.20     | 146976.10          | 1023401.30      | 648027.10       | 482298.20        | 114808.80          |

图 2D: 全国及各地区平均消费支出结构



## 2.2 归一化 (Z-score 标准化)

**目的：** 8 个分项支出变量在数值尺度（量纲）上存在差异。为防止尺度较大的变量在后续分析中主导结果，必须对所有 8 个数值变量进行 Z-score 标准化（归一化），使其均值为 0，标准差为 1。

**结果：** 数据标准化完成，以下为标准化后的数据预览：

表 2：归一化 (Z-score) 后的数据预览 (前 6 行, 8 变量)

| 食品烟酒    | 衣着      | 居住      | 生活用品及服务 | 交通通信    | 教育文化娱乐  | 医疗保健    | 其他用品及服务 |
|---------|---------|---------|---------|---------|---------|---------|---------|
| 0.8068  | 0.8124  | 3.4024  | 1.6590  | 0.7745  | 0.9829  | 2.4993  | 1.9410  |
| 0.6959  | 0.1429  | 0.2761  | 0.6156  | 0.7389  | 0.9295  | 1.9175  | 1.5485  |
| -0.7624 | 0.1158  | -0.1972 | 0.0730  | -0.5906 | -0.8146 | -0.4828 | -0.2902 |
| -1.6161 | -0.3396 | -0.5402 | -0.6834 | -0.9415 | -0.4779 | -0.3460 | -0.5676 |
| -0.2344 | 1.4467  | -0.2959 | 0.1487  | 1.2401  | -0.1115 | 0.2818  | 0.5834  |
| -0.3326 | -0.2718 | -0.3621 | -0.7669 | -0.4186 | -0.2382 | 0.4589  | 0.3237  |

## 2.3 预处理可视化

**目的：** 通过图表直观展示归一化的必要性，并探索变量间的相关关系。

图 3A: 8项支出(原始金额)分布






图 3B: 8项支出(归一化后)分布



**结果 (图 3A, 3B):** 原始数据 (图 3A) 的箱线图显示各变量尺度存在巨大差异, 特别是“居住”远高于其他项。归一化处理后 (图 3B), 所有变量都被转换到相似的尺度上, 可以进行后续分析。

图 3C: 8项支出相关性热力图



结果 (图 3C): 相关性热力图（图 3C）显示，8 个支出变量之间普遍存在较强的正相关关系（颜色越蓝，相关性越强，数值越大），例如 Food 与 Trans(0.85)、Housing(0.81)高度相关。这证明了使用降维技术（PCA 和 FA）的合理性。

### 三、降维分析（PCA 与 FA）

#### 3.1 正态性检验

##### 单变量正态性检验结果（Shapiro-Wilk）

该表格显示了对 8 项消费支出原始金额数据进行的 Shapiro-Wilk 正态性检验结果。显著性水平  $\alpha = 0.05$ 。

原假设 (H0)：数据服从正态分布。

单变量正态性检验结果 (Shapiro-Wilk)

| 消费项目 (Variable) | P 值 (P-value) | 是否服从正态分布 (Normal?)<br>(p > 0.05) |
|-----------------|---------------|----------------------------------|
| 食品烟酒 (Food)     | 0.0476        | 否                                |
| 衣着 (Cloth)      | 0.0142        | 否                                |
| 居住 (Housing)    | 0.0000        | 否                                |
| 生活用品及服务 (Life)  | 0.1310        | 是                                |

单变量正态性检验结果 (Shapiro-Wilk)

| 消费项目 (Variable) | P 值 (P-value) | 是否服从正态分布 (Normal?)<br>(p > 0.05) |
|-----------------|---------------|----------------------------------|
| 交通通信 (Trans)    | 0.0016        | 否                                |
| 教育文化娱乐 (Edu)    | 0.1610        | 是                                |
| 医疗保健 (Health)   | 0.0118        | 否                                |
| 其他用品及服务 (Other) | 0.0003        | 否                                |

结果总结： 在  $\alpha = 0.05$  的显著性水平下，8 个消费支出变量中，仅有 “生活用品及服务” ( $p=0.131$ ) 和 “教育文化娱乐” ( $p=0.161$ ) 的 P 值大于 0.05，可以认为它们近似服从正态分布。其他 6 个变量（食品、衣着、居住、交通、医疗、其他）的 P 值均小于 0.05，我们拒绝原假设，认为它们不服从正态分布。

讨论： 由于大部分变量不服从正态分布，因此数据整体也不满足多元正态分布的假设。但这并不妨碍我们继续使用 PCA、因子分析和 K-Means 等探索性方法。在使用对正态性更敏感的方法（如 LDA）时，需要注意这一前提条件。数据的归一化（标准化）处理对于消除量纲影响仍然是必要的。

3.2 主成分分析 (PCA)

目的： 将 8 个相关的消费变量浓缩为少数几个不相关的主成分。

结果 (贡献率):

表 3: PCA 贡献率总结 (8 变量)

|                        | 综合消费水平 | 结构(衣着/生活 vs 医疗) | 主成分 3  | 主成分 4  | 主成分 5  | 主成分 6  | 主成分 7  | 主成分 8  |
|------------------------|--------|-----------------|--------|--------|--------|--------|--------|--------|
| Standard deviation     | 2.2682 | 1.0563          | 0.8800 | 0.6589 | 0.5201 | 0.3752 | 0.2814 | 0.2009 |
| Proportion of Variance | 0.6431 | 0.1395          | 0.0968 | 0.0543 | 0.0338 | 0.0176 | 0.0099 | 0.0050 |
| Cumulative Proportion  | 0.6431 | 0.7826          | 0.8794 | 0.9337 | 0.9675 | 0.9851 | 0.9950 | 1.0000 |

结果 (载荷):

表 4: PCA 载荷 (Rotation) (8 变量)

|  | 综合消费水平 | 结构(衣着/生活 vs 医疗) | 主成分 3 | 主成分 4 | 主成分 5 | 主成分 6 | 主成分 7 | 主成分 8 |
|--|--------|-----------------|-------|-------|-------|-------|-------|-------|
|--|--------|-----------------|-------|-------|-------|-------|-------|-------|

表 4：PCA 载荷 (Rotation) (8 变量)

|         | 综合<br>消费<br>水平 | 结构(衣着/生活 vs<br>医疗) | 主成分<br>3 | 主成分<br>4 | 主成分<br>5 | 主成分<br>6 | 主成分<br>7 | 主成分<br>8 |
|---------|----------------|--------------------|----------|----------|----------|----------|----------|----------|
| 食品烟酒    | -0.355         | 0.031              | -0.534   | 0.399    | -0.226   | 0.552    | -0.113   | -0.245   |
| 衣着      | -0.241         | -0.722             | 0.352    | 0.048    | 0.104    | 0.172    | 0.390    | -0.320   |
| 居住      | -0.377         | 0.252              | 0.000    | 0.545    | 0.174    | -0.613   | 0.239    | -0.184   |
| 生活用品及服务 | -0.381         | -0.350             | -0.137   | -0.016   | 0.513    | -0.102   | -0.570   | 0.340    |
| 交通通信    | -0.381         | -0.122             | -0.167   | -0.519   | -0.508   | -0.402   | -0.180   | -0.301   |
| 教育文化娱乐  | -0.357         | 0.326              | -0.223   | -0.508   | 0.427    | 0.197    | 0.484    | 0.046    |
| 医疗保健    | -0.296         | 0.413              | 0.653    | -0.050   | 0.062    | 0.268    | -0.383   | -0.301   |
| 其他用品及服务 | -0.410         | 0.020              | 0.260    | 0.100    | -0.448   | 0.088    | 0.201    | 0.711    |

结果分析：

1. **贡献率：** 主成分 1（综合消费水平）解释了总方差的 **64.31%**。主成分 1 和 主成分 2 累计解释了 **78.26%** 的方差。
2. **主成分 1 含义：** 观察载荷（表 4），所有 8 个变量在 主成分 1 上的系数（载荷）均为**负数**。这确认 主成分 1 是一个“**综合消费水平指数**”。得分越低（负得越多），代表综合消费水平越高。
3. **主成分 2 含义：** 主成分 2 与 医疗保健 (0.413) 和 教育文化娱乐 (0.326) 呈正相关，而与 衣着 (-0.722) 和 Life (-0.350) 呈负相关。这表明 主成分 2 是一个新的“**消费结构轴**”，反映了“健康与教育”支出与“衣着与生活用品”支出之间的权衡。

3.3 因子分析 (FA)

**目的：** 寻找驱动这 8 个变量间相关性的潜在“因子”。

**结果 (因子数量)：** 根据 Kaiser 准则（特征值 > 1），PCA 结果（表 3）显示有 2 个成分的标准差大于 1（主成分 1=2.2682, 主成分 2=1.0563），因此建议因子数量为 **2**。

**结果 (因子载荷)：**

表 5：因子分析载荷 (Varimax 旋转后, 8 变量)

|      | Factor1 | Factor2 |
|------|---------|---------|
| 食品烟酒 | 0.773   | 0.218   |
| 衣着   |         | 0.993   |
| 居住   | 0.838   | 0.202   |

表 5：因子分析载荷 (Varimax 旋转后, 8 变量)

|         | Factor1 | Factor2 |
|---------|---------|---------|
| 生活用品及服务 | 0.612   | 0.654   |
| 交通通信    | 0.728   | 0.426   |
| 教育文化娱乐  | 0.857   |         |
| 医疗保健    | 0.646   | 0.154   |
| 其他用品及服务 | 0.772   | 0.484   |

表 5a：因子分析方差解释 (8 变量)

|                | Factor1 | Factor2 |
|----------------|---------|---------|
| SS loadings    | 3.961   | 1.947   |
| Proportion Var | 0.495   | 0.243   |
| Cumulative Var | 0.495   | 0.738   |

结果分析：

- 1. **因子 1 (Factor1) 含义：** 该因子在 居住 (0.838), 医疗保健 (0.857), 食品烟酒 (0.773), 交通通信 (0.728) 等多个基础和发展型支出上都有高载荷。这是一个“综合生活发展因子”。
- 2. **因子 2 (Factor2) 含义：** 该因子在 衣着 (0.993) 上有极高载荷，并在 生活用品及服务(0.654) 和 其他用品及服务 (0.484) 上有中高载荷。这是一个“衣着与生活品质因子”。
- 3. **总结：** 因子分析将 8 个变量归纳为“综合生活发展”和“衣着与生活品质”两个潜在驱动因素，这两个因素共同解释了 73.8%的方差。这与 PCA 的结果略有不同，提供了另一种理解变量结构的视角。

## 四、 聚类分析 (K-Means)


### 4.1 聚类数量选择

**目的：** 使用肘部法则确定最佳的聚类数量（K 值）。

**结果 (图 7A)：** 肘部法则图显示，K=3 是一个明显的“手肘”位置。



图 7A: 肘部法则 (Elbow Method)



4.2 聚类分配结果

目的： 基于 K=3，对 31 个地区进行 K-Means 聚类。

结果：

表 6: 各地区聚类分配结果

| Region | Cluster | Region | Cluster | Region | Cluster |
|--------|---------|--------|---------|--------|---------|
| 北京     | 3       | 江苏     | 1       | 广东     | 1       |
| 天津     | 1       | 浙江     | 3       | 广西     | 2       |
| 河北     | 2       | 安徽     | 2       | 海南     | 2       |
| 山西     | 2       | 福建     | 1       | 重庆     | 1       |
| 内蒙古    | 1       | 江西     | 2       | 四川     | 2       |
| 辽宁     | 2       | 山东     | 1       | 贵州     | 2       |
| 吉林     | 2       | 河南     | 2       | 云南     | 2       |
| 黑龙江    | 2       | 湖北     | 2       | 西藏     | 1       |
| 上海     | 3       | 湖南     | 1       | 陕西     | 2       |
|        |         |        |         | 甘肃     | 2       |
|        |         |        |         | 青海     | 2       |

表 6：各地区聚类分配结果

| Region | Cluster | Region | Cluster | Region | Cluster |
|--------|---------|--------|---------|--------|---------|
|        |         |        |         | 宁夏     | 2       |
|        |         |        |         | 新疆     | 2       |

结果分析：

- 聚类 1 (Cluster 1)： 天津, 内蒙古, 江苏, 福建, 山东, 湖南, 广东, 重庆, 西藏 (9 个地区)。
- 聚类 2 (Cluster 2)： 河北, 山西, 辽宁, 吉林等 19 个地区。
- 聚类 3 (Cluster 3)： 北京, 上海, 浙江 (3 个地区)。

五、 聚类结果分析与检验

5.1 聚类画像（雷达图）

目的： 绘制 3 个新聚类在 8 项原始消费支出（绝对金额）上的平均画像。

结果 (图 8A)：



结果分析： 雷达图（图 8A）显示了城镇居民三个聚类的层次和结构差异：


- 聚类 3 (绿色)： 北京、上海、浙江。在所有维度上的支出均最高，代表“高水平-高发展”消费区（居住、教育、医疗突出）。

- **聚类 1 (黑色):** 天津、江苏等。整体支出水平居中，各项支出相对均衡，代表“**中高水平-均衡**”消费区。
- **聚类 2 (红色):** 河北、山西等。整体支出水平最低，代表“**中低水平-基础**”消费区。

5.2 聚类可视化 (PCA 图)

目的： 将新的聚类结果绘制在 PCA 二维空间中。

结果 (图 9A):



结果分析:

- X 轴 (主成分 1) 代表“综合消费水平”（负向为高）。
- **聚类 3 (绿色/京沪浙):** 位于 X 轴的最左端（PC1 得分低），消费水平最高。
- **聚类 1 (黑色/津苏等):** 位于 X 轴的中间，消费水平中高。
- **聚类 2 (红色/冀晋等):** 位于 X 轴的右侧（PC1 得分高），消费水平中低。

该图清晰地展示了基于城镇居民数据的 3 个聚类在主成分空间中的区分度。

5.3 聚类效果检验 (ANOVA)

目的： 使用 ANOVA 检验 3 个聚类在 Food（食品支出）上的均值差异是否显著。

结果 (表 7):

表 7: ANOVA 检验结果 (Food ~ Cluster, 8 变量, 城镇)

|           | Df | Sum Sq   | Mean Sq  | F value | Pr(>F)   |
|-----------|----|----------|----------|---------|----------|
| Cluster   | 2  | 57903174 | 28951587 | 20.47   | 3.32e-06 |
| Residuals | 28 | 39595572 | 1414128  |         |          |

**结果分析：** 检验的 p-value (Pr(>F)) 为 **3.32e-06**，远小于 0.05 。  
**结论：** 基于城镇居民数据划分的 3 个聚类在“食品支出”上存在高度统计显著的差异。这证明了聚类的有效性。

5.4 关键指标判别 (LDA)

**目的：** 找出区分这 3 个新聚类的最强分项支出指标。

在本研究中，我们使用费希尔判别法来识别哪些消费支出变量（食品、衣着等 8 个）对于区分我们通过聚类分析得到的 3 个消费模式（Cluster 1, 2, 3）贡献最大。判别函数的系数（Loadings / Coefficients）直接反映了各个原始变量在构建这些“最佳区分轴”时的权重和方向。

通过最大化“组间平方和”与“组内平方和”的比值，费希尔判别法可以找到最佳的投影方向。第一个判别函数（LD1）是使得该比值最大的方向，第二个判别函数（LD2）是在与 LD1 正交（不相关）的方向中使得剩余比值最大的方向。

**结果 (表 8)：**

表 8: LDA 判别函数系数 (8 变量, 城镇)

|         | LD1     | LD2     |
|---------|---------|---------|
| Food    | -0.2495 | -1.0655 |
| Cloth   | -0.9086 | -0.4379 |
| Housing | -1.8402 | 1.1296  |
| Life    | -0.6424 | -0.7043 |
| Trans   | -0.4592 | -0.2572 |
| Edu     | -0.5371 | 0.1704  |
| Health  | -0.0450 | -0.3053 |
| Other   | 0.2839  | 1.1424  |

**结果分析：** 我们重点关注 LD1（第一判别函数）：

- 系数绝对值最大的变量是 Housing **(-1.84)**。
- 其次是 Cloth **(-0.91)**。

**结论：** 对于城镇居民数据，区分不同消费模式（高/中/低）的最关键分项指标是“居住”和“衣着”支出。这之前基于全体居民数据的结论（“其他”和“食品”最关键）不同，突显了不同层次城镇消费结构的差异。

## 六、 结论

本研究通过对中国 31 个省市（含全国）2023 年城镇居民的 8 项人均消费分项支出（绝对金额）进行多元统计分析，得出以下结论：

- 1. **降维分析：** 8 项支出指标存在较强相关性（图 3C）。主成分分析（PCA）和因子分析（FA）均表明，这些指标可被归纳为两个核心维度：
  - “综合/基本消费水平与发展”（PCA 的 PC1，FA 的 Factor1，由居住、教育、食品等驱动）。
  - “消费结构（衣着/生活品质）”（PCA 的 PC2，FA 的 Factor2，由衣着、生活用品等驱动）。

主成分 1 解释了 64.3%的方差，前两个主成分累计解释 78.3%。两个因子累计解释 73.8%的方差。

- 2. **聚类分析：** K-Means 聚类（K=3，图 7A）将 31 个地区划分为三个消费模式（表 6, 图 8A, 图 9A）：
  - 集群 3 (高水平-高发展)：** 北京、上海、浙江。消费水平最高，尤其在居住、教育、医疗方面突出。
  - 集群 1 (中高水平-均衡/偏服务)：** 天津、江苏、广东等 9 个地区。整体水平居中，各项支出相对均衡，服务类（如交通、其他）相对较高。
  - 集群 2 (中低水平-基础)：** 河北、山西及其他 19 个地区。整体消费水平最低。
- 3. **统计验证：** ANOVA 检验（表 7）显示，这三个聚类在“食品支出”上的差异具有高度统计显著性（ $p < 0.001$ ），证明了聚类的有效性。
- 4. **关键指标：** 判别分析（表 8）显示，在区分这三个集群时，第一判别函数（LD1）中系数绝对值最大的变量是“居住”（-1.84）和“衣着”（-0.91）。这表明，对于城镇居民，“居住”和“衣着”支出水平是划分不同消费模式的最关键因素。第二判别函数（LD2）则主要由“其他”（1.14）、“居住”（1.13）和“交通”/“教育”（负向）定义，反映了居住/其他与交通/教育之间的结构权衡。

## 附录（R 代码）：

```
library(MASS) # 用于判别分析 lda()
library(stats) # 用于 prcomp(), kmeans(), aov(), scale(), factanal()
library(graphics) # 用于 plot(), boxplot()
library(fmsb) # 用于雷达图
library(corrplot) # 用于绘制相关性热力图
library(readxl) # 新增：用于读取 Excel 文件

# -----
# 步骤 1：数据导入 (已修改为读取 XLSX)
# -----
# 定义 Excel 文件路径
excel_file_path <- "C:\\study\\多元统计分析\\小组报告\\小组报告\\data.xlsx" # 请确保路径和文件名正确

# 使用 read_excel 读取第一个工作表
data_raw <- read_excel(excel_file_path,
  sheet = 1,
  col_names = TRUE,
  .name_repair = "minimal")

# 将读入的数据转换为标准数据框
data_raw <- as.data.frame(data_raw)
```

```

# --- (调试信息, 可选) ---
# cat("\n--- 调试信息: 检查 data_raw (来自 Excel) ---\n")
# cat("实际读入的列数:", ncol(data_raw), "\n")
# cat("实际读入的列名:\n")
# print(colnames(data_raw))
# cat("实际读入的数据预览 (前 3 行):\n")
# print(head(data_raw, 3))
# cat("--- 调试结束 ---\n\n")
# --- (调试结束) ---

# 选择 地区(第 1 列) 和 8 项分项支出金额(第 3 列到第 10 列)
# *** (确保跳过第 2 列 "消费支出") ***
expected_cols <- c(1, 3:10)
if(max(expected_cols) <= ncol(data_raw)) {
  # 注意: 这里我们包含了全国行, 所以是 data_raw 而不是去除全国行的数据
  # 如果您的 data.xlsx 第一行不是全国, 请调整
  # 如果想去除全国行进行分析, 可以在这里过滤: data_raw <- data_raw[-1, ]
  data <- data_raw[, expected_cols]

  # 为这 9 列数据框重命名 (Region + 8 个分项)
  new_names <- c("Region", "Food", "Cloth", "Housing", "Life",
    "Trans", "Edu", "Health", "Other")
  # 确保列数匹配才重命名
  if(ncol(data) == length(new_names)) {
    colnames(data) <- new_names
    cat("--- 1. 数据导入成功 (已选择 1 个地区 + 8 个分项支出) ---\n")
    print(head(data))
  } else {
    stop("错误: 选择后的列数与预期名称数量不匹配! 请检查 Excel 文件结构或列选择。")
  }
} else {
  stop(paste("错误: 尝试选择的列 (最大索引:", max(expected_cols), ") 超出了实际读入的列数 (", ncol(data_raw), ")。请检查 Excel 文件。"))
}

# -----
# 步骤 2: 数据预处理 (添加了均值和方差计算及均值雷达图)
# -----

# (1) 提取用于分析的变量 (8 项绝对支出)
# *** 注意: 如果后续分析不想包含 "全国" 行, 需要在此过滤 ***
# data_numeric_all <- data[, -1] # 包含全国行
# data_numeric <- data[-1, -1] # 不包含全国行 (用于 PCA 等分析)
# region_labels <- data$Region[-1] # 不包含全国的地区标签

# 为了保持代码简洁, 我们假设后续分析也包含全国行
# 如果不希望包含, 请取消上面三行的注释, 并注释掉下面三行
data_numeric_all <- data[, -1] # 包含全国行的数据
data_numeric <- data_numeric_all # 假设分析也用包含全国的数据
region_labels <- data$Region # 包含全国的地区标签

# (2) 计算并输出均值和方差 (基于所有行, 含全国)
cat("\n--- 2A. 各项支出的均值 (Mean, 含全国) ---\n")
means <- colMeans(data_numeric_all) # 使用包含全国的数据计算均值
print(means)

cat("\n--- 2B. 各项支出的方差 (Variance, 含全国) ---\n")
variances <- apply(data_numeric_all, 2, var) # 使用包含全国的数据计算方差
print(variances)

# *** 新增: 绘制平均值雷达图 ***

```

```

cat("\n--- 2C. 正在生成：平均消费支出雷达图 ---\n")
# 准备雷达图数据
means_df <- as.data.frame(t(means)) # 将均值向量转为数据框的一行
# 定义坐标轴最大/最小值 (可以基于均值动态调整，或固定)
# 这里使用动态调整，取各项均值最大值的 1.2 倍
radar_max_mean <- rep(max(means) * 1.2, 8)
radar_min_mean <- rep(0, 8)
data_radar_mean <- rbind(radar_max_mean, radar_min_mean, means_df)
# 创建中文标签
chinese_axis_labels_short <- c("食品", "衣着", "居住", "生活",
                                "交通", "教育", "医疗", "其他")
# 绘制雷达图
par(mar=c(1,1,1,1)) # 调整边距
radarchart(data_radar_mean,
            axistype = 1, pcol = "blue", pfcpl = rgb(0,0,1,0.3), plwd = 2,
            cglcol="grey", cglty=1, axislabcol="grey", cglwd=0.8,
            vlcex=0.8, title = "图 2D: 全国及各地区平均消费支出结构",
            vlabels = chinese_axis_labels_short)
par(mar = c(5.1, 4.1, 4.1, 2.1)) # 恢复默认边距
*** 新增结束 ***

```

```

# (4) 归一化 (Z-score 标准化) - 基于用于后续分析的数据 (data_numeric)
# 必须进行 Z-score 标准化 (归一化)，以消除量纲影响。
data_scaled <- scale(data_numeric) # 对用于分析的数据进行标准化

```

```

cat("\n--- 2D. 归一化 (Z-score) 后的数据 (前 5 行) ---\n") # 重新编号为 2D
print(head(data_scaled))

```

```

# -----
# 步骤 3：数据预处理的可视化 (无需修改)
# -----

```

```

# (1) 图表 3A：原始数据箱线图 (展示量纲差异)
cat("\n--- 3A. 正在生成：原始数据箱线图 (展示量纲差异) ---\n")
par(mar = c(6, 4, 4, 2)) # 调整边距以容纳中文标签
boxplot(data_numeric, # 使用用于分析的数据绘制
        main = "图 3A: 8 项支出 (原始金额) 分布",
        names = chinese_axis_labels_short,
        col = "red",
        las = 2, # 旋转标签
        cex.axis = 0.7)

```

```

# (2) 图表 3B：归一化后的数据箱线图 (确认预处理效果)
cat("\n--- 3B. 正在生成：归一化数据箱线图 (确认处理效果) ---\n")
boxplot(data_scaled, # 使用标准化后的数据绘制
        main = "图 3B: 8 项支出 (归一化后) 分布",
        names = chinese_axis_labels_short,
        col = "lightgreen",
        las = 2, # 旋转标签
        cex.axis = 0.7)
par(mar = c(5.1, 4.1, 4.1, 2.1)) # 恢复默认边距

```

```

# (3) 图表 3C：相关性热力图 (探索变量关系)
cat("\n--- 3C. 正在生成：相关性热力图 ---\n")
# 计算相关性矩阵
cor_matrix <- cor(data_numeric) # 使用用于分析的数据计算
# 绘制热力图
corrplot(cor_matrix,
        method = "color", # 使用颜色
        type = "upper", # 只显示上三角
        order = "hclust", # 按聚类顺序排序
        addCoef.col = "black", # 添加相关系数
        tl.col = "black", tl.srt = 45, # 旋转标签

```

```

main = "图3C: 8 项支出相关性热力图",
mar = c(0, 0, 1, 0)) # 调整标题边距

# -----
# 步骤4: 正态性讨论与统计检验 (无需修改)
# -----
cat("\n--- 4. 正态性检验 (Shapiro-Wilk Test) ---\n")
# 以 "Food" 变量为例
shapiro_test_result <- shapiro.test(data_numeric$Food)
print(shapiro_test_result)

# -----
# 步骤5: 降维分析 (主成分分析 - PCA) (无需修改)
# -----
cat("\n--- 5. 主成分分析 (PCA) 结果 ---\n")
# 我们对标准化后的8个绝对值变量进行PCA
pca_result <- prcomp(data_scaled) # 使用标准化后的数据

# (1) 查看方差解释率
cat("\n--- PCA 贡献率总结 ---\n")
summary_pca <- summary(pca_result)
print(summary_pca)

# (2) 查看主成分载荷 (Loadings)
cat("\n--- PCA 载荷 (Loadings / Rotation) ---\n")
print(pca_result$rotation)

# -----
# 步骤6: 降维分析 (因子分析 - FA) (无需修改)
# -----
cat("\n--- 6. 因子分析 (FA) 结果 ---\n")

# (1) 决定因子数量
eigenvalues <- pca_result$sdev^2
n_factors <- sum(eigenvalues > 1)
cat(paste("\n--- 根据 Kaiser 准则 (特征值>1), 建议的因子数量为:", n_factors, "---\n"))

# (2) 执行因子分析
if (n_factors >= 1) {
  fa_result <- factanal(data_scaled, # 使用标准化后的数据
    factors = n_factors,
    rotation = "varimax")

  # (3) 查看因子载荷 (Loadings)
  cat("\n--- 因子分析 载荷 (Loadings) ---\n")
  print(fa_result$loadings)
} else {
  cat("\n--- 因子分析失败: 没有特征值 > 1 的因子 ---\n")
}

# -----
# 步骤7: 聚类分析 (K-Means) (无需修改)
# -----
cat("\n--- 7. 聚类分析 (K-Means) ---\n")

# (1) 决定 K 值 (肘部法则)
cat("\n--- 正在生成 K 值选择的 '肘部法则' 图 ---\n")
set.seed(123)
wss <- (nrow(data_scaled)-1) * sum(apply(data_scaled, 2, var))
for (i in 2:10) wss[i] <- sum(kmeans(data_scaled, centers=i, nstart=25)$withinss)
plot(1:10, wss, type="b",
  xlab="聚类数量 (K)",
  ylab="组内平方和 (WSS)",
  main="图7A: 肘部法则 (Elbow Method)")

```



```

# (2) 执行K-Means (根据肘部法则, 选择K=3)
k_best <- 3
set.seed(123)
kmeans_result <- kmeans(data_scaled, centers = k_best, nstart = 25) # 使用标准化后的数据

# (3) 将聚类结果添加回原数据
# *** 注意: 这里的data 可能包含或不包含全国行, 取决于步骤2 的选择 ***
data$Cluster <- as.factor(kmeans_result$cluster)

cat(paste("\n--- 聚类分析完毕 (K=", k_best, ") ---\n"))
cat(" 各地区的聚类分配结果:\n")
# 确保打印时包含地区标签
if (nrow(data) == length(region_labels)){
  print(data.frame(region = region_labels, Cluster = data$Cluster))
} else {
  print(" 聚类结果与地区标签数量不匹配, 请检查步骤2 的过滤设置。")
  print(data$Cluster) # 仅打印聚类结果
}

# -----
# 步骤8: 可视化图表 (雷达图) (无需修改)
# -----
cat("\n--- 8. 正在生成: 雷达图 (对比聚类平均画像) ---\n")

# A. 计算每个聚类 (Cluster 1, 2, 3) 的8 项指标的平均值
cluster_means_raw <- aggregate(data_numeric, # 使用原始数值计算均值
                                by = list(Cluster = data$Cluster),
                                FUN = mean)
cluster_data <- cluster_means_raw[, -1]

# B. 准备雷达图数据 (定义最大/最小值)
max_val <- max(cluster_data) * 1.2
data_radar_max <- rep(max_val, 8) # 8 个变量
data_radar_min <- rep(0, 8)      # 8 个变量
data_radar <- rbind(data_radar_max, data_radar_min, cluster_data)

# C. 绘制雷达图
par(mar = c(1, 1, 1, 1))
colors_border = c(rgb(0,0,0,0.9), rgb(1,0,0,0.9), rgb(0,0.8,0,0.9))
colors_fill = c(rgb(0,0,0,0.3), rgb(1,0,0,0.3), rgb(0,0.8,0,0.3))

radarchart(data_radar,
            axistype = 1,
            pcol = colors_border, pfcpl = colors_fill, plwd = 2, plty = 1,
            cglcol = "grey", cglty = 1, axislabcol = "grey", cglwd = 0.8,
            vlcex = 0.8, vlabels = chinese_axis_labels_short) # 使用8 个中文标签

# 添加图例
legend(x = 0.8, y = 1.3,
       legend = cluster_means_raw$Cluster,
       bty = "n", fill = colors_fill, cex = 1.2)
par(mar = c(5.1, 4.1, 4.1, 2.1)) # 恢复默认边距

# -----
# 步骤9: 聚类结果的可视化 (PCA 图) (无需修改)
# -----
cat("\n--- 9. 聚类结果可视化 (PCA 1 vs PCA 2) ---\n")

# 获取PC1 和PC2 的得分
pc_scores <- pca_result$x[, 1:2]

# 确定x 轴和y 轴的范围
x_range <- range(pc_scores[, 1]) * 1.1
y_range <- range(pc_scores[, 2]) * 1.1

```

```

plot(pc_scores[, 1], pc_scores[, 2],
     col = data$Cluster,
     pch = 19, cex = 1.5,
     main = "图 9A: 聚类分析结果 (基于 PCA 主成分)",
     xlab = "主成分 1 (PC1: 综合消费水平)",
     ylab = "主成分 2 (PC2: 消费结构)",
     xlim = x_range,
     ylim = y_range
)

# 添加地区标签
text(pc_scores[, 1], pc_scores[, 2],
     labels = region_labels,
     pos = 3,
     cex = 0.7)

# 添加图例
legend("bottomright",
      legend = levels(data$Cluster),
      fill = 1:k_best,
      title = "Cluster",
      cex = 0.8)

# -----
# 步骤 10: 检验聚类效果 (ANOVA) (无需修改)
# -----
cat("\n--- 10. 统计检验 (ANOVA) ---\n")
# 检验: 我们分出的 3 个聚类, 在 "食品"(Food) 上是否真的存在显著差异?
anova_result <- aov(Food ~ Cluster, data = data) # 使用包含聚类标签的 data
summary_anova <- summary(anova_result)
print(summary_anova)

# -----
# 步骤 11: 判别分析 (LDA) (无需修改)
# -----
cat("\n--- 11. 判别分析 (LDA) ---\n")
# 目的: 哪些【分项支出】是区分这 3 个聚类的最关键因素?
lda_result <- lda(data$Cluster ~ ., data = as.data.frame(data_scaled)) # 使用标准化数据和聚类标签
cat("\n--- 判别函数系数 (Coefficients of linear discriminants) ---\n")
print(lda_result$scaling)

# -----
# 步骤 12: 整理报告 (无需修改)
# -----
cat("\n--- 12. 最终分析报告表 ---\n")
# 将 PCA 得分和聚类结果合并到原始数据
data$PCA_Score_PC1 <- pca_result$x[, 1]
# 按聚类排序
data_final_report <- data[order(data$Cluster), ]
# 打印最终报告 (不含 Total 列)
print(data_final_report)

cat("\n--- 所有分析步骤已完成 --- \n")

```