

第二章多元正态分布的参数估计

September 23, 2025

Outline

概率论基础回顾

单参数和多参数的最大似然估计

引言

基本概念

多元分布

随机向量的数字特征

多元正态分布

多元正态分布的参数估计

随机试验

随机试验

- ▶ 古典概率：随机性事件，如掷骰子
- ▶ 现代数学基础：集合论，
- ▶ 概率论：随机性事件→随机性变量
- ▶ 随机试验
 1. 可重复性：可以在同一条件下多次进行
 2. （结果的）可限定性：确定的结果范围
 3. （结果的）随机性

样本空间 Ω

样本空间 Ω

- ▶ 随机试验中所有可能结果的集合称为样本空间 Ω
- ▶ Borel事件域 $\mathcal{F}$, Ω 中若干元素的集合,
 - (a) $\Omega \in \mathcal{F}$
 - (b) 若 $A \in \mathcal{F}$, $\bar{A} = \Omega - A$, 则 $\bar{A} \in \mathcal{F}$
 - (c) 若 $A_i \in \mathcal{F}, i = 1, 2, \dots, n$, 则 $\bigcup_{i=1}^n A_i \in \mathcal{F}$

$\mathcal{F}$: 保证在 Ω 中讨论是有意义的。

概率空间 $(\Omega, \mathcal{F}, P)$

概率空间 $(\Omega, \mathcal{F}, P)$: 设 $X(\omega)$ 是 Ω 中的一个函数, $\omega \in \mathcal{F}$, ω 表示的是随机事件, $X(\omega) = x \in \mathbb{R}$, 若满足以下性质, 则 $(\Omega, \mathcal{F}, P)$ 称为概率空间。

1. 非负性: $P(X) \geq 0$

2. 完备性: $P(\Omega) = 1$

3. 可列可加性: 若 $x_i \cap x_j = \emptyset$, 则 $P\left(\bigcup_{i=1}^n x_i\right) = \sum_{i=1}^n P(x_i)$

P 称为概率 (测度) 。

全概率公式

划分：设 ω 为试验 E 的样本空间， $B_1, B_2, \dots, B_n$ 为 E 的一组事件，若：

1. $B_i \cap B_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$
2. $B_1 \cup B_2 \cup \dots \cup B_n = \omega$

则称 $B_1, B_2, \dots, B_n$ 为样本空间 ω 的一个**划分**。

随机变量

- ▶ **随机变量**: 给定概率空间 $(\Omega, \mathcal{F}, P)$ 。设 $X = X(\omega)$ 是定义域为 Ω 的一个函数。如果对任意一个实数 x , Ω 的子集为:

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F}$$

称 $X(\omega)$ 为随机变量, 简写为 X 。

- ▶ 离散随机变量
- ▶ 连续随机变量

离散随机变量

离散随机变量: $X(\omega) = x \in \mathbb{R}$ 中离散数值的集合, 其概率分布一般采用概率分布表 (也可以成为分布律) 来描述。

$$\left(\begin{matrix} x_i \\ p(x_i) \end{matrix} \right)_{i=1}^{\infty}$$

通常把函数

$$p(x_i) = P(X = x_i), i = 1, 2, \dots, n, \dots$$

称为离散随机变量 X 的概率密度函数或概率分布 (严格上不一样), 具有以下性质:

► 非负性:

$$p(x_i) \geq 0, i = 1, 2, \dots, n, \dots$$

► 完备性:

$$\sum_{i=1}^{\infty} P(x_i) = 1, i = 1, 2, \dots, n, \dots$$

连续随机变量

如果对于随机变量 X 的分布函数 $F(x)$ ，存在非负函数 $f(x)$ ，使对于任意实数 x 有：

$$F(x) = \int_{-\infty}^x f(t)dt$$

则称 X 为连续随机变量，其中函数 $f(x)$ 称为 X 的概率密度函数，简称概率密度。

- (1) 非负性： $f(x) \geq 0$;
- (2) 规范性： $\int_{-\infty}^{+\infty} f(x)dx = 1$;
- (3) 对于任意实数($x_1 \leq x_2$)

$$P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx$$

- (4) 若 $f(x)$ 在点 x 处连续，则有 $F'(x) = f(x)$ 。

多维随机变量

0.3.4 多维随机变量

多维随机变量： $x_1, x_2, \dots, x_n \in \mathbb{R}$ 称为 n 维随机变量，概率分布函数 $F(x_1, x_2, \dots, x_n)$ ，概率密度函数 $f(x_1, x_2, \dots, x_n)$ 。

► 离散型多维随机变量：

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

► 连续型多维随机变量：

$$f(x_1, x_2, \dots, x_n) = \frac{\partial^n F(x_1, x_2, \dots, x_n)}{\partial x_1 \partial x_2 \dots \partial x_n} \geq 0$$

数学期望或均值 $E(X)$ EX m_x μ

- ▶ 离散型随机变量: $m_x = \sum_{x=-\infty}^{\infty} x_i p_i, \quad p_i = P(x = x_i)$
- ▶ 连续型随机变量: $m_x = \int_{-\infty}^{\infty} x f(x) dx$
- ▶ 性质:
 1. $E[c] = c$
 2. $E[kX] = kE[X]$
 3. $E[X \pm Y] = E[X] \pm E[Y]$
 4. 若 X 与 Y 独立, 则 $E[XY] = E[X]E[Y]$

方差与标准差

- ▶ 方差: $D[X] = E[(x - m_x)^2] = \int_{-\infty}^{\infty} (x - m_x)^2 f_X(x) dx$
或 $\sum_{i=-\infty}^{\infty} (x_i - m_x)^2 P_i$
- ▶ 标准差或根方差: $\sqrt{D(x)}$
- ▶ 性质:
 1. $D[c] = 0$
 2. $D[X] = E[X^2] - (m_x)^2$
 3. $D[X] \geq 0$
 4. 当 $D[kX] = k^2 D(X)$, k 为常数
 5. 当 X 与 Y 相互独立时, $D[X \pm Y] = D[X] \pm D[Y]$

协方差

协方差:

$$\begin{aligned}C(X, Y) &= E[(x - m_x)(y - m_y)] \\&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_x)(y - m_y) f_{XY}(x, y) dx dy\end{aligned}$$

性质:

1. $C(X, Y) = E(XY) - E(X)E(Y)$
2. $C(X, X) = D(X)$
3. $C(X, Y) = C(Y, X)$ (仅对实随机变量成立)
4. $C(X, c) = 0$ (c 为常数)
5. $C(aX, bY) = abC(X, Y)$
6. $C(X, Y \pm Z) = C(X, Y) \pm C(X, Z)$
7. 若 $C(X, Y) = 0$, 则称 X, Y 不相关, 常数与任何随机变量都不相关
8. 若 X, Y 独立, 则 $C(X, Y) = 0$

协方差

相关函数:

$$R(X, Y) = E[XY] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{XY}(x, y) dx dy$$

协方差和相关函数的关系:

$$R(X, Y) = C(X, Y) + m_x m_y$$

若 $R(X, Y) = 0$, 则称 X, Y 正交。

$$\begin{aligned} C(X, Y) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_x)(y - m_y) f_{XY}(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (xy - m_x y - m_y x + m_x m_y) f_{XY}(x, y) dx dy \\ &= R(X, Y) - m_x m_y - m_y m_x + m_x m_y \\ &= R(X, Y) - m_x m_y \end{aligned}$$

协方差

相关系数: 对协方差函数进行归一化

$$\rho(X, Y) = \frac{C(X, Y)}{\sqrt{D(X)D(Y)}}$$

1. $\rho(X, X) = 1$
2. $\rho(X, Y) = \rho(Y, X)$ (仅对实随机变量成立)
3. $\rho(X, Y) \leq 1 : |C(X, Y)| \leq \sqrt{D(X)D(Y)} \implies \rho(X, Y) \leq 1$
4. 若 X, Y 独立, $\rho(X, Y) = 0$ 。当 $\rho(X, Y) = 0$, 则称 X, Y 不相关。
5. $\rho(X, Y) = \pm 1$, 则称 X, Y 全相关。 $\rho(X, Y) = 1$, X, Y 正线性相关; $\rho(X, Y) = -1$, X, Y 负线性相关。

随机变量的矩

矩是数学期望、方差等数字特征的一般形式，对随机变量本身的幂（原点矩）或随机变量减均值后的幂（中心矩）求概率平均称为矩，总的幂次称为矩的阶数。

- ▶ 均值（？）；方差（？）；协方差（？）；相关函数（？）。
- ▶ 设 (X, Y) 为二维随机变量， $E(X^k Y^l)$ 为随机变量 X 和 Y 的 $k + l$ 阶混合原点矩； $E\{[X - E(X)]^k [Y - E(Y)]^l\}$ 为随机变量 X 和 Y 的 $k + l$ 阶混合中心矩。协方差（？）

随机变量的特征函数

随机变量 X 的特征函数:

$$\varphi_X(\lambda) = E[e^{i\lambda x}], -\infty < \lambda < +\infty$$

对于离散随机变量 X , 概率函数为 $P\{X = x_k\} = p_k, (k = 1, 2, \dots)$ 时, X 的特征函数为:

$$\varphi_X(\lambda) = \sum_k p_k e^{i\lambda x_k}$$

对于连续随机变量 X , 密度函数为 $f(x)$ 时, X 的特征函数为:

$$\varphi_X(\lambda) = \int_{-\infty}^{\infty} e^{i\lambda x} f(x) dx$$

特征函数与矩的关系

$$E[x^n] = \left. \frac{\partial^n \varphi_X(\lambda)}{i^n \partial \lambda^n} \right|_{\lambda=0}$$

$$\begin{aligned} \frac{\partial^n \varphi_X(\lambda)}{i^n \partial \lambda^n} &= \frac{\partial^n}{i^n \partial \lambda^n} E[e^{i\lambda x}] = \frac{1}{i^n} E \left[\frac{\partial^n e^{i\lambda x}}{\partial \lambda^n} \right] \\ &= \frac{1}{i^n} E \left[(ix)^n e^{i\lambda x} \right] = E \left[x^n e^{i\lambda x} \right] \end{aligned}$$

特征函数简化了求矩计算，从积分运算，变为求导运算。

中心极限定理

中心极限定理

- ▶ 独立同分布：对于 n 个独立的相同分布的随机变量 $x_1, x_2, \dots, x_n$, x_i 的均值均为 m , 方差为 σ^2 , 当 n 足够大时, $y = \sum_{i=1}^n x_i$ 的概率分布趋于正态分布 $\mathcal{N}(nm, n\sigma^2)$
- ▶ 独立不同分布：对于 n 个独立的不同分布（但具有相同均值和方差）的随机变量 $x_1, x_2, \dots, x_n$, x_i 的均值均为 m , 方差为 σ^2 , 当 n 足够大时, $y = \sum_{i=1}^n x_i$ 的概率分布趋于正态分布 $\mathcal{N}(?, ?)$
- ▶ 对于 n 个满足相同二项分布的随机变量（取1为 p , 取0为 $1 - p$ ）, $x_1, x_2, \dots, x_n$ 的均值为 $?$, 方差为 $?$, 当 n 足够大时, $y = \sum_{i=1}^n x_i$ 的概率分布趋于正态分布 $?$

一元离散型随机变量

θ 是待估参数，对于离散型随机事件 X ，当一次抽样得到观测值为 $(x_1, x_2, \dots, x_n)$ 时，得此观测值的概率为：

$$P\{X_1 = x_1, \dots, X_n = x_n\} = P\{X_1 = x_1\} \cdots P\{X_n = x_n\}$$

$$P(x_1; \theta)P(x_2; \theta) \cdots P(x_n; \theta) = \prod_{i=1}^n P(x_i; \theta) = L(\theta)$$

$L(\theta)$ 为待估参数 θ 的函数，称为似然函数。若 $L(\theta)$ 在 $\hat{\theta}$ 处达到最大值，则称 $\hat{\theta}$ 为参数 θ 的最大似然估计值。

一元连续型随机变量

θ 是待估参数，对于连续型随机事件 X ，密度函数为
为 $X \sim f(x; \theta)$ ，当一次抽样得到观测值为 $(x_1, x_2, \dots, x_n)$ 时，得
此观测值的概率为：

$$P\{X_1 = x_1, \dots, X_n = x_n\} = f\{X_1 = x_1\} \cdots f\{X_n = x_n\}$$

$$f(x_1; \theta)f(x_2; \theta) \cdots f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = L(\theta)$$

$L(\theta)$ 为待估参数 θ 的函数，称为似然函数。若 $L(\theta)$ 在 $\hat{\theta}$ 处达到最大值，则称 $\hat{\theta}$ 为参数 θ 的最大似然估计值。

单参数的最大似然估计

假设 $\hat{\theta}$ 是 $L(\theta)$ 的最大值点， $\hat{\theta}$ 一般满足条件：

$$\frac{dL(\theta)}{d\theta} = 0$$

从而满足条件：

$$\frac{d \ln L(\theta)}{d\theta} = \frac{1}{L(\theta)} \frac{dL(\theta)}{d\theta} = 0$$

求解似然方程，得到驻点 $\hat{\theta}$ ，并判定是否为最大值点。

单参数的最大似然估计

1. 写出似然函数

$$L(\theta) = \begin{cases} \prod_{i=1}^n P(x_i; \theta) & \text{离散型} \\ \prod_{i=1}^n f(x_i; \theta) & \text{连续型} \end{cases}$$

2. 写出似然方程组:

$$\frac{dL(\theta)}{d\theta} = 0$$

或:

$$\frac{d \ln L(\theta)}{d\theta} = \frac{1}{L(\theta)} \frac{dL(\theta)}{d\theta} = 0$$

3. 求解似然方程, 得到驻点, 并判定是否为最大值点。

单参数的最大似然估计

例10: (0-1分布), 设总体分布为:

$$P\{X = x\} = p^x(1 - p)^{1-x}$$

p 为待估参数, 设一抽样得观测值为 $(x_1, x_2, \dots, x_n)$, 求 p 的最大似然值。

多参数的最大似然估计

1. 写出似然函数

$$L(\theta_1, \dots, \theta_k) = \begin{cases} \prod_{i=1}^n P(x_i; \theta_1, \theta_2, \dots, \theta_k) & \text{离散型} \\ \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_k) & \text{连续型} \end{cases}$$

2. 写出似然方程组:

$$\left\{ \begin{array}{l} \frac{\partial}{\partial \theta_1} \ln L(\theta_1, \theta_2, \dots, \theta_k) = 0 \\ \frac{\partial}{\partial \theta_2} \ln L(\theta_1, \theta_2, \dots, \theta_k) = 0 \\ \vdots \\ \frac{\partial}{\partial \theta_k} \ln L(\theta_1, \theta_2, \dots, \theta_k) = 0 \end{array} \right.$$

3. 求解似然方程组, 得到驻点, 并判定是否为最大值点。

多参数的最大似然估计

例11: (正态分布), 设总体分布为:

$$X \sim \Psi(x) = \frac{1}{\sqrt{2\pi\delta}} e^{-\frac{(x-\mu)^2}{2\delta}}$$

μ , δ 为待估参数, 设一抽样得观测值为 $(x_1, x_2, \dots, x_n)$, 求 μ 和 δ 的最大似然值。

引言

- ▶ 多元统计分析涉及到的都是随机向量或多个随机向量放在一起组成的随机矩阵。
- ▶ 在研究公司的运营情况时，要考虑公司的获利能力、资金周转能力、竞争能力以及偿债能力等财务指标。
- ▶ 研究国家财政收入时，税收收入、企业收入、债务收入、国家能源交通重点建设基金收入、基本建设贷款归还收入、国家预算调节基金收入、其他收入等都是需要同时考察的指标。
- ▶ 显然，如果我们只研究一个指标或是将这些指标割裂开分别研究，是不能从整体上把握研究问题的实质的，解决这些问题就需要多元统计分析方法。

引言

- ▶ 在实用中遇到的随机向量常常是服从正态分布或近似正态分布，或虽本身不是正态分布，但它的样本均值近似于正态分布。
- ▶ 现实世界中许多实际问题的解决办法都是以总体服从正态分布或近似正态分布为前提的。在多元统计分析中，多元正态分布占有重要地位。
- ▶ 在实际问题中，多元正态分布中均值向量和协方差阵通常是未知的，一般的做法是由样本来估计。在此我们介绍最常见的最大似然估计法对参数进行估计，并讨论其有关的性质。

基本概念

研究的数据通常是多个变量的总体同时 p 个指标（变量），又进行了 n 次观测得到的，我们把这 p 个指标表示为 $X_1, X_2, \dots, X_p$ ，常用向量 $X = (X_1, X_2, \dots, X_p)'$ 表示对同一个体观测的 p 个变量。在多元统计分析中，仍然将所研究对象的全体称为总体，它是由许多（有限和无限）的个体构成的集合，如果构成总体的个体是具有 p 个需要观测指标的个体，我们称这样的总体为 p 维总体（或 p 元总体）。若观测了 n 个个体，则可得到如下表的数据，称每一个个体的 p 个变量为一个样品，而全体 n 个样品组成一个样本。

多元随机变量

变量	X_1	X_2	$\cdots$	X_p
1	X_{11}	X_{12}	$\cdots$	X_{1p}
2	X_{21}	X_{22}	$\cdots$	X_{2p}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	X_{n1}	X_{n2}	$\cdots$	X_{np}

横看记为:

$$X_{(a)} = (X_{a1}, X_{a2}, \dots, X_{ap})', a = 1, 2, \dots, n$$

表示为第 a 个样品的观测值。竖看为,

$$X_{(j)} = (X_{1j}, X_{2j}, \dots, X_{nj})', j = 1, 2, \dots, p$$

表示为第 j 个变量 X_j 的 n 次观测值。

多元随机变量


也可用矩阵表示为:

$$\mathbf{X} = \begin{bmatrix} X_{11} & X_{12} & \vdots & X_{1p} \\ X_{21} & X_{22} & \vdots & X_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ X_{m1} & X_{m2} & \vdots & X_{mp} \end{bmatrix} = (X_1, X_2, \dots, X_p) = \begin{bmatrix} X'_{(1)} \\ X'_{(2)} \\ \vdots \\ X'_{(n)} \end{bmatrix}$$

简记为 $\mathbf{X}$ 。

多元随机变量

例：Fisher的鸢尾花数据集（Fisher's iris flower data set），包含了三类鸢尾花，山鸢尾（Setosa）、杂色鸢尾（Versicolour）、维吉尼亚鸢尾（Virginica）的花萼、花瓣的长度与宽度。



引言

Sepal length ⇅	Sepal width ▲	Petal length ⇅	Petal width ⇅	Species ⇅
5.0	2.0	3.5	1.0	<i>I. versicolor</i>
6.2	2.2	4.5	1.5	<i>I. versicolor</i>
6.0	2.2	5.0	1.5	<i>I. virginica</i>
6.0	2.2	4.0	1.0	<i>I. versicolor</i>
6.3	2.3	4.4	1.3	<i>I. versicolor</i>
5.5	2.3	4.0	1.3	<i>I. versicolor</i>
5.0	2.3	3.3	1.0	<i>I. versicolor</i>
4.5	2.3	1.3	0.3	<i>I. setosa</i>
5.5	2.4	3.8	1.1	<i>I. versicolor</i>
5.5	2.4	3.7	1.0	<i>I. versicolor</i>
4.9	2.4	3.3	1.0	<i>I. versicolor</i>
6.7	2.5	5.8	1.8	<i>I. virginica</i>
6.3	2.5	5.0	1.9	<i>I. virginica</i>

多元分布

定义2.1 将 p 个随机变量 $X_1, X_2, \dots, X_p$ 的整体称为 p 维随机向量, 记为 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$ 。

定义2.2 设 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$ 是 p 维随机向量, 它的多元分布函数定义为:

$$F(\mathbf{x}) \triangleq F(X_1, X_2, \dots, X_p) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_p \leq x_p)$$

记为 $\mathbf{X} \sim F(\mathbf{x})$, 其中 $\mathbf{x} = (x_1, x_2, \dots, x_p)' \in \mathbb{R}^p$, $\mathbb{R}^p$ 表示 p 维欧氏空间。多维随机向量的统计特性可用它的分布函数来完整地描述。

多元分布

定义2.3 设 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$ 是 p 维随机向量, 若存在有限个或可列个 p 维数向量 $x_1, x_2, \dots$,

记 $P(X = x_k) = p_k, (k = 1, 2, \dots)$ 且满足 $p_1 + p_2 + \dots = 1$, 则称 $\mathbf{X}$ 为离散型随机向量,

称 $P(X = x_k) = p_k, (k = 1, 2, \dots)$ 为 $\mathbf{X}$ 的**概率分布**。

设 $\mathbf{X} \sim F(x) \triangleq F(x_1, x_2, \dots, x_p)$, 若存在一个非负函数 $f(x_1, x_2, \dots, x_p)$, 使得对一切 $\mathbf{X} = (x_1, x_2, \dots, x_p)$ 有:

$$F(x) \triangleq F(X_1, X_2, \dots, X_p) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_p} f(t_1, t_2, \dots, t_p) dt_1 \dots dt_p$$

则称 $\mathbf{X}$ 为连续型随机变量, 称 $f(x_1, x_2, \dots, x_p)$ 为**分布密度函数**, 简称为**密度函数**或**分布密度**。

多元分布

一个 p 元函数 $f(x_1, x_2, \dots, x_p)$ 能作为 $\mathbb{R}^p$ 中某个随机向量的密度函数的主要条件是:

1. $f(x_1, x_2, \dots, x_p) \geq 0, \forall (x_1, x_2, \dots, x_p)' \in \mathbb{R}^p$

2.
$$\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f((x_1, x_2, \dots, x_p)) dx_1 \dots dx_p = 1$$

离散型随机向量的统计性质可由它的概率分布完全确定, 连续型随机向量的统计性质可由它的分布密度完全确定。

多元分布

例1: 试证函数为随机向量 $\mathbf{X} = (X_1, X_2)'$ 密度函数。

$$f(x_1, x_2) = \begin{cases} e^{-(x_1+x_2)}, & x_1 \geq 0, x_2 \geq 0 \\ 0, & \text{其他} \end{cases}$$

多元变量的分割

定义2.4: 设 $\mathbf{X}$ 是 p 维随机向量, 称由它的 $q(< p)$ 个分量组成的子向量 $\mathbf{X}^{(i)} = (X_{i1}, X_{i2}, \dots, X_{iq})'$ 的分布为 $\mathbf{X}$ 的边缘 (或边际) 分布, 相对地把 $\mathbf{X}$ 的分布称为联合分布。通过变换 $\mathbf{X}$ 中各分量的次序, 总可假定 $\mathbf{X}^{(1)}$ 正好是 $\mathbf{X}$ 的前 q 个分量, 其余 $p - q$ 个分量

为 $\mathbf{X}^{(2)}$, 则 $\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}_{p-q}^q$, 相应的取值也可分为两部

分 $\mathbf{x} = \begin{bmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{bmatrix}$ 。

边缘分布

当 $\mathbf{X}$ 的分布函数是 $F(x_1, x_2, \dots, x_q)$ 时, $\mathbf{X}^{(1)}$ 的分布函数即边缘分布函数为:

$$\begin{aligned} F(x_1, x_2, \dots, x_q) &= P(X_1 \leq x_1, \dots, X_q \leq x_q) \\ &= P(X_1 \leq x_1, \dots, X_q \leq x_q, X_{q+1} \leq \infty, \dots, X_p \leq \infty) \\ &= F(x_1, x_2, \dots, x_q, \infty, \dots, \infty) \end{aligned}$$

当 $\mathbf{X}$ 有分布密度 $f(x_1, x_2, \dots, x_q)$ 时 (亦称联合分布密度函数), 则 $\mathbf{X}^{(1)}$ 也有分布密度, 即边缘密度函数为:

$$f_1(x_1, x_2, \dots, x_q) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x_1, \dots, x_p) dx_{q+1}, \dots, dx_p$$

边缘密度函数

例2: 对例1中的 $\mathbf{X} = (X_1, X_2)'$ 求边缘密度函数。

定义2.5: 若 p 个随机变量 $X_1, X_2, \dots, X_p$ 的联合分布等于各自的边缘分布的乘积, 则称 $X_1, X_2, \dots, X_p$ 是相互独立的。

例3: 例2中的 X_1 和 X_2 是否相互独立?

均值（向量）

定义2.6 设 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$, 若 $E(X_i) (i = 1, \dots, p)$ 存在且有限, 则称 $E(\mathbf{X}) = (E(X_1), E(X_2), \dots, E(X_p))'$ 为 $\mathbf{X}$ 的均值（向量）或数学期望, 有时也把 $E(\mathbf{X})$ 和 $E(X_i)$ 分别记为 $\boldsymbol{\mu}$ 和 μ_i , 即 $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_p)'$, 容易推得均值（向量）具有以下性质:

1. $E(\mathbf{A}\mathbf{X}) = \mathbf{A}E(\mathbf{X})$;
2. $E(\mathbf{A}\mathbf{X}\mathbf{B}) = \mathbf{A}E(\mathbf{X})\mathbf{B}$
3. $E(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}) = \mathbf{A}E(\mathbf{X}) + \mathbf{B}E(\mathbf{Y})$

其中, $\mathbf{X}$ 、 $\mathbf{Y}$ 为随机向量, $\mathbf{A}$ 、 $\mathbf{B}$ 为大小适合运算的常数矩阵。

方差

定义2.7 设 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$, $\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$,
称(2.4)

$$\begin{aligned} D(\mathbf{X}) &\triangleq E(\mathbf{X} - E(\mathbf{X}))(\mathbf{X} - E(\mathbf{X}))' \\ &= \begin{bmatrix} \text{cov}(X_1, X_1) & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_p) \\ \text{cov}(X_2, X_1) & \text{cov}(X_2, X_2) & \dots & \text{cov}(X_2, X_p) \\ \vdots & \vdots & & \vdots \\ \text{cov}(X_p, X_1) & \text{cov}(X_p, X_2) & \dots & \text{cov}(X_p, X_p) \end{bmatrix} \end{aligned}$$

为 $\mathbf{X}$ 的方差或协方差阵, 有时把 $D(\mathbf{X})$ 简记为 Σ , $\text{cov}(X_i, X_j)$ 简记为 σ_{ij} , 从而有 $\Sigma = (\sigma_{ij})_{p \times p}$;

斜差

称随机向量 $\mathbf{X}$ 和 $\mathbf{Y}$ 的协差阵为

$$\begin{aligned} \text{cov}(\mathbf{X}, \mathbf{Y}) &\triangleq E(\mathbf{X} - E(\mathbf{X}))(\mathbf{Y} - E(\mathbf{Y}))' \\ &= \begin{bmatrix} \text{cov}(X_1, Y_1) & \text{cov}(X_1, Y_2) & \dots & \text{cov}(X_1, Y_p) \\ \text{cov}(X_2, Y_1) & \text{cov}(X_2, Y_2) & \dots & \text{cov}(X_2, Y_p) \\ \vdots & \vdots & & \vdots \\ \text{cov}(X_p, Y_1) & \text{cov}(X_p, Y_2) & \dots & \text{cov}(X_p, Y_p) \end{bmatrix} \end{aligned}$$

当 $\mathbf{X} = \mathbf{Y}$ 时，即为 $D(\mathbf{X})$ 。若 $\text{cov}(\mathbf{X}, \mathbf{Y}) = 0$ ，则称 $\mathbf{X}$ 和 $\mathbf{Y}$ 不相关，由 $\mathbf{X}$ 和 $\mathbf{Y}$ 相互独立易推得 $\text{cov}(\mathbf{X}, \mathbf{Y}) = 0$ ，即 $\mathbf{X}$ 和 $\mathbf{Y}$ 不相关；但反过来，当 $\mathbf{X}$ 和 $\mathbf{Y}$ 不相关时，一般不能推知它们独立。

斜差

当 $\mathbf{A}$ 、 $\mathbf{B}$ 为常数矩阵时，由定义可以推出协方差阵有如下性质：

1. 对于常数向量 $\mathbf{a}$ ，有 $D(\mathbf{X} + \mathbf{a}) = D(\mathbf{X})$ ；
2. $D(\mathbf{AX}) = \mathbf{AD}(\mathbf{X})\mathbf{A}' = \mathbf{A}\Sigma\mathbf{A}'$
3. $\text{cov}(\mathbf{AX}, \mathbf{BY}) = \mathbf{Acov}(\mathbf{X}, \mathbf{Y})\mathbf{B}'$ ；
4. 设 $\mathbf{X}$ 为 p 维随机向量，期望和协方差存在，
记 $\boldsymbol{\mu} = E(\mathbf{X})$ ， $\Sigma = D(\mathbf{X})$ ， $\mathbf{A}$ 为 $n \times p$ 常数阵，则：

$$E(\mathbf{X}'\mathbf{AX}) = \text{tr}(\mathbf{A}\Sigma) + \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}$$

对于任何的随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$ 来说，其协方差阵 Σ 都是对称阵，同时总是非负定（半正定）的，大多数情况是正定的。

相关系数

相关阵: $\mathbf{R} = \text{corr}(\mathbf{X}) = (\rho_{ij})_{p \times p}$, 其中:


$$\rho_{ij} = \frac{\text{cov}(X_i, X_j)}{\sqrt{D(X_i)}\sqrt{D(X_j)}} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{jj}}}, i, j = 1, \dots, p$$

标准化:


$$x_j^* = \frac{X_j - E(X_j)}{\sqrt{D(X_j)}}, j = 1, 2, \dots, p$$

标准化数据的斜差阵正好是原指标的相关阵。

多元正态分布



多元正态分布



多元正态分布

定义2.8 若 p 维随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_p)'$ 的密度函数为:

$$f(x_1, x_2, \dots, x_p) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

其中 $\mathbf{X} = (x_1, x_2, \dots, x_p)'$, $\boldsymbol{\mu}$ 是 p 维向量, Σ 是 p 阶正定阵, 则称 $\mathbf{X}$ 服从 p 元正态分布, 也称 $\mathbf{X}$ 为 p 维正态随机向量, 简记为 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$, $\boldsymbol{\mu}$ 为 $\mathbf{X}$ 的均值(向量), Σ 为 $\mathbf{X}$ 的协差阵。当 $|\Sigma| = 0$ 时, Σ^{-1} 不存在, $\mathbf{X}$ 也就不存在通常意义下的密度函数, 然而可以形式的给出一个表达式, 有些问题可以利用这一形式对 $|\Sigma| \neq 0$ 及 $|\Sigma| = 0$ 的情况给出一个统一的处理。

定理2.1 设 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$, 则有 $E(\mathbf{X}) = \boldsymbol{\mu}$, $D(\mathbf{X}) = \Sigma$ 。

多元正态分布的性质

1. 若 $\mathbf{X} = (X_1, X_2, \dots, X_p)' \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma}$ 是对角阵, 则 $X_1, X_2, \dots, X_p$ 相互独立。;
2. 若 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\mathbf{A}$ 为 $s \times p$ 阶常数阵, $\mathbf{d}$ 为 s 维常数向量, 则

$$\mathbf{AX} + \mathbf{d} \sim N_s(\mathbf{A}\boldsymbol{\mu} + \mathbf{d}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

即正态随机向量的线性函数还是正态的;

3. 若 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 将 $\mathbf{X}$, $\boldsymbol{\mu}$, $\boldsymbol{\Sigma}$ 作如下剖分;

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}_{p-q}^q, \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}_{p-q}^q, \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}_{p-q}^q$$

则: $\mathbf{X}^{(1)} \sim N_q(\boldsymbol{\mu}^{(1)}, \boldsymbol{\Sigma}_{11})$, $\mathbf{X}^{(2)} \sim N_{p-q}(\boldsymbol{\mu}^{(2)}, \boldsymbol{\Sigma}_{22})$ 。

(1) 多元正态分布的任何边缘分布为正态分布, 但反之不真; (2), 由于 $\boldsymbol{\Sigma}_{12} = \text{cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$, 故 $\boldsymbol{\Sigma}_{12} = \mathbf{0}$ 表示 $\mathbf{X}^{(1)}$ 和 $\mathbf{X}^{(2)}$ 不相关, 因此可知, 对于多元正态变量而言, $\mathbf{X}^{(1)}$ 和 $\mathbf{X}^{(2)}$ 的不相关与独立是等价的。

多元正态分布的性质

例2.4 若 $\mathbf{X} = (X_1, X_2, X_3)' \sim N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 其中:

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix}, \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{bmatrix}, \mathbf{a} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \end{bmatrix}$$

1. $\mathbf{a}'\mathbf{X}$ 的分布;
2. $\mathbf{A}'\mathbf{X}$ 的分布;
3. $[\mathbf{X}_1, \mathbf{X}_2]'$ 的分布;

多元样本的数字特征

1. 样本阵 $\mathbf{X}$;
2. 样本均值向量 $\boldsymbol{\mu}$;
3. 样本离差阵 $\mathbf{S}$;
4. 样本斜差阵 $\mathbf{V}$;
5. 样本相关阵 $\mathbf{R}$ 。

均值向量与协差阵的最大似然估计

多元正态分布有两组参数，均值 $\boldsymbol{\mu}$ 和协差阵 $\boldsymbol{\Sigma}$ ，在许多问题中它们是未知的，需要通过样本来估计。那么，通过样本来估计总体的参数叫做参数估计，参数估计的原则和方法是很多的，最大似然法给出 $\boldsymbol{\mu}$ 和协差阵 $\boldsymbol{\Sigma}$ 的估计量：

$$\begin{cases} \hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{x}} \\ \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})' = \frac{1}{n} \mathbf{S} \end{cases}$$

多元正态总体的均值向量 $\boldsymbol{\mu}$ 的极大似然估计量就是样本均值向量，其协差阵 $\boldsymbol{\Sigma}$ 的极大似然估计就是样本协差阵。

均值向量 μ 和协差阵 Σ 的估计量

1. $E(\bar{\mathbf{X}})$, 即 $\bar{\mathbf{X}}$ 是 μ 的无偏估计;
 $E\left(\frac{1}{n}\mathbf{S}\right) = \frac{n-1}{n}\Sigma$, 即不是 Σ 的无偏估计;
而 $E\left(\frac{1}{n-1}\mathbf{S}\right) = \Sigma$, 即是 Σ 的无偏估计;
2. $\bar{\mathbf{X}}$, $\frac{1}{n-1}\mathbf{S}$ 分别是 μ , Σ 的有效估计;
3. $\bar{\mathbf{X}}$, $\frac{1}{n}\mathbf{S}$ (或 $\frac{1}{n-1}\mathbf{S}$) 分别是 μ , Σ 的一致估计 (相合估计)。

均值向量 μ 和协差阵 Σ 的估计量

样本均值向量和样本离差阵在多元统计推断中具有十分重要的作用，并有如下结论：

定理2.2 设 $\bar{\mathbf{X}}$ 和 $\mathbf{S}$ 分别是正态总体 $N_p(\mu, \Sigma)$ 的样本均值向量和离差阵，则

1. $\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$;
2. 离差阵 $\mathbf{S}$ 可以写为：

$$\mathbf{S} = \sum_{a=1}^{n-1} \mathbf{Z}_a \mathbf{Z}_a'$$

其中， $\mathbf{Z}_1, \dots, \mathbf{Z}_{n-1}$ 独立同分布于 $N_p(0, \Sigma)$ ；

3. $\bar{\mathbf{X}}$ 和 $\mathbf{S}$ 相互独立；
4. $\mathbf{S}$ 为正定阵的充要条件是 $n > p$ 。

Wishart分布

离差阵 $\mathbf{S}$ 的分布：为此给出威沙特（Wishart, 1928）分布，并指出它是一元 χ^2 分布的推广，也是构成其它重要分布的基础。

定义2.10

设 $\mathbf{X}_{(a)} = (X_{a1}, X_{a2}, \dots, X_{ap})' \sim N_p(\boldsymbol{\mu}_a, \boldsymbol{\Sigma})$, $a = 1, 2, \dots, n$ 且相互独立，则由 $\mathbf{X}_{(a)}$ 组成的随机矩阵：

$$\mathbf{W}_{p \times p} = \sum_{a=1}^n \mathbf{X}_{(a)} \mathbf{X}_{(a)}'$$

的分布称为非中心Wishart分布，记为 $\mathbf{W}_p(n, \boldsymbol{\Sigma}, \mathbf{Z})$ ，其

中 $\mathbf{Z} = \sum_{a=1}^n (\mu_{a1}, \dots, \mu_{ap}) (\mu_{a1}, \dots, \mu_{ap})' = \sum_{a=1}^n \boldsymbol{\mu}_a \boldsymbol{\mu}_a'$, $\boldsymbol{\mu}_a$ 称为非中心参数。

Wishart分布

当 $\boldsymbol{\mu}_a = 0$ 时称为中心Wishart分布，记为 $\mathbf{W}_p(n, \boldsymbol{\Sigma})$ ，
当 $n \geq p$ ， $\boldsymbol{\Sigma} > 0$ ， $\mathbf{W}_p(n, \boldsymbol{\Sigma})$ 有密度存在，其表达式为(2.20)：

$$f(\mathbf{w}) = \begin{cases} \frac{|\mathbf{w}|^{\frac{1}{2}(n-p-1)} \exp[-\frac{1}{2} \text{tr} \boldsymbol{\Sigma}^{-1} \mathbf{w}]}{2^{np/2} \pi^{p(p-1)/4} |\boldsymbol{\Sigma}|^{n/2} \prod_{i=1}^p \Gamma(\frac{n-i+1}{2})}, & \text{当 } \mathbf{w} \text{ 为正定阵} \\ 0, & \text{其他} \end{cases}$$

当 $p = 1$ ， $\boldsymbol{\Sigma} = \sigma^2$ 时， $f(\mathbf{w})$ 就是 $\sigma^2 \chi^2(n)$ 的分布密度，此时

(2.19) 式为 $\sum_{a=1}^n \mathbf{X}_{(a)} \mathbf{X}'_{(a)} = \sum_{a=1}^n \mathbf{X}_{(a)}^2$ ，有 $\frac{1}{\sigma^2} \sum_{a=1}^n \mathbf{X}_{(a)}^2 \sim \chi^2(n)$ 。

因此，Wishart分布是 $\chi^2(n)$ 分布在 p 维正态情况下的推广。

Wishart分布的基本性质:

1. 若 $\mathbf{X}_{(a)} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $a = 1, 2, \dots, n$ 且相互独立, 则样本离差阵 $\mathbf{S} = \sum_{a=1}^n (\mathbf{X}_{(a)} - \bar{\mathbf{X}}) \cdot (\mathbf{X}_{(a)} - \bar{\mathbf{X}})'$ $\sim W_p(n-1, \boldsymbol{\Sigma})$, 其中 $\bar{\mathbf{X}} = \frac{1}{n} \sum_{a=1}^n \mathbf{X}_{(a)}$ 。
2. 若 $\mathbf{S}_i \sim W_p(n_i, \boldsymbol{\Sigma})$, $i = 1, \dots, k$, 且相互独立, 则

$$\sum_{i=1}^k \mathbf{S}_i \sim W_p\left(\sum_{i=1}^k n_i, \boldsymbol{\Sigma}\right)$$

3. 若 $\mathbf{X}_{p \times p} \sim W_p(n, \boldsymbol{\Sigma})$, $\mathbf{C}_{p \times p}$ 为非奇异阵, 则

$$\mathbf{CXC} \sim W_p(n, \mathbf{C}\boldsymbol{\Sigma}\mathbf{C}')$$

作业

课后习题：2.1-2.3、2.6-2.9

假设随机向量 $\mathbf{y} = (Y_1, Y_2, Y_3, Y_4)$ ，均值向量为 $\boldsymbol{\mu} = (4, 3, 2, 1)'$ ，协方差矩阵为：

$$\boldsymbol{\Sigma} = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}, \mathbf{A} = [1, 2], \mathbf{B} = \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix}.$$

将 $\mathbf{y}$ 分为 $\mathbf{y}^{(1)} = (Y_1, Y_2)'$ 和 $\mathbf{y}^{(2)} = (Y_3, Y_4)'$ ，求：(1) $E(\mathbf{y}^{(1)})$ ；
(2) $E(\mathbf{A}\mathbf{y}^{(1)})$ ；(3) $cov(\mathbf{y}^{(1)})$ ；(4) $cov(\mathbf{A}\mathbf{y}^{(1)})$ ；
(5) $E(\mathbf{B}\mathbf{y}^{(2)})$ ；(6) $cov(\mathbf{B}\mathbf{y}^{(2)})$ ；(7) $cov(\mathbf{y}^{(1)}, \mathbf{y}^{(2)})$ ；
(8) $cov(\mathbf{A}\mathbf{y}^{(1)}, \mathbf{y}^{(2)})$