

回顾：数据缺失，离群值检测和正态性检测

1.5 缺失数据

1.6 离群值检测

1.7 正态性检测-对数转换

1.8 同方差和异方差

1.11 决定系数

统计学采用方差描述随机变量的变异程度，即离散程度。

(样本值-平均值) 的平方和，称为**总变异**。

(样本值-预测值) 的平方和，称为**不能被解释的变异程度**。

1.11 决定系数

回归平方和 (SSR: Sum of the Squared Regression), 又称
可解释变异 (ESS : Explained Sum of the Squared Error),
是预测值和平均值之间的残差平方和

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

1.11 决定系数

和方差 (Sum of the Squared Error, SSE), 是拟合数据和观测数据误差的平方和

$$SSE = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

1.11 决定系数

总变异=可以被解释的变异+不能被解释的变异

$$SST = SSR + SSE$$

1.11 决定系数

决定系数 (coefficient of determination) 是用来评价回归模型变异程度的重要统计量, 一般用 R^2 表示

$$R^2 = \frac{SSR}{SST}$$

1.11 决定系数

决定系数是用可以被解释的变异/总变异,决定系数越高,代表可以被解释的程度越高, 回归模型的效果越好

$$R^2 = \frac{SSR}{SST}$$

$$R^2 = 1 - \frac{SSE}{SST}$$

1.11 决定系数

如果样本数据接近完全线性，则和方差 $SSE \approx 0$ $SSR \approx SST$

意味着Y的变化接近完全由回归线解释， $R^2 \approx 1$

如果SSR接近0，则表明X与Y之间几乎毫无关系， $SSE \approx SST$

回归模型无法解释Y， $R^2 \approx 0$

1.12 特征工程

特征工程是采用工程方法，从原始数据中最大限度提取和规范有价值特征，用以支持算法和模型的训练与测试。

业界流行一种看法：数据和特征决定了机器学习的上限，而模型和算法只是逼近这个上限。

1.12 特征工程

完成房价数据集的特征提取与构建，主要步骤为：

- (1) 读入训练集与测试集
- (2) 处理缺失数据
- (3) 处理高相关性的特征，避免共线性
- (4) 对非数值型列进行One-Hot编码
- (5) 对数值型特征作正态分布检查，必要时作对数变换，实现同方差

1.13 数据集划分与标准化

将数据划分为训练集与测试集。

常用比例：训练集 70%-80%，测试集 20%-30%

1.14 线性回归模型

线性回归的本质是找一组「特征系数」，让特征的线性组合尽可能接近目标值，公式如下：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

β_0

截距项（偏置项）：所有特征为 0 时， y 的基准值

$\beta_1 \dots \beta_n$

特征系数（权重）：每个特征对 y 的影响幅度

$x_1 \dots x_n$

特征变量（自变量）

ϵ

误差项（残差）：模型无法解释的部分（不可避免）