

回顾： 数据查看和统计， 相关性分析

1.5 缺失数据

1.6 离群值检测

1.7 正态性检测-对数转换

1.8 同方差和异方差

1.8 同方差和异方差

1. 同方差 (Homoscedasticity)

- 定义：无论自变量 (X) 取什么值，因变量 (Y) 的误差波动幅度（方差）都保持不变。
- 理解：数据点均匀地分布在回归线周围，像一个宽度一致的管子。
- 这是经典线性回归模型的理想假设，意味着模型预测的可靠性在所有范围内是一致的。

2. 异方差 (Heteroscedasticity)

- 定义：随着自变量 (X) 的变化，因变量 (Y) 的误差波动幅度（方差）发生改变（通常是随 X 增大而变大）。
- 理解：数据点分布在回归线周围，形状像一个喇叭口或漏斗（一头窄，一头宽）。
- 意义：这违反了经典回归假设。虽然不影响预测值的无偏性，但会导致标准误计算错误，从而使假设检验（如 t 检验）失效。

1.9 线性回归假设

线性回归： 是利用数理统计中的回归分析，来确定一个因变量与一个或多个自变量间相互依赖的定量关系的一种统计分析方法。

1.9 线性回归假设

只包括一个自变量和一个因变量的回归分析，如果二者的关系可用一条直线近似表示，这种回归分析称为一元线性回归分析。回归函数可表示为公式 1.3。

$$y = \beta_0 + \beta_1 x + \varepsilon \quad (1.3)$$

x 是自变量， y 是需要估计的因变量。 β_0 是常数项，表示回归直线在 y 轴上的截距。 β_1 是回归系数（或称权重），即回归直线的斜率，表示 x 变化一个单位， y 会变化 β_1 。 ε 表示误差项，表示除了 x 与 y 的线性关系之外的随机因素对 y 的影响。

1.9 线性回归假设

如果回归分析中包括两个或两个以上的自变量，且因变量和自变量之间是线性关系，则称为多元线性回归分析。回归函数可表示为公式 1.4。

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon \quad (1.4)$$

1.9 线性回归假设

应用线性回归， 需要满足5条基本假设：

- (1) 线性关系
- (2) 多元正态
- (3) 无多重共线性
- (4) 无自相关
- (5) 同方差

1.10 参数估计

$$SalePrice = \beta_0 + \beta_1 (GrLivArea) + \varepsilon$$

$$\hat{\beta}_1 = r_{xy} \frac{s_y}{s_x}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

评价模型好坏,
可用均方误差:

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$