

例1 房价预测与回归问题



例1 房价预测与回归问题



如何让机器从**数据集**中学习建立**数学模型**？

如何评估**机器学习**的效果？

1.1 数据集

表 1.1 爱荷华州艾姆斯市房价数据集

文件名	数据规模	文件大小	功 能
train.csv	81 列，1460 行	449 KB	训练集
test.csv	80 列，1459 行	440 KB	测试集
data_description.txt	所有列变量	13 KB	列变量数据解析

注：数据集由杜鲁门州立大学统计学教授 DeCock 统计整理。

1.2 数据集观察

1.3使用mat作图

1.4 相关矩阵

相关系数：是度量两个变量间的线性关系的统计量，一般用字母 r 表示，如公式1.1所示。

$$\rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \quad (1.1)$$

$\rho_{XY} \in [-1, 1]$, σ_X 和 σ_Y 分别是随机变量 X 和 Y 的标准差

$Cov(X, Y) = EXY - EX \times EY$, EX 、 EY 、 EXY 表示数学期望

1.4 相关矩阵

相关矩阵（Correlation Matrix）：又称相关系数矩阵，是由 n 维随机向量 $(X_1, X_2, \dots, X_n)$ 中任意的 X_i, X_j 之间的相关系数 ρ_{ij} 构成的 $n \times n$ 维矩阵，记作 $\mathbf{R}$ ，如公式 1.2 所示。

$$\mathbf{R} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1n} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ \rho_{n1} & \rho_{n2} & \cdots & \rho_{nn} \end{bmatrix} \quad (1.2)$$

相关矩阵 $\mathbf{R}$ 的对角元素的值均为 1，而且是对称矩阵。