

上机实验报告 02

数据挖掘与机器学习

学号：1043220122 姓名：林鑫 班级：信计 2302 班

1 实验目的

本实验旨在利用 Python 对数据进行探索性数据分析，通过数据清洗、可视化、统计分析及简单建模，掌握数据处理的基本方法。实验可参考 Script02.ipynb 中的分析思路（如变量关系分析、残差图、回归系数计算、同方差与异方差检验等），将其应用于其它数据。

2 实验环境

编程语言：Python

主要库：pandas 数据处理；numpy 数值计算；matplotlib & seaborn 数据可视化；sklearn 机器学习工具（用于评估指标）；scipy 统计分析（如正态性检验）；statsmodels 异方差检验（Breusch-Pagan）等。

3 数据描述

数据来源与样本 本实验使用沪深 300 指数最近三年日频数据（沪深 300_ 最近三年.csv）。数据由 get_data.py 通过腾讯财经接口（web.ifzq.gtimg.cn）拉取沪深 300 日 K 线前复权数据并导出为 CSV 得到。原始数据为交易日级别的行情数据，经清洗后共 727 条有效记录，时间跨度为 2023-03-13 至 2026-03-13，覆盖约三年交易日，样本量足以进行描述性统计、相关性与简单回归分析。

原始字段说明 原始数据包含字段：**日期**（交易日期）、**收盘**（当日收盘指数）、**开盘**（当日开盘指数）、**高**（当日最高）、**低**（当日最低）、**交易量**（字符串形式，如“123533.67K”）、**涨跌幅**（百分比字符串，如“0.24%”）。从原始字段可知：收盘价在约 3160–4790 点之间

波动，涨跌幅与交易量反映市场活跃程度与波动幅度，需经类型转换后方可参与数值计算。

预处理后变量 预处理后用于分析的数值型变量包括：收盘价、开盘价、最高、最低；交易量转为 `volume_k`（单位：千）；日收益率 `ret_close`（由收盘价 `pct_change()` 计算）；当日振幅 `range_pct = (高 - 低)/收盘`；开收差 `oc_pct = (收盘 - 开盘)/开盘`。仅首日的 `ret_close` 与 `pct_change` 因无前一日数据而缺失，其余无缺失；数据按日期升序排列，可直接用于时间序列分析与回归建模。

4 实验内容与步骤

4.1 数据加载与预处理

- **读入数据**：使用 `pd.read_csv(path)` 读入 CSV 文件，`df.head()` 预览。
- **类型转换**：`pd.to_datetime(df['日期'], errors='coerce')` 将日期转为时间类型；对“交易量”字符串用 `str.replace()` 去掉“K”后 `pd.to_numeric()` 转为 `volume_k`；对“涨跌幅”同理得到 `pct_change`；对收盘、开盘、高、低使用 `pd.to_numeric()` 转为 `float`。
- **衍生特征**：`df['ret_close'] = df['收盘'].pct_change()` 计算日收益率；`range_pct = (高-低)/收盘`、`oc_pct = (收盘-开盘)/开盘` 计算振幅与开收差。
- **排序与缺失**：`df.dropna(subset=['日期']).sort_values('日期').reset_index(drop=True)` 按日期升序；用 `df.isna().sum()` 检查各列缺失数量，后续回归前对建模用列 `dropna()`。

4.2 缺失数据统计

按列统计缺失数量与占比，与上机示例一致：`total = df.isnull().sum().sort_values(ascending=False)`，`percent = (df.isnull().sum() / df.shape[0]).sort_values(ascending=False)`，用 `pd.concat([total, percent], axis=1, keys=['Total', 'Percent'])` 得到缺失数据表，仅展示 `Total > 0` 的列。

4.3 描述性统计分析

对数值列使用 `df['收盘'].describe()`、`df['ret_close'].dropna().describe()` 查看 `count`、`mean`、`std`、`min`、分位数、`max`。计算分布形态：`ret.skew()`（偏度）、`ret.kurt()`（峰度），用于判断是否偏离正态。

4.4 正态性检验

对日收益率 `ret_close` 做正态性检验。使用 `scipy.stats.shapiro()`（小样本或抽样）与 `scipy.stats.normaltest()`（D'Agostino K^2 ），根据 p-value 是否小于 0.05 判断是否拒绝正态性假设。

4.5 数据可视化分析

- 价格走势: `plt.plot(df['日期'], df['收盘'])` 绘制收盘价时序图。
- 收益率分布与 QQ 图: `plt.hist()` 叠加 `scipy.stats.norm.pdf()` 的正态曲线; `scipy.stats.probplot(ret, dist='norm', plot=ax)` 绘制 QQ 图。
- 箱线图与离群值: `plt.subplots()` 与 `ax.boxplot()` 或 `seaborn.boxplot()` 对 `range_pct`、`ret_close` 等绘制箱线图, 观察离群点。
- 正态性/对数转换对比: 对 `volume_k` 用 `np.log1p()` 得到 `log_volume_k`, 分别画直方图与 `stats.probplot()`, 对比转换前后是否更接近正态。

4.6 相关性分析

选取 `ret_close`、`range_pct`、`oc_pct`、`volume_k` 等数值列, 用 `df[num_cols].corr()` 计算 Pearson 相关系数矩阵; `sns.heatmap(corr, annot=True, cmap=...)` 绘制热力图。用 `sns.scatterplot()` 绘制振幅与成交量、振幅与绝对收益率等散点图, 观察变量间关系。

4.7 简单线性回归分析

- 多元回归: 因变量 $y = \text{ret_close.shift}(-1)$ (下一日收益率), 自变量 X 为 `ret_close`、`range_pct`、`oc_pct`、`volume_k`; `model_df.dropna()` 后按时间序列 `iloc[:split]` 与 `iloc[split:]` 划分前 80% 训练、后 20% 测试。使用 `sklearn.linear_model.LinearRegression()` 的 `fit()`、`predict()`; `sklearn.metrics` 的 `mean_squared_error()`、`mean_absolute_error()`、`r2_score()` 计算 MSE、MAE、 R^2 ; 输出 `lr.coef_`、`lr.intercept_` 得到回归方程。
- 残差图: `resid = y_true - y_pred`, 用 `plt.scatter(yhat, resid)` 与 `plt.scatter(X['range_pct', resid])` 绘制预测值 vs 残差、自变量 vs 残差, 观察是否同方差。
- 同方差与异方差: 结合残差图判断; 使用 `statsmodels.stats.diagnostic.het_breuschpagan(resid, add_constant(X))` 进行 Breusch-Pagan 异方差检验, $p < 0.05$ 时拒绝同方差假设。
- 一元回归与手工系数: 以 `range_pct` 解释 `abs_ret`, 用 `df.corr()` 或 `np.corrcoef()` 得 r_{xy} , $\beta_1 = r_{xy} * (\text{std}_y / \text{std}_x)$, $\beta_0 = \text{mean}_y - \beta_1 * \text{mean}_x$; 计算 `y_hat` 与 MSE、 $R^2 = r^2$, 并绘制一元回归残差图。

4.8 其它，可选做

可扩展：加入技术指标（均线、RSI）、滚动窗口、非线性模型（如随机森林/GBDT），或对残差结构进行进一步对比分析。

5 实验结果与分析

5.1 数据加载与预处理的结果与分析

清洗前后行数均为 727，时间范围为 2023-03-13 至 2026-03-13。缺失值检查显示：日期、收盘、开盘、高、低、volume_k、range_pct、oc_pct 均无缺失；仅 pct_change 与 ret_close 各 1 个缺失（首日）。数据质量较好，首日缺失在回归时通过 dropna 排除；类型转换与衍生特征为后续分析提供了统一可用的数值基础。

5.2 缺失数据统计的结果与分析

表1 为按列统计的缺失数量与占比。仅 pct_change、ret_close 有 1 条缺失，对应首日无前一日收益；其余列 Total 为 0。说明无需大量删行，仅在建模时对所用列 dropna 即可。

表 1: 缺失数据统计（仅列出有缺失的列）

变量	Total	Percent
pct_change	1	0.14%
ret_close	1	0.14%

5.3 描述性统计分析的结果与分析

收盘价与日收益率 ret_close 的描述性统计见表2 与表3。收盘价中位数与均值接近，分布较对称；日收益率偏度约 0.46（略右偏）、峰度约 12.07（远大于正态的 0），呈“尖峰厚尾”，与正态分布明显偏离，符合金融时间序列常见特征，后续回归需注意残差分布与稳健推断。

表 2: 收盘价描述性统计

统计量	收盘
count	727
mean	3894.65
std	413.82
min	3159.25
25%	3572.44
50%	3865.47
75%	4036.51
max	4790.69

表 3: 日收益率 ret_close 描述性统计及分布形态

统计量	ret_close
count	726
mean	0.00028
std	0.0107
min	-0.0705
25%	-0.00535
50%	-0.00012
75%	0.00518
max	0.0848
偏度	0.46
峰度	12.07

5.4 正态性检验的结果与分析

Shapiro-Wilk 与 D'Agostino K^2 检验的 p-value 均远小于 0.05, 拒绝“日收益率服从正态分布”的原假设, 与描述性统计中的偏度、峰度及 QQ 图结论一致, 说明 OLS 残差也可能非正态, 推断时可考虑稳健标准误或非参数方法。

5.5 数据可视化分析的结果与分析

原始数据与可视化目的 原始数据为 727 个交易日的指数与交易量等, 数值量纲与分布差异较大 (如收盘为数千点、收益率为小数、交易量为万位)。通过箱线图、直方图、

QQ 图与散点图，可直观查看各变量的分布形态、离群值、是否近似正态以及变量间关系，为后续建模与检验提供依据。




图 1: 离群值检测箱线图 (range_pct、ret_close 等)

原始数据说明:range_pct 为当日振幅 (高 - 低)/收盘,反映单日波动幅度;ret_close 为日收益率,由相邻两日收盘价计算。原始序列中二者均存在极端取值 (如单日大涨大跌、振幅异常放大的交易日)。

结果分析:箱线图中箱体表示四分位距 (IQR),须线延伸至 $1.5 \times \text{IQR}$ 内的最值,之外为离群点。range_pct 的箱体集中在较低水平,但存在若干高位离群点,对应波动异常放大的交易日;ret_close 上下须外均有离群点,对应极端正负收益日 (如单日涨跌超过约 5%–7% 的交易日)。这说明原始数据中涨跌幅与振幅存在极端值,可能来自重大事件或流动性冲击;线性回归对离群值较敏感,建模时必要时可对尾部截尾或采用稳健方法,并在残差分析中关注这些点的影响。




图 2: 正态性: 交易量对数转换前后对比 (直方图与 QQ 图)

原始数据说明: 原始交易量 `volume_k` 以“千”为单位, 数值多为正且跨度大, 分布往往右偏 (少数交易日放量导致长右尾), 直接用于回归或假设检验时可能违背正态性假设。

结果分析: 左列为 `volume_k` 的直方图与 QQ 图。直方图呈明显右偏, 右侧拖尾较长; QQ 图中点在中段大致沿参考线, 两端尤其是右端明显上翘, 偏离“理论正态线”, 说明右尾比正态分布更厚。右列为 `log1p(volume_k)` 的直方图与 QQ 图。对数转换后直方图更接近钟形, QQ 图上的点整体更贴近对角线, 右端偏离减轻。结论: 对数转换可改善交易量的正态性、减轻右偏, 便于后续将其纳入线性模型或进行基于正态的推断; 若不对转换, 大成交量交易日可能对回归系数与残差产生较大影响。




图 3: 日收益率分布（直方图叠加正态曲线与 QQ 图）

原始数据说明：日收益率 `ret_close` 由原始收盘价序列计算得到，反映指数日度回报。金融中日收益率通常具有“尖峰厚尾”特征：多数交易日收益接近 0，但极端正负收益出现的概率高于正态分布所预测。

结果分析：直方图中心在 0 附近，大部分观测集中在均值两侧，但相比叠加的正态曲线，经验分布峰部更尖、两侧尾部更厚，即“尖峰厚尾”。QQ 图在中间段大致沿对角线，但在左端下弯、右端上翘，对应负收益与正收益的厚尾：极端负收益与极端正收益均多于正态假设下的预期。这与表3 中偏度 0.46、峰度 12.07 的结论一致，说明日收益率明显偏离正态分布。含义：若以 OLS 做回归，残差也可能呈现类似非正态与厚尾，假设检验与置信区间依赖正态假设时需谨慎；可结合残差图与稳健标准误，或考虑对收益率做变换/使用稳健回归方法。

5.6 相关性分析的结果与分析




图 4: 数值型变量相关系数热力图

原始数据说明: 参与相关矩阵的变量包括收盘、开盘、高、低、volume_k、ret_close、range_pct、oc_pct 等数值列，均为原始或衍生后的连续变量，便于计算 Pearson 相关系数。

结果分析: 热力图中颜色深浅表示相关系数绝对值大小。可观察到: oc_pct (开收差) 与 ret_close (日收益率) 高度正相关，因二者均反映当日涨跌方向与幅度; range_pct (振幅) 与当日绝对收益率 (或与 ret_close 的某种度量) 往往呈正相关，即波动大的交易日其绝对收益的绝对值也倾向于较大; volume_k (交易量) 与其他变量的线性相关相对较弱。这些关系为回归中纳入 range_pct、oc_pct 等特征提供了依据; 同时 oc_pct 与 ret_close 高度相关可能带来多重共线性，回归系数解释时需注意，可结合 VIF 或变量选择进一步分析。




图 5: 振幅与成交量散点图

原始数据说明：横轴为当日振幅 `range_pct`，纵轴为交易量 `volume_k`（或绝对收益率等）；每个点对应一个交易日，可观察“波动幅度”与“成交活跃度”或“绝对收益”之间的散点形态。

结果分析：若点云呈从左下到右上的带状趋势，说明振幅较大时成交量或绝对收益往往较大，符合“波动放大时交投更活跃”的直觉；若整体趋势不明显或呈非线性，则线性相关系数较弱。本实验散点图若关系较弱，与多元回归中 `volume_k` 系数接近 0 的结果一致，即线性意义上成交量对下一日收益率的边际解释力有限。散点图还可帮助识别远离点云的离群日，便于在建模或结果解读时单独关注。

5.7 简单线性回归分析的结果与分析

多元线性回归以当日 `ret_close`、`range_pct`、`oc_pct`、`volume_k` 为自变量，下一日收益率为因变量，回归系数与模型评估见表4 与表5。回归方程为：

$$y = -0.001633 - 0.0970 \times \text{ret_close} + 0.1063 \times \text{range_pct} + 0.2380 \times \text{oc_pct} + 0 \times \text{volume_k}$$

测试集 R^2 为负，说明模型在样本外解释力很弱，甚至逊于用均值预测；`volume_k` 系数接近 0，与相关性及散点图中成交量与收益线性关系较弱的结论一致。

表 4: 多元线性回归系数与截距

变量	系数
截距 (intercept)	-0.001633
<code>ret_close</code>	-0.0970
<code>range_pct</code>	0.1063
<code>oc_pct</code>	0.2380
<code>volume_k</code>	≈ 0

表 5: 多元线性回归模型评估 (Train / Test)

指标	训练集	测试集
MSE	0.000118	0.000092
MAE	0.00725	0.00758
R^2	0.0259	-0.0586




图 6: 多元线性回归残差图

原始数据说明：残差为测试集上的“真实下一日收益率 - 模型预测值”；横轴可为预测值 y_{hat} 或自变量 range_pct ，纵轴为残差。若模型设定与同方差假设成立，残差应围绕 0 随机波动且波动幅度不随横轴系统性变化。

结果分析：左图（预测值 vs 残差）用于检查残差是否随预测值增大而出现“喇叭口”或“漏斗形”，即异方差。右图（ range_pct vs 残差）用于检查残差方差是否随振幅增大而增大。若两图中残差在 0 线两侧大致均匀、带状宽度稳定，则同方差假设大致成立；若在高预测值或高 range_pct 一侧残差绝对值明显变大，则存在异方差，OLS 标准误可能低估，可考虑稳健标准误或加权最小二乘。此外，日收益率本身具有厚尾特征，残差也可能出现少量远离 0 的点，需结合 Breusch-Pagan 检验综合判断。

5.8 同方差与异方差的结果与分析

经典线性回归假设之一为同方差（残差方差恒定）。若残差图呈“喇叭口”或“漏斗形”，即残差绝对值随预测值或自变量增大而增大，则存在异方差。Breusch-Pagan 检验以残差平方对自变量做辅助回归，LM 或 F 的 p-value 若小于 0.05，则拒绝同方差假设。本实验对 Test 集残差做 Breusch-Pagan 检验：若 $p < 0.05$ ，则存在异方差，OLS 标准误不可靠，可考虑稳健标准误（如 White、HC）或加权最小二乘（WLS）；若 $p \geq 0.05$ ，则未拒绝同方差假设，残差方差相对稳定。结合残差图与检验结果综合判断。




图 7: 一元线性回归残差图 (range_pct → abs_ret)

原始数据说明:一元回归以当日振幅 `range_pct` 为自变量、当日绝对收益率 `abs_ret` (`|ret_close|`) 为因变量，用于演示手工计算 β_0 、 β_1 及残差图解读。二者在定义上存在内在联系：振幅大时当日涨跌幅的绝对值往往也较大，故线性相关较强。

结果分析:手工计算得 $R^2 \approx 0.58$, $MSE \approx 2.59 \times 10^{-5}$ 。 R^2 较高主要因为 `range_pct` 与 `abs_ret` 存在内生相关,并非单纯的预测关系,预测意义有限。残差图横轴为 `range_pct`, 纵轴为残差。若残差随 `range_pct` 增大而上下分散程度加大（喇叭口），则存在异方差；若在 0 线两侧大致均匀、带宽稳定，则同方差假设相对可接受。可与多元回归残差图对比：多元回归预测的是“下一日收益率”，一元回归解释的是“当日绝对收益”，二者残差结构可能不同，便于理解不同设定下同方差假设是否成立。

6 实验总结

1. **数据清洗:**完成日期、交易量、涨跌幅的类型转换与衍生特征 (`ret_close`、`range_pct`、`oc_pct`) 构建；缺失仅首日两列，已在建模时 `dropna` 处理。
2. **缺失与正态性:**缺失数据统计表明确各列缺失情况；正态性检验（Shapiro-Wilk、D'Agostino K^2 ）表明日收益率拒绝正态性，交易量经 `log1p` 转换后更接近正态。
3. **描述性统计与分布:**收盘价分布较对称；日收益率尖峰厚尾、偏度约 0.46、峰度约 12.07。

4. **可视化与离群值：**箱线图显示 `ret_close`、`range_pct` 存在离群值；对数转换与收益率 QQ 图验证了正态性讨论；热力图与散点图揭示了变量间关系，为回归变量选择提供依据。
5. **回归与评估：**多元线性回归得到回归方程及 Train/Test 的 MSE、MAE、 R^2 ；时间序列前 80%/后 20% 划分；测试集 R^2 为负，说明简单线性模型对下一日收益的样本外预测能力不足；一元回归 R^2 较高但与内生性有关，预测意义有限。
6. **同方差与异方差：**通过残差图可初步诊断同方差；Breusch-Pagan 检验可正式检验异方差；若存在异方差或厚尾，可考虑稳健标准误、加权最小二乘或非线性/稳健模型。
7. **局限性：**`range_pct` 与 `abs_ret` 存在内生相关；更规范做法可尝试前日特征预测当日收益或 CAPM 等模型；可扩展方向包括技术指标、滚动窗口、非线性模型（如随机森林/GBDT）及残差结构对比。