

A decorative border of various school and study-related items surrounds the central text. On the left, there is a stack of books, a calculator, a pencil, a compass, a protractor, a ruler, a small apple, a notepad with the equation $E=mc^2$, and a desk lamp. On the right, there is a desk with a chair, a clock, a telescope on a tripod, a palm tree, a CD, a briefcase, and an open book. The items are drawn in a simple, sketchy style.

SVM 支持向量机


毛亚文

2025年11月17日

目录

- 第一单元：什么是SVM
- 第二单元：公式推导证明（拉格朗日，对偶）
- 第三单元：SMO算法
- 第四单元：软间隔和正则化
- 第五单元：核函数和核方法
- 第六单元：支持向量回归




A decorative border surrounds the central text, featuring various school and study-related items. On the left, there is a calculator, a pencil, a compass, a ruler, a protractor, a pencil sharpener, an apple, a book with the formula $E=mc^2$, and a desk lamp. On the right, there is a desk with a chair, a clock, a telescope, a palm tree, a paper airplane, a briefcase, a backpack, and a stack of books. The background is a light gray with a subtle pattern of small dots.

第一单元

划分领地

——什么是SVM


什么是SVM?



支持向量机 (support vector machines, SVM) 是一种二分类模型，它将实例的特征向量映射为空间中的一些点，SVM 的目的就是想要画出一条线，以“最好地”区分这两类点，以至如果以后有了新的点，这条线也能做出很好的分类。SVM 适合中小型数据样本、非线性、高维的分类问题。



什么是SVM?



1. 超平面: $f(x) = w^T x + b$

当 $f(x)$ 等于0的时候, x 是位于超平面上的点;
而 $f(x) > 0$ 的点对应 $y=1$ 的数据点; $f(x) < 0$
的点对应 $y=-1$ 的点。

间隔: 数据集中所有的点到超平面的最小距离的2倍, 称为分类器或数据集的间隔



2. 支持向量: 就是离分隔超平面最近的那些点

目标: 找到一个最优的分离超平面, 尽可能地降低(对新数据)分类的错误率。直观的讲, 就是希望数据集中的样本离这个超平面的距离越远越好。



什么是SVM?

■ 函数间隔和几何间隔:

- 样本 $(\mathbf{x}_i, y_i)$ 到超平面 $(\mathbf{w}, b)$ 的函数间隔: $l_i = y_i (\mathbf{w}^T \mathbf{x}_i + b)$
- 样本 $(\mathbf{x}_i, y_i)$ 到超平面 $(\mathbf{w}, b)$ 的几何间隔: $r_i = \frac{1}{\|\mathbf{w}\|} y_i (\mathbf{w}^T \mathbf{x}_i + b)$
- 数据集 $\mathbf{X}$ 到超平面 $(\mathbf{w}, b)$ 的函数间隔定义为: 所有样本的函数间隔的最小值, 即

$$l = \min_{i=1, \dots, N} l_i$$

- 数据集 $\mathbf{X}$ 到超平面 $(\mathbf{w}, b)$ 的几何间隔定义为: 所有样本的几何间隔的最小值, 即

$$r = \min_{i=1, \dots, N} r_i \quad \longrightarrow \quad \max_{\mathbf{w}, b} r$$
$$s. t. \frac{1}{\|\mathbf{w}\|} y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq r, i = 1, \dots, N$$

注意到, 若将 w 和 b 同比例缩放, 不会改变超平面的方程, 也不会改变样本到超平面的几何间隔, 但会改变函数间隔。设函数间隔 $l = r\|\mathbf{w}\| = 1$,

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|}$$
$$s. t. y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0, i = 1, \dots, N$$



第二单元

怎么划分领地

——公式推导证明



公式推导证明

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, n$$

利用拉格朗日乘子得到其对偶问题:

$$\min_{w,b} \max_{\alpha \geq 0} L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$

$$\text{s.t. } y_i (w^T x_i + b) \geq 1$$



$$\max_{\alpha \geq 0} \min_{w,b} L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$
$$\text{s.t. } y_i (w^T x_i + b) \geq 1$$

KKT条件与Slater条件

$$\frac{\partial L}{\partial w} = 0 \rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$



公式推导证明

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) \xleftarrow{\text{代入}} \frac{\partial L}{\partial w} = 0 \rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i \quad \frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

最终求解问题:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{s.t.} \quad & \alpha_i \geq 0, \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned} \quad \begin{aligned} f(x) &= w^T x + b \\ &= \sum_{i=1}^n \alpha_i y_i (x_i)^T x + b \end{aligned}$$





KKT与Slater

KKT:

原问题是凸优化问题，且存在绝对可行点，所谓绝对可行点就是使得约束条件中的等式约束都成立，不等式约束都不取等号地成立的点。

- [1] $L(w, b, \alpha)$ 在 w, b 两处的偏导为0;
- [2] $\alpha_i(1 - y_i(w^T x_i + b)) = 0, i = 1, 2, \dots, n$;
- [3] $y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, n$;
- [4] $\alpha_i \geq 0, i = 1, 2, \dots, n$;




Slater:

对于硬间隔SVM，原始问题是凸的。Slater条件要求存在一个 $(\tilde{\mathbf{w}}, \tilde{b})$ 使得：

$$y_i(\tilde{\mathbf{w}} \cdot \mathbf{x}_i + \tilde{b}) > 1, \quad \forall i$$

这意味着存在一个超平面，能够完全将两类数据分开，并且所有数据点都至少离开间隔边界一段正距离。这正好对应于数据集是线性可分的情况。

- 如果数据是线性可分的，Slater条件成立 $\Rightarrow$ 强对偶性成立 $\Rightarrow$ KKT条件是必要且充分的。
- 如果数据不是线性可分的（即我们后面要引入软间隔SVM的情况），硬间隔SVM的原始问题本身不可行，Slater条件不适用。此时我们需要使用软间隔形式，并可以证明其仍然满足强对偶性。

The slide features a light gray background with a decorative border of hand-drawn school supplies. On the left, there is a calculator, a notebook, a pencil, an apple, a ruler, and a small book with the formula $E=mc^2$. On the right, there is a desk with a clock, a telescope, a palm tree, a paper airplane, a CD, a briefcase, and an open book. In the center, a balance scale is depicted with a large arrow pointing to the right, which contains the text '第三单元'.

第三单元

挖河

——SMO算法

SMO

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t. \quad \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$



$$\min_{\alpha} \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i$$

$$s.t. \quad \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

SMO算法:

如果所有变量的解都满足此优化问题的KKT条件，那么这个最优化问题的解就得到了。否则，选择两个变量，固定其他变量，针对这两个变量构建一个二次规划问题。子问题的两个变量，一个是违反KKT条件最严重的那一个，另一个由约束条件自动确定。如此，SMO算法将原问题不断分解为子问题求解，进而达到求解原问题的目的。



SMO

$$f(\alpha_1, \alpha_2) = \frac{1}{2}K_{11}\alpha_1^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_1y_2K_{12}\alpha_1\alpha_2 + y_1\alpha_1v_1 + y_2\alpha_2v_2 - \alpha_1 - \alpha_2 + r$$

$$\begin{cases} v_1 = \sum_{i=3}^n y_i \alpha_i^* K_{i1} \\ v_2 = \sum_{i=3}^n y_i \alpha_i^* K_{i2} \end{cases} \quad \begin{cases} 0 \leq \alpha_1 \leq C \\ 0 \leq \alpha_2 \leq C \\ y_1\alpha_1 + y_2\alpha_2 = -\sum_{i=3}^n y_i \alpha_i = \gamma \end{cases}$$

迭代求出所有乘子的值, 再根据支持向量 (x_s, y_s) 满足 $y_s f(x_s) = 1$ 求出偏移项 b (均值)

超平面:

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle x_i, x \rangle + b$$

第四单元

找间谍
——软间隔和正则化

软间隔和正则化

可换成正则项

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n l_a(y_i(w^T x_i + b) - 1)$$

hinge损失

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\min \frac{1}{2} \|w\|^2 + C \sum \xi_i$$

s.t

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

- 0/1损失
- hinge损失 $l_a(z) = \max(0, 1 - z)$
- 指数损失
- 对率损失




Fig. 1(a)




Fig. 1(b)



软间隔和正则化

$$L(W, b, \alpha, \xi, C, \mu) = \frac{1}{2} \|W\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (1 - \xi_i - y_i (W X_i + b)) - \sum_{i=1}^n \mu_i \xi_i$$

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j X_i^T X_j \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C \\ & \sum_{j=1}^m \alpha_i y_i = 0 \end{aligned}$$



软间隔和正则化

$$p^* = \min_{W, b, \xi} \max_{\alpha, \mu} L(W, b, \alpha, \xi, C, \mu)$$

$$d^* = \max_{\alpha, \mu} \min_{W, b, \xi} L(W, b, \alpha, \xi, C, \mu)$$

$$\frac{\partial L}{\partial W} = 0 \Rightarrow W = \sum_{i=1}^n \alpha_i y_i X_i^T$$


$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C - \alpha_i - \mu_i = 0$$

$$\max_{\alpha, \mu} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j X_i^T X_j$$

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j X_i^T X_j \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C \\ & \sum_{j=1}^m \alpha_j y_j = 0 \end{aligned}$$






第五单元

非线性分类

核函数与核方法




核函数与核方法



- 线性分类方法求解非线性分类问题大致可分为两步：首先使用一个变换将原空间的数据映射至新空间；然后在新空间里用线性分类学习方法对数据进行分类，核技巧就属于这样的方法。

同一类别在纵轴上同时提高或下降的操作应该如何实现？



- 核技巧的基本思想就是通过一个非线性变换将输入空间映射至特征空间，使得输入空间的超曲面模型对应于特征空间的超平面模型，这样，就可以通过在特征空间利用线性支持向量机求解分类问题。





核函数与核方法


对偶问题：

$$\begin{aligned}
 & \min_{\alpha} \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i \\
 & \quad \downarrow \\
 & \min_{\alpha} \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \varphi(x_i)^T \varphi(x_j) - \sum_{i=1}^n \alpha_i \\
 & \quad \downarrow \\
 & \min_{\alpha} \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^n \alpha_i \\
 & \quad \downarrow \\
 & f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b
 \end{aligned}$$

- **核函数**：是映射关系 $\varphi(x)$ 的内积 ($K(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$)，映射函数本身仅仅是一种映射关系，并没有增加维度的特性，不过可以利用核函数的特性，构造可以增加维度的核函数。**核函数和映射没有关系。核函数只是用来计算映射到高维空间之后的内积的一种简便方法。**
- 如果有一个待求解的非线性分类问题，我们没有必要去计算其对应特征空间中的内积，只需要找到这个非线性分类问题对应的核函数，将输入空间的数据代入核函数中，便可求得该问题的解。（**核函数的选择要合适，如何判断是否为核函数：对称函数对应的核矩阵半正定**）

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$





第六单元

SVM应用

支持向量回归



岭回归 vs Lasso

1. 岭回归:

岭回归使用 **L2范数的平方** (即 $\|\mathbf{w}\|_2^2$) 作为正则化项。其目标是:

$$\min_{\mathbf{w}} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{z}_i - y_i)^2 + \lambda \|\mathbf{w}\|_2^2$$

关键特性: 岭回归的损失函数是**处处可微的**, 因此通常有解析解, 并且求解稳定。它倾向于将权重缩小 towards zero but not exactly to zero。

2. Lasso回归:

Lasso回归使用 **L1范数** (即 $\|\mathbf{w}\|_1$) 作为正则化项。其目标是:

$$\min_{\mathbf{w}} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{z}_i - y_i)^2 + \lambda \|\mathbf{w}\|_1$$

关键特性: Lasso回归的损失函数在零点不可微, 倾向于产生**稀疏解**, 即它会将一部分特征的权重**精确地** 压缩到0, 从而实现特征选择。






Fig. 1 中的坐标系表示 $\mathbf{w}$ 的两维，一圈又一圈的椭圆表示函数 $J = \frac{1}{n} \sum_{i=1}^n (\mathbf{w}^\top \mathbf{x}_i - y_i)^2$ 的等高线，椭圆越往外， J 的值越大， $\mathbf{w}^*$ 表示使得损失 J 取得全局最优的值。使用 Gradient descent，也就是让 $\mathbf{w}$ 向着 $\mathbf{w}^*$ 的位置走。如果没有 L1 或者 L2 正则化约束， $\mathbf{w}^*$ 是可以被取到的。但是，由于有了约束 $\|\mathbf{w}\|_1 \leq t$ 或 $\|\mathbf{w}\|_2^2 \leq t$ ， $\mathbf{w}$ 的取值只能限制在 Fig. 1 所示的灰色方形和圆形区域。当然调整 t 的值，我们能够扩大这两个区域。





支持向量回归

1. 核线性回归

$$\min_{\mathbf{w}} \quad \frac{\lambda}{n} \mathbf{w}^T \mathbf{w} + \frac{1}{n} \sum_{i=1}^n \text{err}(y_i, \mathbf{w}^T \mathbf{z}_i)$$

其中最优的 $\mathbf{w}_* = \sum_{i=1}^n \beta_i \mathbf{z}_i$

首先写出原始的带正则项的线性回归并进行核化，然后写成矩阵的形式：

$$\begin{aligned} & \min_{\mathbf{w}} \quad \frac{\lambda}{n} \mathbf{w}^T \mathbf{w} + \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{z}_i)^2 \\ \Rightarrow & \min_{\beta} \quad \frac{\lambda}{n} \sum_{i=1}^n \sum_{j=1}^n \beta_i \beta_j K(\mathbf{x}_i, \mathbf{x}_j) + \frac{1}{n} \sum_{i=1}^n (y_i - \sum_{j=1}^n \beta_j K(\mathbf{x}_i, \mathbf{x}_j))^2 \\ \Rightarrow & \min_{\beta} \quad \frac{\lambda}{n} \beta^T \mathbf{K} \beta + \frac{1}{n} \|\mathbf{y} - \mathbf{K} \beta\|^2 \\ \Rightarrow & \min_{\beta} \quad \frac{\lambda}{n} \beta^T \mathbf{K} \beta + \frac{1}{n} (\beta^T \mathbf{K}^T \mathbf{K} \beta - 2 \beta^T \mathbf{K}^T \mathbf{y} + \mathbf{y}^T \mathbf{y}) \end{aligned}$$

对 β 求偏导，令偏导为0得：

$$\begin{aligned} \nabla E_{\text{aug}}(\beta) &= \frac{2}{n} (\lambda \mathbf{K}^T \mathbf{I} \beta + \mathbf{K}^T \mathbf{K} \beta - \mathbf{K}^T \mathbf{y}) = \frac{2}{n} \mathbf{K}^T ((\lambda \mathbf{I} + \mathbf{K}) \beta - \mathbf{y}) = 0 \\ \Rightarrow & \beta = (\lambda \mathbf{I} + \mathbf{K})^{-1} \mathbf{y} \end{aligned}$$

$$O(n^3)$$

2. 带正则项的线性回归

$$\min_{\mathbf{w}} \quad \sum_{i=1}^n (\mathbf{w}^T \mathbf{z}_i - y_i)^2 + \lambda \|\mathbf{w}\|_2^2$$

$$J(\mathbf{w}) = (\mathbf{y} - \mathbf{X} \mathbf{w})^T (\mathbf{y} - \mathbf{X} \mathbf{w}) + \lambda \|\mathbf{w}\|^2$$


$$\mathbf{w} = (\lambda \mathbf{I} + \mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$$O(d^3 + d^2 n)$$






支持向量回归



- 传统的回归模型采用的是模型输出 $f(x)$ 与真实值 y 之间的差别计算损失，只有二者完全相同的时候，损失才为0。这样可能太苛刻了，如果适当放宽条件，假设 $f(x)$ 和 y 之间最多有 ϵ 的差距，即当 $|f(x) - y| > \epsilon$ 时才计算损失，即

$$\text{error}(y, f(\mathbf{x})) = \max(0, |f(\mathbf{x}) - y| - \epsilon)$$

这种回归任务称为管道（tube）回归。



- tube 目标函数：

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n \max(0, |\mathbf{w}^T \mathbf{x}_i + b - y_i| - \epsilon)$$





支持向量回归

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n \max(0, |\mathbf{w}^T \mathbf{x}_i + b - y_i| - \epsilon) \longrightarrow \min_{\mathbf{w}, b, \xi} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n \xi_i \longrightarrow \min_{\mathbf{w}, b, \xi^\vee, \xi^\wedge} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n (\xi_i^\vee + \xi_i^\wedge)$$

$$\text{s. t. } |y_i - (\mathbf{w}^T \mathbf{x}_i + b)| \leq \epsilon + \xi_i \quad \text{s. t. } -\epsilon - \xi_i^\vee \leq y_i - (\mathbf{w}^T \mathbf{x}_i + b) \leq \epsilon + \xi_i^\wedge$$

$$\xi_i \geq 0, \quad \xi_i^\vee \geq 0, \quad \xi_i^\wedge \geq 0$$

对偶问题

$$\mathcal{L}(\mathbf{w}, b, \xi^\vee, \xi^\wedge, \alpha^\vee, \alpha^\wedge, \beta^\vee, \beta^\wedge) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n (\xi_i^\vee + \xi_i^\wedge) + \sum_{i=1}^n \alpha_i^\wedge (y_i - (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^\wedge)$$

$$+ \sum_{i=1}^n \alpha_i^\vee (-y_i + (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^\vee) - \sum_{i=1}^n \beta_i^\wedge \xi_i^\wedge - \sum_{i=1}^n \beta_i^\vee \xi_i^\vee$$

求偏导代入

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \alpha_i^\wedge \mathbf{x}_i + \sum_{i=1}^n \alpha_i^\vee \mathbf{x}_i = 0$$

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_{i=1}^n \alpha_i^\wedge + \sum_{i=1}^n \alpha_i^\vee = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i^\wedge} = C - \alpha_i^\wedge - \beta_i^\wedge = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i^\vee} = C - \alpha_i^\vee - \beta_i^\vee = 0$$

$$\max_{\alpha^\vee, \alpha^\wedge} \sum_{i=1}^n y_i (\alpha_i^\wedge - \alpha_i^\vee) - \epsilon (\alpha_i^\wedge + \alpha_i^\vee) - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^\wedge - \alpha_i^\vee) (\alpha_j^\wedge - \alpha_j^\vee) \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s. t. } \sum_{i=1}^n (\alpha_i^\vee - \alpha_i^\wedge) = 0$$

$$0 < \alpha_i^\wedge, \alpha_i^\vee < C$$

$$\alpha_i^\wedge \alpha_i^\vee = 0; \quad \xi_i^\wedge \xi_i^\vee = 0$$

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

$$= \sum_{i=1}^n (\alpha_i^\wedge - \alpha_i^\vee) \mathbf{x}_i^T \mathbf{x} + b$$

$$= \sum_{i=1}^n (\alpha_i^\wedge - \alpha_i^\vee) \mathbf{K}(\mathbf{x}_i, \mathbf{x}) + b$$



支持向量回归

$$\max_{\alpha^V, \alpha^A} \sum_{i=1}^n y_i (\alpha_i^A - \alpha_i^V) - \epsilon (\alpha_i^A + \alpha_i^V) - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^A - \alpha_i^V) (\alpha_j^A - \alpha_j^V) \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s. t. } \sum_{i=1}^n (\alpha_i^V - \alpha_i^A) = 0$$

$$0 \leq \alpha_i^A, \alpha_i^V \leq C$$

$$\alpha_i^A \alpha_i^V = 0; \quad \xi_i^A \xi_i^V = 0$$

$$\begin{aligned} f(\mathbf{x}) &= \mathbf{w}^T \mathbf{x} + b \\ &= \sum_{i=1}^n (\alpha_i^A - \alpha_i^V) \mathbf{x}_i^T \mathbf{x} + b \end{aligned}$$

$$\begin{aligned} \mathcal{L}(\mathbf{w}, b, \xi^V, \xi^A, \alpha^V, \alpha^A, \beta^V, \beta^A) &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n (\xi_i^V + \xi_i^A) + \sum_{i=1}^n \alpha_i^A (y_i - (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^A) \\ &\quad + \sum_{i=1}^n \alpha_i^V (-y_i + (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^V) - \sum_{i=1}^n \beta_i^A \xi_i^A - \sum_{i=1}^n \beta_i^V \xi_i^V \end{aligned}$$

- **解的稀疏性**：仅当样本不落入 ϵ -间隔带中，相应的 α_i^A 和 α_i^V 才能取非零值。
- 能使 $(\alpha_i^A - \alpha_i^V) \neq 0$ 的样本即为支持向量回归的**支持向量**，且**必落在 ϵ -间隔带外**。也就是说支持向量回归仅是训练样本中的一部分，因此它的解具有稀疏性。

对于管道中样本的松弛性可以有以下推导：

$$\begin{aligned} &|\mathbf{w}^T \mathbf{x}_i + b - y_i| < \epsilon \\ \Rightarrow &\xi_i^V = \xi_i^A = 0 \\ \Rightarrow &y_i - (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^A \neq 0; \quad -y_i + (\mathbf{w}^T \mathbf{x}_i + b) - \epsilon - \xi_i^V \neq 0; \\ \Rightarrow &\alpha_i^A = 0; \quad \alpha_i^V = 0 \\ \Rightarrow &\beta_i = \alpha_i^A - \alpha_i^V = 0 \end{aligned}$$



总结

求最优超平面: $w^T \cdot x + b$ (即求其中的 w 、 b 参数)

⇓

求最大几何间隔: $\max \frac{2}{\|w\|} \quad s.t., y_i(w^T \cdot x_i + b) \geq 1, i = 1, \dots, n$ (n 为训练样本数)

⇓

求最大几何间隔: $\min \frac{1}{2} \|w\|^2 \quad s.t., y_i(w^T \cdot x_i + b) \geq 1, i = 1, \dots, n$ (n 为训练样本数)

⇓

把约束条件融合到优化目标函数中, 建立拉格朗日公式:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) \quad s.t., \alpha_i \geq 0$$

⇓

优化目标变为: $\min_{w, b} (\max_{\alpha_i \geq 0} L(w, b, \alpha))$

⇓ 满足 KKT 条件

求对偶问题: $\max_{\alpha_i \geq 0} (\min_{w, b} L(w, b, \alpha))$

⇓

对 w, b 求极小值, 即对 w 和 b 求偏导, 并令其值为 0, 则得:

$$w = \sum_{i=1}^n \alpha_i y_i x_i \quad \sum_{i=1}^n \alpha_i y_i = 0$$

⇓

把 w 和 b 代入 $L(w, b, \alpha)$, 则得:

$$\max_{\alpha_i \geq 0} W(\alpha) = \max_{\alpha_i \geq 0} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \right), \quad s.t., \sum_{i=1}^n \alpha_i y_i = 0$$

注: $K(x_j, x_i) = x_j^T x_i$, 表示向量内积

⇓

对 α_i 求导, 即可求出 $W(\alpha)$ 的极大值, 采用 SMO 方法




无论SVM还是SVR，不考虑偏移项 b ，学到的模型总能表示成核函数的线性组合，因此可以通过“核方法”将线性学习器拓展为非线性学习器




蚩尤


一条河




$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b$$



$$\begin{aligned} f(\mathbf{x}) &= \mathbf{w}^T \mathbf{x} + b \\ &= \sum_{i=1}^n (\alpha_i^{\wedge} - \alpha_i^{\vee}) \mathbf{K}(\mathbf{x}_i, \mathbf{x}) + b \end{aligned}$$



谢谢！



公式推导

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) \\ &= \frac{1}{2} w^T w - \sum_{i=1}^n \alpha_i y_i w^T x_i - \sum \alpha_i y_i b + \sum \alpha_i \\ &= \frac{1}{2} w^T \sum \alpha_i y_i x_i - \sum_{i=1}^n \alpha_i y_i w^T x_i - \sum \alpha_i y_i b + \sum \alpha_i \\ &= -\frac{1}{2} w^T \sum \alpha_i y_i x_i - \sum \alpha_i y_i b + \sum \alpha_i \\ &= -\frac{1}{2} \left(\sum \alpha_i y_i x_i \right)^T \sum \alpha_i y_i x_i - \sum \alpha_i y_i b + \sum \alpha_i \end{aligned}$$



公式推导

$$\begin{aligned} L(w, b, \alpha) &= -\frac{1}{2} \left(\sum \alpha_i y_i x_i \right)^T \sum \alpha_i y_i x_i - \sum \alpha_i y_i b + \sum \alpha_i \\ &= -\frac{1}{2} \sum \alpha_i y_i (x_i)^T \sum \alpha_i y_i x_i - \sum \alpha_i y_i b + \sum \alpha_i \\ &= -\frac{1}{2} \sum_{i=1, j=1}^n \alpha_i y_i (x_i)^T \alpha_j y_j x_j - \sum \alpha_i y_i b + \sum \alpha_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j (x_i)^T x_j \end{aligned}$$



- 面先从小例子来阐述问题。假设我们有两个数据， $x = (x_1, x_2, x_3)$ $y = (y_1, y_2, y_3)$ 。此时在3D空间已经不能对其进行线性划分了，那么我们通过一个函数将数据映射到更高维的空间，比如9维的话，那么 $f(x) = (x_1x_1, x_1x_2, x_1x_3, x_2x_1, x_2x_2, x_2x_3, x_3x_1, x_3x_2, x_3x_3)$ ，由于需要计算内积，所以在新的数据在 9 维空间，需要计算 $\langle f(x), f(y) \rangle$ 的内积，需要花费 $O(n^2)$ 。
- 再具体点，令 $x = (1, 2, 3)$ ， $y = (4, 5, 6)$ ，那么 $f(x) = (1, 2, 3, 2, 4, 6, 3, 6, 9)$ ， $f(y) = (16, 20, 24, 20, 25, 36, 24, 30, 36)$

$$\text{此时： } \langle f(x), f(y) \rangle = 16 + 40 + 72 + 40 + 100 + 180 + 72 + 180 + 324 = 1024$$

我们发现 $K(x, y) = (\langle x, y \rangle)^2$ ，代入上式： $K(x, y) = (4 + 10 + 18)^2 = 32^2 = 1024$ ，也就是说： $K(x, y) = (\langle x, y \rangle)^2 = \langle f(x), f(y) \rangle$ 。

- 但是 $K(x, y)$ 计算起来却比 $\langle f(x), f(y) \rangle$ 简单的多，也就是说只要用 $K(x, y)$ 来计算，效果与 $\langle f(x), f(y) \rangle$ 是一样的，但是计算效率却大幅度提高了，如 $K(x, y)$ 是 $O(n)$ ，而 $\langle f(x), f(y) \rangle$ 是 $O(n^2)$ ，所以使用核函数的好处就是，可以在一个低维空间去完成一个高纬度（或者无限维度）样本内积的计算，比如上面例子中 $K(x, y)$ 的3D空间对比 $\langle f(x), f(y) \rangle$ 的9D空间。

