

FCM算法中权重指数m的研究

许磊, 吴晓娟

山东大学山东大学信息科学与工程学院 (250100)

E-mail: xuleisdu@sina.com

摘要: 模糊c均值算法(FCM)是最常用的聚类算法之一。使用模糊c均值算法时, 选取恰当的权重指数(m)是非常重要的。本文通过推导证明, 得出权重指数m不仅决定FCM算法的聚类模糊程度和样本在类间的分享程度, 而且还影响目标函数的凹凸性及算法的收敛性。

关键词: 权重指数; 硬C均值算法; 模糊c均值算法; 划分熵

1. 引言

模糊聚类是无监督模式识别中的一个重要部分, 在模式分类、图像处理和模糊规则提取等众多的领域中获得了广泛的应用^[1]。在众多的聚类算法中, 模糊c均值(FCM)算法是最重要也是最为人们熟悉的方法之一。FCM算法是一种调整划分方法, 通过目标函数 J_m 极小化的必要条件之间的Pickard迭代来实现, 其中m称为加权指数。当m=1时, J_1 是著名的类内加权均方误差和目标函数, 经常被用来定义硬c均值(HCM)算法和ISODATA算法^[2]。1973, Dunn^[3]首先把 J_1 扩展到 J_2 , 后来Bezdek又把 J_2 推广到了一个m的无限族 $\{J_m, 1 \leq m \leq \infty\}$ ^[4]。这些算法现已被成功地应用到了许多问题中, 包括特征分析, 聚类和分类器设计等。对于FCM算法目标函数 J_m 中加权指数m的影响, Bezdek认为“参数m控制着模糊类间的分享程度”^[1], 所以要实现FCM算法就必须选择一个合适的m值。在实际应用中, 大多数研究者认为m的最佳取值范围为[1.5, 2.5], 这与Pal等的实验结论一致^[5]。

2. 硬C均值算法(HCM)

研究模糊c均值(FCM)算法, 首先应该了解硬C均值 (HCM)算法。HCM算法是经典的硬聚类算法之一, 能够对超椭圆球状的数据进行分类。设 $X = \{x_1, x_2, \dots, x_n\} \subset R^s$, 其中的数据集 $x_i = [x_{1i}, x_{2i}, \dots, x_{si}] \in R^s$, n是数据集中元素的个数, c是聚类中心数($1 < c < n$), $d_{ij} = \|x_i - v_j\|$ 是样本 x_i 和聚类中心 v_j 的欧氏距离, $v_j \in R^s$ ($1 \leq j \leq c$)。 u_{ij} 是第i个样本到第j个聚类中心的隶属度, $U = [u_{ij}]$ 是一个 $c \times n$ 的矩阵, $V = [v_1, v_2, \dots, v_c]$ 是一个 $s \times c$ 的矩阵。

硬C均值聚类问题可表示成下面的数学规划问题:

$$\min J_1(U, c) = \sum_{i=1}^c \sum_{j=1}^n u_{ij} d_{ij}^2 \quad (1)$$

$$\sum_{j=1}^n u_{ij} = 1, \quad 1 \leq j \leq n \quad (2)$$

$$u_{ij} \in [0, 1], \quad 1 \leq j \leq n, 1 \leq i \leq c \quad (3)$$

$$n > \sum_{j=1}^n u_{ij} > 0, \quad 1 \leq i \leq c \quad (4)$$

上述数学规划问题可通过如下的算法来求解：

起始 迭代标准 $\varepsilon > 0$ ，初始分类 $V^{(0)}$ 和 $k = 0$ ；

步骤1 用下述公式计算 $U^{(k)}$

$$u_{ij}(k) = \begin{cases} 1 & d_{ij}(k) = \min d_{ir}(k) \\ 0 & \text{其它} \end{cases} \quad (5)$$

步骤2 用下述公式计算 $V^{(k+1)}$

$$\forall j \quad v_j(k+1) = \frac{\sum_{i=1}^n u_{ij}(k)x_j}{\sum_{i=1}^n u_{ij}(k)} \quad (6)$$

步骤3 用一个矩阵范数 $\|\bullet\|$ 比较 $V^{(k)}$ 与 $V^{(k+1)}$ ，若

$$\|V^{(k+1)} - V^{(k)}\| \leq \varepsilon \quad (7)$$

则停止迭代，否则置 $k=k+1$ ，转向步骤1。

上述方法也可以用初始化聚类中心 $U^{(0)}$ 来作为起始。

3. 模糊C均值聚类算法

Dunn依据Ruspini定义的集合的模糊划分概念，将HCM算法推广到模糊情形，如果不给隶属度 u_{ij} 乘一个权重，这种推广是无效的。而最简单和最直接的方法是将 u_{ij} 变成 u_{ij}^2 ，由此Dunn给出下面的模糊C均值聚类(FCM)算法：

$$\min J_2(U, c) = \sum_{i=1}^c \sum_{j=1}^n u_{ij}^2 d_{ij}^2 \quad (8)$$

$$\text{使得} \quad \sum_{i=1}^c u_{ij} = 1, \quad 1 \leq j \leq n \quad (9)$$

$$u_{ij} \in [0, 1], \quad 1 \leq j \leq n, 1 \leq i \leq c \quad (10)$$

$$n > \sum_{j=1}^n u_{ij} > 0, \quad 1 \leq i \leq c \quad (11)$$

我们将上述表达推广到更一般的情形，给出模糊聚类的一般描述，模糊聚类问题可表示成下面的数学规划问题：

$$\min J_m(U, c) = \sum_{i=1}^c \sum_{j=1}^n u_{ij}^2 d_{ij}^2 \quad (12)$$

$$\text{使得} \quad \sum_{i=1}^c u_{ij} = 1, \quad 1 \leq j \leq n \quad (13)$$

$$u_{ij} \in [0,1], 1 \leq j \leq n, 1 \leq i \leq c \quad (14)$$

$$n > \sum_{j=1}^n u_{ij} > 0 \quad 1 \leq i \leq c \quad (15)$$

这里 m 是权重因子($m > 1$),我们使用如下算法来解上述的数学规划问题。

起始 迭代标准 $\varepsilon > 0$, 初始分类 $V^{(0)}$, 和 $k = 0$;

步骤1 用下述公式计算 $U^{(k)}$, 如果 $\forall j, r, d_{rj}(k) > 0$, 则有

$$u_{ij} = 1 / \sum_{r=1}^c \left(\frac{d_{ij}(k)}{d_{rj}(k)} \right)^{\frac{2}{m-1}} \quad (16)$$

如果存在 j, r , 使得 $d_{rj}(k) = (0)$, 则令: $u_{ij}(k) = 1$ 且对 $i \neq r, u_{ij}(k) = 0$

步骤2 用下述公式计算 $V^{(k+1)}$

$$\forall i \quad v(k+1) = \frac{\sum_{j=1}^n u_{ij}^m(k) x_j}{\sum_{j=1}^n u_{ij}^m(k)} \quad (17)$$

步骤3 用一个矩阵范数 $\|\bullet\|$ 比较 $V^{(k)}$ 与 $V^{(k+1)}$, 若

$$\|V^{(k+1)} - V^{(k)}\| \leq \varepsilon \quad (18)$$

则停止迭代, 否则置 $k = k+1$, 转向步骤1。

上述方法也可以用初始化聚类中心 $U^{(0)}$ 来作为起始。该算法是收敛的, 其解点是问题FCL的局部最小点或鞍点。对于满足下述条件的解集 Ω , 上述算法可以收敛到一个局部最小点。

$$\begin{aligned} \forall \quad U \in M_{fnc}, J_m(U^*, V^*) \leq J_m(U, V^*) \\ V \in R^{sc}, J_m(U^*, V^*) \leq J_m(U, V^*) \end{aligned} \quad (19)$$

M_{fnc} 表示满足条件(13), (14), (15)的矩阵集合。

FCM算法是目前比较流行的一种模糊聚类算法, 究其原因大致由以下几个方面: 首先模糊C均值泛函 J_m 仍是由传统的硬C均值泛函 J_1 的自然推广, 我们知道, J_1 是一个应用十分广泛的聚类准则, 对其在理论上的研究已经相当完善, 这就为 J_m 的研究提供了良好的条件。数学上看, J_m 与 R^s 的希尔伯特空间结构(正交投影和均方逼近理论)有密切的关系, 因此 J_m 比其它泛函有更深厚的数学基础。

最后, 也是最重要的是它不仅在许多领域获得了非常成功的应用, 而且以FCM算法为基础, 人们提出基于其它原型的模糊聚类算法, 形成了一大批FCM类型的算法: 如模糊C线(FCL)、模糊C面(FCP)等聚类算法, 分别实现了对呈线状、超平面状结构模式子集(或聚类)的检测。

4. 加权指数 m 对FCM算法的影响

为了把硬C均值聚类中的目标函数扩展到模糊情形, 引入加权指数 m , 给出模糊C均值类型

聚类目标函数的普遍形式 $\{J_m(U, P), m \in [1, \infty]\}$ 。FCM算法通过极小化 J_m 而获得最佳聚类结果 (U^*, V^*) ，如果不考虑隶属函数和聚类原型与参数 m 的嵌套隐含关系，有

$$\begin{aligned}\frac{\partial J_m(U, V)}{\partial m} &= \sum_{i=1}^c \sum_{j=1}^n (\mu_{ij})^m \cdot \log(\mu_{ij}) \cdot (d_{ij})^2 \\ &= \sum_{i=1}^c \sum_{j=1}^n [\mu_{ij} \cdot \log(\mu_{ij})] \cdot [\mu_{ij}^{m-1} (d_{ij})^2] < 0\end{aligned}\quad (20)$$

从式(20)可知 J_m 的增加而单调递减。对应不同的 m 值，显然有不同的最佳模糊划分，因此，FCM算法对加权指数 m 存在聚类有效性问题。也就是说需要确定 m 为何值时 J_m 对应的聚类结果是最有效最合理的。可见参数 m 对FCM算法有重要影响。

为了研究参数 m 对FCM算法的影响，首先讨论对应于 m 可行解两端的情况，有如下定理：

定理1 对于 $m \in [1, \infty)$ 的FCM算法，存在以下情况：

- (1) 当 $m \rightarrow 1^+$ 时，FCM算法退化为HCM；
- (2) 当 $m = 1$ 时，FCM算法变成HCM；
- (3) 当 $m \rightarrow \infty$ 时，FCM算法的聚类结果是最模糊的，即 $u_{ij} = 1/c$ 。

从目标函数以及划分矩阵和聚类原型的迭代公式出发，易证定理1成立。为了衡量模糊聚类结果的模糊程度，根据信息熵的形式定义划分熵的公式：

定义 对于给定的聚类数 c 和划分矩阵 U ，其划分熵定义为：

$$H_m(U, c) = \frac{1}{n} \sum_{i=1}^c \sum_{j=1}^n u_{ij} \cdot \log_a \left(\frac{1}{u_{ij}} \right) \quad (21)$$

其中 $a \in (1, \infty)$ 为对数的底数，且约定 $u_{ij} = 0$ 时，有 $u_{ij} \cdot \log_a(u_{ij}) = 0$ 。对于模糊聚类问题，我们当然不满足于数据的硬划分，还想获得样本间的相近信息。在此前提下，样本集的划分越分明就越有利于分类，因此，对于给定的 m 值，总希望模糊聚类的划分熵越小越好。

加权指数 m 影响FCM算法的性能，因此也必然对聚类结果的划分熵产生影响，有关影响可由定理2来表述。

定理2 对于 $1 < c < n$ ， $m \in [1, \infty)$ 的FCM算法，其划分熵具有如下性质：

- (1) $0 < H_m(U, c) < \log_a c$ ；
- (2) 当 $m \rightarrow 1^+$ 时， $H_m(U, c) = 0 \Leftrightarrow U$ 是硬划分；
- (3) 当 $m = 1$ 时， $H_m(U, c)$ 以概率1趋近于0；
- (4) 当 $m \rightarrow \infty$ 时， $H_m(U, c) = \log_a c \Leftrightarrow U = [1/c]$ 。

定理2的证明可以从定理1的结论导出。显然，参数 m 控制着FCM聚类结果的模糊性，而且 m 越大聚类结果越模糊，在 m 可行解的两端分别对应着划分熵的最大值与最小值。由于我们希望的聚类结果不要太模糊，这种要求在调用FCM算法时， m 的值不要太大。

那么，小的 m 值是否就一定对应好的聚类结果呢？答案是否定的。因为较大的加权指数 m 还

具有抑制噪声的功能,在从噪声污染的数据中获取模式样本的模糊聚类应用中起着重要的作用。参数 m 抑制噪声的功能是通过对隶属函数加以较大权重,使隶属度普遍较底的点(噪声点)对目标函数的贡献小,使得它们在确定聚类中心(原型模式)和隶属函数时被忽略。

参数 m 对FCM算法的影响还表现在, m 的取值直接影响模糊C均值聚类目标函数 $J_m(U,V)$ 的凸凹性和算法的收敛性。

对于给定的数据集 X 、分类数 c 以及参数 m 后,算法的迭代序列将完全取决于初始化。一种常用的初始化方法为质心法,即初始化为 $v_i^{(0)} = \bar{X}, i=1,2,\dots,c$ 或 $U = [\mu_{ij}] = [1/c]$ 。研究表明,对于这种初始化方法,参数 m 的选择直接影响算法的运行,太小的 m 值将使这种初始点为 $J_m(U,V)$ 的鞍点,导致基于爬山的FCM算法停止在该点上而无法爬山搜索。为了避免这一问题,就必须对 m 取值的下界作出限制,如何定界可从定理3中得到指导。

定理3 对于 $\forall i, j$, 如果有 $d_{ij}^* > 0$ 且 $v_i^* = \bar{X}$, 那么对于 $n=2, 0 < |\varepsilon| < 1/c$ 和 $\forall m > 1$ 有 $J_m(U_\varepsilon, V_\varepsilon) \leq J_m(U^*, V^*)$; 对于 $n > 2$ 的情况,对于任意足够小的 $\varepsilon > 0$, 当且仅当 $m < n/n-2$ 时该不等式成立。

其中的变量定义如下:

$$U^* = \begin{pmatrix} 1/c & 1/c & \dots & 1/c \\ 1/c & 1/c & \dots & 1/c \\ \vdots & \vdots & \dots & \vdots \\ 1/c & 1/c & \dots & 1/c \end{pmatrix} \quad D_1 = \begin{pmatrix} 1 & 0 & \dots & 0 \\ -1 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

$U_\varepsilon = U^* + \varepsilon D_1$, V^* 和 V_ε 分别为 U^* 和 U_ε 对应的聚类原型。

定理3告诉我们,如果 m 的值选择的太小($< n/n-2$), FCM算法在数据集的质心处将会出现鞍点。然而,定理3并没有告诉我们:当 $n > 2$ 对 $m > 2$ 的FCM的目标函数是否存在鞍点?从实验的角度得出的经验法则是,给定 n ,选择 $m \geq n/(n-2)$, 这样至少可以避免由定理3提供的鞍点。

5. 结 论

综上所述,参数 m 对FCM算法有重要影响,其影响主要是:统一了HCM算法和FCM算法;决定聚类的模糊程度,控制样本在类间的分享程度;抑制噪声;影响目标函数的凹凸性及算法的收敛性等。因此,加权指数 m 是FCM算法中的一个重要的参数。

参考文献

- [1] J.C.Bezdek. Pattern recognition with fuzzy objective function algorithms. New York: Plenum, 1981
- [2] R. Duda and P. Hart . Pattern classification and scene analysis. New York :Wiley ,1973
- [3] J . C. Dunn. J . Cybern. ,1973 ,3(3) :32 ~ 57
- [4] J . C.Bezdek. Fuzzy mathematics in pattern classification. Ph. D. dissertation ,Cornell Univ. Ithaca ,NY,1973
- [5] N.R.Pal, J.C.Bezdek. On cluster validity for the fuzzy c-means model [J]. IEEE Trans Fuzzy Systems ,1995 ,3(3) :370 – 379
- [6] 于剑,程乾生.关于 FCM 算法中的权重指数 m 的一点注记.电子学报,2003,3(31):478-490
- [7] 边肇祺,张学工:《模式识别》,北京:清华大学出版社,2000

Study of Weighting Exponent m in a FCM Algorithm

XU Lei, Wu Xiaojuan

School of Information Science and Engineering, Shandong University, Jinan, PRC, 250100

Abstract

The fuzzy c-means algorithm (FCM) is one of widely used clustering algorithms. It is very important to select an appropriate fuzziness index m when implementing the FCM. This paper proved from the deduction that the Weighting exponent m not only decide the clustering fuzzy degree of the FCM algorithm and the sharing degree of Exemplars between classes, but also affect the concavity-convexity of the object function and the convergence of the algorithm.

Keywords: *Weighting exponent; HCM algorithm; FCM algorithm; Partition entropy*

作者简介:

许磊, 男, 1982 年生, 硕士研究生, 主要研究方向是模式识别和视频处理。

吴晓娟, 女, 教授, 博士生导师, 主要研究方向模式识别和数字图像处理。