

一种改进的模糊支持向量机隶属度确定方法

刘成忠^{1,3}, 韩 虎², 黄高宝³

- (1. 甘肃农业大学信息科学技术学院, 兰州 730070;
2. 兰州交通大学数理与软件工程学院, 兰州 730070;
3. 甘肃省干旱生境作物学重点实验室, 兰州 730070)

摘 要: 为了克服支持向量机方法对于噪声或异常样本敏感的问题, 本文研究基于粗糙集理论的粗糙单类支持向量机, 提出一种改进的模糊支持向量机隶属度确定方法. 该算法首先利用粗糙集思想构造一个最小粗糙球, 分别得到对应粗糙球的上近似、下近似与边界区域, 然后依据样本在超球中的位置对分布在下近似、边界域和粗糙球以外的样本, 分别采用三种不同的方式计算其各自的隶属度. 最后通过对比实验表明, 与传统支持向量机方法相比, 本文提出的改进方法使模糊支持向量机具有更好的抗噪性能及分类能力.

关键词: 模糊支持向量机; 隶属度; 粗糙集

中图分类号: TP206.3 **文献标识码:** A **文章编号:** 0490-6756(2011)03-0546-05

An improved method for determining the membership of fuzzy SVM

LIU Cheng-Zhong^{1,3}, HAN Hu², HUANG Gao-Bao³

- (1. School of Information Science & Technology, Gansu Agricultural University, Lanzhou 730070, China;
2. School of Mathematics, Physics and Software Engineering, Lanzhou Jiaotong University, Lanzhou 730070, China;
3. Gansu Provincial Key Laboratory of Aridland Crop Science, Lanzhou 730070, China)

Abstract: In order to overcome the problem that support vector machine is sensitive to noises and outliers, rough one-class support vector machine based on rough set is researched and an improved method for determining the membership of fuzzy support vector machine is proposed in the paper. At first, the smallest rough sphere which encloses the data points is constructed. And then, those data points are divided into upper approximation region, low approximation region and boundary region by the distance between data points and the center of the rough sphere. At last, several comparative experiments using synthetic and real life data set show the performance and the validity of the method.

Key words: fuzzy support vector machine, membership, rough set

1 引 言

支持向量机 SVM (Support Vector Machine) 是一种基于统计学习理论的专门研究有限样本预测的机器学习方法, 它是建立在结构风险最小化基

础上, 比传统的学习方法具有较好的学习性能和泛化能力^[1,2]. 但支持向量机是根据类的边界情况, 用较少的支持向量来进行分类的, 如果无法正确区分出处在类边缘附近的野值或含噪声样本, 则求出的分类面不是真正的最优分类面. 针对这种情况提

收稿日期: 2010-08-30

基金项目: 甘肃省自然科学基金 (096RJZA004); 甘肃省教育厅科研基金 (0902-04); 甘肃省科技支撑计划 (1011NKCA058)

作者简介: 刘成忠 (1969—), 男, 甘肃天祝人, 副教授, 博士研究生, 主要研究方向为智能决策支持系统.

通讯作者: 黄高宝. E-mail: liucz@gsau.edu.cn

出的模糊支持向量机方法,对每个样本引入了一个模糊隶属度参数,使得样本对目标函数的贡献率出现差异,从而达到消除噪声与野值样本影响的目的^[3-5]。

模糊支持向量机的分类性能受限于隶属度函数的设计,但隶属度函数的构造方法,还没有一个可遵循的一般性准则。关于隶属度函数,不少学者的研究方法是基于样本到类中心之间的距离来度量其隶属度的大小^[4-6]。文献[5]提出根据样本到类中心的距离来度量其隶属度的大小,但该方法并不能将野值或含噪样本从有效样本集中区分出来,以致将野值或含噪样本赋予和有效样本相同的隶属度,严重影响分类性能。文献[6]在计算隶属度时,对类中有效样本与野值分别进行了考虑,对有效样本采用样本到类中心的距离来度量其隶属度,而对野值的隶属度直接赋予一个很小的值。该方法的关键在于如何确定野值点,错误判断野值点会严重影响分类器的性能,但确定野值点又是非常困难的。

本文提出了一种基于粗糙单类支持向量机的隶属度确定方法,运用粗糙集思想构造一个最小粗糙球,划分粗糙球的上近似、下近似与边界区域,然后依据样本所处的位置,对分布在下近似、边界域和粗糙球以外的样本分别采用3种不同的方式计算其各自的隶属度。实验表明,本文提出的方法使模糊支持向量机对噪声和野值点的敏感度降低,而泛化能力得到提高。

2 模糊支持向量机

模糊支持向量机就是根据不同输入样本对分类贡献的不同,赋予不同的隶属度。假设给定一组训练样本 $\{(x_1, y_1, s_1), \dots, (x_l, y_l, s_l)\}$, 其中 $s_i, i = 1, \dots, l$ 就是样本 x_i 属于所在类的隶属度,则模糊支持向量机模型如下所示。

$$\min \frac{1}{2} \|w\|^2 - \varphi + \frac{1}{l} \sum_{i=1}^l s_i \xi_i, \quad (1)$$

$$\text{s. t. } y_i(w \cdot \phi(x_i) + b) \geq \rho - \xi_i, \\ \xi_i \geq 0, \rho \geq 0, i = 1, \dots, l$$

式(1)中,松弛项由传统支持向量机中的单一松弛因子变成了带有不同权重的松弛因子,对式(1)构造拉格朗日函数

$$L(w, b, \xi, \rho, \alpha, \beta, \lambda) = \\ \frac{1}{2} \|w\|^2 - \varphi + \frac{1}{l} \sum_{i=1}^l s_i \xi_i -$$

$$\sum_{i=1}^l \alpha_i (y_i (w \cdot \phi(x_i) + b) - \rho + \xi_i) - \\ \sum_{i=1}^l \beta_i \xi_i - \lambda \rho \quad (2)$$

其中 $\alpha_i \geq 0, \beta_i \geq 0, \lambda \geq 0, i = 1, \dots, l$ 均为拉格朗日乘子,由于在鞍点处的 w, b, ξ, ρ 的偏导数为零,则

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^l \alpha_i y_i \phi(w \cdot x_i) = 0 \quad (3)$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^l \alpha_i y_i = 0 \quad (4)$$

$$\frac{\partial L}{\partial \xi_i} = \frac{1}{l} s_i - \alpha_i - \beta_i = 0 \quad (5)$$

$$\frac{\partial L}{\partial \rho} = -v + \sum_{i=1}^l \alpha_i - \lambda = 0 \quad (6)$$

将式(3)~式(6)代入式(2)得到模糊支持向量机的对偶描述如下。

$$\min(\alpha) = \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (7)$$

$$\text{s. t. } \sum_{i=1}^l \alpha_i y_i = 0, 0 \leq \alpha_i \leq \frac{1}{l} s_i, \sum_{i=1}^l \alpha_i \geq v,$$

通过对式(7)二次规划问题的求解,求得各样本对应的 Lagrange 系数 $\alpha_i, i = 1, \dots, l$, 则模糊支持向量机方法的最优判别函数为

$$f(x) = \text{sgn}(\sum_{i=1}^m \alpha_i^* y_i K(x \cdot x_i) + b^*) \quad (8)$$

其中 Lagrange 系数 $\alpha_i \geq 0$ 满足条件:

$$0 < \alpha_i \leq \frac{1}{l} s_i \quad (9)$$

注意在支持向量机训练过程中,噪声和异常样本往往会产生很大的拉格朗日乘子,从而主导了决策函数^[7]。而模糊支持向量机正是针对这个问题,对那些噪声或异常样本指定较小的隶属度,抑制噪声对分类器的影响,提高模型的抗干扰能力。

3 基于粗糙单类支持向量机的隶属度设计

在采用模糊技术处理时,隶属度函数的设计是整个模糊算法的关键所在,这要求隶属度函数必须能客观、准确地反映系统中样本存在的不确定性。

3.1 单类支持向量机

单类支持向量机(One-Class SVM)有两种实现途径,一种是根据构造超球面的方法来实现,另一种是通过构造与原点的超平面来实现。本文使用第一种方法进行研究,算法的基本思想就是寻

找一个超球体,使其半径尽可能小的同时,包含的训练样本数尽可能多,其目标函数为

$$\min R^2 + C \sum_{i=1}^l \xi_i \quad (10)$$

$$\text{s. t. } \|\phi(\mathbf{x}_i) - \mu\| \leq R^2 + \xi_i, \xi_i \geq 0$$

其中, R 为球半径, μ 为球心, ξ 为松弛变量. C 为正则化参数,控制对错分样本的惩罚程度,实现对球的大小和所包含的样本数之间的折衷. 同 SVM 求解类似,对式(10)构造拉格朗日函数,得到其对偶表达式为

$$W(\alpha) = \min \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^l \alpha_i K(\mathbf{x}_i, \mathbf{x}_j) \quad (11)$$

$$\text{s. t. } 0 \leq \alpha \leq C, \sum_{i=1}^l \alpha_i = 1$$

式(11)中, $K(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x}) \cdot \phi(\mathbf{y})$ 为满足 Mercer 条件的核函数. 通过求解式(11)得到一组 α_i , 当 $0 < \alpha_i < C$ 时, 对应样本构成支持向量集合(SVs), 用来描绘包围球, 位于包围球附近. 当 $\alpha_i = C$ 时, 对应样本位于包围球外边, 称为噪声或野值点. 同时可以确定包围球半径和球心分别为 $R = \|\mathbf{x}_i - \mu\|$ 和 $\mu = \sum_i \alpha_i \mathbf{x}_i$.

3.2 粗糙单类支持向量机

粗糙单类支持向量机就是利用粗糙集思想对传统单类支持向量机进行拓展^[8], 通过构造一个最小粗糙包围球, 分别得到对应粗糙球的上近似、下近似与边界区域, 具体说明见图 1.




图 1 最小粗糙包围球

Fig. 1 The smallest rough surrounding sphere

以 R 为半径的超球构成了最小粗糙包围球的下近似, 以 T 为半径的超球构成了最小粗糙包围球的上近似, 其中 $T > R$, 两个超球之间的部分构成最小粗糙包围球的边界区域. 对分布在不同区域

的样本给予不同的惩罚, 建立目标函数为

$$\min R^2 + T^2 + \frac{1}{\nu m} \sum_{i=1}^l \xi_i + \frac{\delta}{\nu m} \sum_{i=1}^l \xi'_i \quad (12)$$

$$\text{s. t. } \|\phi(\mathbf{x}_i) - \mu\| \leq R^2 + \xi_i + \xi'_i,$$

$$0 \leq \xi_i \leq T^2 - R^2, \xi'_i \geq 0$$

同理采用拉格朗日乘子法对问题(12)进行求解. 下式“=”左边请补充为 $L(R, T, \mu, \xi_i, \xi'_i)$

$$\begin{aligned} L(R, T, \mu, \xi_i, \xi'_i) = & R^2 + T^2 + \frac{1}{\nu m} \sum_{i=1}^l \xi_i + \frac{\delta}{\nu m} \sum_{i=1}^l \xi'_i + \\ & \sum_{i=1}^l \alpha_i (\|\phi(\mathbf{x}_i) - \mu\| R^2 - \xi_i - \xi'_i) - \\ & \sum_{i=1}^l \beta_i \xi_i - \sum_{i=1}^l \lambda_i (T^2 - R^2 - \xi_i) - \sum_{i=1}^l \eta_i \xi'_i \end{aligned} \quad (13)$$

其中 $\alpha_i \geq 0, \beta_i \geq 0, \lambda_i \geq 0, \eta_i \geq 0$, 同时满足 KKT 条件如下.

$$\sum_{i=1}^l \alpha_i = 2 \quad (14)$$

$$\mu = \frac{1}{2} \sum_{i=1}^l \alpha_i \phi(\mathbf{x}_i) \quad (15)$$

$$\beta_i - \lambda_i = \frac{1}{\nu m} - \alpha_i \quad (16)$$

$$\frac{\delta}{\nu m} - \alpha_i = \eta_i \quad (17)$$

$$\alpha_i (\|\phi(\mathbf{x}_i) - \mu\| - R^2 - \xi_i - \xi'_i) = 0 \quad (18)$$

$$\lambda_i (T^2 - R^2 - \xi_i) = 0 \quad (19)$$

$$\beta_i \xi_i = 0, \eta_i \xi'_i = 0 \quad (20)$$

通过以上各式, 可以得到问题(12)的对偶表达式为

$$W(\alpha) = \min \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^l \alpha_i K(\mathbf{x}_i, \mathbf{x}_j) \quad (21)$$

$$\text{s. t. } 0 \leq \alpha_i \leq \frac{\delta}{\nu m}, \sum_{i=1}^l \alpha_i = 2$$

3.3 隶属度设计


在粗糙单类支持向量机模型中, 根据 α_i 的取值把样本划分在了 3 个不同的区域, 分别代表了 3 种不同性质的样本. 当 $0 \leq \alpha_i < 1/\nu m$ 时对应样本满足 $\|\phi(\mathbf{x}_i) - \mu\| \leq R^2$, 位于最小粗糙包围球的下近似区域, 代表正常样本; 当 $1/\nu m \leq \alpha_i < \delta/\nu m$ 时对应样本满足 $\|\phi(\mathbf{x}_i) - \mu\| \leq R^2 + \xi_i$, 位于最小粗糙包围球的边界域, 代表混杂在另一类中的噪声样本; 当 $\alpha_i = \delta/\nu m$ 时对应样本满足

$\|\phi(x_i) - \mu\| \leq R^2 + \xi_i + \xi'_i$, 位于最小粗糙包围球的上近似区域以外, 代表孤立野值点。

在确定样本隶属度时, 根据样本在最小粗糙球中的分布, 采用三种不同方式计算, 如式(22)所示。

$$s(x_i) = \begin{cases} 1, & d(x_i) \leq R \\ 0.5 * (\frac{1}{1+d(x_i)-R}) + 0.5, & R < d(x_i) \leq T \\ 0.5 * (\frac{1}{1+d(x_i)-T})^p, & d(x_i) > T \end{cases} \quad (22)$$

其中 $d(x_i)$ 表示样本 x_i 到最小粗糙包围球心的距离, R 与 T 分别代表下近似球与上近似球的半径。参数 p 可以取不同的正整数, 本文取 $p = 2$ 。



4 实验结果与分析

为了验证本文提出的改进模糊支持向量机(F-vSVM)方法的有效性, 本节以传统支持向量机方法为参照进行分类对比实验。采用的测试数据为人工合成数据集和一组 UCI 的标准数据集。

4.1 合成数据集实验

本部分实验是对分布在二维平面上的一组含有野值和噪声的样本进行分类, 分别采用 vSVM 和 F-vSVM。分类结果如图 2 所示。




图2 不同模型的分类结果
Fig.2 The results of the classification of different models

图 2(a)为传统支持向量机分类结果, 由于野值样本与噪声点的存在, 严重地影响了传统支持向量机方法的最优分类面; 图 2(b)是本文提出的改进模糊支持向量机分类结果, 能够有效区分野值样本和正常样本, 并通过给予不同的惩罚从而降低噪声对最优分类面地影响, 具有更好的推广性能。

4.2 UCI 标准数据集实验

为了进一步验证新算法的性能, 对 UCI 机器学习数据库中的 4 个标准数据集进行了实验, 它们的有关信息如表 1 所示。

选取的 4 个标准数据集源于不同的应用领域, Credit approval 来自商业领域, 是关于信用卡申请的记录; Live disorder、Heart disease 和 Breast cancer 来自于医疗应用领域, 是关于疾病诊断的记录。实验过程中, 各数据集进一步区分为原始样本集、含噪声为 5% 和含噪声为 10% 的样本集 3 种类别进行验证实验。

表1 数据集信息
Tab.1 Data set information

数据集	样本	特征	类别
信用卡审批	690	15	2
肝病诊断	1000	19	2
心脏病诊断	270	13	2
乳腺癌诊断	683	10	2

整个实验过程分为两个阶段: 第一阶段, 根据设计的隶属度确定方法计算各个样本的隶属度。在这个过程中, 为了简化实验过程, 仅使用 RBF 核函数并给定其参数 $\sigma = 1, \nu = 0.3$, 参数 δ 在 $[1, 5]$ 上得到, 步长设定为 0.5; 第二阶段, 进行样本分类。为区别线性和非线性两种情况, 实验使用 Linear 核函数和 RBF 核函数。为了方便比较, 指定 RBF 核函数参数 $\sigma = 1$; 参数 ν 采用网格搜索技术, 即取

值范围为[0.1,0.5],步长为 0.1. 最终实验结果采用 5 折交叉验证取平均值得到.

通过表 2 与表 3 的实验数据可以看出,在线性和非线性情况下,相比传统的支持向量机方法,本文提出的改进模糊支持向量机算法在 4 个不同的

实验数据集上都取得了较好的实验结果.同时也可以看出,随着噪声数据的不断增加,传统支持向量机的推广性能下降明显,而改进算法有着较好的抗干扰能力,有效降低了噪声对最优分类面地影响.

表 2 线性分类正确率(%)
Tab.2 The accuracy of linear classification (%)

分类准确度		信誉卡审批	肝病诊断	心脏病诊断	乳腺癌诊断
F=0%	vSVM	80.22	65.42	82.61	96.42
	F-vSVM	80.89	66.65	83.33	96.68
F=5%	vSVM	79.11	62.03	77.82	94.26
	F-vSVM	80.24	66.60	82.31	95.87
F=10%	vSVM	72.14	58.41	72.50	87.11
	F-vSVM	79.05	64.52	82.20	94.05

表 3 非线性分类正确率(%)
Tab.3 The accuracy of nonlinear classification (%)

分类准确度		信誉卡审批	肝病诊断	心脏病诊断	乳腺癌诊断
F=0%	vSVM	86.44	66.86	83.70	96.76
	F-vSVM	87.03	68.29	84.81	96.91
F=5%	vSVM	81.10	65.43	80.74	95.15
	F-vSVM	85.26	67.71	83.70	96.03
F=10%	vSVM	78.25	58.86	75.41	95.15
	F-vSVM	84.24	64.31	82.05	95.29

5 结 语

针对支持向量机方法对于噪声或孤立野值点敏感的问题,本文提出一种基于粗糙单类支持向量机的隶属度确定方法.运用粗糙集思想构造一个最小粗糙球,分别得到对应粗糙球的上近似、下近似与边界区域,然后依据样本在超球中的位置,对分布在下近似、边界域和粗糙球以外的样本分别采用三种不同方式计算其各自的隶属度.最后通过在一个合成数据集和一组 UCI 标准数据集上的对比实验表明,本文提出的隶属度确定方法使改进模糊支持向量机算法具有更好的抗噪性能及推广能力.

参考文献:

[1] Li G Z, Wang M. An introduction to support vector machine[M]. Beijing: Publishing House of Electronic Industry, 2005.
[2] Burges C. A tutorial on support vector machines for

pattern recognition[J]. Data Mining and Knowledge Discovery, 1998, 2(2): 121.
[3] 李红莲,王春花,袁保宗. 一种改进的支持向量机 NN-SVM[J]. 计算机学报, 2003, 26(8): 1015.
[4] Lin C F, Wan S D. Fuzzy support vector machines [J]. IEEE Trans. on Neural Networks, 2002, 13 (2): 464.
[5] 张翔,肖小玲,徐光佑. 基于样本之间紧密度的模糊支持向量机方法[J]. 软件学报, 2006, 17(5): 951.
[6] 杜喆,刘三阳,齐小刚. 一种新隶属度函数的模糊支持向量机[J]. 系统仿真学报, 2009, 21(7): 1901.
[7] 王凯,张永祥,姚晓山,等. 支持向量机惩罚参数的自适应调整方法[J]. 计算机工程与应用, 2008, 44 (26): 45.
[8] Asharaf S, Shevade S K, Narasimha M. Rough support vector clustering[J]. Pattern recognition, 2005, 38(10): 1779.
[9] 陈宏,何小海,吴炜,等. 应用 SVM 的三维车型识别技术[J]. 四川大学学报: 自然科学版, 2006, 43 (6): 1279.

[责任编辑: 伍少梅]