

基于模糊隶属度函数的脑图像分割方法

杨 兵 刘晓芳*

(中国计量大学计算机应用与技术研究所 浙江 杭州 310018)

(浙江省电磁波信息技术与计量检测重点实验室 浙江 杭州 310018)

摘 要 为提高医学图像在组织边界不清晰以及灰度不均匀下的分割性能,提出一种基于多类样本间模糊距离的隶属度函数分割方法。通过磁共振序列测量确定反映磁共振图像脑部组织特性的映射图,经预处理后得到样本模糊标签;设计基于多样本类间模糊距离的隶属度函数确定各样本的隶属度,该隶属度的确定综合考虑了同类样本与不同类样本之间的空间距离,降低了同类样本之间的隶属度依赖;训练模糊支持向量机对三种主要脑组织进行分割。在脑图像公开数据集上的分割实验表明,改进算法可有效提高分割精度。

关键词 模糊支持向量机 类间距离 隶属度函数 图像分割 模糊标签

中图分类号 TP391

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2022.04.040

BRAIN IMAGE SEGMENTATION METHOD BASED ON FUZZY MEMBERSHIP FUNCTION

Yang Bing Liu Xiaofang*

(Institute of Computer Application and Technology, China Jiliang University, Hangzhou 310018, Zhejiang, China)

(Key Laboratory of Electromagnetic Wave Information Technology and Metrology of Zhejiang Province, College of Information Engineering, China Jiliang University, Hangzhou 310018, Zhejiang, China)

Abstract In order to improve the segmentation performance of medical images under unclear tissue boundaries and non-uniformity intensity, a membership function segmentation method based on fuzzy distance between multiple types of samples is proposed. Maps reflecting the characteristics of brain tissues in magnetic resonance images were determined by magnetic resonance sequence measurement, and the sample fuzzy labels were obtained after preprocessing. A membership function based on the fuzzy distance between multiple samples was designed to determine the membership of each sample. The determination of the degree comprehensively considered the spatial distance between the same sample and different samples, and reduced the degree of membership dependence between the same samples. The fuzzy support vector machine was trained to segment the three main brain tissues. Segmentation experiments on public image datasets of brain images show that the improved algorithm can effectively improve the segmentation accuracy.

Keywords Fuzzy support vector machine Inter-class distance Membership function Image segmentation Fuzzy labels

0 引 言

磁共振成像(Magnetic Resonance Imaging, MRI)具有软组织对比度高、无放射损伤等优点^[1],广泛用于人体脑部成像。脑图像分析是了解人脑健康状况以及生

理特征的重要渠道,其中脑图像分割是研究人脑解剖结构以及智能诊断脑部疾病的基础,近年来,机器学习技术因其具有良好的数据预测能力以及模型泛化性能,被广泛用于医疗数据智能诊断^[2]中。脑组织分割和脑肿瘤智能检测是脑部图像分割的两个重要研究方向,本文的目的是应用机器学习技术对脑图像中脑灰

质(Gray Matter, GM)、脑白质(White Matter, WM)、脑脊液(Cerebrospinal Fluid, CSF)三种主要脑组织进行自动分割。

由于成像设备等原因,磁共振图像存在各组织之间没有明显的边界、各组织之间灰度值重叠等现象^[1],针对此问题, Vaishnav 等^[3]将支持向量机用于脑影像智能分析中,证明支持向量机可以根据医学图像灰度不均匀以及组织边缘不清晰等特点做出准确的识别分析。支持向量机是一种基于类间最大距离的数据处理算法,其分类超平面的建立仅依赖于少数支持向量^[4],具有较好的泛化性能和判别能力,在此基础上,模糊支持向量机将模糊理论和支持向量机相结合^[5],提出根据空间距离判别规则对样本赋权,在解决样本数据不完全属于某一类的情况下表现出了较好的预测能力,广泛应用于医学图像分析中。

隶属度函数的设计是构建模糊支持向量机模型的关键^[5]。目前,隶属度函数的设计大多基于同类样本之间的几何距离,没有考虑到不同类样本之间的模糊距离,无法有效解决灰度不均匀带来的像素值交叉重叠问题。基于此,本文提出一种基于类间样本模糊距离的隶属度确定方法,综合考虑同类样本中心以及不同类样本中心对待赋权样本的影响,训练模糊支持向量机模型对三种主要脑组织进行自动分割。

1 相关工作

1.1 图像分割

图像分割是指利用计算机辅助技术将图像划分为具有不同性质的图像块^[6],传统算法如直方图方法^[7]提取图像特征如梯度特征,颜色直方图、纹理特征将图像划分为不同图像块。然而,由于医学图像具有灰度不均匀、各组织之间边界不清晰等特点,传统算法不能较好适应此种情况。

研究人员将支持向量机应用于医学图像处理中,如 Blumenthal 等^[8]将支持向量机应用于肿瘤图像分类, Khedher 等^[9]将支持向量机与主成分分析方法结合用于阿尔兹海默症的早期诊断, Emblem 等^[10]将支持向量机用于术前脑部胶质瘤生存预测。然而,上述方法没有充分考虑到医学图像的特点,没有将同类样本距离以及不同类样本距离引入支持向量机中,无法有效解决医学图像分割面临的边界不清晰和灰度不均匀等问题。由支持向量机改进的模糊支持向量机在处

理样本不完全属于某一类的问题上表现出不错的应用前景,模糊支持向量机的构建主要分为三部分:1) 根据样本隶属度函数计算样本隶属度;2) 对样本进行赋权,训练模糊支持向量机模型;3) 对模型调整参数,使其具有较好的判别能力与泛化性能。

1.2 支持向量机

支持向量机是一种基于类间距离最大化的数据处理算法^[11],其目标是在多维特征空间中确定最优分类超平面,使得分类确信度(confidence)最大。支持向量机能够很好地处理线性可分问题,对于线性不可分问题,支持向量机引入核函数将原始数据从低维空间映射到高维空间,从而解决原始数据在低维空间中线性不可分的问题。即考虑以下问题:

$$f(x) = \sum_{i=1}^n w_i \phi_i(x) + b \quad (1)$$

式中: ϕ 为原始数据空间到高维特征空间的映射; w 为数据权重项; b 为数据偏置项。核函数就是将映射形式 ϕ 隐式地表示为原始数据内积的形式:

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle \phi_i(x), \phi(x) \rangle + b \quad (2)$$

式中: $\langle \cdot \rangle$ 表示数据样本内积; y 为数据样本标签。 $\langle \phi_i(x), \phi(x) \rangle$ 也可表示为 $K(x, z) = \langle \phi(x), \phi(z) \rangle$, $K(\cdot)$ 为核函数,常用的核函数有多项式核函数 $K(x_1, x_2) = (\langle x_1, x_2 \rangle + R)^d$, d 为多项式系数,高斯核函数 $K(x_1, x_2) = \exp(-\|x_1 - x_2\|^2 / 2\delta^2)$, δ 为高斯核宽度,线性核函数 $K(x_1, x_2) = \langle x_1, x_2 \rangle$, α 为拉格朗日乘子,其可以通过求解以下对偶问题得到:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(x_i), \phi(x_j) \rangle \quad (3) \\ \text{s. t.} \quad & \alpha_i \geq 0, i = 1, 2, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

对于离群点,支持向量机通过引入松弛变量 ξ 来更好地容忍少数离群点对于分类超平面地影响,目标是解决以下原始问题:

$$\begin{aligned} \min \quad & \frac{1}{2} w^T \cdot w + C \sum_{l=1}^n \xi_l \quad (4) \\ \text{s. t.} \quad & y_l (w^T x_l + b) \geq 1 - \xi_l, i = 1, 2, \dots, n \\ & \xi_l \geq 0, l = 1, 2, \dots, n \end{aligned}$$

式中: w 为权重因子; C 用于控制最大分离超平面与数据偏差的权重; x 为样本数据点; ξ 为松弛变量; y 为样本数据的标签。通过拉格朗日法求解得到以下对偶问题:

$$\begin{aligned} &\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{l=1}^n \alpha_i \alpha_l y_i y_l K(x_i, x_l) \\ &\text{s. t.} \quad \sum_{i=1}^n y_i \alpha_i = 0 \\ &0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned} \tag{5}$$

通过对拉格朗日乘子 α 的求解,将原始问题转化为对偶问题。

1.3 模糊支持向量机

传统支持向量机中,每个样本点完全属于某一类,不能处理样本同时属于多类的情况。Khodaghohi 等^[12]将模糊理论引入支持向量机中,赋予每个样本点不同的隶属度 m_l ($0 < m_l \leq 1$) 来表征样本点属于某一类的程度。其原始问题如下:

$$\begin{aligned} &\min_{w,b,\xi} \quad \frac{1}{2} w^T \cdot w + C \sum_{l=1}^n m_l \xi_l \\ &\text{s. t.} \quad y_l (w \cdot x_l + b) \geq 1 - \xi_l \\ &\xi_l \geq 0, l = 1, 2, \dots, n \end{aligned} \tag{6}$$

由拉格朗日乘子法得到原始问题的对偶问题:

$$\begin{aligned} &\min_{\alpha} \quad \frac{1}{2} \sum_{j=1}^n \sum_{l=1}^n \alpha_j \alpha_l y_j y_l K(x_j, x_l) - \sum_{j=1}^n \alpha_j \\ &\text{s. t.} \quad \sum_{j=1}^n y_j \alpha_j = 0 \\ &0 \leq \alpha_j \leq m_j C, j = 1, 2, \dots, n \end{aligned} \tag{7}$$

样本隶属度的确定是构建模糊支持向量机的关键。Lin 等^[13]提出一种基于样本到样本中心距离的隶属度确定方法,假设有样本集 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, $y \in \{-1, +1\}$, x_+ 表示正类样本的均值, x_- 表示负类样本的均值, $r_+ = \max |x_i - x_+|$, $r_- = \max |x_i - x_-|$, 则样本隶属度 m_i 定义为:

$$m_i = \begin{cases} 1 - \frac{|x_i - x_+|}{r_+ + \delta} & y_i = 1 \\ 1 - \frac{|x_i - x_-|}{r_- + \delta} & y_i = -1 \end{cases} \tag{8}$$

上述方法没有考虑到各类别样本之间的内在联系,将各类别的样本孤立看待。张翔等^[14]考虑了样本与样本中心的关系以及样本之间的紧密度,提出了一种基于样本紧密度的隶属度计算方法,但无法有效解决孤立样本隶属度赋权问题。

2 模糊隶属度函数设计

由于成像技术等原因,医学图像中的每个像素的灰度值通常是多种组织灰度值的平均,这也导致医学图像中组织与组织之间边界不清晰。针对此问题,本文设计了一种基于不同类别样本之间模糊距离的隶属

度计算方法。
图 1 中,超球体分别表示三种不同的脑组织。AB、AC、BC 表示各脑组织样本间最远距离。a、b、c 分别表示各脑组织样本中心,设样本点 x_1 到三种脑组织的距离分别为 L_2 、 L_1 、 L_3 。




图1 样本隶属度

$$L_l = |x_1 - \bar{X}_l| \quad l = 1, 2, 3 \tag{9}$$

样本点 x_2 到超球体中心 b、a、c 的距离分别为 M_1 、 M_2 、 M_3 。

$$M_l = |x_2 - \bar{X}_l| \quad l = 1, 2, 3 \tag{10}$$

样本点 x_3 到超球体中心 b、a、c 的距离分别为 N_1 、 N_2 、 N_3 。

$$N_l = |x_3 - \bar{X}_l| \quad l = 1, 2, 3 \tag{11}$$

则样本点 x_1 的隶属度 m_1 为:

$$m_1 = 1 - \lambda \frac{\sum_{l=1}^3 L_l}{AB + BC + AC} \tag{12}$$

样本点 x_2 的隶属度 m_2 为:

$$m_2 = 1 - \lambda \frac{\sum_{l=1}^3 M_l}{AB + BC + AC} \tag{13}$$

由于样本点 x_3 位于三角形 ABC 之外,故样本点 x_3 的隶属度 m_3 为:

$$m_3 = \mu \frac{\sum_{l=1}^3 N_l}{AB + BC + AC} \tag{14}$$

式中: λ 、 μ 为模糊距离系数。若 $L_1 = M_1$,即样本点 x_1 和样本点 x_2 在超球体内处于同一球面上,但由于 $L_2 + L_3 < M_2 + M_3$,故 $m_1 > m_2$,这表明,即使处于同一超球面上的样本点,距离其他两类中心距离更近的样本点获得更大的隶属度。若有 $L_1 = N_1$,即样本点 x_1 和样本点 x_3 在超球体内处于同一球面上,但由于样本点 x_3 位于三角形 ABC 之外,故样本点 x_3 赋予较小的隶属度,从而使得位于三类样本中心附近的样本点获得更大隶属度。

综上,对于位于三角形 ABC 之内的样本隶属度计算公式为:

$$m_i = 1 - \lambda \frac{\sum_{l=1}^N |x_i - \bar{X}_l|}{\sum_{j=1}^N \sum_{l=1}^N FD(\text{超球}_i, \text{超球}_j)} \quad i \neq j \quad (15)$$

式中: λ 为模糊距离系数, $\sum_{l=1}^N |x_i - \bar{X}_l|$ 为样本点 x_i 距样本类中心的模糊距离。位于三角形 ABC 之内的样本隶属度 $m_i > 0.5$ 。位于三角形 ABC 之外的样本隶属度计算公式为:

$$m_i = \mu \frac{\sum_{l=1}^N |x_i - \bar{X}_l|}{\sum_{j=1}^N \sum_{l=1}^N FD(\text{超球}_i, \text{超球}_j)} \quad i \neq j \quad (16)$$

式中: μ 为模糊距离系数,使位于三角形 ABC 之外的样本隶属度 $m_i < 0.5$ 。

式(15)和式(16)中, x_i 表示不同类别样本点, $\bar{X}_l$ 表示类别 l 的均值, N 表示样本类别数目, FD 表示最远距离。

3 整体算法流程

本文提出的算法整体流程如图2所示。




图2 整体算法流程

根据图2,模糊隶属度函数算法主要步骤如下:

1) 根据具体应用实例,提取数据特征,如图像的梯度特征,纹理特征等。

2) 结合样本标签,计算每个数据样本的模糊隶属度。应用于图像数据时,不计算背景样本的模糊隶属度。

3) 根据输入数据特征,并划分数数据集为训练集、验证集以及测试集,将步骤2)计算的样本模糊隶属度作为样本数据权重,建立模糊支持向量机模型。

4) 使用交叉验证策略,根据验证集的分类精度调整模型参数(惩罚系数 C 、核函数系数、模糊距离系数 μ 和 λ 等)。

5) 使用步骤4)得到的分类模型,验证模型在测试集上的精度。

此外,本文还给出了具体的算法执行流程,其中图像的问题特征提取和样本的模糊隶属度计算以伪代码方式展现。

Step 1 设定模型初始参数,包括惩罚系数 C ,迭代次数 $MaxG$,核函数系数 σ ,模糊距离系数 λ, μ 等。

Step 2 数据样本预处理,包括归一化,去除异常值等。

$$x^* = \frac{x - \mu}{\sigma} \quad (17)$$

Step 3 设定数据划分比例: a, b, c 。分别将数据分别划分为训练集、验证集、测试集。

Step 4 提取数据特征,如图像的梯度特征、纹理特征(对比度 CON 、 ASM 能量、熵)等。

$$G_x(x, y) = H(x + 1, y) - H(x - 1, y)$$

$$G_y(x, y) = H(x, y + 1) - H(x, y - 1)$$

$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2}$$

$$\theta(x, y) = \tan^{-1} \left(\frac{G_y(x, y)}{G_x(x, y)} \right) \quad (18)$$

$$ASM = \sum_i \sum_j P(i, j | d, \theta)^2$$

$$CON = \sum_i \sum_j (i - j)^2 P(i, j | d, \theta)$$

$$ENT = - \sum_i \sum_j P(i, j | d, \theta) \log P(i, j | d, \theta)$$

以图像的纹理特征提取为例, $imgLength$ 、 $imgwidth$ 分别表示图像的长和宽, $GLCM_GrayLevel$ 表示灰度共生矩阵的灰度级数, $greycomatrix_distantance$ 表示灰度共生矩阵距离, $greycomatrix_angles$ 表示灰度共生矩阵的角度, $texture_property$ 表示需要提取的纹理特征, $glcm$ 表示灰度共生矩阵。

For $i = 1$ to $imgLength$:

For $j = 1$ to $imgWidth$:

If $i < 3$ or $j < 3$:

continue

使用 7×7 的窗口大小计算灰度共生矩阵

$GLCM_window = img[i - 3 : i + 4, i - 3 : j + 4]$

计算灰度共生矩阵

$glcm =$

$greycomatrix(glcm_window,$

```
greycmatrix_distance,greycmatrix_angles,GLCM_GrayLevel)
# 计算纹理特征 1
texture_property_1 =
greycoprops( glcm,texture_property[0])
texture_1[i,j] = texture_property_1[0][0]
# 计算纹理特征 2
texture_property_2 =
greycoprops( glcm,texture_property[1])
texture_2[i,j] = texture_property_2[0][0]
# 计算纹理特征 3
texture_property_3 =
greycoprops( glcm, texture_property[2])
texture_3[i,j] = texture_property_3[0][0]
```

Step 5 计算并保存每个数据样本的模糊隶属度:

$$m_i = 1 - \lambda \frac{\sum_{l=1}^N |x_i - \bar{X}_l|}{\sum_{j=1}^N \sum_{i=1}^N FD(\text{超球}_i, \text{超球}_j)}$$
$$m_i = \mu \frac{\sum_{l=1}^N |x_i - \bar{X}_l|}{\sum_{j=1}^N \sum_{i=1}^N FD(\text{超球}_i, \text{超球}_j)} \quad i \neq j \quad (19)$$

其中,两类样本之间的最远距离用动态规划法求解,N 表示负类样本数,M 表示正类样本数,Dn(i,j)表示负样本 i 到正样本 j 的距离,Dp(i,j)表示正样本 i 到负样本 j 的距离,伪代码如下:

```
For i = 1 to N;
    FarthestDistance[i] = 0
For j = 1 to M;
    FarthestDistance[j] = 0
For i = 1 to N;
    For j = 1 to M;
        If Dn(i,j) + Dp(i,j) > FarthestDistance[i][j]:
            FarthestDistance[i][j] = Dn(i,j) + Dp(i,j)
        If Dn(i,j) + Dp(j,i) > FarthestDistance[i][j]:
            FarthestDistance[i][j] = Dn(i,j) + Dp(j,i)
```

Step 6 选择并初始化核函数、惩罚系数 C、模糊距离系数 λ 和 μ 等。

Step 7 根据 Step 1 – Step 6 建立模糊支持向量机模型。

$$\min_{\alpha} \frac{1}{2} \sum_{j=1}^n \sum_{l=1}^n \alpha_j \alpha_l y_j y_l K(x_j, x_l) - \sum_{j=1}^n \alpha_j \quad (20)$$
$$\text{s. t.} \quad \sum_{j=1}^n y_j \alpha_j = 0$$
$$0 \leq \alpha_j \leq m_j C, j = 1, 2, \dots, n$$

Step 8 选择评价指标对验证集定律评价。

Step 9 若 Step 8 的评价结果不满足精度要求或

算法迭代数小于迭代次数 MaxG,则返回 Step 6,否则执行 Step 10。

Step 10 保存算法模型,输入测试集并输出预测结果,算法结束。


4 实 验

实验采用的硬件设备是 Intel Core 4.2 GHz i7-7700k CPU 以及 NVIDIA Geforce GTX 1080Ti GPU,软件环境采用 Python 3.5,所用图像处理软件包括 scikit-image, SimpleITK、以及神经影响处理工具 NiBabel。此外,还用到机器学习处理软件包 scikit-learn (sklearn)。

4.1 实验数据

本文所用实验数据来自 brainweb^[15],其包含了多个数据的人工分割结果。磁共振图像中纵向弛豫时间 T1 是指成像扫描仪射频脉冲发射后,核自旋磁化强度受到激发时,从高能状态恢复到原始稳定状态的快慢程度^[16]。T1 值也是磁共振成像中软组织对比的重要来源,针对不同组织的成像,T1 映射图可以作为反映组织生理健康程度的参考,故计算 T1 映射图对于临床诊断、疾病治疗都至关重要。

本文根据 T1 值生成图像标签。在成像序列中,重复时间 TR、回波时间 TE、反转时间 (Inversion Time, TI) 以及发射角 (Flip Angle, FA) 影响图像对比度。根据成像对比度质量和实际操作经验设置 SE 序列以及 FLASH 序列的成像参数。此外,层面厚度 ST 由梯度强度和脉冲带宽决定,在 2D 图像中,ST 越小则空间分辨率越高,但图像信噪比也随之下降,本文结合磁共振相关原理和常用层面厚度来设置层面厚度 ST。磁共振图像序列采用自旋回波-反转恢复 (Spin-Echo Inversion Recovery, SE-IR) 序列,序列翻转时间 (Inversion Time, TI) 分别为 800、1 200、1 600、2 200 采集得到,如图 3 所示。图 3 成像参数为:重复时间 (Repetition Time, TR)/回波时间 (Echo Time, TE) 为 2 500/14,层面厚度 (Slice Thickness, ST) 为 3 mm。




(a) TI = 800 (b) TI = 1 200 (c) TI = 1 600 (d) TI = 2 200


图 3 不同 TI 的 T1 加权图像序列

待分割脑图像如图 4 所示,实验中采用了两个脉冲序列:SE 序列和小角度快速激发梯度回波 (Fast Imaging

using Low Angle Shot,FLASH) 序列。图像的噪声水平为 3% 和 20%,灰度不均匀性(Intensity Non-uniformity, INU)为 20% 和 40%。其中 SE 成像参数:TR/TE 为 1 500/13,ST 为 3 mm。FLASH 成像参数:TR/TE 为 25/13,发射角(Flip Angle)为 15°。



(a) SE 图像,从左至右噪声比例和灰度不均匀程度依次为:3%、20%、3%、40%、20%、20%



(a) FLASH 图像,从左至右噪声比例和灰度不均匀程度依次为:3%、20%、3%、40%、20%、20%

图 4 部分实验图像

4.2 标签图像获取

本文将 T1 映射图作为磁共振图像数据的参考标签。首先计算 MR 扫描部位的 T1 值,通过设置脉冲序列中特定的成像参数,扫描得到不同参数 MR 图像序列,再根据 Bloch 方程设计 T1 的计算方法^[17]。最后,通过非线性最小二乘法,拟合得到每个像素点的 T1 值。本文中,采用经典的自旋回波反转恢复序列,通过采集不同反转时间的 T1 加权图像,然后运用计算 T1 值:

$$S(TI_n) = a + be^{-\frac{TI_n}{T_1}}$$
 (21)

式中: a 、 b 是待定复数形式参数,通过拟合得到; TI 是反转时间(Inversion Time),是采用自旋回波反转恢复序列进行扫描时需要设置的参数; $n = 1, 2, \dots$ 是序列图像的序号; S 表示采集的 MR 图像上的某个像素值。

4.3 标签图像处理

为了从 T1 映射图上得到训练分割模型所需要的标签信息,需要对 T1 映射图做一些预处理。图 5 为原始 T1 映射图的直方图,可以看出,每种脑组织像素值在直方图上表现为一个数值范围(其中 0 表示背景),对其取三个阈值再经过形态学滤波去除图像空洞及毛刺得到模糊标签。由于模糊标签中存在一些噪声标签,影响后续脑组织分割,在本文中,采用 Northcutt 等^[18]提出的标签去噪方法去除噪声标签,最终得到的模糊标签为分割脑组织的图像标签。




图 5 原始 T1 映射图 图 6 原始 T1 映射图 图 7 经过预处理后的 T1 映射图

4.4 模型评价指标

采用的分割评价指标包括分类准确率(Classification Accuracy, CA)、召回率(Recall)、Dice 系数(Dice Index, DI)。三者计算公式如下:

$$CA = \frac{a}{a + b} \times 100\%$$
 (22)

$$DI = \frac{2TP}{2TP + FP + FN}$$
 (23)

$$Recall = \frac{TP}{TP + FN}$$
 (24)

式中: a 表示正确分类样本数; b 为错误分类样本数; TP 表示分类器将正类划分为正类的样本数; FP 表示分类器将负类划分为正类的样本数; FN 表示分类器将正类划分为负类的样本数。

4.5 脑图像分割实验

本文评估了不同组合的图像特征以及模型参数(模糊支持向量机惩罚系数 C 、高斯核函数宽度、模糊距离系数 μ 和 λ)对 SE 图像中三种脑组织分割结果的影响,采用的图像为 3% noise、20% INU。模糊距离参数 λ 和 μ 对分类精度的影响见表 1,惩罚系数 C 和核函数宽度 σ 对分类精度的影响见表 2,不同特征组合对分类精度的影响见表 3。

表 1 模糊距离参数 λ 和 μ 对分类精度的影响	
模型参数	指标 CA/%
$\lambda = 0.5, \mu = 0.5$	90.2
$\lambda = 0.3, \mu = 0.7$	88.7
$\lambda = 0.4, \mu = 0.6$	85.6
$\lambda = 0.6, \mu = 0.4$	95.1
$\lambda = 0.2, \mu = 0.8$	92.5

表 2 惩罚系数 C 和核函数宽度 σ 对分类精度的影响	
模型参数	指标 CA/%
$C = 1, \sigma = 1$	82.3
$C = 1, \sigma = 2$	80.1
$C = 10, \sigma = 1$	84.2

续表 2

模型参数	指标 CA/%
$C = 10, \sigma = 2$	83.1
$C = 1\ 000, \sigma = 1$	96.2
$C = 1\ 000, \sigma = 2$	94.6

表 3 不同特征组合对分类精度的影响

特征组合	指标 CA/%
特征组合 1	92.3
特征组合 2	93.1
特征组合 3	91.5
特征组合 4	93.2
特征组合 5	94.9
特征组合 6	95.6

特征组合 1:灰度共生矩阵窗口大小为 5×5 , 像素距离 1 mm, 像素角度 45 度, 梯度, 对比度 (contrast), 相关性 (correlation), ASM 能量 (Angular Second Moment, ASM), 逆差矩 (Inverse Different Moment, IDM)。

特征组合 2:灰度共生矩阵窗口大小为 5×5 , 像素距离 3 mm, 像素角度 90 度, 梯度, 相关性 (correlation), ASM 能量 (Angular Second Moment, ASM)。

特征组合 3:灰度共生矩阵窗口大小为 5×5 , 像素距离 3 mm, 像素角度 45 度, 梯度, 逆差矩 (Inverse Different Moment, IDM), ASM 能量 (Angular Second Moment, ASM)。

特征组合 4:灰度共生矩阵窗口大小为 7×7 , 像素距离 3 mm, 像素角度 90 度, 梯度, 对比度 (contrast), 相关性 (correlation), ASM 能量 (Angular Second Moment, ASM)。

特征组合 5:灰度共生矩阵窗口大小为 7×7 , 像素距离 3 mm, 像素角度 90 度, 像素角度 45 度, 梯度, 对比度 (contrast), 相关性 (correlation), ASM 能量 (Angular Second Moment, ASM), 逆差矩 (Inverse Different Moment, IDM)。

特征组合 6:灰度共生矩阵窗口大小为 7×7 , 像素距离 3 mm, 像素角度 90 度, 像素角度 45 度, 对比度 (contrast), 相关性 (correlation), ASM 能量 (Angular Second Moment, ASM), 逆差矩 (Inverse Different Moment, IDM)。


本文基于灰度共生矩阵 (Gray Level Co-occurrence Matrix, GLCM) 提取脑组织特征。GLCM 是一种在特定空间和方向提取像素间相关性的纹理描述方法, 由于图像像素值分布导致图像空间像素出现一定的排列规律, 故图像中间隔一定距离的像素之间存在可提取的

纹理特征。基于表 1 – 表 3 给出的不同模型参数对分类精度的影响, 并结合脑部图像呈现细小的纹理性质, 本文基于 GLCM, 用 7×7 的滑动窗口, 像素距离 1 mm 和 3 mm, 像素角度 45 度和 90 度提取了脑图像的纹理特征, 其统计量分别为: 对比度 (contrast), 相关性 (correlation), 逆差矩 (Inverse Different Moment, IDM), ASM 能量 (Angular Second Moment, ASM), 共提取纹理特征总计 16 个, 此外, 还提取了梯度值等特征 10 个。


本文所用脑图像均重采样为 $60 \times 180 \times 180$ 大小, 为了增加图像数量, 还使用了旋转、中心裁剪等数据增强技术, 得到扩充后图像 8 000 幅, 其中, 5 000 幅用于模型训练, 1 000 幅用于模型验证, 2 000 幅用于模型测试。模糊支持向量机中, 惩罚系数 $C = 1\ 000$, 高斯核函数宽度 $\sigma = 1$, 模糊距离系数 λ, μ 分别取 0.6、0.4。本文分别在 SE 图像和 FLASH 图像, 不同噪声比例和灰度不均匀程度上进行了实验, 分割结果如图 8 所示。



(a) 标准图像 (Ground Truth) 及其标准分割结果 (脑脊液, 脑灰质, 脑白质)



(b) SE 图像及脑组织分割结果 (脑脊液, 脑灰质, 脑白质)



(c) FLASH 图像及脑组织分割结果 (脑脊液, 脑灰质, 脑白质)

图 8 各脑组织分割结果

可以看出, 在 SE 图像上, 噪声 3%, 灰度不均匀 40% 的图像的脑白质分割效果最好, 也最接近标准图像的分割结果。本文方法能较好地判别孤立像素点, 分割结果空洞情况较少, 能对不同序列图像做出准确分割。

从表 4 中可以看出, 对于 SE 图像, 以 CA 为评价指标时, 本文方法对噪声 3% 的图像实现了精确分割。结合表 4 和表 5, SE 图像的分割结果稍好于 FLASH 图像, 在噪声 20%、灰度不均匀 20% 图像上, 两者相差较多。在 SE 图像上, 本文方法平均 CA 为 87%, 平均召回率为 0.81, 平均 DI 系数为 0.82。

表 4 SE 图像分割评价

SE 序列	DI	Recall	CA/%
Noise:3% ,INU:20%	0.91	0.93	95
Noise:3% ,INU:40%	0.88	0.90	93
Noise:20% ,INU:20%	0.75	0.79	83

表 5 FLASH 图像分割评价

FLASH 序列	DI	Recall	CA/%
Noise:3% ,INU:20%	0.89	0.91	93
Noise:3% ,INU:40%	0.85	0.82	88
Noise:20% ,INU:20%	0.72	0.70	80

上述实验结果表明,本文方法对于不同序列的脑图像具有较好的分割准确率和泛化性能。此外,本文还给出了三种脑组织在三种评价指标下的分割精度,如表 6 – 表 8 所示。

表 6 脑脊液分割评价

脑脊液	DI	Recall	CA/%
Noise:3% ,INU:20%	0.84	0.82	88
Noise:3% ,INU:40%	0.81	0.85	85
Noise:20% ,INU:20%	0.71	0.75	76

表 7 脑白质分割评价

脑白质	DI	Recall	CA/%
Noise:3% ,INU:20%	0.91	0.93	95
Noise:3% ,INU:40%	0.90	0.91	93
Noise:20% ,INU:20%	0.82	0.84	83

表 8 脑灰质分割评价

脑灰质	DI	Recall	CA/%
Noise:3% ,INU:20%	0.83	0.82	87
Noise:3% ,INU:40%	0.78	0.80	82
Noise:20% ,INU:20%	0.73	0.76	80

可以看出,脑白质的分割精度最高,对脑白质的分割误判也最少,其次是脑脊液,最后是脑灰质。三组图像中脑白质的平均分割准确率达到 90.33%,脑脊液平均分割准确率为 83%,脑灰质平均分割准确率为 83%。在实验样本图像中,脑白质的组织边缘较清晰,基于灰度共生矩阵提取脑组织的纹理特性时,脑白质的纹理可以较好地提取出来。

此外,为了说明本文分割方法在脑组织分割上的有效性与准确性,本文方法与目前主流的脑组织分割方法随机森林(Random Forest)方法、模糊 C 均值方法(Fuzzy C means)、Snake 形变模型进行分析比较,结果

如表 9 和图 9 所示。

表 9 本文方法与其他三种方法分割性能比较

方法	图像类型	DI
随机森林	Noise:3% ,INU:20%	0.85
	Noise:3% ,INU:40%	0.83
	Noise:20% ,INU:20%	0.67
Snake 形变模型	Noise:3% ,INU:20%	0.89
	Noise:3% ,INU:40%	0.80
	Noise:20% ,INU:20%	0.71
模糊 C 均值	Noise:3% ,INU:20%	0.88
	Noise:3% ,INU:40%	0.86
	Noise:20% ,INU:20%	0.69
本文方法	Noise:3% ,INU:20%	0.90
	Noise:3% ,INU:40%	0.87
	Noise:20% ,INU:20%	0.74




图 9 本文方法与其他方法分割结果比较

表 9 中,对于噪声 3%、灰度不均匀 20% 的图像,本文方法 DI 系数为 0.90,高于其他三种方法中最高的 Snake 形变模型 0.89 的 DI 系数,相对于随机森林分割算法 0.85 的 DI 系数高出 5.9%。对于低噪声比例和低灰度不均匀程度的图像来说,本文方法和模糊 C 均值所取得的分割精度接近。对于灰度不均匀为 40% 的图像,本文方法 DI 系数为 0.87,而随机森林算法所取得的 DI 系数为 0.83。对于噪声 20% 的图像,相比于其他算法,本文方法的 DI 系数明显提升,和随机森林比较,本文方法 DI 提升 10.4%,相对于 Snake 形变模型和模糊 C 均值分别提升 4.2%、7.2%。图 9 表明,本文方法相对于其他三种方法在两种不同的 Noise 比例和 INU 的图像上的分割精度均有所提升。

5 结 语

针对医学图像组织边缘不清晰以及灰度不均匀问题,本文提出了一种基于类间模糊距离的隶属度函数计算方法,样本隶属度的确定不仅取决于同类样本之间的空间距离,还取决于不同类样本之间的空间距离,以解决样本标签交叉重叠的问题。此外,针对医学图像人工标注的困难,本文提出了基于 T1 映射图的模糊标签获取方法,减少人工标注图像的困难。三种主要脑组织分割实验表明,本文方法可准确有效地分割脑部图像,在处理医学图像具有很好应用前景。此外,本文提出的模糊隶属度函数在模糊支持向量机的基础上,可用于分类噪声较多的数据样本。一方面,模糊支持向量机对通过样本重新调整权重的方式增加了对噪声样本的鲁棒性;另一方面,基于本文提出的模糊隶属度函数在综合考虑类内距离和类间距离的基础上,重新计算样本的模糊隶属度,进一步提升了算法模型对噪声样本的鲁棒性。

参 考 文 献

- [1] Alboliras E, Hijazi Z M, Lopez L, et al. Visual guide to neonatal cardiology[M]. New Jersey: John Wiley & Sons Inc, 2018.
 - [2] Blumenthal D T, Artzi M, Liberman G, et al. Classification of high-grade glioma into tumor and nontumor components using support vector machine[J]. American Journal of Neuroradiology, 2017, 38(5): 908-914.
 - [3] Vaishnav K B, Amshakala K. An automated MRI brain image segmentation and tumor detection using SOM-clustering and proximal support vector machine classifier[C]//2015 IEEE International Conference on Engineering and Technology(ICETECH). IEEE, 2015: 1-6.
 - [4] Nick G, Schonlau M. Support vector machines[J]. The Statistician, 2016, 16(4): 917-937.
 - [5] Fan Q, Wang Z, Li D D, et al. Entropy-based fuzzy support vector machine for imbalanced datasets[J]. Knowledge-Based Systems, 2017, 115: 87-99.
 - [6] Zheng Y, Jeon B, M, Xu D, et al. Image segmentation by generalized hierarchical fuzzy C-means algorithm[J]. Journal of Intelligent & Fuzzy Systems, 2015, 28(2): 961-973.
 - [7] Rajinikanth V, Couceiro M S. RGB histogram-based color image segmentation using firefly algorithm[J]. Procedia Computer Science, 2015, 46: 1449-1457.
 - [8] Blumenthal D T, Artzi X M, Liberman X G, et al. Classification of high-grade glioma into tumor and nontumor components using support vector machine[J]. American Journal of Neuroradiology, 2017, 38(5): 908-914.
 - [9] Khedher L, Ramírez J, Górriz J M, et al. Early diagnosis of Alzheimer's disease based on partial least squares, principal component analysis and support vector machine using segmented MRI images[J]. Neurocomputing, 2015, 151: 139-150.
 - [10] Emblem K E, Pinho M C, Zöllner F G, et al. A generic support vector machine model for preoperative glioma survival associations[J]. Radiology, 2015, 275(1): 228-234.
 - [11] Olatomiwa L, Mekhilef S, Shamshirband S, et al. A support vector machine-firefly algorithm-based model for global solar radiation prediction[J]. Solar Energy, 2015, 115: 632-644.
 - [12] Khodagholi M, Dolati A, Hosseinzadeh A. A new method to determine data membership and find noise and outlier data using fuzzy support vector machine[J]. Signal and Data Processing, 2018, 15(3): 101-112.
 - [13] Lin C F, Wang S D. Fuzzy support vector machines[J]. IEEE transactions on neural networks, 2002, 13(2): 464-471.
 - [14] 张翔,肖小玲,徐光祐. 基于样本之间紧密度的模糊支持向量机方法[J]. 软件学报, 2006, 17(5): 951-958.
 - [15] Aubert-Broche B, Evans A C, Collins L. A new improved version of the realistic digital brain phantom[J]. Neuroimage, 2006, 32(1): 138-145.
 - [16] Deoni S C. Magnetic resonance relaxation and quantitative measurement in the brain[J]. Methods in Molecular Biology, 2011: 65-108.
 - [17] Baleanu D, Magin R L, Bhalekar S, et al. Chaos in the fractional order nonlinear Bloch equation with delay[J]. Communications in Nonlinear Science and Numerical Simulation, 2015, 25(1/3): 41-49.
 - [18] Northcutt C G, Wu T, Chuang I L. Learning with confident examples: Rank pruning for robust classification with noisy labels[EB]. arXiv:1705.01936, 2017.
-
- (上接第 212 页)
- [16] 杨福增,刘珊,陈丽萍,等. 基于立体视觉技术的多种农田障碍物检测方法[J]. 农业机械学报, 2012, 43(5): 168-172, 202.
 - [17] 雷晓妹,伍忠东,雍玖,等. 基于动态特征模板匹配的 AR-ToolKit 三维注册[J]. 计算机应用与软件, 2017, 34(7): 104-109.
 - [18] 刘国华,李涛. 面向微尺度对象的多视场协同测量方法研究[J]. 计算机应用与软件, 2017, 34(8): 107-113.
 - [19] 雍玖,王阳萍,雷晓妹,等. 基于改进 ORB 特征检测的全景视频拼接[J]. 计算机应用与软件, 2017, 34(5): 182-188.
 - [20] Zhang Z. A flexible new technique for camera calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.