

聚类分析

聚类(Clustering):

- ◆ 聚类是一个将数据集划分为若干组（class）或类（cluster）的过程，并使得同一个组内的数据对象具有较高的相似度；而不同组中的数据对象是不相似的。
- ◆ 相似或不相似是基于数据描述属性的取值来确定的，通常利用各数据对象间的**距离**来进行表示。
- ◆ 聚类分析尤其适合用来探讨样本间的相互关联关系从而对一个样本结构做一个初步的评价。

示 例

表中给出9个顾客的购买信息，包括购买的商品的数量及价格，根据此两个特征量，将顾客聚类成3类（购买大量的高价产品；购买少量的高价产品；购买少量的低价产品）。

表 6-1 包含相似对象的类的样本集

	商品的数量	价 格
类 1	2	1700
	3	2000
	4	2300
	10	1800
类 2	12	2100
	11	2500
	2	1600
类 3	3	2000
	3	3500

示例

聚类是一个非常困难的事情，因为在一个 n 维样本空间中，数据可以以不同的形状和大小揭示类。

如在二维欧几里得空间中，上面数据可以分类三个类也可以分为四个类，类的数量的任意性是聚类过程中的主要问题。




图 6-1 二维空间的点的聚类分析

聚类分析的应用：

- ◆**市场分析：** 帮助市场分析人员从客户基本库中发现不同的客户群，并用购买模式刻画不同的客户群的特征；
- ◆**万维网：** 对WEB日志的数据进行聚类，以发现相同的用户访问模式；
- ◆**图像处理；**
- ◆**模式识别；**
- ◆**孤立点检测。**

什么是好的聚类：

◆一个好的聚类方法将产生以下的高聚类：

➤最大化类内的相似性；

➤最小化类间的相似性。

◆聚类结果的质量依靠所使用度量的相似性和它的执行。

◆聚类方法的质量也可以用它发现一些或所有隐含模式的能力来度量。

聚类分析中的数据类型

- ◆ 基本数据； 需要进行标准化处理
- ◆ 二元变量；
- ◆ 符号型变量；
- ◆ 顺序型和比例数值型变量；
- ◆ 混合数据类型。

不同的数据类型可以用不同的方法计算其相似度矩阵

基本的数据结构

许多基于内存的聚类算法选择如下两种具有代表性的
数据结构：

- (1) 数据矩阵；
- (2) 相似度矩阵。

(1) 数据矩阵

数据矩阵：

是一个数据对象—属性结构，由n个对象组成，如：人；
每个对象利用p个属性加以描述，如：年龄、身高、体重等。
数据矩阵采用关系表形式或n*p矩阵来表示：

$$\begin{bmatrix} x_{11} & \dots & x_{1f} & \dots & x_{1p} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{if} & \dots & x_{ip} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & \dots & x_{nf} & \dots & x_{np} \end{bmatrix}$$

(2) 相似度矩阵

相似度矩阵（差异矩阵）：

是一个对象—对象结构，存放n个对象两两之间的相似性（差异性），采用n*n的矩阵形式表示：

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \dots & \dots & \dots & \dots \\ d(n,1) & d(n,2) & \dots & \dots & 0 \end{bmatrix}$$

用各种距离公式可以算出

度量值的标准化

为什么标准化？

- 通常，选用的度量单位将直接影响聚类分析的结果，如：将高度的度量单位由“米”变为“英尺”，或将重量的单位由“千克”变为“英镑”，可能会产生非常不同的聚类结构。
- 一般，度量单位越小，变量可能的值域越大，对聚类结果的影响也越大。因此，为避免对度量单位选择的依赖，数据应当标准化。

相似性距离

在标准化之后,或在无需标准化的特定应用中,由间隔数值所描述对象之间的差异(或相似)程度可以通过计算相应两个对象之间距离来确定。最常用的距离计算公式就是欧氏距离(Euclidean distance),具体公式内容如下:

$$d(i, j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \cdots + |x_{ip} - x_{jp}|^2)}$$

其中 $i = (x_{i1}, x_{i2}, \dots, x_{ip})$; $j = (x_{j1}, x_{j2}, \dots, x_{jp})$; 它们分别表示一个 p -维数据对象。

相似性距离

另一个常用的距离计算方法就是 Manhattan 距离，它的具体计算公式定义如下：

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$

欧氏距离和 Manhattan 距离均满足距离函数的有关数学性质（要求）：

- ◆ $d(i, j) \geq 0$ ，这表示对象之间距离为非负数的一个数值；
- ◆ $d(i, i) = 0$ ；这表示对象自身之间距离为零；
- ◆ $d(i, j) = d(j, i)$ ；这表示对象之间距离是对称函数；
- ◆ $d(i, j) \leq d(i, h) + d(h, j)$ ；这表示对象自身之间距离满足“两边之和不小于第三边”的性质；若将两个对象之间距离用一条边来表示的话；其中 h 为第三个对象。

相似性距离

Minkowski 距离是欧式距离和 Manhattan 距离的一个推广，它的计算公式定义如下：

$$d(i, j) = (|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \cdots + |x_{ip} - x_{jp}|^q)^{1/q}$$

其中 q 为一个正整数；当 $q=1$ 时，它代表 Manhattan 距离计算公式；而当 $q=2$ 时，它代表欧氏距离计算公式。

若每个变量均可被赋予一个权值，以表示其所代表属性的重要性。那么带权的欧氏距离计算公式就是：

$$d(i, j) = \sqrt{w_1 |x_{i1} - x_{j1}|^2 + w_2 |x_{i2} - x_{j2}|^2 + \cdots + w_p |x_{ip} - x_{jp}|^2}$$

同样，Manhattan 距离和 Minkowski 距离也可以引入权值进行计算。

什么是二元变量

二元变量（二值变量）：

- 一个二元变量只有两个状态：0或者1。其中0代表变量所表示的状态不存在；1则代表相应的状态存在。
- 如：给定变量smoker，用以描述一个病人是否吸烟的情况，如用smoker为1表示病人吸烟；若smoker为0表示病人不吸烟。

二元变量的相异度计算

差异矩阵法：

如果假设所有的二元变量有相同的权重，则可以得到一个两行两列（2*2）的条件表。

		对象 j		
对象 i		1	0	合计
	1	q	r	$q + r$
	0	s	t	$s + t$
	合计	$q + s$	$r + t$	p

(1) 符号变量

符号变量（标称变量）：

- 符号变量是二元变量的推广，可具有多于两个的状态值，如颜色变量（红、橙、黄、绿、蓝等）。
- 设一个符号变量所取的状态个数为M，其中的状态可以用字母、符号，或一个整数集合来表示，如 蛋白质序列片段：

MFSFVDLRLLLLLAATALLTHGQEEGQVEGQDEDIPPITCVQNGLRYPHSDRV

(1) 符号变量

对于符号变量，最常用的计算对象*i*和对象*j*之间差异（程度）的方法就是简单匹配方法。

$$d(i, j) = \frac{p - m}{p}$$

其中 *m* 表示对象*i*和对象*j*中取同样状态的符号变量个数（匹配数）；*p* 为所有的符号变量个数。

还可以，将符号变量转化为数值变量

聚类方法

目前，在文献报道中有大量的聚类算法，算法的选择主要取决于数据的类型、聚类的目的和应用。如果聚类分析被用作描述或探索性的攻击，则可以对同样的数据尝试多种算法，以发现数据可能揭示的结果。

主要的聚类分析方法

大体上，主要的聚类算法可以划分为如下几类：

- (1) 划分方法；
- (2) 层次方法；
- (3) 基于密度的方法；
- (4) 基于网格的方法；
- (5) 基于模型的方法；

划分方法

◆ 给定一个n个对象或元组的数据库，划分方法构建数据的k个划分，每个划分表示一个聚簇（类），且 $k \leq n$ 同时满足如下条件：

- (1) 每个聚类内至少包含一个对象；
- (2) 每个对象必须属于且只属于一个聚类。

◆ **注意：**在模糊划分计算中第二个要求可以放宽。

◆ 一个好的划分的一般**准则**：

- 在同一个类内的对象间尽可能接近或相似([high intra-class similarity](#))；
- 不同类中的对象间尽可能远离或不同([low inter-class similarity](#))。

划分方法

◆为达到全局最优，基于划分的聚类会要求穷举所有可能的划分，但实际中，绝大多数应用采用了以下两个比较流行的启发式方法：

(1) k-平均 (k-means) 算法： 每个聚类用该聚类中对象的平均值来表示；
不一定在数据中

(2) k-中心点 (k-mediods) 算法： 每个聚类用接近聚类中心的一个对象来表示。
一定在数据样本中

K-平均聚类算法

- ◆ K-平均 (k-means) 算法以k为参数，把n个对象分为k个簇，以使簇内对象具有较高的相似度，而簇间的相似度较低。
- ◆ 相似度的计算根据一个簇中对象的**平均值**（被看作簇的重心）来进行。

K-平均聚类算法

算法的基本思想：

- ◆ 首先，随机的选择 k 个对象，每个对象初始的代表了一个簇的平均值；
- ◆ 对剩余的每个对象，根据其与各个簇中心的距离，将它赋给最近的簇；
- ◆ 然后重新计算每个簇的平均值。
- ◆ 这个过程不断重复，直到准则函数收敛。

示例

示例 6.2: 假设空间数据对象分布如图-6.2 (a) 所示, 设 $k=3$, 也就是需要将数据集划分为三份 (聚类)。




图-6.2 k -means 算法聚类过程示意描述

K-平均聚类算法

算法的**特点**:

我觉得大部分要是数值型数据才有意义

- 只适用于聚类**均值有意义**的场合，在某些应用中，如：数据集中包含符号属性时，直接应用k-means算法就有问题；
- 用户必须事先指定**k的个数**；
指定类别
- 对**噪声和孤立点数据敏感**，少量的该类数据能够对聚类均值起到很大的影响。

基于层次的聚类方法

大体上，主要的聚类算法可以划分为如下几类：

- (1) 划分方法；
- (2) 层次方法；
- (3) 基于密度的方法；
- (4) 基于网格的方法；
- (5) 基于模型的方法。

层次方法

层次方法：


该方法对给定的数据对象集合进行层次分解，根据层次分解的方式，层次的方法被分为凝聚的和分裂的：

◆ **凝聚层次方法**：也称自底向上方法，一开始将每个对象作为单独的一组，然后相继地合并相近的对象或组，直到所有的组合为一个，或达到某个终止条件，代表：AGNES算法；


◆ **分裂层次方法**：也称自顶向下方法，一开始所有对象置于一个簇中，在迭代的每一步，一个簇被分裂为更小的簇，直到最终每个对象单独为一个簇，或达到某个终止条件，代表：DIANA算法。



凝聚的
(AGNES)




系统聚类法



分裂的
(DIANA)

AGNES算法




AGNES算法示意图

DIANA算法

- ◆ DIANA 算法：与AGNES算法相反，初始所有节点都在一个大簇中，根据某些准则被一步步地分解，直到达到初始设定的簇数目。
- ◆ 聚类过程中，DIANA算法将用到如下两种测度方法：
 - **簇的直径**：一个簇中的任意两个数据点的距离中的最大值；
 - **平均相异度**（平均距离）：

$$d_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{x \in C_i} \sum_{y \in C_j} |x - y|$$

DIANA算法



DIANA算法示意图

基于层次的聚类方法

大体上，主要的聚类算法可以划分为如下几类：


- (1) 划分方法；
- (2) 层次方法；
- (3) 基于密度的方法；
- (4) 基于网格的方法；
- (5) 基于模型的方法。

基于密度的聚类方法

密度方法：

- 绝大多数聚类方法基于对象之间的距离进行聚类，这样的方法只能发现球状的簇，而在发现任意形状的簇上遇到了困难。
- 基于密度的方法**：只要一个区域中点的密度（对象或数据点的数目）超过某个阈值，就将其加到与之相近的聚类中去。
- 这种方法可以过滤噪声孤立点数据，发现任意形状的簇。
- 代表算法有：**DBSCAN**、OPTICS、DENCLUE算法等。

DBSCAN算法描述



模糊聚类

- 模糊聚类中数据对象都会以一定程度属于某个类，模糊聚类得到模糊隶属度矩阵 $[u_{ki}]$ 以后，再根据一定的截取原则，对模糊隶属度矩阵进行分类截取，确定数据对象的最终类属结果。隶属度表示一个数据对象属于某一类的程度，隶属度的取值区间是 $[0, 1]$ ，隶属度越大表示数据样本属于该类的程度越高；隶属度越小则属于该类的程度越低。

FCM算法

- FCM算法属于划分式聚类算法，用模糊的方法来处理聚类问题，它从一个初始划分开始，需要预先指定聚类数目，还需要定义一个最优化聚类标准也就是目标函数，作为度量各类样本分布的代价函数。FCM把 N 个数据向量分成 C 个模糊类，用每个类的聚类中心代表该类。通过反复迭代运算，逐步降低目标函数的误差值，当目标函数值收敛时，得到最终聚类结果。

FCM算法

FCM 算法的目标函数定义为:

$$J_{FCM} = \sum_{k=1}^C \sum_{i=1}^N (u_{ik})^m d^2(\mathbf{x}_i, \mathbf{v}_k)$$

其中隶属度的约束条件为:

$$\sum_{k=1}^C u_{ik} = 1 \quad i = 1, 2, \dots, N$$

它把 N 个向量 $\mathbf{x}_i (i=1, 2, \dots, N)$ 分为 C 个类别, 用每类的聚类中心代表该类, 聚类中心集为 $V = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_l\}$ 。 u_{ik} 表示第 i 个数据点属于第 k 类的隶属度,

若距离采用欧氏距离: $d(\mathbf{x}_i, \mathbf{v}_k) = \sqrt{\sum_{p=1}^L (x_{ip} - v_{kp})^2}$ (L 为样本维数),

则目标函数公式变为:

$$J_{FCM} = \sum_{i=1}^N \sum_{k=1}^C (u_{ik})^2 \sum_{p=1}^L (x_{ip} - v_{kp})^2$$

对于 $k \in \{1, 2, \dots, C\}$ 和 $p \in \{1, 2, \dots, L\}$, 对 v_{kp} 求偏导数并令其为零, 得:

$$\frac{\partial J_{FCM}}{\partial v_{kp}} = 2 \sum_{i=1}^N (u_{ik})^2 (x_{ip} - v_{kp})$$

$$2 \sum_{i=1}^N (u_{ik})^2 (x_{ip} - v_{kp}) = 0$$

解得:

$$v_{kp} = \frac{\sum_{i=1}^N (u_{ik})^2 x_{ip}}{\sum_{i=1}^N (u_{ik})^2}$$

$$J_{FCM} = \sum_{i=1}^N \sum_{k=1}^C (u_{ik})^2 d^2(x_i, v_k) - \sum_{i=1}^N \lambda_i \left(\sum_{k=1}^C u_{ik} - 1 \right)$$

对于 $r \in \{1, 2, \dots, N\}$ 和 $s \in \{1, 2, \dots, C\}$, 对 u_{rs} 求偏导数并令其为零, 得:

$$\frac{\partial J_{FCM}}{\partial u_{rs}} = 2(u_{rs})d^2(x_r, v_s) - \lambda_r = 0 \quad (A2)$$

$$u_{rs} = \frac{\lambda_r}{2d^2(x_r, v_s)} \quad (A3)$$

对公式(A3)考虑约束条件 $\sum_{k=1}^C u_{rk} = 1$, 得:
$$\sum_{k=1}^C \frac{\lambda_r}{2d^2(x_r, v_k)} = 1$$

解得:

$$\lambda_r = \frac{1}{\sum_{k=1}^C \frac{1}{2d^2(x_r, v_k)}}$$

将 λ_r 代入公式(A3)得:

FCM算法

聚类中心和的更新公式：

$$\mathbf{v}_k = \frac{\sum_{i=1}^N u_{ik}^m \cdot \mathbf{x}_i}{\sum_{i=1}^N u_{ik}^m}$$

隶属度的更新公式：

$$u_{ik} = \frac{1}{\sum_{r=1}^C \frac{d^2(\mathbf{x}_i, \mathbf{v}_k)}{d^2(\mathbf{x}_i, \mathbf{v}_r)}}$$

主要步骤


- (1) 确定聚类数目 c 和参数 m
- (2) 随机初始化聚类中心 V
- (3) 利用迭代公式计算隶属度
- (4) 利用迭代公式计算聚类中心
- (5) 重复步骤(3)、(4)，进行反复迭代运算，直到目标函数收敛到最小值，完成模糊划分。

FCM算法

算法的输出是 C 个聚类中心点向量和 $C*N$ 的一个模糊划分矩阵，这个矩阵表示的是每个样本点属于每个类的隶属度。根据这个划分矩阵按照模糊集合中的最大隶属原则就能够确定每个样本点归为哪个类。聚类中心表示的是每个类的平均特征，可以认为是这个类的代表点。

输出隶属度

数据点 _↵	隶属度 _↵		
	A 类 _↵	B 类 _↵	C 类 _↵
1 _↵	0.1103 _↵	0.7789 _↵	0.1106 _↵
2 _↵	0.0534 _↵	0.5406 _↵	0.4058 _↵
3 _↵	0.7285 _↵	0.2470 _↵	0.0244 _↵
4 _↵	0.0921 _↵	0.8617 _↵	0.0461 _↵
5 _↵	0.6870 _↵	0.2857 _↵	0.0272 _↵
6 _↵	0.0646 _↵	0.6196 _↵	0.3157 _↵
7 _↵	0.2082 _↵	0.6649 _↵	0.1268 _↵
8 _↵	0.1800 _↵	0.7880 _↵	0.0319 _↵
9 _↵	0.2098 _↵	0.6537 _↵	0.1363 _↵



FCM 分类结果

FCM特点


- * FCM中，同一样本属于所有类的隶属度之和为1，使得它对噪声敏感。
- * FCM采用迭代下降的算法，其对初始化的聚类中心或隶属度矩阵敏感，不能保证收敛到全局最优解，有可能收敛到局部极值。
- * FCM需要预先设定聚类类别个数，类别个数设定不同，可能导致不同的聚类结果。

因此，FCM改进算法的基本思想：优化目标函数中的相关参数、算法停止准则的设立和原型初始化等。


FCM改进

- 由于FCM算法原理简单，计算效率高，相似性度量运用灵活，受到很多学者的关注并对其进行改进，包括改变相似性度量方法，发现椭圆形状的簇；自动控制聚类数目，尽量减少输入参数的先验信息；引入核函数，处理非线性问题；引入具有全局寻优能力的优化算法，降低陷入局部最优的可能等等。




模糊核聚类



■ **Delta_Set**



Ring_Data



模糊核聚类

1) 多项式核函数: ↵

$$K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + c)^d$$

2) Sigmoid 核函数: ↵

$$K(\mathbf{x}, \mathbf{y}) = \tanh(-b \cdot (\mathbf{x} \cdot \mathbf{y}) - c)$$

3) 高斯核函数: ↵

$$K(\mathbf{x}, \mathbf{y}) = \exp\left(\frac{-\|\mathbf{x} - \mathbf{y}\|^2}{\sigma^2}\right)$$

模糊核聚类

样本 $\mathbf{x}_i$ 是一个 L 维的向量 $\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{iL}]^T$ 。

假设 ϕ 是一个非线性映射函数, $\phi: p \in OS \rightarrow \phi(p) \in HS$,

其中 p 是观察空间 OS 中的变量,

$\phi(p)$ 表示映射后的高维特征空间 HS 中的变量。

模糊核聚类的目标函数公式为:

$$J_{KFCM} = \sum_{k=1}^C \sum_{i=1}^N u_{ki}^m \|\phi(\mathbf{x}_i) - \phi(\mathbf{v}_k)\|^2$$

满足约束条件:
$$\sum_{k=1}^C u_{ki} = 1 \quad i = 1, 2, \dots, N$$

模糊核聚类

采用核函数的方法可以把内积计算转化为核计算:

$$\begin{aligned}\|\phi(\mathbf{x}_i) - \phi(\mathbf{v}_k)\|^2 &= \phi(\mathbf{x}_i) \cdot \phi(\mathbf{x}_i) - 2\phi(\mathbf{x}_i) \cdot \phi(\mathbf{v}_k) + \phi(\mathbf{v}_k) \cdot \phi(\mathbf{v}_k) \\ &= K(\mathbf{x}_i, \mathbf{x}_i) + K(\mathbf{v}_k, \mathbf{v}_k) - 2K(\mathbf{x}_i, \mathbf{v}_k)\end{aligned}$$

模糊核聚类

$$u_{ki} = \frac{(1 - K(\mathbf{x}_i, \mathbf{v}_k))^{-\frac{1}{m-1}}}{\sum_{j=1}^C (1 - K(\mathbf{x}_i, \mathbf{v}_j))^{-\frac{1}{m-1}}}$$
$$\mathbf{v}_k = \frac{\sum_{i=1}^N u_{ki}^m \cdot K(\mathbf{x}_i, \mathbf{v}_k) \cdot \mathbf{x}_i}{\sum_{i=1}^N u_{ki}^m \cdot K(\mathbf{x}_i, \mathbf{v}_k)}$$